

С.П. Шарый

Курс
ВЫЧИСЛИТЕЛЬНЫХ
МЕТОДОВ

Курс ВЫЧИСЛИТЕЛЬНЫХ МЕТОДОВ

С. П. ШАРЫЙ

Институт вычислительных технологий СО РАН

Новосибирск – 2012

Книга является систематическим учебником по курсу вычислительных методов и написана на основе лекций, читаемых автором на механико-математическом факультете Новосибирского государственного университета. Особенностью книги является изложение методов интервального анализа и результатов конструктивной математики, связанных с традиционными разделами численного анализа.

Оглавление

Предисловие	7
Глава 1. Введение	8
1.1 Погрешности вычислений	9
1.2 Обусловленность математических задач	9
1.3 Интервальная арифметика	12
1.4 Интервальные расширения функций	15
1.5 Элементы конструктивной математики	18
1.6 Сложность задач и трудоёмкость алгоритмов	20
Литература к Главе 1	21
Глава 2. Численные методы анализа	23
2.1 Интерполирование функций	24
2.1a Постановка задачи	24
2.1б Интерполяционный полином Лагранжа	28
2.1в Разделённые разности и их свойства	30
2.1г Интерполяционный полином Ньютона	35
2.1д Погрешность алгебраической интерполяции	37
2.1е Полиномы Чебышёва	41
2.1ж Интерполяция с кратными узлами	46
2.1з Общие факты алгебраической интерполяции	48
2.2 Сплаины	52
2.2a Элементы теории	52
2.2б Интерполяционные кубические сплайны	55
2.3 Нелинейные методы интерполяции	59
2.4 Численное дифференцирование	61
2.4a Интерполяционный подход	62

2.4б	Оценка погрешности численного дифференцирования	66
2.4в	Метод неопределённых коэффициентов	70
2.4г	Полная погрешность дифференцирования	71
2.5	Приближение в евклидовых пространствах	74
2.5а	Обсуждение постановки задачи	74
2.5б	Метод наименьших квадратов	76
2.5в	Полиномы Лежандра	81
2.6	Численное интегрирование	87
2.6а	Простейшие квадратурные формулы	89
2.6б	Квадратурная формула Симпсона	92
2.6в	Дальнейшие формулы Ньютона-Котеса	96
2.6г	Интерполяционные квадратурные формулы	97
2.6д	Сходимость квадратур	98
2.6е	Составные квадратурные формулы	101
2.6ж	Квадратурные формулы Гаусса	104
2.6з	Выбор узлов для квадратурных формул Гаусса	109
2.7	Правило Рунге для оценки погрешности	114
	Литература к Главе 2	115
Глава 3.	Численные методы линейной алгебры	118
3.1	Задачи вычислительной линейной алгебры	118
3.1а	Особенности постановок задач	118
3.1б	Сингулярные числа и сингулярные векторы	120
3.1в	Матрицы с диагональным преобладанием	125
3.2	Нормы векторов и матриц	128
3.2а	Векторные нормы	128
3.2б	Матричные нормы	131
3.2в	Подчинённые матричные нормы	133
3.2г	Топология на множествах векторов и матриц	137
3.2д	Спектральный радиус	141
3.2е	Матричный ряд Неймана	144
3.2ж	Число обусловленности матриц	146
3.2з	Примеры хорошообусловленных и плохообусловленных матриц	150
3.2и	Практическое применение числа обусловленности	152
3.3	Прямые методы решения линейных систем	155
3.3а	Решение треугольных линейных систем	156
3.3б	Метод Гаусса для решения линейных систем	157

3.3в	Матричная интерпретация метода Гаусса	160
3.3г	Существование LU-разложения	163
3.3д	Метод Гаусса с выбором ведущего элемента	165
3.3е	Обусловленность и матричные преобразования	168
3.3ж	QR-разложение матриц	171
3.3з	Ортогональные матрицы отражения	173
3.3и	Метод Хаусхолдера	176
3.3к	Матрицы вращения	179
3.3л	Ортогонализация Грама-Шмидта	181
3.3м	Метод Холесского	181
3.3н	Метод прогонки	185
3.4	Итерационные методы для систем линейных уравнений	190
3.4а	Условие сходимости стационарных методов	191
3.4б	Подготовка системы к итерационному процессу	196
3.4в	Оптимизация скалярного предобуславливателя	199
3.4г	Итерационный метод Якоби	202
3.4д	Итерационный метод Гаусса-Зейделя	205
3.4е	Методы релаксации	210
3.4ж	Оценка погрешности итерационного метода	214
3.5	Нестационарные итерационные методы	217
3.5а	Краткая теория	217
3.5б	Метод наискорейшего спуска	220
3.5в	Метод сопряжённых градиентов	227
3.6	Вычисление обратной матрицы и определителя	227
3.7	Линейная задача о наименьших квадратах	229
3.8	Решение проблемы собственных значений	230
3.8а	Обсуждение постановки задачи	230
3.8б	Обусловленность проблемы собственных значений	232
3.8в	Коэффициенты перекося матрицы	236
3.8г	Круги Гершгорина	241
3.8д	Степенной метод	243
3.8е	Обратные степенные итерации	251
3.8ж	Сдвиги спектра	251
3.8з	Метод Якоби	254
3.8и	Базовый QR-алгоритм	259
3.8к	Модификации QR-алгоритма	262
	Литература к Главе 3	265

Глава 4. Решение нелинейных уравнений и их систем	270
4.1 Вычислительно-корректные задачи	272
4.1а Формальные определения	272
4.1б Задача решения уравнений не является вычислительно-корректной	274
4.1в ε -решения уравнений	275
4.1г Недостаточность ε -решений	277
4.2 Теоретические основы численных методов	279
4.3 Классические методы решения уравнений	283
4.3а Предварительная локализация решений	284
4.3б Метод дихотомии	285
4.3в Метод простой итерации	285
4.3г Метод Ньютона и его модификации	287
4.3д Методы Чебышёва	287
4.4 Классические методы решения систем уравнений	287
4.4а Метод простой итерации	287
4.4б Метод Ньютона и его модификации	287
4.5 Интервальные линейные системы уравнений	287
4.6 Интервальные методы решения уравнений	289
4.6а Одномерный интервальный метод Ньютона	292
4.6б Многомерный интервальный метод Ньютона	295
4.6в Метод Кравчика	297
4.7 Глобальное решение уравнений	299
Литература к Главе 4	302
Обозначения	305
Краткий биографический словарь	308
Предметный указатель	312

Предисловие

Представляемый вниманию читателей курс методов вычислений написан на основе лекций, которые читаются автором на механико-математическом факультете Новосибирского государственного университета. Его содержание в основной своей части традиционно и повторяет на современном уровне тематику, заданную ещё в знаменитых «Лекциях о приближённых вычислениях» акад. А.Н. Крылова, первый в мире систематический учебник вычислительных методов. Условно материал книги можно назвать «вычислительные методы-1», поскольку в стандарте университетского образования, существует вторая часть курса, посвящённая численному решению дифференциальных уравнений, как обыкновенных, так и в частных производных, интегральных уравнений и др.

Вместе с тем, книга имеет ряд особенностей. Во-первых, в ней широко представлены элементы интервального анализа и современные интервальные методы для решения традиционных задач вычислительной математики. Во-вторых, автор счёл уместным поместить в книгу краткий очерк идей конструктивной математики и теории сложности вычислений, тесно связанных с предметом математики вычислительной.

Глава 1

Введение

Курс методов вычислений является частью более широкой математической дисциплины — вычислительной математики, которую можно неформально определить «как математику вычислений» или «математику, возникающую в связи с разнообразными процессами вычислений».

Три типа задач, в основном, интересуют нас в связи с процессом вычислений:

- Как конструктивно найти (вычислить) тот или иной математический объект или его конструктивное приближение?
- Какова трудоёмкость нахождения тех или иных объектов? может ли она быть уменьшена и как именно?
- Если алгоритм для нахождения некоторого объекта уже известен, то как наилучшим образом организовать вычисления по этому алгоритму на том или ином конкретном вычислительном устройстве? Например, чтобы при этом уменьшить погрешность вычисления и/или сделать его менее трудоёмким?

Вопросы из последнего пункта сделались особенно актуальными в связи с развитием различных архитектур электронных вычислительных машин, в частности, с связью с вхождением в нашу повседневную жизнь многопроцессорных и параллельных компьютеров.

Ясно, что все три отмеченных выше типа вопросов тесно связаны между собой. К примеру, если нам удаётся построить алгоритм для

решения какой-либо задачи, то, оценив сложность его исполнения, мы тем самым предъявляем и верхнюю оценку трудоёмкости решения этой задачи.

Развитие вычислительной математики в различные исторические периоды имело свои особенности и акценты. Так, в период «холодной войны» (примерно вторую половину XX века) на первый план выдвинулась разработка и применение конкретных практических алгоритмов для решения сложных задач математического моделирования (в основном, вычислительной физики, механики и управления). Нужно было запускать и наводить ракеты, улучшать характеристики самолётов и других сложных технических устройств т. п. Ранее, в XVII–XIX веках, вычислительные методы гармонично входили в сферу научных интересов крупнейших математиков — Ньютона, Эйлера, Лобачевского, Гаусса, Якоби и многих других, чьи имена остались в названиях некоторых численных методов.

Исторически сложилось, что исследования по второму пункту относятся, главным образом, к различным теориям вычислительной сложности и к теории алгоритмов, которая в 30-е годы XX века вычленилась из абстрактной математической логики. Но традиционная вычислительная математика, предметом которой считается построение и исследование конкретных численных методов, также немало способствует прогрессу в этой области.

1.1 Погрешности вычислений

Для правильного учёта погрешностей реализации вычислительных методов на различных устройствах и для правильной организации этих методов нужно знать детали конкретного способа вычислений. В современных электронных цифровых вычислительных машинах (ЭЦВМ), на которых выполняется подавляющая часть современных вычислений, эти детали реализации регламентируются стандартом IEEE 754 и его дополнением и развитием, формализованным в виде стандарта IEEE 854 [33, 25].

1.2 Обусловленность математических задач

Вынесенный в заголовок этого параграфа термин — *обусловленность* — означает меру чувствительности решения задачи к изменениям (воз-

мущениям) её входных данных. Ясно, что любая информация подобного сорта чрезвычайно важна при практических вычислениях, так как позволяет оценивать достоверность результатов, полученных в условиях приближённого характера этих вычислений. С другой стороны, зная о высокой чувствительности решения мы можем предпринимать необходимые меры для компенсации этого явления — повышать разрядность вычислений, наконец, модифицировать или вообще сменить выбранный вычислительный алгоритм и т. п.

Существует несколько уровней рассмотрения поставленного вопроса. Во-первых, следует знать, является ли вообще непрерывной зависимость решения задачи от входных данных. Задачи, решение которых не зависит непрерывно от их данных, называют *некорректными* (выше на стр. 74 в качестве примера таких задач мы встречались с задачей дифференцирования). Во-вторых, в случае наличия этой непрерывности желательно иметь некоторую количественную меру чувствительности решения как функции от входных данных.

Переходя к формальным конструкциям, предположим, что в рассматриваемой задаче по значениям из множества $\mathcal{D}$ входных данных мы должны вычислить решение задачи из множества ответов $\mathcal{S}$. Отображение $\phi : \mathcal{D} \rightarrow \mathcal{S}$, сопоставляющее всякому x из $\mathcal{D}$ решение задачи из $\mathcal{S}$, мы будем называть *разрешающим отображением* (или *разрешающим оператором*). Отображение ϕ может быть выписано явным образом, если ответ к задаче задаётся каким-либо выражением. Часто разрешающее отображение задаётся неявно, как, например, при решении системы уравнений

$$F(a, x) = 0$$

с входными параметрами a . Даже при неявном задании нередко можно теоретически выписать вид разрешающего отображения, как, к примеру, $x = A^{-1}b$ при решении системы линейных уравнений $Ax = b$ с квадратной матрицей A . Но в любом случае удобно предполагать существование этого отображения и некоторые его свойства. Пусть также $\mathcal{D}$ и $\mathcal{S}$ являются линейными нормированными пространствами. Очевидно, что самый первый вопрос, касающийся обусловленности задачи, требует, чтобы разрешающее отображение ϕ было непрерывным относительно некоторого задания норм в $\mathcal{D}$ и $\mathcal{S}$.

Что касается числовой меры обусловленности математических задач, то существуют два подхода к её введению. Одни из них условно может быть назван *дифференциальным*, а другой основан на оценивании *константы Липшица* разрешающего оператора.

Пусть разрешающее отображение дифференцируемо по крайней мере в интересующей нас точке a из множества входных данных $\mathcal{D}$. Тогда можно считать, что

$$\phi(a + \Delta a) \approx \phi(a) + \phi'(a) \cdot \Delta a,$$

и потому мерой чувствительности решения может служить $\|\phi'(a)\|$. Для более детального описания зависимости различных компонент решения $\phi(a)$ от a часто привлекают отдельные частные производные $\frac{\partial \phi_i}{\partial a_j}$, т. е. элементы матрицы Якоби $\phi'(a)$ разрешающего отображения ϕ , которые при этом называют *коэффициентами чувствительности*. Интересна также мера относительной чувствительности решения, которую можно извлечь из соотношения

$$\frac{\phi(a + \Delta a) - \phi(a)}{\|\phi(a)\|} \approx \left(\frac{\phi'(a)}{\|\phi(a)\|} \cdot \|a\| \right) \frac{\Delta a}{\|a\|}.$$

Второй подход к определению обусловленности требует нахождения как можно более точных констант C_1 и C_2 в неравенствах

$$\|\phi(a + \Delta a) - \phi(a)\| \leq C_1 \|\Delta a\| \quad (1.1)$$

и

$$\frac{\|\phi(a + \Delta a) - \phi(a)\|}{\|\phi(a)\|} \leq C_2 \frac{\|\Delta a\|}{\|a\|}. \quad (1.2)$$

Величины этих констант, зависящие от задачи, а иногда и конкретных входных данных, берутся за меру обусловленности решения задачи.

В связи с неравенствами (1.1)–(1.2) напомним, что вещественная функция $f : \mathbb{R}^n \supseteq D \rightarrow \mathbb{R}$ называется *непрерывной по Липшицу* (или просто *липшицевой*), если существует такая константа L , что

$$|f(x') - f(x'')| \leq L \cdot \text{dist}(x', x'')$$

для любых $x', x'' \in D$. Величину L называют при этом *константой Липшица* функции f на D . Понятие непрерывности по Липшицу формализует интуитивно понятное условие соразмерности изменения функции изменению аргумента. Именно, приращение функции не должно превосходить приращение аргумента (по абсолютной величине или в некоторой заданной метрике) более чем в определённое фиксированное число раз. При этом сама функция может быть и негладкой, как, например, модуль числа в окрестности нуля. Отметим, что понятие

непрерывности по Липшицу является более сильным свойством, чем просто непрерывность или даже равномерная непрерывность, так как влечёт за собой их обоих.




Рис. 1.1. Непрерывная функция $y = \sqrt{x}$ имеет бесконечно большую скорость роста и не является липшицевой

Нетрудно видеть, что искомые константы C_1 и C_2 в неравенствах (1.1) и (1.2), характеризующие чувствительность решения задачи по отношению к возмущениям входных данных — это не что иное, как константы Липшица для разрешающего отображения ϕ и произведение константы Липшица L_ψ отображения $\psi : \mathcal{D} \rightarrow \mathcal{S}$, действующего по правилу $a \mapsto \phi(a)/\|\phi(a)\|$ на норму $\|a\|$. В последнем случае

$$\frac{\|\phi(a + \Delta a) - \phi(a)\|}{\|\phi(a)\|} \approx L_\psi \|\Delta a\| \leq L_\psi \|a\| \cdot \frac{\|\Delta a\|}{\|a\|}.$$

1.3 Интервальная арифметика

Исходной идеей создания интервальной арифметики является наблюдение о том, что всё в нашем мире неточно и нам в реальности чаще всего приходится работать не с точными значениями величин, которые образуют основу классической «идеальной» математики, а с целыми диапазонами значений той или иной величины. Например, в цифровых ЭВМ множество вещественных чисел, которые точно представляются с помощью разрядной сетки, конечно, и из-за присутствия округления каждое из этих чисел, в действительности, является представителем целого интервала значений обычной вещественной оси $\mathbb{R}$.

Нельзя ли организовать операции и отношения между диапазонами-интервалами так, как это сделано для обычных точных значений? С

тем, чтобы можно было работать с ними, подобно обычным числам, опираясь на алгебраические преобразования, аналитические операции и т.п.? Ответ на эти вопросы положителен, хотя свойства получающейся «интервальной арифметики» оказываются во многом непохожими на привычные свойства операций с обычными числами.

Предположим, что нам даны переменные x и y , точные значения которых неизвестны, но мы знаем, что они могут находиться в интервалах $[\underline{x}, \bar{x}]$ и $[\underline{y}, \bar{y}]$ соответственно. Что можно сказать о значении суммы $x + y$?

Складывая почленно неравенства

$$\begin{aligned}\underline{x} &\leq x \leq \bar{x}, \\ \underline{y} &\leq y \leq \bar{y},\end{aligned}$$

получим

$$\underline{x} + \underline{y} \leq x + y \leq \bar{x} + \bar{y},$$

так что $x + y \in [\underline{x} + \underline{y}, \bar{x} + \bar{y}]$.

На аналогичный вопрос, связанный с областью значений разности $x - y$ можно ответить, складывая почленно неравенства

$$\begin{aligned}\underline{x} &\leq x \leq \bar{x}, \\ -\bar{y} &\leq -y \leq -\underline{y}.\end{aligned}$$

Имеем $x - y \in [\underline{x} - \bar{y}, \bar{x} - \underline{y}]$. Для умножения

$$x \cdot y \in [\min\{\underline{x}\underline{y}, \underline{x}\bar{y}, \bar{x}\underline{y}, \bar{x}\bar{y}\}, \max\{\underline{x}\underline{y}, \underline{x}\bar{y}, \bar{x}\underline{y}, \bar{x}\bar{y}\}].$$

Рассмотрим множество всех вещественных интервалов $\mathbf{a} := [\underline{a}, \bar{a}] = \{x \in \mathbb{R} \mid \underline{a} \leq x \leq \bar{a}\}$, и бинарные операции — сложение, вычитание, умножение и деление — определим между ними «по представителям», т.е. в соответствии со следующим фундаментальным принципом:

$$\mathbf{a} \star \mathbf{b} := \{a \star b \mid a \in \mathbf{a}, b \in \mathbf{b}\} \quad (1.3)$$

для интервалов $\mathbf{a}$, $\mathbf{b}$, таких что выполнение точечной операции $a \star b$, $\star \in \{+, -, \cdot, /\}$, имеет смысл для любых $a \in \mathbf{a}$ и $b \in \mathbf{b}$. При этом вещественные числа a отождествляются с интервалами нулевой ширины $[a, a]$, называемыми также *вырожденными интервалами*. Кроме того, через $(-\mathbf{a})$ условимся обозначать интервал $(-1) \cdot \mathbf{a}$.

Для интервальных арифметических операций развёрнутое определение, равносильное (1.3), задаётся следующими формулами:

$$a + b = [\underline{a} + \underline{b}, \overline{a} + \overline{b}], \quad (1.4)$$

$$a - b = [\underline{a} - \overline{b}, \overline{a} - \underline{b}], \quad (1.5)$$

$$a \cdot b = [\min\{\underline{a}\underline{b}, \underline{a}\overline{b}, \overline{a}\underline{b}, \overline{a}\overline{b}\}, \max\{\underline{a}\underline{b}, \underline{a}\overline{b}, \overline{a}\underline{b}, \overline{a}\overline{b}\}], \quad (1.6)$$

$$a/b = a \cdot [1/\overline{b}, 1/\underline{b}] \quad \text{для } b \neq 0. \quad (1.7)$$

Алгебраическая система $\langle \mathbb{IR}, +, -, \cdot, / \rangle$, образованная множеством всех вещественных интервалов $\mathbf{a} := [\underline{a}, \overline{a}] = \{x \in \mathbb{R} \mid \underline{a} \leq x \leq \overline{a}\}$ с бинарными операциями сложения, вычитания, умножения и деления, которые определены формулами (1.4)–(1.7), называется *классической интервальной арифметикой*.

Алгебраические свойства классической интервальной арифметики существенно беднее, чем у поля вещественных чисел $\mathbb{R}$. В частности, особенностью интервальной арифметики является отсутствие дистрибутивности умножения относительно сложения: в общем случае

$$(a + b)c \neq ac + bc.$$

Например,

$$[1, 2] \cdot (1 - 1) = 0 \neq [-1, 1] = [1, 2] \cdot 1 - [1, 2] \cdot 1.$$

Тем не менее, имеет место более слабое свойство

$$a(b + c) \subseteq ab + ac \quad (1.8)$$


называемое *субдистрибутивностью* умножения относительно сложения. В ряде частных случаев дистрибутивность всё-таки выполняется:

$$a(b + c) = ab + ac, \quad \text{если } a \text{ — вещественное число}, \quad (1.9)$$

$$a(b + c) = ab + ac, \quad \text{если } b, c \geq 0 \text{ или } b, c \leq 0. \quad (1.10)$$

Сумма (разность) двух интервальных матриц одинакового размера есть интервальная матрица того же размера, образованная поэлементными суммами (разностями) операндов.

Если $\mathbf{A} = (a_{ij}) \in \mathbb{IR}^{m \times l}$ и $\mathbf{B} = (b_{ij}) \in \mathbb{IR}^{l \times n}$, то произведение матриц

Рис. 1.2. Интервальные векторы-брусы в $\mathbb{R}^2$.

A и B есть матрица $C = (c_{ij}) \in \mathbb{IR}^{m \times n}$, такая что

$$c_{ij} := \sum_{k=1}^l a_{ik} b_{kj}.$$

1.4 Интервальные расширения функций

Задача об определении области значений функции на том или ином подмножестве области её определения, эквивалентная задаче оптимизации, в интервальном анализе принимает специфическую форму задачи о вычислении так называемого *интервального расширения функции*.

Определение 1.4.1 Пусть D — непустое подмножество пространства $\mathbb{R}^n$. Интервальная функция $\mathbf{f} : \mathbb{ID} \rightarrow \mathbb{IR}^m$ называется интервальным продолжением вещественной функции $f : D \rightarrow \mathbb{R}^m$, если $\mathbf{f}(x) = f(x)$ для всех $x \in D$.

Определение 1.4.2 Пусть D — непустое подмножество пространства $\mathbb{R}^n$. Интервальная функция $\mathbf{f} : \mathbb{ID} \rightarrow \mathbb{IR}^m$ называется интервальным расширением вещественной функции $f : D \rightarrow \mathbb{R}^m$, если

- 1) $\mathbf{f}(x)$ — интервальное продолжение $f(x)$,
- 2) $\mathbf{f}(x)$ монотонна по включению, т. е.

$$x' \subseteq x'' \Rightarrow \mathbf{f}(x') \subseteq \mathbf{f}(x'') \text{ на } \mathbb{ID}.$$

Таким образом, если $\mathbf{f}(x)$ — интервальное расширение функции $f(x)$, то для области значений f на брусе $X \subset D$ мы получаем следу-




Рис. 1.3. Интервальное расширение функции даёт внешнюю оценку её области значений

ющую внешнюю (с помощью объемлющего множества) оценку:

$$\{f(x) \mid x \in X\} = \bigcup_{x \in X} f(x) = \bigcup_{x \in X} \mathbf{f}(x) \subseteq \mathbf{f}(X).$$

Эффективное построение интервальных расширений функций — это важнейшая задача интервального анализа, поиски различных решений которой продолжают и в настоящее время. Уместно привести в рамках нашего беглого обзора некоторые общезначимые результаты в этом направлении. Первый из них часто называют «основной теоремой интервальной арифметики»:

Теорема 1.4.1 Если для рациональной функции $f(x) = f(x_1, x_2, \dots, x_n)$ на брусе $\mathbf{x} = (\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n) \in \mathbb{IR}^n$ определён результат $\mathbf{f}_{\mathbf{x}}(\mathbf{x})$ подстановки вместо её аргументов интервалов их изменения $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ и выполнения всех действий над ними по правилам интервальной арифметики, то

$$\{f(x) \mid x \in \mathbf{x}\} \subseteq \mathbf{f}(\mathbf{x}),$$

т. е. $\mathbf{f}(\mathbf{x})$ содержит множество значений функции $f(x)$ на $\mathbf{x}$.

Нетрудно понять, что по отношению к рациональной функции $f(x)$ интервальная функция $\mathbf{f}_{\mathbf{x}}(\mathbf{x})$, о которой идёт речь в Теореме 1.4.1, является интервальным расширением. Оно называется *естественным интервальным расширением* и вычисляется совершенно элементарно.

Пример 1.4.1 Для функции $f(x) = x/(x+1)$ на интервале $[1, 2]$ область значений в соответствии с результатом Теоремы 1.4.1 можно оценить извне как

$$\frac{[1, 2]}{[1, 2] + 1} = \frac{[1, 2]}{[2, 3]} = [\frac{1}{3}, 1].$$

Но если предварительно переписать выражение для функции в виде

$$f(x) = \frac{1}{1 + 1/x},$$

разделив числитель и знаменатель дроби на $x \neq 0$, то интервальное оценивание даст уже результат

$$\frac{1}{1 + 1/[1, 2]} = \frac{1}{[1, \frac{3}{2}]} = [\frac{2}{3}, 1].$$

Он более узок, т.е. более точен, и совпадает к тому же с областью значений. Как видим качество интервального оценивания существенно зависит от вида выражения. ■

Использование естественного интервального расширения подчас даёт весьма грубые оценки областей значений функций, в связи с чем получили развитие более совершенные способы (формы) нахождения интервальных расширений. Одна из наиболее популярных — так называемая *центрированная форма*:

$$f_c(\mathbf{x}, \tilde{x}) = f(\tilde{x}) + \sum_{i=1}^n g_i(\mathbf{x}, \tilde{x})(\mathbf{x}_i - \tilde{x}_i),$$

где $\tilde{x} = (\tilde{x}_1, \tilde{x}_2, \dots, \tilde{x}_n)$ — некоторая фиксированная точка, называемая «центром»,

$g_i(\mathbf{x}, \tilde{x})$ — интервальные расширения некоторых функций $g_i(\mathbf{x}, \tilde{x})$, которые строятся по f и зависят в общем случае как от $\tilde{x}$, так и от $\mathbf{x}$.

В частности, $g_i(\mathbf{x}, \tilde{x})$ могут быть внешними интервальными оценками областей значений производных $\partial f(\mathbf{x})/\partial x_i$ на $\mathbf{x}$. За дальнейшей информацией мы отсылаем заинтересованного читателя к книгам [1, 23, 28, 29], развёрнуто излагающим проблему построения интервальных расширений функций.

Для дальнейшего важно отметить, что точность интервального оценивания при использовании любой из форм интервального расширения критическим образом зависит от ширины бруса оценивания. Если обозначить через $f(\mathbf{x})$ точную область значений целевой функции на $\mathbf{x}$, т. е. $f(\mathbf{x}) = \{f(x) \mid x \in \mathbf{x}\}$, то для естественного интервального расширения липшицевых функций имеет место неравенство

$$\text{dist}(\mathbf{f}_c(\mathbf{x}), f(\mathbf{x})) \leq C \|\text{wid } \mathbf{x}\| \quad (1.11)$$

с некоторой константой C , и этот факт обычно выражают словами «естественное интервальное расширение имеет первый порядок точности». Для центрированной формы верно соотношение

$$\text{dist}(\mathbf{f}_c(\mathbf{x}, \tilde{x}), f(\mathbf{x})) \leq 2(\text{wid } \mathbf{g}(\mathbf{x}, \tilde{x}))^\top |\mathbf{x} - \tilde{x}|, \quad (1.12)$$

где $\mathbf{g}(\mathbf{x}, \tilde{x}) = (g_1(\mathbf{x}, \tilde{x}), g_2(\mathbf{x}, \tilde{x}), \dots, g_n(\mathbf{x}, \tilde{x}))$. В случае, когда интервальные оценки для функций $g_i(\mathbf{x}, \tilde{x})$ находятся с первым порядком точности, общий порядок точности центрированной формы согласно (1.12) будет уже вторым. Вывод этих оценок заинтересованный читатель может найти, к примеру, в [23, 29].

1.5 Элементы конструктивной математики

Конструктивная математика — это неформальное название той части современной математики, тех математических дисциплин, — теории алгоритмов, теории сложности вычислений, и ряда других — в которых главным объектом изучения являются процессы построения тех или иных математических объектов,

В частности, теория алгоритмов и рекурсивных функций — это математическая дисциплина, исследующая конструктивные свойства различных математических объектов. Её основные понятия — это *алгоритм*, *конструктивный объект*, *вычислимость*, *разрешимость* и др.

Алгоритм — это конечная последовательность инструкций, записанных на некотором языке и определяющих процесс переработки исходных данных в искомые результаты (ответ решаемой задачи и т.п.). Алгоритм принципиально конечен и определяет собой конечный процесс. Далее, *конструктивным объектом* называется объект, который может быть построен с помощью некоторой конечной последовательности действий над каким-то конечным алфавитом. Таковы, например,

рациональные числа. Строго говоря, конструктивные объекты и только они могут быть получены в качестве ответов при решении задачи на реальных цифровых ЭВМ с конечными быстродействием и объёмом памяти.

В частности, конечными машинами являются широко распространенные ныне электронные цифровые вычислительные машины: они способны представлять, по сути дела, только конечные множества чисел. Таким образом, обречены на неудачу любые попытки использовать их для выполнения арифметических абсолютно точных операций над числовыми полями $\mathbb{R}$ и $\mathbb{C}$, которые являются бесконечными (и даже непрерывными) множествами, большинство элементов которых не представимы в цифровых ЭВМ.

Оказывается, что значительная часть объектов, с которыми работают современная математика и её приложения, не являются конструктивными. В частности, неконструктивным является традиционное понятие вещественного числа, подразумевающее бесконечную процедуру определения всех знаков его десятичного разложения (которое в общем случае непериодично). Факт неконструктивности вещественных чисел может быть обоснован строго математически (см. [31]), и он указывает на принципиальные границы возможностей алгоритмического подхода и ЭВМ в деле решения задач математического анализа.

Тем не менее, и в этом океане неконструктивности имеет смысл выделить объекты, которые могут быть «достаточно хорошо» приближены конструктивными объектами. На этом пути мы приходим к понятию *вычислимого вещественного числа* [31, 22]¹: вещественное число α называется вычислимым, если существует алгоритм, дающий по всякому натуральному числу n рациональное приближение к α с погрешностью $\frac{1}{n}$. Множество всех вычислимых вещественных чисел образует *вычислимый континуум*. Соответственно, *вычислимая вещественная функция* определяется как отображение из вычислимого континуума в вычислимый континуум, задаваемая алгоритмом преобразования программы аргумента в программу значений.

Важно помнить, что и вычисляемое вещественное число, и вычислимая функция — это уже не конструктивные объекты. Но, как выясняется, даже ценой ослабления наших требований к конструктивности нельзя вполне преодолеть принципиальные алгоритмические трудности, связанные с задачей решения уравнений. Для вычислимых веще-

¹Совершенно аналогичным является определение *конструктивного вещественного числа* у Б.А. Кушнера [30].

ственных чисел и функций ряд традиционных постановок задач оказывается *алгоритмически неразрешимыми* в том смысле, что построение общих алгоритмов их решения принципиально невозможно.

Например, алгоритмически неразрешимыми являются задачи

- 1) распознавания равно нулю или нет произвольное вычислимое вещественного число [30, 31, 32], распознавания равенства двух вычислимых вещественных чисел [30, 31, 22, 24];
- 2) нахождения для каждой совместной системы линейных уравнений над полем конструктивных вещественных чисел какого-либо ее решения [30, 32];
- 3) нахождения нулей всякой непрерывной кусочно-линейной знакопеременной функции [32].

Приведённые выше результаты задают, как нам представляется, ту абсолютную и совершенно объективную мерку (в отличие от субъективных пристрастий), с которой мы должны подходить к оценке трудоёмкости тех или иных вычислительных методов. Получается, что необходимость переформулировки задачи решения уравнений и систем уравнений связана ещё и с тем, что в традиционной постановке эти задачи оказываются алгоритмически неразрешимыми! На фоне этого мрачного факта наличие даже экспоненциально трудного алгоритма с небольшим основанием «одноэтажной» экспоненты в оценке сложности (вроде 2^n) можно рассматривать как вполне приемлемый вариант разрешимости задачи, и именно это имеет место в ситуации с вычислением вращения векторного поля (степени отображения).

Вычислительная математика тесно примыкает к конструктивной

1.6 Сложность задач и трудоёмкость алгоритмов

Как правило, нас удовлетворит не всякий процесс решения интересующей нас задачи, а лишь только тот, который выполним за практически приемлемое время. Соответственно, помимо алгоритмической разрешимости задач огромную роль играет трудоёмкость тех или иных алгоритмов для их решения.

Получение оценок трудоёмкости задач является непростым делом. Если какой-то алгоритм решает поставленную задачу, то, очевидно,

его трудоёмкость может служить верхней оценкой сложности решения этой задачи. Но вот получение нижних оценок сложности решения задач является чрезвычайно трудным. В явном виде таким оценки найдены лишь для очень небольшого круга задач, которые имеют, скорее, теоретическое значение. В этих условиях широкое распространение получила альтернативная теория сложности, в основе которой лежат понятие сводимости задач друг к другу и вытекающее из него понятие эквивалентности задач по трудоёмкости.

NP-трудные задачи (универсальные переборные задачи) [10]

Литература к Главе 1

Основная

- [1] АЛЕФЕЛЬД Г., ХЕРЦБЕРГЕР Ю. *Введение в интервальные вычисления*. – Москва: Мир, 1987.
- [2] БАРАХНИН В.Б., ШАПЕЕВ В.П. *Введение в численный анализ*. – Санкт-Петербург–Москва–Краснодар: Лань, 2005.
- [3] БАБЕНКО К.И. *Основы численного анализа*. – Москва: Наука, 1986.
- [4] БАУЭР Ф.Л., ГООЗ Г. *Информатика. В 2-х ч.* – Москва: Мир, 1990.
- [5] БАХВАЛОВ Н.С., ЖИДКОВ Н.П., КОБЕЛЬКОВ Г.М. *Численные методы*. – Москва: Бином, 2003, а также другие издания этой книги.
- [6] БАХВАЛОВ Н.С., КОРНЕВ А.А., ЧИЖОНКОВ Е.В. *Численные методы. Решение задач и упражнения*. – Москва: Дрофа, 2008.
- [7] БЕРЕЗИН И.С., ЖИДКОВ Н.П. *Методы вычислений. Т. 1–2*. – Москва: Наука, 1966.
- [8] ВЕРЖБИЦКИЙ В.М. *Численные методы. Части 1–2*. – Москва: «Оникс 21 век», 2005.
- [9] ВОЛКОВ Е.А. *Численные методы*. – Москва: Наука, 1987.
- [10] ГЭРИ М., ДЖОНСОН Д. *Вычислительные машины и труднорешаемые задачи*. – Москва: Мир, 1982.
- [11] ДЕМИДОВИЧ Б.П., МАРОН А.А. *Основы вычислительной математики*. – Москва: Наука, 1970.
- [12] КАЛИТКИН Н.Н. *Численные методы*. – Москва: Наука, 1978.
- [13] КРЫЛОВ В.И., БОБКОВ В.В., МОНАСТЫРНЫЙ П.И. *Вычислительные методы. Т. 1–2*. – Москва: Наука, 1976.
- [14] КУНЦ К.С. *Численный анализ*. – Киев: Техника, 1964.
- [15] КУНЦМАН Ж. *Численные методы*. – Москва: Наука, 1979.
- [16] МАЦОКИН А.М., СОРОКИН С.Б. *Численные методы. Часть 1. Численный анализ*. – Новосибирск: НГУ, 2006.

- [17] Меньшиков Г.Г. *Локализуемые вычисления. Конспект лекций.* – Санкт-Петербург: СПбГУ, Факультет прикладной математики–процессов управления, 2003.
- [18] Миньков С.Л., Миньков Л.Л. *Основы численных методов.* – Томск: Издательство научно-технической литературы, 2005.
- [19] Райс Дж. *Матричные вычисления и математическое обеспечение.* – Москва: Мир, 1984.
- [20] САМАРСКИЙ А.А., ГУЛИН А.В. *Численные методы.* – Москва: Наука, 1989.
- [21] ТЫРТЫШНИКОВ Е.Е. *Методы численного анализа.* – Москва: Академия, 2007.
- [22] УСПЕНСКИЙ В.А., СЕМЁНОВ А.Л. *Теория алгоритмов: основные открытия и приложения.* – Москва: Наука, 1987.
- [23] ШАРЫЙ С.П. *Конечномерный интервальный анализ.* – Электронная книга, 2010 (см. <http://www.nsc.ru/interval/Library/InteBooks>)
- [24] АВЕРТН О. *Precise numerical methods using C++.* – San Diego: Academic Press, 1998.
- [25] GOLDBERG D. What every computer scientist should know about floating point arithmetic // *ACM Computing Surveys.* – 1991. – Vol. 23, No. 1. – P. 5–48.
- [26] HANSEN E., WALSTER G.B. *Global optimization using interval analysis.* – New York: Marcel Dekker, 2003.
- [27] KREINOVICH V., LAKEYEV A.V., ROHN J., KAHL P. *Computational complexity and feasibility of data processing and interval computations.* – Dordrecht: Kluwer, 1997.
- [28] MOORE R.E., KEARFOTT R.B., CLOUD M. *Introduction to interval analysis.* – Philadelphia: SIAM, 2009.
- [29] NEUMAIER A. *Interval methods for systems of equations.* – Cambridge: Cambridge University Press, 1990.

Дополнительная

- [30] КУШНЕР Б.А. *Лекции по конструктивному математическому анализу.* – Москва: Наука, 1973.
- [31] МАТИН-ЛЁФ П. *Очерки по конструктивной математике.* – Москва: Наука, 1975.
- [32] *Математический Энциклопедический Словарь.* – Москва: Большая Российская Энциклопедия, 1995.
- [33] *IEEE Std 754-1985. IEEE Standard for Binary Floating-Point Arithmetic.* – New York: IEEE, 1985.

Глава 2

Численные методы анализа

Под численными методами анализа обычно понимаются методы решения ряда задач, имеющих происхождение в классическом математическом анализе. Традиционно сюда относят задачи интерполирования и приближения функций, задачу суммирования рядов, а также задачу численного нахождения определённых интегралов. Первыми в нашем курсе будут рассмотрены задачи интерполирования и приближения функций.

Задачи интерполирования и приближения функций (часто употребляют также термин «аппроксимация функций») являются тесно связанными друг с другом задачами, которые укладываются в рамки следующей единой неформальной схемы. Для заданных классов функций $\mathcal{F}$ и $\mathcal{G}$ найти способ, по которому любой заданной функции $f \in \mathcal{F}$ может быть сопоставлена функция $g \in \mathcal{G}$, *достаточно близкая* (или даже *наиболее близкая*) к f в оговоренном заранее смысле. В зависимости от смысла, который вкладывается в понятие «близости» функций здесь могут получаться различные конкретные постановки задач. При этом часто считают, что $\mathcal{G} \subset \mathcal{F}$, и, кроме того, эти классы функций наделяются структурой линейного нормированного пространства и т. п.

Задача интерполирования получается из приведённой выше общей формулировки в случае, когда «близость» подразумевает совпадение функций f и g на некотором множестве точек из пересечения их областей определения. Задача приближения (аппроксимации) функций




Рис. 2.1. Различие задач интерполяции и приближения функций.

получается, когда «близость» понимается как малое отклонение f от g относительно какой-то метрики (расстояния), заданной на пересечении семейств функций $\mathcal{F}$ и $\mathcal{G}$. При этом равенство значений функции g заданным значениям не требуется (см. Рис. 2.1). Разнообразные метрики, возникающие в практике математического моделирования, приводят к различным математическим задачам приближения.

2.1 Интерполирование функций

2.1a Постановка задачи

Задача интерполирования — это задача восстановления (доопределения) функции, которая задана на дискретном множестве точек x_i , $i = 0, 1, \dots, n$. Формальная её постановка такова.

Задан интервал $[a, b]$ и конечное множество точек $x_i \in [a, b]$, $i = 0, 1, \dots, n$, называемых *узлами интерполяции*. Даны значения y_i , $i = 0, 1, \dots, n$. Требуется построить функцию $g(x)$ от непрерывного аргумента x , называемую *интерполирующей функцией* (или *интерполантом*), которая в узлах x_i принимает значения y_i , $i = 0, 1, \dots, n$.

Практическая значимость задачи интерполяции станет более понятной, если упомянуть про её применение для вычисления различных функций, как элементарных, таких как $\sin$, $\cos$, $\exp$, $\log$, так и более сложных, которые принято называть *специальными*. С подобной задачей человеческая цивилизация столкнулась очень давно, столетия и даже тысячелетия назад, и типичным способом её решения в докомпьютерную эпоху было составление для нужд практики таблиц — *табуляция* — для значений интересующей нас функции при некоторых

специальных фиксированных значениях аргумента, покрывающих область её определения. Например, $\sin$ и $\cos$ для аргументов, кратных 1° , одному угловому градусу. Но как, имея подобную таблицу, найти значение интересующей нас функции для аргумента, который не выражается целым числом градусов, скажем, синус угла $17^\circ 23'$?

Здесь на помощь приходит интерполяция — восстановление значения функции в промежуточных точках по ряду известных значений в некоторых фиксированных опорных. Собственно, сам термин «интерполирование» («интерполяция») был впервые употреблён в 1656 году Дж. Валлисом при составлении астрономических и математических таблиц. Он происходит от латинского слова *interpolare*, означающего «переделывать», «ремонтировать», «подновлять».

Интересно, что с появлением и развитием цифровых ЭВМ это применение интерполяции не кануло в лету. В начальный период развития ЭЦВМ преобладал алгоритмический подход к вычислению элементарных функций, когда основной упор делался на создании алгоритмов, способных «на голом месте» вычислить функцию, исходя из какого-нибудь её аналитического представления, например, в виде быстросходящегося ряда и т. п. (см., к примеру, [23, 24]). Но затем, по мере удешевления памяти ЭВМ и повышения её быстродействия, постепенно распространился подход, очень сильно напоминающий старый добрый табличный способ, но уже на новом уровне. Хранение сотен килобайт или даже мегабайт цифровой информации никаких проблем сейчас не представляет, и потому в современных компьютерах программы вычисления функций (элементарных и специальных), как правило, включают в себя библиотеки затабулированных значений функции для фиксированных аргументов, опираясь на которые строится значение в нужной нам точке.

Ещё один источник возникновения задачи интерполирования — это желание иметь просто вычисляемое выражение для сложных функциональных зависимостей, которые могут быть заданы явно или неявно, но в исходной форме требуют очень большого труда для своего вычисления.

Если класс $\mathcal{G}$ интерполирующих функций достаточно широк, то ясно, что решение поставленной задачи неединственно (см. Рис. 2.2). Напротив, если $\mathcal{G}$ узок, то у задачи интерполяции может вовсе не быть решений. На практике выбор класса $\mathcal{G}$ обычно диктуется спецификой решаемой практической задачи.

Если, к примеру, заранее известно, что интерполируемая функция




Рис. 2.2. Задача интерполяции может иметь неединственное решение.

периодична, то в качестве интерполирующих функций естественно взять тоже периодические функции — тригонометрические полиномы

$$\sum_{k=0}^m (a_k \cos(kx) + b_k \sin(kx)),$$

(там, где требуется гладкость), либо пилообразные функции (в импульсных системах) и т. п.

Ниже мы подробно рассмотрим ситуацию, когда в качестве интерполирующих функций берутся алгебраические полиномы

$$a_0 + a_1x + a_2x^2 + \cdots + a_mx^m, \quad (2.1)$$

которые просто вычислимы и являются хорошо изученным математически объектом. При этом мы откладываем до §2.13 рассмотрение вопроса о том, насколько хороши полиномы для интерполирования. Вообще проблема наиболее адекватного выбора класса интерполирующих функций $\mathcal{G}$ по заданному классу $\mathcal{F}$ является нетривиальной и требует, чтобы интерполирующие функции были «той же природы», что и интерполируемые функции из $\mathcal{F}$. Если это не так, то задача интерполяции может решаться неудовлетворительно.

Определение 2.1.1 *Интерполирование функций с помощью алгебраических полиномов называют алгебраической интерполяцией. Алгебраический полином $P_m(x) = a_0 + a_1x + a_2x^2 + \cdots + a_mx^m$, решающий*

задачу алгебраической интерполяции, называется интерполяционным полиномом.

Как определить коэффициенты интерполяционного полинома?

Подставим в него последовательно значения аргумента $x_0, x_1, \dots, x_n$, получим соотношения

$$\begin{aligned} a_0 + a_1x_0 + a_2x_0^2 + \dots + a_mx_0^m &= y_0, \\ a_0 + a_1x_1 + a_2x_1^2 + \dots + a_mx_1^m &= y_0, \\ \vdots \quad \quad \quad \vdots \quad \quad \quad \ddots \quad \quad \quad \vdots \quad \quad \quad \vdots & \\ a_0 + a_1x_n + a_2x_n^2 + \dots + a_mx_n^m &= y_0, \end{aligned} \tag{2.2}$$

которые образуют систему линейных уравнений относительно неизвестных коэффициентов $a_0, a_1, a_2, \dots, a_m$ искомого полинома. Решив её, можно построить и сам полином.

В самом общем случае, если мы не накладываем никаких ограничений на соотношение m и n , система (2.2) может не иметь решений, а если они существуют, то могут быть неединственными. Имеется, тем не менее, важный частный случай задачи алгебраической интерполяции, в котором гарантируются разрешимость и единственность решения.

Теорема 2.1.1 *Если $m = n$, т. е. степень интерполяционного полинома на единицу меньше количества узлов, то решение задачи алгебраической интерполяции существует и единственно.*

Доказательство. Матрица системы линейных уравнений (2.2) имеет вид

$$V(x_0, x_1, \dots, x_n) = \begin{pmatrix} 1 & x_0 & x_0^2 & \dots & x_0^n \\ 1 & x_1 & x_1^2 & \dots & x_1^n \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & x_n^2 & \dots & x_n^n \end{pmatrix}, \tag{2.3}$$

и является так называемой матрицей Вандермонда [17]. Её определитель равен, как известно, произведению

$$\prod_{1 \leq i < j \leq n} (x_j - x_i),$$

и он не зануляется, если узлы интерполяции x_i попарно отличны друг от друга. Следовательно, система линейных уравнений (2.2) однозначно разрешима тогда при любой правой части, т.е. при любых y_i , $i = 0, 1, \dots, n$. ■

2.16 Интерполяционный полином Лагранжа

Теорема 2.1.1 и предшествующие ей рассуждения дают, в действительности, конструктивный способ построения интерполяционного полинома через решение системы линейных алгебраических уравнений. Но в силу ряда причин этот способ не очень выгоден в вычислительном отношении. Решение систем линейных уравнений само по себе является не вполне тривиальной задачей. Кроме того, система (2.2) оказывается очень чувствительной к возмущениям данных или, как принято говорить, *плохо обусловлена* (см. §1.2, а числовую оценку этой обусловленности можно найти в §3.23). Поэтому получаемый на этом пути интерполяционный полином может иметь большую погрешность.

На самом деле нам нечасто требуется знать коэффициенты канонической формы (2.1) для интерполяционного полинома. Для большинства практических целей достаточно иметь некоторое конструктивное представление, позволяющее вычислять значения интерполяционного полинома в любой наперед заданной точке.

Для отыскания такого представления заметим, что при фиксированных узлах $x_0, x_1, \dots, x_n$ результат процесса интерполяции линейным образом зависит от данных $y_0, y_1, \dots, y_n$. Более точно, если полином $P(x)$ решает задачу интерполяции с данными $y = (y_0, y_1, \dots, y_n)$, а полином $Q(x)$ решает задачу интерполяции по тем же узлам с данными $z = (z_0, z_1, \dots, z_n)$, то для любых чисел $\alpha, \beta \in \mathbb{R}$ полином $\alpha P(x) + \beta Q(x)$ решает задачу интерполяции для данных $\alpha y + \beta z = (\alpha y_0 + \beta z_0, \alpha y_1 + \beta z_1, \dots, \alpha y_n + \beta z_n)$.¹

Отмеченным свойством линейности можно воспользоваться для решения задачи интерполяции «по частям», которые удовлетворяют отдельным интерполяционным условиям, а затем собрать эти части во-

¹Сказанное можно выразить словами «оператор интерполирования линейен». В действительности, он даже является проектором, и эти наблюдения являются началом большого и плодотворного направления теории приближения функций.

едино. Именно, будем искать интерполяционный полином в виде

$$P_n(x) = \sum_{i=0}^n y_i \phi_i(x), \quad (2.4)$$

где $\phi_i(x)$ — полином степени n , такой что

$$\phi_i(x_j) = \delta_{ij} = \begin{cases} 0, & \text{при } i \neq j, \\ 1, & \text{при } i = j, \end{cases} \quad (2.5)$$

$i, j = 0, 1, \dots, n$, и посредством δ_{ij} обозначен символ Кронекера. Полином $y_i \phi_i(x)$ имеет степень n и решает задачу интерполяции по узлам $x_0, x_1, \dots, x_n$ с данными $(0, \dots, 0, y_i, 0, \dots, 0)$, $i = 0, 1, \dots, n$, и потому в силу представления (2.4) полином $P_n(x)$ в целом действительно удовлетворяет условиям задачи.

Коль скоро $\phi_i(x)$ зануляется в точках $x_0, \dots, x_{i-1}, x_{i+1}, \dots, x_n$, то ясно, что он должен иметь вид

$$\phi_i(x) = \Phi_i(x - x_0) \cdots (x - x_{i-1})(x - x_{i+1}) \cdots (x - x_n) \quad (2.6)$$

с некоторым нормирующим множителем Φ_i . Для определения Φ_i подставим в выражение (2.6) значение аргумента $x = x_i$ и в силу (2.5) получим

$$\Phi_i(x_i - x_0) \cdots (x_i - x_{i-1})(x_i - x_{i+1}) \cdots (x_i - x_n) = 1.$$

Следовательно,

$$\Phi_i = \frac{1}{(x_i - x_0) \cdots (x_i - x_{i-1})(x_i - x_{i+1}) \cdots (x_i - x_n)},$$

и потому

$$\phi_i(x) = \frac{(x - x_0) \cdots (x - x_{i-1})(x - x_{i+1}) \cdots (x - x_n)}{(x_i - x_0) \cdots (x_i - x_{i-1})(x_i - x_{i+1}) \cdots (x_i - x_n)}.$$

Полиномы $\phi_i(x)$ называют *базисными полиномами Лагранжа*, а иногда *полиномами влияния i -го узла*.

В целом, задачу алгебраической интерполяции решает полином

$$P_n(x) = \sum_{i=0}^n y_i \frac{\prod_{j \neq i} (x - x_j)}{\prod_{j \neq i} (x_i - x_j)}.$$

Его называют *интерполяционным полиномом в форме Лагранжа* или просто *интерполяционным полиномом Лагранжа*.

Далее нам потребуется его запись в несколько другом виде. Введём вспомогательную функцию

$$\omega_n(x) = (x - x_0) \cdots (x - x_{i-1})(x - x_{i+1}) \cdots (x - x_n) \quad (2.7)$$

— полином $(n + 1)$ -й степени, зануляющийся во всех узлах интерполяции. Тогда

$$\phi_i(x) = \frac{\omega_n(x)}{(x - x_i) \omega'_n(x_i)}, \quad (2.8)$$

и в целом

$$P_n(x) = \sum_{i=0}^n y_i \frac{\omega_n(x)}{(x - x_i) \omega'_n(x_i)}.$$

2.1в Разделённые разности и их свойства

Пусть дана функция f и попарно различные точки $x_0, x_1, \dots, x_n$ из её области определения, в которых функция принимает значения $f(x_0), f(x_1), \dots, f(x_n)$. *Разделёнными разностями* функции f , обозначаемыми $f^\angle(x_i, x_{i+1})$, называются отношения

$$f^\angle(x_i, x_{i+1}) := \frac{f(x_{i+1}) - f(x_i)}{x_{i+1} - x_i},$$

$i = 0, 1, \dots, n - 1$. Разделённые разности второго порядка — это величины

$$f^\angle(x_i, x_{i+1}, x_{i+2}) := \frac{f^\angle(x_{i+1}, x_{i+2}) - f^\angle(x_i, x_{i+1})}{x_{i+2} - x_i},$$

$i = 0, 1, \dots, n - 2$, которые являются разделёнными разностями от разделённых разностей. Аналогичным образом вводятся разделённые разности высших порядков: *разделённая разность k -го порядка* есть, по определению,

$$f^\angle(x_i, x_{i+1}, \dots, x_{i+k}) := \frac{f^\angle(x_{i+1}, \dots, x_{i+k}) - f^\angle(x_i, \dots, x_{i+k-1})}{x_{i+k} - x_i},$$

$i = 0, 1, \dots, n - k$, т. е. она равна разделённой разности от разделённых разностей предыдущего $(k - 1)$ -го порядка. Для удобства и единообразия можно также считать, что сами значения функции являются разделёнными разностями нулевого порядка.




Рис. 2.3. Иллюстрация смысла разделённых разностей, как углового коэффициента секущей графика функции

Нетрудно увидеть геометрический смысл разделённой разности. Это угловой коэффициент (тангенс угла наклона к оси абсцисс) секущей графика функции $y = f(x)$, взятой между точками, имеющими аргументы x_i и x_{i+1} . В связи с этим уместно упомянуть, что разделённую разность иногда называют *наклоном* функции между заданными точками (см. [16]). Разделённые разности-наклоны могут быть определены для функций многих переменных и даже для операторов, действующих из одного абстрактного пространства в другое. Интересно, что в начале XX века для обозначения этой конструкции использовался также термин «подъём функции» [33].

Операция взятия разделённой разности является линейной: для любых функций f , g и для любых скаляров α , β справедливо

$$(\alpha f + \beta g)^\angle = \alpha f^\angle + \beta g^\angle. \quad (2.9)$$

Для разделённой разности первого порядка это очевидно следует из определения, а для разделённых разностей высших порядков показывается несложной индукцией по величине порядка.

Предложение 2.1.1 *Имеет место представление*

$$f^\angle(x_i, x_{i+1}, \dots, x_{i+k}) = \sum_{j=i}^{i+k} \frac{f(x_j)}{\prod_{\substack{l=i \\ l \neq j}}^{i+k} (x_j - x_l)}. \quad (2.10)$$

Доказательство. Оно проводится индукцией по порядку k разделённой разности.

При $k = 1$ доказываемая формула, как нетрудно проверить, совпадает с определением разделённой разности первого порядка.

Пусть Предложение уже доказано при всех $k \leq m$ для некоторого положительного целого числа m . Тогда

$$\begin{aligned}
 & f^{\angle}(x_i, x_{i+1}, \dots, x_{i+m+1}) \\
 &= \frac{f^{\angle}(x_{i+1}, x_{i+1}, \dots, x_{i+m+1}) - f^{\angle}(x_i, x_{i+1}, \dots, x_{i+m})}{x_{i+m+1} - x_i} \\
 &= \frac{1}{x_{i+m+1} - x_i} \left(\sum_{j=i+1}^{i+m+1} \frac{f(x_j)}{\prod_{\substack{l=i+1 \\ l \neq j}}^{i+m+1} (x_j - x_l)} - \sum_{j=i}^{i+m} \frac{f(x_j)}{\prod_{\substack{l=i \\ l \neq j}}^{i+m} (x_j - x_l)} \right) \\
 &= \frac{f(x_{i+m+1})}{(x_{i+m+1} - x_i) \prod_{l=i+1}^{i+m} (x_{i+m+1} - x_l)} \\
 &\quad + \frac{1}{x_{i+m+1} - x_i} \left(\sum_{j=i+1}^{i+m} \frac{f(x_j)}{\prod_{\substack{l=i+1 \\ l \neq j}}^{i+m+1} (x_j - x_l)} - \sum_{j=i+1}^{i+m} \frac{f(x_j)}{\prod_{\substack{l=i \\ l \neq j}}^{i+m} (x_j - x_l)} \right) \\
 &\quad - \frac{f(x_i)}{(x_{i+m+1} - x_i) \prod_{l=i+1}^{i+m} (x_i - x_l)}.
 \end{aligned}$$

В полученную сумму члены с $f(x_i)$ и $f(x_{i+m+1})$ входят по одному разу, причём их коэффициенты уже имеют вид, совпадающий с тем, что утверждает Предложение. Члены с остальными $f(x_j)$ входят дважды, и после приведения подобных членов коэффициент при $f(x_j)$ будет

равен

$$\begin{aligned}
 & \frac{\prod_{\substack{l=i+1 \\ l \neq j}}^{i+m+1} (x_j - x_l)}{x_{i+m+1} - x_i} - \frac{\prod_{\substack{l=i \\ l \neq j}}^{i+m} (x_j - x_l)}{x_{i+m+1} - x_i} \\
 &= \frac{(x_j - x_i) - (x_j - x_{i+m+1})}{(x_{i+m+1} - x_i) \prod_{\substack{l=i \\ l \neq j}}^{i+m+1} (x_j - x_l)} = \frac{1}{\prod_{\substack{l=i \\ l \neq j}}^{i+m+1} (x_j - x_l)},
 \end{aligned}$$

что и требовалось показать. ■

Следствие. Разделённая разность — симметричная функция своих аргументов, т. е. она не изменяется при любой их перестановке. Это непосредственно следует из вида выражения, стоящего в правой части представления (2.10).

Пример 2.1.1 Вычислим разделённые разности от полинома $g(x) = x^3 - 4x + 1$.

Прежде всего, воспользуемся свойством линейности разделённой разности (2.9), и будем искать по отдельности разделённые разности от мономов, образующих $g(x)$. Далее, вспомним известную из алгебры формулу

$$a^n - b^n = (a - b)(a^{n-1} + a^{n-2}b + \dots + ab^{n-2} + b^{n-1}). \quad (2.11)$$

Поэтому

$$\frac{x_2^3 - x_1^3}{x_2 - x_1} = x_2^2 + x_2x_1 + x_1^2.$$

Для линейного монома $(-4x)$ разделённая разность находится тривиально, а для константы она равна нулю. Следовательно, в целом

$$g'(x_1, x_2) = x_2^2 + x_2x_1 + x_1^2 - 4.$$

Вычислим вторую разделённую разность от $g(x)$:

$$\begin{aligned} g^{\prime\prime}(x_1, x_2, x_3) &= \frac{g^{\prime}(x_2, x_3) - g^{\prime}(x_1, x_2)}{x_3 - x_1} \\ &= \frac{(x_3^2 + x_3x_2 + x_2^2 - 4) - (x_2^2 + x_2x_1 + x_1^2 - 4)}{x_3 - x_1} \\ &= \frac{x_3^2 + (x_3 - x_1)x_2 - x_1^2}{x_3 - x_1} = x_1 + x_2 + x_3. \end{aligned}$$

Третья разделённая разность

$$\begin{aligned} g^{\prime\prime\prime}(x_1, x_2, x_3, x_4) &= \frac{g^{\prime\prime}(x_2, x_3, x_4) - g^{\prime\prime}(x_1, x_2, x_3)}{x_4 - x_1} \\ &= \frac{(x_2 + x_3 + x_4) - (x_1 + x_2 + x_3)}{x_4 - x_1} \\ &= \frac{x_4 - x_1}{x_4 - x_1} = 1, \end{aligned}$$

т.е. является постоянной. Четвертая и последующие разделённые разности от $g(x)$ будут, очевидно, тождественно нулевыми функциями. ■

Вообще, на основании формулы (2.11) нетрудно найти разделённую разность любого порядка от произвольного полинома. При этом взятие каждой разделённой разности уменьшает степень получающегося полинома на единицу, так что разделённые разности порядка более n от полинома степени n равны нулю. Именно это мы могли наблюдать в Примере 2.1в.

Сделанное наблюдение демонстрирует глубокую аналогию между разделёнными разностями и производными, применение которых также последовательно уменьшает степень полинома. В действительности, эта связь видна даже из определения разделённой разности, которую можно рассматривать как «недоделанную производную» и у которой отсутствует переход к пределу.

Предложение 2.1.2 (связь разделённых разностей с производными)
Пусть $f \in C^n[a, b]$, т.е. функция f непрерывно дифференцируема n раз на интервале $[a, b]$, где расположены узлы $x_0, x_1, \dots, x_n$, и пусть $\underline{x} = \min\{x_0, x_1, \dots, x_n\}$, $\bar{x} = \max\{x_0, x_1, \dots, x_n\}$. Тогда

$$f^{\prime\prime\prime\prime}(x_0, x_1, \dots, x_n) = \frac{1}{n!} f^{(n)}(\xi)$$

для некоторой точки $\xi \in]\underline{x}, \overline{x}[$.

Для разделённых разностей первого порядка этот факт непосредственно следует из теоремы Лагранжа о среднем, а в общем случае его доказательство будет приведено несколько позже, в §2.1д.

2.1г Интерполяционный полином Ньютона

Выведем теперь другую форму интерполяционного полинома с учётом требования иметь такое выражение, которое в минимальной степени перестраивалось бы при смене набора узлов интерполяции.

Если представить

$$P_n(x) = P_0(x) + \sum_{i=1}^n (P_i(x) - P_{i-1}(x)), \quad (2.12)$$

где $P_i(x)$ — интерполяционный полином, построенный по узлам $x_0, x_1, \dots, x_i$, причём $P_0(x) = f(x_0)$, то при добавлении или удалении узлов перестройке должна подвергнуться лишь та часть выражения (2.12), которая вовлекает эти изменяемые узлы, а первые члены в (2.12) останутся неизменными, коль скоро зависят только от первых узлов интерполяции. Таким образом, стоящая перед нами задача окажется решённой, если будут найдены удобные и просто выписываемые выражения для разностей $P_i(x) - P_{i-1}(x)$.

Заметим, что разность $(P_i(x) - P_{i-1}(x))$ есть полином степени i , который обращается в нуль в узлах $x_0, x_1, \dots, x_{i-1}$. Поэтому должно быть

$$P_i(x) - P_{i-1}(x) = A_i(x - x_0)(x - x_1) \cdots (x - x_{i-1})$$

с некоторой константой A_i . Для её определения вспомним, что $P_i(x_i) = y_i = f(x_i)$ по условию интерполяции. Следовательно,

$$A_i = \frac{f(x_i) - P_{i-1}(x_i)}{(x_i - x_0)(x_i - x_1) \cdots (x_i - x_{i-1})}.$$

Отсюда, пользуясь выражением для интерполяционного полинома в

форме Лагранжа и Предложением 2.1.1, нетрудно вывести, что

$$\begin{aligned}
 A_i &= \frac{1}{\prod_{k=0}^{i-1} (x_i - x_k)} \cdot \left(f(x_i) - \sum_{j=0}^{i-1} f(x_j) \frac{\prod_{\substack{k=0 \\ k \neq j}}^{i-1} (x_i - x_k)}{\prod_{\substack{k=0 \\ k \neq j}}^{i-1} (x_j - x_k)} \right) \\
 &= \frac{f(x_i)}{\prod_{k=0}^{i-1} (x_i - x_k)} - \sum_{j=0}^{i-1} \left(\frac{1}{\prod_{k=0}^{i-1} (x_i - x_k)} f(x_j) \frac{\prod_{\substack{k=0 \\ k \neq j}}^{i-1} (x_i - x_k)}{\prod_{\substack{k=0 \\ k \neq j}}^{i-1} (x_j - x_k)} \right) \\
 &= \frac{f(x_i)}{\prod_{k=0}^{i-1} (x_i - x_k)} - \sum_{j=0}^{i-1} \frac{f(x_j)}{(x_i - x_j) \prod_{\substack{k=0 \\ k \neq j}}^{i-1} (x_j - x_k)} \\
 &= \frac{f(x_i)}{\prod_{\substack{k=0 \\ k \neq i}}^i (x_i - x_k)} + \sum_{j=0}^{i-1} \frac{f(x_j)}{(x_j - x_i) \prod_{\substack{k=0 \\ k \neq j}}^{i-1} (x_j - x_k)} \\
 &= \sum_{j=0}^i \frac{f(x_j)}{\prod_{\substack{k=0 \\ k \neq j}}^i (x_j - x_k)} = f^\angle(x_0, x_1, \dots, x_i).
 \end{aligned}$$

Окончательно

$$\begin{aligned}
 P_n(x) &= \\
 &f(x_0) + (x - x_0) f^\angle(x_0, x_1) + (x - x_0)(x - x_1) f^\angle(x_0, x_1, x_2) + \\
 &\dots + (x - x_0)(x - x_1) \cdots (x - x_{n-1}) f^\angle(x_0, x_1, x_2, \dots, x_n).
 \end{aligned}$$

Это выражение называется интерполяционным полиномом в форме Ньютона, или просто интерполяционным полином Ньютона. Оно

является равносильной формой записи интерполяционного полинома, широко применяемой во многих ситуациях, где использование формы Лагранжа по тем или иным причинам оказывается неудобным.

С учётом результата Предложения 2.1.2, т. е. равенства

$$f^{\ell}(x_0, x_1, \dots, x_n) = \frac{1}{n!} f^{(n)}(\xi)$$

ясно видно, что интерполяционный полином Ньютона для гладкой функции непрерывного аргумента является прямым аналогом формулы Тейлора (полинома Тейлора)

$$f(x_0) + (x - x_0)f'(x_0) + (x - x_0)^2 \frac{f''(x_0)}{2!} + \dots + (x - x_0)^n \frac{f^{(n)}(x_0)}{n!}.$$

При этом аналогами степеней переменной $(x - x_0)^k$ являются произведения $(x - x_0)(x - x_1) \cdots (x - x_k)$, которые в случае равномерного и упорядоченного расположения узлов $x_0, x_1, \dots, x_k$ часто называют *обобщённой степенью* [11].

2.1д Погрешность алгебраической интерполяции с простыми узлами

Задача интерполяции, успешно решённая в предшествующих параграфах, часто находится в более широком контексте, описанном во введении к этой теме, на стр. 23. То есть, значения $y_0, y_1, \dots, y_n$ принимаются в узлах $x_0, x_1, \dots, x_n$ некоторой реальной функцией $f(x)$, свойства которой (хотя бы отчасти) известны. Насколько сильно будет отличаться от неё построенный нами интерполант? Именно это отличие понимается под «погрешностью интерполяции».

Определение 2.1.2 *Остаточным членом или остатком интерполирования называется функция $R(f, x) = f(x) - g(x)$, являющаяся разностью рассматриваемой функции $f(x)$ и интерполирующей её функции $g(x)$.*

Предложение 2.1.3 *Если точка z не совпадает ни с одним из узлов интерполирования, то в задаче алгебраической интерполяции остаточный член $R_n(f, z) := f(x) - P_n(x)$ равен*

$$R_n(f, z) = f^{\ell}(x_0, x_1, \dots, x_n, z) \cdot \omega_n(z), \quad (2.13)$$

где функция ω_n определяется посредством (2.7), т. е.

$$\omega_n(x) = \prod_{i=0}^n (x - x_i).$$

Доказательство. Выпишем для f интерполяционный полином Ньютона по узлам $x_0, x_1, \dots, x_n, z$:

$$P_{n+1}(x) = P_n(x) + (x - x_0)(x - x_1) \cdots (x - x_n) f^{\angle}(x_0, x_1, \dots, x_n, z),$$

где $P_n(x)$ — полином Ньютона для узлов $x_0, x_1, \dots, x_n$. Подставляя в это соотношение значение $x = z$, получим

$$P_{n+1}(z) = P_n(z) + (z - x_0)(z - x_1) \cdots (z - x_n) f^{\angle}(x_0, x_1, \dots, x_n, z).$$

Но $P_{n+1}(z) = f(z)$ по построению полинома P_{n+1} . Поэтому

$$\begin{aligned} R_n(f, z) &= f(z) - P_n(z) \\ &= (z - x_0)(z - x_1) \cdots (z - x_n) f^{\angle}(x_0, x_1, \dots, x_n, z), \end{aligned}$$

что и требовалось. ■

Доказательство Предложения 2.1.2 о связи разделённых разностей с производными.

Утверждение, сформулированное в этом Предложении, равносильно следующему: на $]x_0, x_n[$ существует точка ξ , которая является нулём функции

$$\theta(x) = f^{(n)}(x) - n! f^{\angle}(x_0, x_1, \dots, x_n).$$

Эта функция, в свою очередь, есть n -ая производная по x от функции погрешности аппроксимации $R_n(f, x)$, т. е.

$$f^{(n)}(x) - n! f^{\angle}(x_0, x_1, \dots, x_n) = R_n^{(n)}(f, x),$$

в чём можно убедиться непосредственным дифференцированием, беря интерполяционный полином $P_n(x)$ в форме Ньютона. Поясним: в интерполяционном полиноме Ньютона только у разделённой разности n -го порядка $f^{\angle}(x_0, x_1, \dots, x_n)$ коэффициент является полиномом n -ой степени от x , у остальных разделённых разностей эти коэффициенты суть полиномы меньших степеней, которые исчезнут при n -кратном

дифференцировании. А от полинома n -ой степени после дифференцирования останется $n!$.

Итак, функция $R_n(f, x) = f(x) - P_n(x)$ является n -кратно дифференцируемой на $[a, b]$ и обращается в нуль в $n + 1$ различных точках $x_0, x_1, \dots, x_n$, которые без какого-либо ограничения общности можно считать упорядоченными, так что $x_0 < x_1 < \dots < x_n$. В силу известной теоремы Роля производная $R'_n(f, x)$ обязана зануляться внутри n интервалов $[x_0, x_1], [x_1, x_2], \dots, [x_{n-1}, x_n]$, т. е. она имеет n корней.

Далее, повторяя те же рассуждения в отношении второй производной $R''_n(f, x)$, приходим к выводу, что она должна иметь на $]x, \bar{x}[$ не менее $n - 1$ нулей, и т. д. вплоть до $R_n^{(n)}(f, x)$, которая должна иметь на $]x, \bar{x}[$ хотя бы один нуль. Это и требовалось доказать. ■

Теорема 2.1.2 Если $f \in C^{n+1}[a, b]$, т. е. функция $f(x)$ непрерывно дифференцируема $n+1$ раз на интервале $[a, b]$, то при её интерполировании по попарно различным узлам $x_0, x_1, \dots, x_n$ интерполяционным полиномом $P_n(x)$ остаточный член $R_n(f, x)$ может быть представлен в виде

$$R_n(f, x) = \frac{f^{(n+1)}(\xi(x))}{(n+1)!} \cdot \omega_n(x), \quad (2.14)$$

где $\xi(x)$ — некоторая точка, принадлежащая открытому интервалу $]a, b[$ и зависящая от x , а функция ω_n определена в (2.7).

Доказательство. Если $x = x_i$ для одного из узлов интерполирования, то $R_n(f, x) = 0$, но в то же время и $\omega_n(x) = 0$, и потому в качестве ξ можно взять любую точку из открытого интервала $]a, b[$.

Если же аргумент x остаточного члена не совпадает ни с одним из узлов интерполирования, то применяем результаты двух предшествующих Предложений. ■

Полезны огрублённые оценки, удобные для применения при практическом вычислении погрешности интерполирования:

$$|R_n(f, x)| \leq \frac{M_{n+1}}{(n+1)!} \cdot |\omega_n(x)|, \quad (2.15)$$

или даже совсем простая

$$|R_n(f, x)| \leq \frac{M_{n+1}(b-a)^{n+1}}{(n+1)!}, \quad (2.16)$$




Рис. 2.4. Типичное поведение полинома $\omega_n(x)$: быстрый рост за пределами интервала узлов

где $M_{n+1} = \max_{\xi \in [a,b]} |f^{(n+1)}(\xi)|$.

Отметим, что полученные выше оценки — (2.14) и её следствия (2.15) и (2.16) — становятся неприменимыми, если гладкость функции f меньше, чем $n + 1$.

Поведение полинома $\omega_n(x)$ при изменении x типично для полиномов с вещественными корнями вообще. Если аргумент x находится на интервале $[\underline{x}, \bar{x}]$ расположения его корней или «не слишком далёко» от него, то $\omega_n(x)$ принимает относительно умеренные значения, так как формирующие его множители $(x - x_i)$ «не слишком велики». Если же значения аргумента x существенно отличаются от его корней, то абсолютная величина $\omega_n(x)$, а вместе с ней и погрешность интерполяции, очень быстро растут. На Рис. 2.4 изображён график такого полинома нечётной (седьмой) степени. В связи с этим полезно на качественном уровне различать два случая. Если значения интерполируемой функции ищутся в точках, далёких от интервала узлов интерполяции, используют термин *экстраполяция*. Ей противопоставляется *интерполяция* в узком смысле, когда значения функции восстанавливаются на интервале, где расположены узлы, или недалеко от него. Как правило, экстраполяция сопровождается существенными ошибками и используется ограниченным образом.

В рассмотренной выше постановке задачи интерполирования расположение узлов считалось данным извне и фиксированным. Подобный подход соответствует тем практическим задачам, в которых измерения величины y_i могут осуществляться, к примеру, лишь в какие-то фиксированные моменты времени x_i , либо в определённых выделенных точках пространства и т. п., то есть заданы внешним образом и не могут быть изменены по нашему желанию.

Но существуют задачи, в которых мы можем управлять выбором узлов интерполирования. При этом естественно возникает вопрос о том, как сделать этот выбор наилучшим образом, чтобы погрешность интерполирования была как можно меньшей. В наиболее общей формулировке эта задача является весьма трудной, и её решение существенно завязано на свойства интерполируемой функции $f(x)$. Но имеет смысл рассмотреть и упрощённую постановку задачи, в которой на заданном интервале минимизируются значения полинома $\omega_n(x)$, а множитель $f^{(n+1)}(\xi(x))/(n+1)!$ в выражении (2.14) для остаточного члена условно рассматривается как «приближённая константа».

Фактически, ответ на поставленный вопрос сводится к подбору узлов $x_0, x_1, \dots, x_n$ в пределах заданного интервала $[a, b]$ так, чтобы полином $\omega_n(x) = (x-x_0)(x-x_1)\dots(x-x_n)$ принимал «как можно меньшие значения» на $[a, b]$. Конкретный смысл, который вкладывается в эту фразу, может быть весьма различен, так как функция — полином $\omega_n(x)$ в нашем случае — определяется своими значениями в бесконечном множестве аргументов, и малость одних значений функции может иметь место наряду с очень большими значениями при других аргументах. Ниже мы рассматриваем «отклонение от нуля» как максимум абсолютных значений функции на интервале, т.е. $\max_{x \in [a, b]} \omega_n(x)$. Это условие является одним из наиболее часто встречающихся в прикладных задачах.

2.1e Полиномы Чебышёва

Полиномы Чебышёва — это семейство полиномов, обозначаемых по традиции² как $T_n(x)$, и зависящее от неотрицательного целого параметра n . Они могут быть определены различными равносильными способами, и наиболее просто и наглядно их *тригонометрическое опреде-*

²Буква «Т» является первой в немецком (Tschebyschev) и французском (Tchebychev) написаниях фамилии П.Л. Чебышёва, открывшего эти полиномы.

ление:

$$T_n(x) = \cos(n \arccos x), \quad x \in [-1, 1], \quad (2.17)$$

$n = 0, 1, 2, \dots$ Полином степени n однозначно определяется своими значениями в $(n + 1)$ -точках, а формулой (2.17) мы фактически задаём значения функции в бесконечном множестве точек. Поэтому если посредством (2.17) в самом деле задаются полиномы, то они однозначно определяются на всей вещественной оси, а не только для значений аргумента $x \in [-1, 1]$.

Представление (2.17), в действительности, справедливо для любых $x \in \mathbb{R}$, если под $\arccos x$ понимать комплексное значение и, соответственно, рассматривать косинус от комплексного аргумента. Можно показать, что

$$T_n(x) = \operatorname{ch}(n \operatorname{arch} x),$$

где ch — гиперболический косинус, а arch — обратная к нему функция, и это определение удобно применять при вещественных x , таких что $|x| \geq 1$.

Предложение 2.1.4 $T_n(x)$ — полином степени n , и его старший коэффициент при $n \geq 1$ равен 2^{n-1} .

Доказательство. Мы проведём его индукцией по номеру n полинома Чебышёва. При $n = 0$ имеем $T_0(x) = 1$, при $n = 1$ справедливо $T_1(x) = x$, так что база индукции установлена.

Далее, из известной тригонометрической формулы

$$\cos \alpha + \cos \beta = 2 \cos \left(\frac{\alpha + \beta}{2} \right) \cos \left(\frac{\alpha - \beta}{2} \right)$$

следует, что

$$\begin{aligned} \cos((n+1) \arccos x) + \cos((n-1) \arccos x) \\ = 2 \cos(n \arccos x) \cos(\arccos x) \\ = 2x \cos(n \arccos x). \end{aligned}$$

Следовательно,

$$T_{n+1}(x) = 2x T_n(x) - T_{n-1}(x) \quad (2.18)$$

для любых $n = 1, 2, \dots$

Таким образом, если $T_n(x)$ и $T_{n-1}(x)$ являются полиномами, то $T_{n+1}(x)$ — также полином, степень которого на единицу выше степени $T_n(x)$, а старший коэффициент — в 2 раза больше. ■

Полученные в доказательстве рекуррентные формулы (2.18) позволяют последовательно выписывать явные алгебраические выражения для полиномов Чебышёва:

$$\begin{aligned} T_0(x) &= 1, \\ T_1(x) &= x, \\ T_2(x) &= 2x^2 - 1, \\ T_3(x) &= 4x^3 - 3x, \\ T_4(x) &= 8x^4 - 8x^2 + 1, \\ T_5(x) &= 16x^5 - 20x^3 + 5x, \\ &\dots \end{aligned}$$

По рекуррентным формулам (2.18) и следующим из них явным выражениям полиномы Чебышёва единообразно определяются для любых вещественных значений аргумента x .




Рис. 2.5. Графики первых полиномов Чебышёва на интервале $[-1.2, 1.2]$.

Дальнейшие свойства полиномов Чебышёва:

1) При чётном (нечётном) n полином Чебышёва $T_n(x)$ есть чётная (нечётная) функция от x . Действительно, выражение для $T_n(x)$ при чётном n содержит только чётные степени x , а при нечётном n — только нечётные степени x .

2) Полином $T_n(x)$ имеет n вещественных корней, все они находятся в интервале $[-1, 1]$ и выражаются формулой

$$\hat{x}_k = \cos \frac{(2k-1)\pi}{2n}, \quad k = 1, 2, \dots, n.$$

Геометрическая иллюстрация расположения корней полинома Чебышёва дана на Рис. 2.6, из неё видно что эти корни расположены существенно неравномерно: они сгущаются к концам интервала $[-1, 1]$, а в середине более разрежены.

3) $\max_{x \in [-1, 1]} |T_n(x)| = 1$, и этот максимум достигается в точках $x_s = \cos(s\pi/n)$, $s = 0, 1, \dots, n$, причём $T_n(x_s) = (-1)^s$, $s = 0, 1, \dots, n$. Это непосредственно следует из тригонометрического определения полиномов Чебышёва.




Рис. 2.6. Иллюстрация расположения корней полиномов Чебышёва.

4) Полином $\tilde{T}_n(x) = 2^{1-n} T_n(x)$, $n \geq 1$, среди всех полиномов n -ой степени со старшим коэффициентом 1 имеет на интервале $[-1, 1]$ наименьшее отклонение от нуля. Иными словами, если $Q_n(x)$ — полином степени n со старшим коэффициентом 1, то

$$\max_{x \in [-1, 1]} |Q_n(x)| \geq \max_{x \in [-1, 1]} |\tilde{T}_n(x)| = 2^{1-n}. \quad (2.19)$$

Доказательство. Предположим противное доказываемому, т.е. что для какого-то $Q_n(x)$ выполняется неравенство, противоположное по смыслу (2.19). Тогда полином $\tilde{T}_n(x) - Q_n(x)$ имеет степень $n - 1$, но в то же время в точках $x_s = \cos(s\pi/n)$, $s = 0, 1, \dots, n$, должно быть справедливо

$$\begin{aligned} \operatorname{sgn}(\tilde{T}_n(x_s) - Q_n(x_s)) &= \operatorname{sgn}((-1)^s 2^{1-n} - Q_n(x_s)) \\ &= \operatorname{sgn}((-1)^s 2^{1-n}) = (-1)^s. \end{aligned}$$

Итак, на интервале $[x_s, x_{s+1}]$ полином $\tilde{T}_n(x) - Q_n(x)$ меняет знак, и потому обязан иметь корень. Коль скоро это происходит для $s = 0, 1, \dots, n - 1$, т.е. всего n раз, то полином $\tilde{T}_n(x) - Q_n(x)$ необходимо имеет n корней на $[-1, 1]$, что невозможно из-за того, что степень этого полинома равна $n - 1$. ■

Если мы осуществляем интерполяцию на интервале $[a, b]$, отличном от $[-1, 1]$, то линейной заменой переменной

$$y = \frac{1}{2}(b + a) + \frac{1}{2}(b - a)x$$

интервал $[-1, 1]$ можно перевести в $[a, b]$. При этом

$$x = \frac{2y - (b + a)}{(b - a)}.$$

Корням полинома Чебышёва на $[-1, 1]$ соответствуют тогда точки

$$y_k = \frac{1}{2}(b + a) + \frac{1}{2}(b - a) \cos \frac{(2k - 1)\pi}{2n}, \quad k = 1, 2, \dots, n.$$

из интервала $[a, b]$.

Итак, полином

$$2^{1-2n} (b - a)^n \cdot T_n \left(\frac{2x - (b + a)}{b - a} \right)$$

наименее уклоняется от нуля на $[a, b]$ среди всех полиномов n -ой степени со старшим коэффициентом 1, и максимум его модуля на этом интервале равен $2^{1-n} (b - a)^n$.

Возвращаясь к задаче интерполирования, можно сказать, что выбор узлов интерполирования по корням полиномов Чебышёва позволяет при прочих равных условиях существенно уменьшить погрешность. Помимо интерполирования полиномы Чебышёва имеют и другие важные применения в различных задачах вычислительной математики.

2.1ж Алгебраическая интерполяция с кратными узлами

Кратным узлом называют, по определению, узел, в котором информация о функции задаётся более одного раза. Помимо значения функции это может быть какая-либо дополнительная информация о ней, к примеру, значения производных и т.п. К задаче интерполяции с кратными узлами мы приходим, в частности, если количество узлов не больше, чем степень интерполяционного полинома, который нужно построить по этим узлам.

Рассмотрим следующую постановку задачи

Даны несовпадающие точки $x_0, x_1, \dots, x_n$ — узлы интерполирования, в которых заданы значения $y_i^{(k)}$, $k = 0, 1, \dots, N_i - 1$, — их принимает интерполируемая функции f и её производные $f^{(k)}(x)$. При этом число N_i называют *кратностью* узла x_i . Требуется построить полином $H_m(x)$ степени m , такой что

$$H_m^{(k)}(x_i) = y_i^{(k)}, \quad i = 0, 1, \dots, n, \quad k = 0, 1, \dots, N_i - 1. \quad (2.20)$$

Теорема 2.1.3 *Решение задачи алгебраической интерполяции с кратными узлами при $m = N_0 + N_1 + \dots + N_n - 1$ существует и единственно.*

Доказательство. В канонической форме полином $H_m(x)$ имеет вид

$$H_m(x) = \sum_{l=0}^m a_l x^l,$$

и для определения его коэффициентов $a_0, a_1, \dots, a_m$ станем дифференцировать $H_m(x)$ и подставлять в него условия (2.20). Получим систему линейных алгебраических уравнений относительно $a_0, a_1, \dots, a_m$, в которой при $m = N_0 + N_1 + \dots + N_n - 1$ число уравнений $N_0 + N_1 + \dots + N_n - 1$ совпадает с числом неизвестных, равным $m + 1$.

Итак, получена система линейных уравнений

$$Ga = y \quad (2.21)$$

с квадратной $(m + 1) \times (m + 1)$ -матрицей G и вектором неизвестных $a = (a_0, a_1, \dots, a_m)^T \in \mathbb{R}^{m+1}$, которую можно выписать даже в явном виде. Тем не менее, её прямое исследование весьма сложно, и потому мы пойдём окольным путём.

Для определения свойств матрицы G исследуем однородную систему, отвечающую нулевой правой части $y = 0$, т. е.

$$Ga = 0.$$

Вектор правой части y образован значениями интерполируемой функции и её производных $y_i^{(k)}$ в узлах x_i , $i = 0, 1, \dots, n$. Однородная система $Ga = 0$ отвечает случаю $y_i^{(k)} = 0$ для всех $i = 0, 1, \dots, n$, $k = 0, 1, \dots, N_i - 1$. Каким является вектор решений a этой системы?

Если правая часть в (2.21) — нулевая, то это означает, что полином $H_m(x)$ с учётом кратности имеет $N_0 + N_1 + \dots + N_n = m + 1$ корней, т. е. больше, чем его степень. Следовательно, он necessarily равен нулю, а соответствующая однородная линейная система $Ga = 0$ имеет лишь нулевое решение. Как следствие, матрица G должна быть неособенной, а неоднородная линейная система (2.21) однозначно разрешима при любой правой части y . Это и требовалось доказать. ■

Задачу алгебраической интерполяции с кратными узлами в исследуемой нами постановке часто называют также задачей *эрмитовой интерполяции*, а сам полином $H_m(x)$ решающий эту задачу, называют при этом *интерполяционным полиномом Эрмита*. Он может иметь, аналогично случаю интерполяции с простыми узлами, форму Лагранжа либо форму Ньютона. Укажем способ построения его лагранжевой формы.

Из выписанного при доказательстве Теоремы 2.1.3 представления вектора коэффициентов $a = (a_0, a_1, \dots, a_n)^\top$ интерполяционного полинома как решения системы (2.21) следует, что a линейно зависит от вектора данных y , т. е. от значений $y_i^{(k)}$, $k = 0, 1, \dots, N_i - 1$, $i = 0, 1, \dots, n$. Поэтому, как и в случае интерполирования с простыми узлами, можно представить $H_m(x)$ в виде линейной комбинации

$$H_m(x) = \sum_{i=0}^n \sum_{k=0}^{N_i-1} y_i^{(k)} \cdot \phi_{ik}(x),$$

где $\phi_{ik}(x)$ — специальные «базисные» полиномы степени m , удовлетворяющие условиям

$$\phi_{ik}^{(l)}(x_j) = \begin{cases} 0, & \text{при } l \neq k \text{ или } i \neq j, \\ 1, & \text{при } l = k \text{ и } i = j. \end{cases} \quad (2.22)$$

Полином $\phi_{ik}(x)$ отвечает линейной системе (2.21) с вектор-столбцом правой части y вида $(0, \dots, 0, 1, 0, \dots, 0)^\top$, в котором все элементы нулевые за исключением одного.

Каков конкретный вид этих базисных полиномов? Перепишем условия (2.22) в виде

$$\phi_{ik}^{(l)}(x_i) = \delta_{kl}, \quad k = 0, 1, \dots, N_i - 1, \quad (2.23)$$

$$\begin{aligned} \phi_{ik}^{(l)}(x_j) &= 0, & j &= 0, 1, \dots, i-1, i+1, \dots, n, \\ & & l &= 0, 1, \dots, N_i - 1. \end{aligned} \quad (2.24)$$

Из второго условия следует, что

$$\phi_{ik}(x) = (x - x_0)^{N_0} \dots (x - x_{i-1})^{N_{i-1}} (x - x_{i+1})^{N_{i+1}} \dots (x - x_n)^{N_n} Q_{ik}(x),$$

где полином $Q_{ik}(x)$ должен определяться из первого условия (2.23). И так далее.

Мы не будем завершать этого построения, так как дальнейшие выкладки весьма громоздки, а алгоритм нахождения полинома из приведённых рассуждения вполне ясен...

Каков погрешность алгебраической интерполяции с кратными узлами?

Теорема 2.1.4 *Если $f \in C^{m+1}[a, b]$, т. е. функция f непрерывно дифференцируема $m+1$ раз на интервале $[a, b]$, то погрешность её интерполирования по попарно различным узлам $x_0, x_1, \dots, x_n \in [a, b]$ полиномом $H_m(x)$ при условии $m = N_0 + N_1 + \dots + N_n - 1$ может быть представлена в виде*

$$R_m(f, x) = f(x) - H_m(x) = \frac{f^{(m+1)}(\xi(x))}{(m+1)!} \cdot \prod_{i=0}^n (x - x_i)^{N_i}, \quad (2.25)$$

где $\xi(x)$ — некоторая точка из $]a, b[$, зависящая от x .

Доказательство этого результата вполне аналогично доказательству теоремы о погрешности интерполирования с простыми узлами и мы его опускаем.

2.13 Общие факты алгебраической интерполяции

Из математического анализа известна

Теорема Вейерштрасса. Если $f : [a, b] \rightarrow \mathbb{R}$ — непрерывная функция, то для всякого $\epsilon > 0$ существует полином $P_n(x)$ степени $n = n(\epsilon)$, равномерно приближающий функцию f с погрешностью, не превосходящей ϵ , т. е. такой, что

$$\max_{x \in [a, b]} |f(x) - P_n(x)| \leq \epsilon.$$

Этот результат служит теоретической основой приближения непрерывных функций алгебраическими полиномами, обеспечивая существование полинома, который сколь угодно близок к заданной непрерывной функции. Вместе с тем, теорема Вейерштрасса слишком обща и не даёт ответа на конкретные вопросы о решении задачи интерполирования, требующей совпадения значений функции и её интерполянта на данном множестве точек-узлов.

Как с теоретической, так и с практической точек зрения интересен вопрос о том, насколько малой может быть сделана погрешность интерполирования при возрастании числа узлов. Вообще, имеет ли место сходимости интерполяционных полиномов к интерполируемой функции при неограниченном возрастании количества узлов?

Применение Теоремы 2.1.2 об оценке погрешности интерполирования при возрастании числа узлов требует также увеличения гладкости интерполируемой функции f . Если эта гладкость ограничена, то сходимости интерполяционных полиномов к интерполируемой функции может не быть. Один из первых примеров на этот счёт привёл С.Н. Бернштейн, рассмотрев на интервале $[-1, 1]$ алгебраическую интерполяцию функции $f(x) = |x|$ по равноотстоящим узлам, включающим и концы этого интервала. Можно показать (см. [9, 29]), что с возрастанием числа узлов соответствующий интерполяционный полином не стремится к $|x|$ ни в одной точке интервала $[-1, 1]$, отличной от -1 , 0 и 1 .

Если интерполируемая функция f имеет бесконечную гладкость, т. е. $f \in C^\infty[a, b]$, и при этом её производные растут «не слишком быстро», так что

$$\sup_{x \in [a, b]} |f^{(n)}(x)| < M^n, \quad (2.26)$$

где M не зависит от n , то из Теоремы 2.1.2 следует, что погрешность




Рис. 2.7. Интерполяция полиномом 10-й степени в примере Рунге

интерполирования может быть оценена сверху как

$$\frac{(M(b-a))^{n+1}}{(n+1)!},$$

то есть очевидно сходится к нулю.

Но при алгебраическом интерполировании в самом общем случае погрешность всё-таки может не сходиться к нулю. По-видимому, наиболее известный из примеров такого рода привёл немецкий математик К. Рунге. В примере Рунге функция

$$\psi(x) = \frac{1}{1 + 25x^2}$$

интерполируется алгебраическими полиномами на интервале $[-1, 1]$ с равномерным расположением узлов интерполяции $x_i = -1 + 2i/n$, $i = 0, 1, 2, \dots, n$. Оказывается, что тогда

$$\lim_{n \rightarrow \infty} \max_{x \in [-1, 1]} |\psi(x) - P_n(x)| = \infty,$$

$P_n(x)$ — интерполяционный полином n -ой степени. При этом с ростом n вблизи концов интервала интерполирования $[-1, 1]$ у полиномов $P_n(x)$ возникают сильные осцилляции, размах которых стремится к бесконечности (см. Рис. 2.7). Интересно, что на интервале $[-\kappa, \kappa]$, где $\kappa \approx 0.726$,

рассматриваемый интерполяционный процесс равномерно сходится к $\psi(x)$. Кроме того, полезно отметить, что функция $\psi(x)$ имеет производные всех порядков для любого вещественного аргумента x , но у концов интервала интерполирования $[-1, 1]$ эти производные уже не удовлетворяют условию (2.26). Таким образом, несмотря на простой вид, функция $\psi(x)$ из примера Рунге своим поведением слишком непохожа на полиномы, производные от которых растут умеренно и, начиная с некоторого порядка, исчезают.

Чтобы строго сформулировать общие результаты о сходимости алгебраических интерполянтов, нам необходимо следующее

Определение 2.1.3 *Говорят, что на интервале $[a, b]$ задан интерполяционный процесс, если задана бесконечная треугольная матрица узлов*

$$\begin{pmatrix} x_0^{(1)} & 0 & 0 & 0 & \cdots \\ x_0^{(2)} & x_1^{(2)} & 0 & 0 & \cdots \\ x_0^{(3)} & x_1^{(3)} & x_2^{(3)} & 0 & \cdots \\ \vdots & \vdots & \vdots & \ddots & \ddots \end{pmatrix},$$

такая что в каждой её строке расположены различные точки интервала $[a, b]$, т. е. $x_i^{(n)} \in [a, b]$ для всех n и всех $i = 0, 1, \dots, n$, причём $x_i^{(n)} \neq x_j^{(n)}$ для $i \neq j$.

Взяв элементы n -ой строки этой матрицы в качестве узлов интерполяции, мы строим интерполяционный полином $P_n(x)$.

Определение 2.1.4 *Интерполяционный процесс для функции f называется сходящимся в точке $y \in [a, b]$, если $P_n(y) \rightarrow f(y)$ при $n \rightarrow \infty$. Интерполяционный процесс для функции f называется сходящимся равномерно, если $\max_{x \in [a, b]} |f(x) - P_n(x)| \rightarrow 0$ при $n \rightarrow \infty$.*

Имеет место

Теорема Фабера. *Не существует бесконечной треугольной матрицы узлов из заданного интервала, такой что соответствующий ей интерполяционный процесс сходил бы равномерно для любой непрерывной функции на этом интервале.*

В частности, даже для интерполяционного процесса по узлам полиномов Чебышёва, рассмотренным в §2.1е и в некотором смысле наилучшим для интерполяции, существуют примеры непрерывных функций, для которых этот интерполяционный процесс всюду расходится. Подробности можно найти в [29].

С другой стороны, справедлива

Теорема Марцинкевича. *Для любой непрерывной на заданном интервале функции f найдётся такая бесконечная треугольная матрица узлов из этого интервала, что соответствующий ей интерполяционный процесс для функции f сходится равномерно.*

Доказательство этих теорем заинтересованный читатель может найти, к примеру, в [9, 10, 44].

Вывод из приведённых выше и, на первый взгляд кажущихся взаимоисключающими, результатов состоит, прежде всего, в том, что множество непрерывных функций является слишком широким, чтобы для него существовал один (или даже несколько) интерполяционных процессов, обеспечивающих сходимость для всех возможных ситуаций. С другой стороны, алгебраические полиномы, несмотря на определённые удобства работы с ними, оказываются слишком капризным инструментом интерполирования достаточно общих непрерывных функций, так что нам нужно озаботиться развитием более тонких методов интерполяции. Этому и будут посвящены следующие параграфы.

2.2 Сплаины

2.2а Элементы теории

Пусть заданный интервал $[a, b]$ разбит на подынтервалы $[x_{i-1}, x_i]$, $i = 1, 2, \dots, n$, так что $a = x_0$ и $x_n = b$. *Сплаином* на $[a, b]$ называется функция, которая вместе со своими производными вплоть до некоторого порядка непрерывна на всём интервале $[a, b]$, и на каждом подынтервале $[x_{i-1}, x_i]$ является некоторым полиномом. Максимальная на всём интервале $[a, b]$ степень полиномов, задающих сплайн, называется *степенью сплайна*. Разность между степенью сплайна и наивысшим порядком его производной, которая непрерывна на $[a, b]$, называется *дефектом сплайна*. Наконец, точки x_i , $i = 0, 1, \dots, n$, называют *узлами сплайна*.

Сплайны находят широкие применения в математике и могут использоваться для различных целей. Если сплайн применяется для решения задачи интерполяции, то он называется *интерполяционным*. Другими словами, интерполяционный сплайн — это сплайн, принимающий в заданных точках $\tilde{x}_i, i = 0, 1, \dots, m$, — узлах интерполяции — требуемые значения f_i , и эти узлы интерполяции, вообще говоря, могут не совпадать с узлами сплайна $x_i, i = 0, 1, \dots, n$.

Термин «сплайн» является удачным заимствованием из английского языка³, где слово «spline» означает гибкую (обычно стальную) линейку, которую, изгибая, использовали чертёжники для проведения гладкой линии между данными фиксированными точками. В середине XX века этот термин вошёл в математику и далее перекочевал во многие языки мира.

Таким образом, сплайны дефекта нуль — это функции задаваемые на всём интервале $[a, b]$ одной полиномиальной формулой, а термин «дефект» весьма точно выражает то, сколько сплайну «не хватает» до полноценного полинома. С другой стороны, именно наличие дефекта обеспечивает сплайну большую гибкость в сравнении с полиномами и делает сплайны в некоторых ситуациях более удобным инструментом приближения и интерполирования функций. Чем больше дефект сплайна, тем больше он отличается от полинома и тем более специфичны его свойства. Но слишком большой дефект приводит к существенному понижению общей гладкости сплайна. В значительном числе приложений сплайнов вполне достаточным оказываются сплайны с минимально возможным дефектом 1, и только такие сплайны мы будем рассматривать далее в нашей книге.

Простейший «настоящий» сплайн имеет дефект 1 и степень 1, будучи просто непрерывно склеенным в узлах $x_i, i = 1, 2, \dots, n-1$. Иными словами, это — кусочно-линейная функция, имеющая несмотря на свою простоту богатые приложения в математике.⁴ Сплайны второй степени часто называют *параболическими сплайнами*.

Пусть имеется интерполяционный сплайн степени d , узлы которого $x_0, x_1, \dots, x_n$ совпадают с узлами интерполирования. Этот сплайн полностью определяется $n(d+1)$ значениями коэффициентов полино-

³Пример неудачного заимствования — термин «вейвлет», который в корне противоречит фонетическому строю русского языка.

⁴Вспомним, к примеру, «ломанные Эйлера», которые применяются для доказательства существования решения задачи Коши для обыкновенных дифференциальных уравнений.




Рис. 2.8. Простейшие сплайны — кусочно-линейные функции.

мов, задающих его на n подынтервалах $[x_{i-1}, x_i]$, $i = 1, 2, \dots, n$. В то же время, в случае дефекта 1 имеется

$d(n-1)$ условий непрерывности в узлах $x_1, x_2, \dots, x_{n-1}$ самого сплайна и его производных вплоть до $(d-1)$ -го порядка,

$(n+1)$ условие интерполяции в узлах $x_0, x_1, \dots, x_n$.

Всего $d(n-1) + (n+1) = n(d+1) - (d-1)$ штук, и потому для определения сплайна не хватает $d-1$ условий, которые обычно задают дополнительно на концах интервала $[a, b]$.

Сказанное имеет следующие важные следствия. Если решать задачу интерполяции с помощью сплайна чётной степени, требуя, чтобы на каждом подынтервале $[x_{i-1}, x_i]$ сплайн являлся бы полиномом чётной степени, то число $(d-1)$ подлежащих доопределению параметров оказывается нечётным. Поэтому на одном из концов интервала $[a, b]$ приходится налагать больше условий, чем на другом. Это приводит, во-первых, к асимметрии задачи, и, во-вторых, может вызвать неустойчивость при определении параметров сплайна. Наконец, интерполяционный сплайн чётной степени при некоторых естественных краевых условиях (периодических, к примеру) может просто не существовать.

Отмеченные недостатки могут решаться, к примеру, выбором узлов сплайна отличными от узлов интерполяции. Но мы далее рассмотрим сплайны нечётной степени 3.

2.26 Интерполяционные кубические сплайны

Наиболее популярны в вычислительной математике сплайны третьей степени с дефектом 1, называемые также *кубическими сплайнами*.

Пусть задан набор узлов $x_0, x_1, \dots, x_n \in [a, b]$, который мы будем называть *сеткой*. Величину $h_i = x_i - x_{i-1}$, $i = 1, 2, \dots, n$, мы будем называть *шагом сетки*. Кубический интерполяционный сплайн на интервале $[a, b]$ с сеткой $a = x_0 < x_1 < \dots < x_n = b$ — это функция $S(x)$, удовлетворяющая следующим условиям:

- 1) $S(x)$ — полином третьей степени на каждом из подинтервалов $[x_{i-1}, x_i]$, $i = 1, 2, \dots, n$;
- 2) $S(x) \in C^2[a, b]$;
- 3) $S(x_i) = f_i$, $i = 0, 1, 2, \dots, n$.

Для построения такого сплайна $S(x)$ нужно определить $4n$ неизвестных величин — по 4 коэффициента полинома третьей степени на каждом из n штук подинтервалов $[x_{i-1}, x_i]$, $i = 1, 2, \dots, n$.

В нашем распоряжении имеются

$3(n - 1)$ условий непрерывности самой функции $S(x)$, её первой и второй производных во внутренних узлах $x_1, x_2, \dots, x_{n-1}$;

$(n + 1)$ условие интерполяции $S(x_i) = f_i$, $i = 0, 1, 2, \dots, n$.

Таким образом, для определения $4n$ неизвестных величин мы имеем всего $(4n - 2)$ условий. Недостающие условия определяют различными способами, среди которых могут быть задание на концах интервала $[a, b]$ первой или второй производной, либо условия периодичности:

$$(I) \quad S'(a) = \beta_0, \quad S'(b) = \beta_n;$$

$$(II) \quad S''(a) = \gamma_0, \quad S''(b) = \gamma_n;$$

$$(III) \quad S^{(k)}(a) = S^{(k)}(b), \quad k = 0, 1, 2.$$

Рассмотрим подробно второй случай задания краевых условий

$$S''(a) = S''(x_0) = \gamma_0,$$

$$S''(b) = S''(x_n) = \gamma_n.$$

Будем искать кусочно-полиномиальное представление нашего кубического сплайна в виде

$$S(x) = \alpha_{i-1} + \beta_{i-1}(x - x_{i-1}) + \gamma_{i-1} \frac{(x - x_{i-1})^2}{2} + \vartheta_{i-1} \frac{(x - x_{i-1})^3}{6}$$

для $x \in [x_{i-1}, x_i]$, $i = 1, 2, \dots, n$. При этом ясно, что

$$S''(x_i) = \gamma_i, \quad i = 0, 1, \dots, n-1.$$

Поскольку $S''(x)$ является линейной функцией на $[x_{i-1}, x_i]$, то её вид полностью определяется двумя её крайними значениями γ_{i-1} и γ_i на концах подинтервала $[x_{i-1}, x_i]$. Имеем поэтому

$$S''(x) = \gamma_{i-1} \frac{x_i - x}{h_i} + \gamma_i \frac{x - x_{i-1}}{h_i}$$

для $x \in [x_{i-1}, x_i]$, $i = 1, 2, \dots, n$. Отметим, что в этих формулах мы уже задействовали известные значения γ_0 и γ_n второй производной S'' на левом и правом концах интервала $[a, b]$. Очевидно, что построенная таким образом функция $S''(x)$ удовлетворяет условию «непрерывной склейки» в узлах $x_1, x_2, \dots, x_{n-1}$, т. е.

$$S''(x_i - 0) = S''(x_i + 0), \quad i = 1, 2, \dots, n-1.$$

Беря дважды первообразную (неопределённый интеграл) от $S''(x)$, мы получим

$$S(x) = \gamma_{i-1} \frac{(x_i - x)^3}{6h_i} + \gamma_i \frac{(x - x_{i-1})^3}{6h_i} + C_1 x + C_2 \quad (2.27)$$

с какими-то константами C_1 и C_2 . Но нам будет удобно представить это выражение в виде

$$S(x) = \gamma_{i-1} \frac{(x_i - x)^3}{6h_i} + \gamma_i \frac{(x - x_{i-1})^3}{6h_i} + K_1(x_i - x) + K_2(x - x_{i-1}), \quad (2.28)$$

где K_1 и K_2 — также константы. Насколько законен переход к такой форме? Из сравнения (2.27) и (2.28) следует, что C_1 и C_2 должны быть связаны с K_1 и K_2 посредством формул

$$C_1 = -K_1 + K_2,$$

$$C_2 = K_1 x_i - K_2 x_{i-1}.$$

Определитель выписанной системы линейных уравнений относительно K_1 и K_2 равен $x_{i-1} - x_i = -h_i$, он не зануляется, и потому переход от C_1 и C_2 к K_1 и K_2 — это неособенная замена переменных. Следовательно, оба представления (2.27) и (2.28) совершенно равносильны друг другу.

Подставляя в выражение (2.28) значение $x = x_{i-1}$ и используя условие $S(x_{i-1}) = f_{i-1}$, будем иметь

$$\gamma_{i-1} \frac{(x_i - x_{i-1})^3}{6h_i} + K_1(x_i - x_{i-1}) = f_{i-1},$$

т. е.

$$\gamma_{i-1} \frac{h_i^2}{6} + K_1 h_i = f_{i-1},$$

откуда

$$K_1 = \frac{f_{i-1}}{h_i} - \frac{\gamma_{i-1} h_i}{6}.$$

Совершенно аналогичным образом, подставляя в (2.28) значение $x = x_i$ и используя условие $S(x_i) = f_i$, найдём

$$K_2 = \frac{f_i}{h_i} - \frac{\gamma_i h_i}{6}.$$

Окончательно выражение сплайна на подинтервале $[x_{i-1}, x_i]$, $i = 1, 2, \dots, n$, выглядит следующим образом

$$\begin{aligned} S(x) = & f_{i-1} \frac{x_i - x}{h_i} + f_i \frac{x - x_{i-1}}{h_i} \\ & + \gamma_{i-1} \frac{(x_i - x)^3 - h_i^2(x_i - x)}{6h_i} + \gamma_i \frac{(x - x_{i-1})^3 - h_i^2(x - x_{i-1})}{6h_i}. \end{aligned} \quad (2.29)$$

Оно не содержит уже величин α_i , β_i и ϑ_i , которые фигурировали ранее в представлении для $S(x)$, но неизвестными остались $\gamma_1, \gamma_2, \dots, \gamma_{n-1}$.

Чтобы завершить определение вида сплайна, т. е. найти $\gamma_1, \gamma_2, \dots, \gamma_{n-1}$, можно воспользоваться условием непрерывности первой производной $S'(x)$ в узлах $x_1, x_2, \dots, x_{n-1}$:

$$S'(x_i - 0) = S'(x_i + 0), \quad i = 1, 2, \dots, n-1. \quad (2.30)$$

Продифференцировав формулу (2.29), будем иметь для $x \in [x_{i-1}, x_i]$

$$S'(x) = \frac{f_i - f_{i-1}}{h_i} - \gamma_{i-1} \frac{3(x_i - x)^2 - h_i^2}{6h_i} + \gamma_i \frac{3(x - x_{i-1})^2 - h_i^2}{6h_i}.$$

Поэтому приравнивание согласно (2.30) производных, которые получены в узлах интерполирования x_i с соседних подинтервалов $[x_{i-1}, x_i]$ и $[x_i, x_{i+1}]$, приводит к системе уравнений

$$\begin{cases} \frac{h_i}{6} \gamma_{i-1} + \frac{h_i + h_{i+1}}{3} \gamma_i + \frac{h_{i+1}}{6} \gamma_{i+1} = \frac{f_{i+1} - f_i}{h_{i+1}} - \frac{f_i - f_{i-1}}{h_i}, \\ i = 1, 2, \dots, n-1, \\ \gamma_0 \text{ и } \gamma_n \text{ заданы.} \end{cases} \quad (2.31)$$

Это система линейных алгебраических уравнений относительно неизвестных переменных $\gamma_1, \gamma_2, \dots, \gamma_{n-1}$, имеющая матрицу

$$\frac{1}{6} \begin{pmatrix} 2(h_1 + h_2) & h_2 & & & 0 \\ h_2 & 2(h_2 + h_3) & h_3 & & \\ & h_3 & 2(h_3 + h_4) & \ddots & \\ & & \ddots & \ddots & \ddots \\ 0 & & & & h_{n-1} & 2(h_{n-1} + h_n) \end{pmatrix},$$

в которой ненулевыми являются лишь три диагонали — главная и соседние с ней — сверху и снизу. Такие матрицы называются *трёхдиагональными*. Кроме того, эта матрица обладает свойством *диагонального преобладания* (см. стр. 126), и потому в силу признака Адамара неособенна. Следовательно, система линейных уравнений (2.31) однозначно разрешима при любой правой части, и искомый сплайн существует и единствен. Для нахождения решения системы (2.31) с трёхдиагональной матрицей может быть с успехом применён метод прогонки, описываемый ниже в §3.3н.

Интересен вопрос о погрешности интерполирования функций и их производных с помощью сплайнов, и ответ на него даёт следующая

Теорема 2.2.1 Пусть $f(x) \in C^p[a, b]$, $p = 1, 2, 3$, а $S(x)$ — интерполяционный кубический сплайн с краевыми условиями (I), (II) или (III). Тогда

$$\max_x |f^{(k)}(x) - S^{(k)}(x)| = O(h^{p-k}), \quad k = 0, \dots, p,$$

где $h = \max_i h_i$.

Доказательство можно увидеть, к примеру, в [12, 15, 34].

Отметим, что, в отличие от интерполяционных полиномов, последовательность интерполяционных кубических сплайнов на равномерной сетке узлов всегда сходится к интерполируемой непрерывной функции. Это относится, в частности, и к функции $f(x) = 1/(1+25x^2)$ из примера Рунге (см. §2.13). Важно также, что с повышением гладкости интерполируемой функции сходимость эта улучшается.

Интерполяционные кубические сплайны $S(x)$, удовлетворяющие на концах интервала $[a, b]$ дополнительным условиям

$$S''(a) = S''(b) = 0,$$

называются *естественными сплайнами*. Их замечательное свойство состоит в том, что они минимизируют функционал

$$\mathcal{E}(\varphi) = \int_a^b (\varphi''(x))^2 dx,$$

который в линейном приближении даёт выражение для энергии упругой деформации гибкой стальной линейки, принимающей форму, которая описывается функцией $\varphi(x)$ на заданном интервале $[a, b]$. Именно, если $S(x)$ — естественный сплайн, построенный по узлам $a = x_0, x_1, \dots, x_n = b$, а $\varphi(x)$ — любая другая дважды гладкая функция, принимающая в этих узлах те же самые значения, то $\mathcal{E}(\varphi) \geq \mathcal{E}(S)$, причём неравенство строго для $\varphi \neq S$. Сформулированное свойство называют *вариационным свойством* естественных сплайнов.

2.3 Нелинейные методы интерполяции

Нелинейными называют методы интерполяции, в которых класс интерполирующих функций $\mathcal{I}$ не является линейным векторным пространством. Важнейший частный случай нелинейных методов интерполяции — это интерполяция с помощью рациональных функций вида

$$y = y(x) = \frac{a_0 + a_1x + a_2x^2 + \dots}{b_0 + b_1x + b_2x^2 + \dots} \quad (2.32)$$

Итак, пусть в узлах $x_0, x_1, \dots, x_n$ заданы значения функции $y_0, y_1, \dots, y_n$. Нам нужно найти рациональную дробь вида (2.32), такую что $y_i = y(x_i)$, $i = 0, 1, \dots, n$.

Поскольку дробь не меняется от умножения числителя и знаменателя на одно и то же ненулевое число, то для какого-нибудь одного из

коэффициентов a_i или b_i может быть выбрано произвольное наперёд заданное значение. Кроме того, параметры a_i и b_i должны удовлетворять $n + 1$ условиям интерполяции в узлах, так что всего этих параметров потребуется $(n + 2)$ штук.

Из формулы (2.32) следует, что

$$a_0 - b_0y + a_1x - b_1xy + a_2x^2 - b_2x^2y + \dots = 0. \quad (2.33)$$

Коль скоро при $x = x_i$ должно быть $y = y_i$, $i = 0, 1, \dots, n$, то получаем $(n + 1)$ равенств

$$a_0 - b_0y_i + a_1x_i - b_1x_iy_i + a_2x_i^2 - b_2x_i^2y_i + \dots = 0, \quad (2.34)$$

$i = 0, 1, \dots, n$. Соотношения (2.33)–(2.34) можно трактовать, как условие линейной зависимости с коэффициентами $a_0, -b_0, a_1, -b_1, \dots$ для вектор-столбцов

$$\begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix}, \quad \begin{pmatrix} y_0 \\ y_1 \\ \vdots \\ y_n \end{pmatrix}, \quad \begin{pmatrix} x_0 \\ x_1 \\ \vdots \\ x_n \end{pmatrix}, \quad \begin{pmatrix} x_0y_0 \\ x_1y_1 \\ \vdots \\ x_ny_n \end{pmatrix}, \quad \begin{pmatrix} x_0^2 \\ x_1^2 \\ \vdots \\ x_n^2 \end{pmatrix}, \quad \begin{pmatrix} x_0^2y_0 \\ x_1^2y_1 \\ \vdots \\ x_n^2y_n \end{pmatrix}, \quad \dots$$

размера $(n + 2)$. Как следствие, определитель

$$\begin{vmatrix} 1 & y_0 & x_0 & x_0y_0 & x_0^2 & x_0^2y_0 & \dots \\ 1 & y_1 & x_1 & x_1y_1 & x_1^2 & x_1^2y_1 & \dots \\ 1 & y_2 & x_2 & x_2y_2 & x_2^2 & x_2^2y_2 & \dots \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \ddots \\ 1 & y_n & x_n & x_ny_n & x_n^2 & x_n^2y_n & \dots \\ 1 & y & x & xy & x^2 & x^2y & \dots \end{vmatrix}$$

размера $(n + 2) \times (n + 2)$ должен быть равен нулю. Разлагая его по последней строке и разрешая полученное равенство нулю относительно y , мы действительно получим выражение для y в виде отношения двух многочленов от x . Реализация этого рецепта требует нахождения значений определителя числовых $(n + 1) \times (n + 1)$ -матриц, и далее в §3.6 мы рассмотрим соответствующие методы. Отметим, что в системах компьютерной математики Scilab и MATLAB для этого существует готовая встроенная функция **det**.

2.4 Численное дифференцирование

Дифференцированием называется, как известно, процесс нахождения производной от заданной функции или же её численного значения в заданной точке. Необходимость выполнения дифференцирования возникает весьма часто и вызвано огромным распространением этой операции в современной математике и её приложениях. Производная бывает нужна и сама по себе, как мгновенная скорость тех или иных процессов, и как вспомогательное средство для построения более сложных процедур, например, в методе Ньютона для численного решения уравнений и систем уравнений (см. §§4.3г и 4.4б).

В настоящее время наиболее распространены три следующих способа вычисления производных:

- символьное (аналитическое) дифференцирование,
- численное дифференцирование,
- автоматическое (алгоритмическое) дифференцирование.

Символьным (аналитическим) дифференцированием называют процесс построения по функции, задаваемой каким-то выражением, производной функции, основываясь на известных из элементарного анализа правилах дифференцирования составных функций (суммы, разности, произведения, частного, композиции, обратной функции и т. п.) и известных производных для простейших функций. На аналогичных принципах основывается автоматическое (алгоритмическое) дифференцирование, но при этом оперируют не выражениями для производных, а их численными значениями при данных значениях аргументов функции. При этом символьное (аналитическое) дифференцирование и автоматическое (алгоритмическое) дифференцирование требуют знания выражения для функции или хотя бы компьютерной программы для её вычисления.

Численным дифференцированием называется процесс нахождения значения производной от функции, использующий значения этой функции в некотором наборе точек её области определения. Таким образом, если функция задана таблично, т. е. лишь на конечном множестве значений аргумента, либо процедура определения значений этой функции является «чёрным ящиком» с неизвестной структурой, то альтернатив численному дифференцированию нет. В частности, иногда мы

вынуждены представлять в виде «чёрного ящика» вычисление значений функции, аналитическое выражение для которой существует, но является слишком сложным для дифференцирования первыми двумя способами.

В основе численного дифференцирования лежат различные идеи. Самая первая состоит в том, чтобы доопределить (восстановить) таблично заданную функцию до функции непрерывного аргумента, к которой уже применима обычная операция дифференцирования. Теория интерполирования, которой посвящены предшествующие параграфы, может оказаться в высшей степени полезной при реализации такого подхода. В частности, таблично заданную функцию можно заменить её интерполяционным полиномом, и его производные считать производными рассматриваемой функции. Для этой процедуры годится также интерполяция сплайнами или какими-либо другими функциями.

2.4a Интерполяционный подход

Итак, пусть задан набор узлов $x_0, x_1, \dots, x_n \in [a, b]$, т. е. сетка с шагом $h_i = x_i - x_{i-1}$, $i = 1, 2, \dots, n$. Кроме того, заданы значения функции $f_0, f_1, \dots, f_n$, такие что $f_i = f(x_i)$, $i = 0, 1, \dots, n$.

Рассмотрим простейший случай численного дифференцирования, когда применяется интерполяционный полином первой степени, который мы строим по двум соседним узлам сетки, т. е. по x_{i-1} и x_i , $i = 1, 2, \dots, n$:

$$\begin{aligned} P_{1,i}(x) &= \frac{x - x_i}{x_{i-1} - x_i} f_{i-1} + \frac{x - x_{i-1}}{x_i - x_{i-1}} f_i \\ &= \frac{f_i - f_{i-1}}{x_i - x_{i-1}} x + \frac{f_{i-1}x_i - f_i x_{i-1}}{x_i - x_{i-1}}, \end{aligned}$$

где у интерполяционного полинома добавлен дополнительный индекс « i », указывающий на ту пару узлов, по которым он построен. Поэтому производная равна

$$P'_{1,i}(x) = \frac{f_i - f_{i-1}}{x_i - x_{i-1}} = \frac{f_i - f_{i-1}}{h_i}.$$

Это значение можно взять за приближение к производной от рассматриваемой функции на интервале $]x_{i-1}, x_i[$, $i = 1, 2, \dots, n$.

Во внутренних узлах сетки — $x_1, x_2, \dots, x_{n-1}$, где встречаются два подинтервала, производную можно брать по любой из возможных формул

$$f'(x_i) \approx f_{\bar{x},i} := \frac{f_i - f_{i-1}}{x_i - x_{i-1}} \quad \text{— разделённая разность назад,}$$

$$f'(x_i) \approx f_{x,i} := \frac{f_{i+1} - f_i}{x_{i+1} - x_i} \quad \text{— разделённая разность вперёд.}$$

Обе они примерно равнозначны и выбор конкретной из них может быть делом соглашения или удобства.

Построим теперь интерполяционные полиномы Лагранжа второй степени по трём соседним точкам сетки x_{i-1}, x_i, x_{i+1} , $i = 1, 2, \dots, n-1$. Имеем

$$\begin{aligned} P_{2,i}(x) &= \frac{(x - x_i)(x - x_{i+1})}{(x_{i-1} - x_i)(x_{i-1} - x_{i+1})} f_{i-1} + \frac{(x - x_{i-1})(x - x_{i+1})}{(x_i - x_{i-1})(x_i - x_{i+1})} f_i \\ &\quad + \frac{(x - x_{i-1})(x - x_i)}{(x_{i+1} - x_{i-1})(x_{i+1} - x_{i-1})} f_{i+1} \\ &= \frac{x^2 - (x_i + x_{i+1})x + x_i x_{i+1}}{(x_{i-1} - x_i)(x_{i-1} - x_{i+1})} f_{i-1} \\ &\quad + \frac{x^2 - (x_{i-1} + x_{i+1})x + x_{i-1} x_{i+1}}{(x_i - x_{i-1})(x_i - x_{i+1})} f_i \\ &\quad + \frac{x^2 - (x_{i-1} + x_i)x + x_{i-1} x_i}{(x_{i+1} - x_{i-1})(x_{i+1} - x_i)} f_{i+1}. \end{aligned}$$

Поэтому

$$\begin{aligned} P'_{2,i}(x) &= \frac{2x - (x_i + x_{i+1})}{(x_{i-1} - x_i)(x_{i-1} - x_{i+1})} f_{i-1} + \frac{2x - (x_{i-1} + x_{i+1})}{(x_i - x_{i-1})(x_i - x_{i+1})} f_i \\ &\quad + \frac{2x - (x_{i-1} + x_i)}{(x_{i+1} - x_{i-1})(x_{i+1} - x_i)} f_{i+1}. \end{aligned}$$

Воспользуемся теперь обозначениями $h_i := x_i - x_{i-1}$, $h_{i+1} := x_{i+1} - x_i$. Тогда $h_i + h_{i+1} = x_{i+1} - x_{i-1}$, а результат предшествующих выкладок

может быть записан в виде

$$f'(x) \approx P'_{2,i}(x) = \frac{2x - x_i - x_{i+1}}{h_i(h_i + h_{i+1})} f_{i-1} - \frac{2x - x_{i-1} - x_{i+1}}{h_i h_{i+1}} f_i + \frac{2x - x_{i-1} - x_i}{h_{i+1}(h_i + h_{i+1})} f_{i+1}. \quad (2.35)$$

Формула (2.35) может применяться для вычисления производных в случае общей неравномерной сетки и для произвольного аргумента. Предположим теперь для простоты, что сетка равномерна, т.е. $h_i = h = \text{const}$, $i = 1, 2, \dots, n$. Кроме того, для таблично заданной функции наиболее интересны производные в тех же точках, где задана сама функция, т.е. в узлах $x_0, x_1, \dots, x_n$. В точке $x = x_i$ из (2.35) получаем для первой производной формулу

$$f'(x_i) \approx f_{\bar{x},i} = \frac{f_{i+1} - f_{i-1}}{2h}, \quad (2.36)$$

называемую *формулой центральной разности*. Подставляя в (2.35) аргумент $x = x_{i-1}$ и сдвигая в получающемся результате индекс на $+1$, получим

$$f'(x_i) \approx \frac{-3f_i + 4f_{i+1} - f_{i+2}}{2h}.$$

Подставляя в (2.35) аргумент $x = x_{i+1}$ и сдвигая в получающемся результате индекс на (-1) , получим

$$f'(x_i) \approx \frac{f_{i-2} - 4f_{i-1} + 3f_i}{2h}.$$

Займёмся теперь выводом формул для второй производной. Используя интерполяционный полином второй степени, можно найти:

$$P''_{2,i}(x) = \frac{2}{h_i(h_i + h_{i+1})} f_{i-1} - \frac{2}{h_i h_{i+1}} f_i + \frac{2}{h_{i+1}(h_i + h_{i+1})} f_{i+1}.$$

В частности, на равномерной сетке с $h_i = h = \text{const}$, $i = 1, 2, \dots, n$ имеем

$$P''_{2,i}(x) = \frac{f_{i-1} - 2f_i + f_{i+1}}{h^2}.$$

Отметим, что полученные выражения для второй производной не зависят от аргумента x .

Несмотря на то, что проведённые выше рассуждения основывались на применении интерполяционного полинома Лагранжа, для взятия производных произвольных порядков на сетке общего вида удобнее использовать интерполяционный полином Ньютона, в котором члены являются полиномами возрастающих степеней.

Выпишем ещё без вывода формулы численного дифференцирования, полученные по четырём точкам, т. е. с применением интерполяционного полинома третьей степени: для первой производной —

$$f'(x_i) \approx \frac{1}{6h}(-11f_i + 18f_{i+1} - 9f_{i+2} + 2f_{i+3}),$$

$$f'(x_i) \approx \frac{1}{6h}(-2f_{i-1} - 3f_i + 6f_{i+1} - f_{i+2}),$$

$$f'(x_i) \approx \frac{1}{6h}(f_{i-2} - 6f_{i-1} + 3f_i + 2f_{i+1}),$$

$$f'(x_i) \approx \frac{1}{6h}(-2f_{i-3} + 9f_{i-2} - 18f_{i-1} + 11f_i),$$

для второй производной —

$$f''(x_i) \approx \frac{1}{h^2}(2f_i - 5f_{i+1} + 4f_{i+2} - f_{i+3}),$$

$$f''(x_i) \approx \frac{1}{h^2}(f_{i-1} - 2f_i + f_{i+1}).$$

В последней формуле один из узлов никак не используется.

В связи с численным дифференцированием, а также во многих других вопросах вычислительной математики чрезвычайно полезно понятие *шаблона формулы*, под которым мы будем понимать совокупность охватываемых этой формулой узлов сетки. Более точно, шаблон формулы численного дифференцирования — это множество узлов сетки, входящих в правую часть этой формулы. Например, шаблоном формулы для вычисления второй производной на равномерной сетке

$$f''(x_i) \approx \frac{f_{i-1} - 2f_i + f_{i+1}}{h^2}$$

являются три точки — x_{i-1} , x_i , x_{i+1} (см. Рис. 2.9).




Рис. 2.9. Шаблон формулы второй разностной производной.

2.46 Оценка погрешности численного дифференцирования

Пусть для численного нахождения k -ой производной функций рассматривается формула численного дифференцирования Φ , имеющая шаблон Π и вовлекающая значения функции f в узлах этого шаблона. Если $f(x)$ — дифференцируемая необходимое число раз функция, такая что $f_i = f(x_i)$ для всех узлов $x_i \in \Pi$, то какова может быть погрешность вычисления $f^{(k)}(x)$ по формуле Φ ? Вопрос этот можно адресовать как к целому интервалу значений аргумента, так и локально, только к той точке x_i , которая служит аргументом левой части формулы численного дифференцирования.

Ранее для погрешности интерполирования функций уже были получены выражения (2.13) и (2.14), и потому заманчивой идеей является их прямое дифференцирование с целью нахождения желаемой погрешности формул, разработанных в предшествующем пункте. Этот путь оказывается очень непростым, так как применение, к примеру, выражения (2.14) требует достаточной гладкости функции $\xi(x)$, о которой мы можем сказать немного. Даже если эта гладкость у $\xi(x)$ имеется, полученные оценки будут содержать производные $\xi'(x)$ и пр., о которых мы знаем ещё меньше. Наконец, шаблон некоторых формул численного дифференцирования содержит меньше точек, чем это необходимо для построения интерполяционных полиномов нужной степени. Такова, к примеру, формула «центральной разности» для первой производной.

Явные выражения для остаточного члена формул численного дифференцирования можно найти, например, в [20, 44], и оно получается методом, напоминающим вывод формулы для погрешности алгебраического интерполирования.

Рассмотрим ниже подробно более простой и достаточно универсальный способ оценивания погрешностей, основанный на разложениях по формуле Тейлора. Суть этого способа заключается, во-первых, в выписывании по формуле Тейлора разложений для функций, входящих в

правую часть формулы численного дифференцирования, и, во-вторых, в аккуратном учёте членов этих разложений с целью получения, по возможности, наиболее точного выражения для ошибки.

Поясним эту методику на примере оценки погрешности для формулы «центральной разности» (2.36)

$$f_{\hat{x},i} = \frac{f_{i+1} - f_{i-1}}{2h}.$$

Предположим, что имеется функция $f \in C^3[x_{i-1}, x_{i+1}]$. Подставляя её в (2.36) и разлагая относительно точки x_i по формуле Тейлора с остаточным членом в форме Лагранжа вплоть до членов второго порядка, получим

$$\begin{aligned} f_{\hat{x},i} &= \frac{1}{2h} \left(\left(f(x_i) + hf'(x_i) + \frac{h^2}{2} f''(x_i) + \frac{h^3}{6} f'''(\xi^+) \right) \right. \\ &\quad \left. - \left(f(x_i) - hf'(x_i) + \frac{h^2}{2} f''(x_i) - \frac{h^3}{6} f'''(\xi^-) \right) \right) \\ &= f'(x_i) + \frac{h^2}{12} f'''(\xi^+) + \frac{h^2}{12} f'''(\xi^-), \end{aligned}$$

где ξ^+ и ξ^- — некоторые точки из открытого интервала $]x_{i-1}, x_{i+1}[$. Поэтому

$$f_{\hat{x},i} - f'(x_i) = \frac{h^2}{12} (f'''(\xi^+) + f'''(\xi^-)) = \frac{\alpha h^2}{6},$$

где $\alpha = \frac{1}{2}(f'''(\xi^+) + f'''(\xi^-))$. В целом справедлива оценка

$$|f_{\hat{x},i} - f'(x_i)| \leq \frac{M_3}{6} h^2,$$

в которой $M_3 = \max_{\xi} |f'''(\xi)|$ для ξ из рассматриваемого множества значений аргумента. То есть, на функциях из C^3 погрешность вычисления второй производной по формуле «центральной разности» равна $O(h^2)$, если шаг сетки равен h .

Определение 2.4.1 *Станем говорить, что приближённая формула (численного дифференцирования, интегрирования и т. п.) имеет p -ый порядок точности (или порядок аппроксимации), если на равномерной сетке её погрешность является величиной $O(h^p)$.*

Нередко понятие порядка точности распространяют и на неравномерные сетки, в которых шаг h_i меняется от узла к узлу. Тогда роль величины h играет какой-нибудь «характерный размер», описывающий данную сетку, например, $h = \max_i h_i$. Порядок точности — важная количественная мера погрешности формулы или метода, и при прочих равных условиях более предпочтительной является формула (метод) более высокого порядка точности. Но следует чётко осознавать, что порядок точности имеет асимптотический характер и отражает поведение погрешности при стремлении шага сетки к нулю. Если этого стремления нет и шаг сетки «достаточно велик», то вполне возможны ситуации, когда метод меньшего порядка точности даёт лучшие результаты.

Из выкладок, проведённых для определения погрешности формулы «центральной разности», хорошо видна особенность метода разложений по формуле Тейлора: его *локальный* характер, вытекающий из свойств самой формулы Тейлора. Наши построения оказываются «привязанными» к определённому узлу (или узлам) сетки, относительно которого и следует строить все разложения, чтобы обеспечить взаимные уничтожения их ненужных членов. Как следствие, в этом специальном узле (узлах) мы можем быстро оценить погрешность. Но за пределами этого узла (узлов), в частности, между узлами сетки всё гораздо сложнее и не так красиво, поскольку взаимные уничтожения членов могут уже не происходить.

Какой порядок точности имеют другие формулы численного дифференцирования?

Методом разложений по формуле Тейлора для дважды гладкой функции f нетрудно получить оценки

$$|f_{x,i} - f'(x_i)| \leq \frac{M_2}{2} h, \quad |f_{\bar{x},i} - f'(x_i)| \leq \frac{M_2}{2} h,$$

где $M_2 = \max_{\xi} |f''(\xi)|$. Таким образом, разность вперёд и разность назад имеют всего лишь первый порядок точности.

Конспективно изложим другие результаты о точности формул чис-

ленного дифференцирования:

$$f'(x_i) = \frac{1}{2h}(-3f_i + 4f_{i+1} - f_{i+2}) + O(h^2),$$

$$f'(x_i) = \frac{1}{2h}(f_{i-2} - 4f_{i-1} + 3f_i) + O(h^2),$$

$$f'(x_i) = \frac{1}{6h}(-2f_{i-1} - 3f_i + 6f_{i+1} - f_{i+2}) + O(h^3),$$

$$f'(x_i) = \frac{1}{6h}(f_{i-2} - 6f_{i-1} + 3f_i + 2f_{i+1}) + O(h^3).$$

Оценим теперь погрешность формулы для второй производной

$$f''(x_i) \approx f_{x\bar{x},i} = \frac{f_{i-1} - 2f_i + f_{i+1}}{h^2}.$$

Для неё

$$\begin{aligned} f_{x\bar{x},i} &= \frac{1}{h^2} \left(\left(f_i - hf'_i + \frac{h^2}{2} f''_i - \frac{h^3}{6} f'''_i + \frac{h^4}{24} f^{\text{IV}}(\xi^-) \right) - 2f_i \right. \\ &\quad \left. + \left(f_i + hf'_i + \frac{h^2}{2} f''_i + \frac{h^3}{6} f'''_i + \frac{h^4}{24} f^{\text{IV}}(\xi^+) \right) \right) \\ &= f''_i + \frac{h^2}{24} (f^{\text{IV}}(\xi^-) + f^{\text{IV}}(\xi^+)), \end{aligned}$$

где ξ^- , ξ^+ — некоторые точки из открытого интервала $]x_{i-1}, x_{i+1}[$, и если $f \in C^4$, то справедлива оценка

$$|f''(x_i) - f_{x\bar{x},i}| \leq \frac{M_4}{12} h^2,$$

где $M_4 = \max_{\xi} |f^{\text{IV}}(\xi)|$. Таким образом, порядок точности этой формулы равен 2 на функциях из C^4 .

Приведём ещё без вывода результат о погрешности формулы для вычисления второй производной вблизи края сетки (таблицы):

$$f''(x_i) = \frac{1}{h^2}(2f_i - 5f_{i+1} + 4f_{i+2} - f_{i+3}) + O(h^2),$$

$$f''(x_i) = \frac{1}{h^2}(f_{i-3} - 4f_{i-2} + 5f_{i-1} - 2f_i) + O(h^2).$$

2.4в Метод неопределённых коэффициентов

Метод неопределённых коэффициентов — это другой подход к получению формул численного дифференцирования, особенно удобный в многомерном случае, когда построение интерполяционного полинома становится непростым.

Станем искать приближённое выражение для производной от функции в виде

$$f^{(k)}(x) \approx \sum_{i=0}^n c_i f(x_i), \quad (2.37)$$

который мотивируется тем обстоятельством, что дифференцирование любого порядка является линейной операцией. При этом коэффициенты c_i постараемся подобрать так, чтобы эта формула являлась точной формулой для всех полиномов степени не выше заданной. Учитывая линейность конструируемой формулы (2.37), можно брать $f(x)$ равной $1, x, x^2, \dots, x^m$. Каждое такое условие порождает какое-то линейное соотношение для коэффициентов c_i , а в целом мы приходим к системе линейных уравнений, для разрешимости которой естественно взять число неизвестных равным числу уравнений, т. е. $m = n$.

Получающаяся система линейных уравнений имеет вид

$$\left\{ \begin{array}{llllll} c_0 & + & c_1 & + \dots + & c_n & = & 0, \\ c_0 x_0 & + & c_1 x_1 & + \dots + & c_n x_n & = & 0, \\ \vdots & & \vdots & & \ddots & & \vdots \\ c_0 x_0^{k-1} & + & c_1 x_1^{k-1} & + \dots + & c_n x_n^{k-1} & = & 0, \\ c_0 x_0^k & + & c_1 x_1^k & + \dots + & c_n x_n^k & = & k!, \\ c_0 x_0^{k+1} & + & c_1 x_1^{k+1} & + \dots + & c_n x_n^{k+1} & = & (k+1)! x, \\ \vdots & & \vdots & & \ddots & & \vdots \\ c_0 x_0^n & + & c_1 x_1^n & + \dots + & c_n x_n^n & = & n(n-1) \dots (n-k+1) x^{n-k}. \end{array} \right. \quad (2.38)$$

Матрица этой системы является матрицей Вандермонда вида (2.3) и неособенна для различных узлов $x_0, x_1, \dots, x_n$. При этом система линейных уравнений однозначно разрешима относительно $c_0, c_1, \dots, c_n$ при любой правой части, но содержательным является лишь случай $k \leq n$. В противном случае, если $k > n$, правая часть системы (2.38)

оказывается нулевой, и, как следствие, система также имеет только бессодержательное нулевое решение. Этот факт имеет интуитивно ясное объяснение: нельзя построить формулу для вычисления производной k -го порядка от функции, используя значения этой функции не более чем в k точках.

Система (2.38) с матрицей Вандермонда, аналогичная системе (2.2), в общем случае является плохообусловленной. Но на практике её решение — вручную или на компьютере — обычно не приводит к большим ошибкам, так как в отличие от случая интерполяции порядок системы (2.38), равный порядку производной, бывает, как правило, небольшим.

Интересен вопрос о взаимоотношении метода неопределённых коэффициентов и рассмотренного ранее в §2.4а интерполяционного подхода к численному дифференцированию. К примеру, Ш.Е. Микеладзе в книге [42] утверждает, что любая формула численного дифференцирования, полученная методом неопределённых коэффициентов, может быть выведена также с помощью интерполяционного подхода, отказывая последнему в оригинальности. Но нельзя отрицать также, что метод неопределённых коэффициентов конструктивно проще и технологичнее в применении, и уже только это обстоятельство оправдывает его существование.

2.4г Полная вычислительная погрешность численного дифференцирования

Рассмотрим поведение полной погрешности численного дифференцирования при расчётах на реальных вычислительных устройствах. Под *полной погрешностью* мы понимаем суммарную ошибку численного нахождения производной, вызванную как приближённым характером самого метода, так и неточностями вычислений на современных цифровых ЭВМ из-за неизбежных ошибок округления и т. п.

Предположим, к примеру, что первая производная функции вычисляется по формуле «разность вперёд»

$$f'(x_i) \approx f_{x,i} = \frac{f_{i+1} - f_i}{h}.$$

Как мы уже знаем, её погрешность

$$|f_{x,i} - f'(x_i)| \leq \frac{M_2 h}{2},$$




Рис. 2.10. Полная погрешность численного дифференцирования

где $M_2 = \max_{\xi \in [a,b]} |f''(\xi)|$. Если значения функции вычисляются с ошибками, то вместо точных f_i и f_{i+1} мы получаем их приближённые значения $\tilde{f}_i$ и $\tilde{f}_{i+1}$, такие что

$$|f_i - \tilde{f}_i| \leq \delta \quad \text{и} \quad |f_{i+1} - \tilde{f}_{i+1}| \leq \delta,$$

где через δ обозначена предельная абсолютная погрешность вычисления значения функции. Тогда предельную полную вычислительную погрешность $E(h, \delta)$ нахождения первой производной функции можно оценить следующим образом

$$\begin{aligned} E(h, \delta) &= \left| \frac{\tilde{f}_{i+1} - \tilde{f}_i}{h} - f'(x_i) \right| \\ &\leq \left| \frac{\tilde{f}_{i+1} - \tilde{f}_i}{h} - \frac{f_{i+1} - f_i}{h} \right| + \left| \frac{f_{i+1} - f_i}{h} - f'(x_i) \right| \\ &\leq \left| \frac{(\tilde{f}_{i+1} - f_{i+1}) + (f_i - \tilde{f}_i)}{h} \right| + \frac{M_2 h}{2} \\ &\leq \frac{|f_{i+1} - \tilde{f}_{i+1}| + |f_i - \tilde{f}_i|}{h} + \frac{M_2 h}{2} = \frac{2\delta}{h} + \frac{M_2 h}{2}. \end{aligned}$$

Отметим, что эта оценка, во-первых, достижима при подходящем сочетании знаков фигурирующих в неравенствах величин, коль ско-

ро достижимо само неравенство треугольника. Во-вторых, оценка не стремится к нулю при уменьшении шага h , так как первое слагаемое неограниченно увеличивается при $h \rightarrow 0$. В целом функция $E(h, \delta)$ при фиксированном δ имеет минимум, определяемый условием

$$\frac{\partial E(h, \delta)}{\partial h} = \frac{\partial}{\partial h} \left(\frac{2\delta}{h} + \frac{M_2 h}{2} \right) = -\frac{2\delta}{h^2} + \frac{M_2}{2} = 0.$$

То есть, оптимальное значение шага численного дифференцирования, при котором достигается минимальная полная погрешность, равно

$$h^* = 2\sqrt{\delta/M_2},$$

и брать меньший шаг численного дифференцирования смысла нет. Значение достигающейся при этом полной погрешности есть $E(h^*, \delta) = 2\sqrt{\delta M_2}$.

Совершенно аналогичная ситуация имеет место и при использовании других формул численного дифференцирования. Производная k -ого порядка определяется тогда формулой типа

$$f^{(k)}(x) = h^{-k} \sum_i c_i f(x_i) + R_k(f, x), \quad (2.39)$$

где $c_i = O(1)$. Если эта формула имеет порядок точности p , то её остаточный член оценивается как $R_k(f, x) \approx c(x) h^p$. Этот остаточный член определяет «идеальную» погрешность численного дифференцирования в отсутствие ошибок вычисления функции, и он неограниченно убывает при $h \rightarrow 0$.

Но если погрешность вычисления значений функции $f(x_i)$ равна δ , то в правой части (2.39) возникает ещё член, абсолютная величина которого оценивается сверху как

$$\delta h^{-k} \sum_i |c_i|.$$

Она неограниченно возрастает при $h \rightarrow 0$. В целом график полной вычислительной погрешности численного дифференцирования выглядит в этом случае примерно так, как на Рис. 2.10.

Практический вывод из вышесказанного состоит в том, что существует оптимальный шаг h численного дифференцирования, минимизирующий полную вычислительную погрешность, и брать меньшее значение шага нецелесообразно.

Отмеченное нами обстоятельство потенциально сколь угодно большого возрастания погрешности численного дифференцирования, в действительности, является отражением более глубокого факта *некорректности* задачи дифференцирования, когда её решение не зависит непрерывно от входных данных (см. §1.2). Если $f(x)$ — исходная функция, производную которой нам требуется найти, то возмущённая функция $f(x) + \frac{1}{n} \sin(nx)$ при $n \rightarrow \infty$ будет очевидно сходиться к исходной, тогда как её производная

$$f'(x) + \cos(nx)$$

не сходится к производной $f'(x)$. При возмущении исходной функции слагаемым $\frac{1}{n} \sin(n^2 x)$ производная вообще может сколь угодно сильно отличаться от производной исходной функции.

2.5 Приближение в евклидовых пространствах

2.5а Обсуждение постановки задачи

В этом параграфе мы займёмся задачей приближения функций и подробно рассмотрим случай, когда отклонение функций друг от друга измеряется в так называемой среднеквадратичной норме.

К задаче приближения функций естественно приходят в ситуации, когда методы интерполирования по различным причинам не удовлетворяют практику. Эти причины могут носить чисто технический характер. К примеру, гладкость сплайна может оказаться недостаточной, либо его построение — слишком сложным. Степень обычного интерполяционного полинома может быть неприемлемо высокой для данного набора узлов интерполяции (а высокая степень — это трудности при вычислении значений полинома). Но причины отказа от интерполяции могут иметь также принципиальный характер. В частности, это происходит, если значения функции в узлах $x_0, x_1, \dots, x_n$ известны неточно. В этих условиях целесообразна коррекция самой постановки задачи.

Именно, имеет смысл отказаться от требования точного равенства $g(x_i)$ значениям функции f_i в узлах $x_0, x_1, \dots, x_n$, допустив, к примеру, принадлежности $g(x_i) \in [\underline{f}_i, \bar{f}_i]$, $i = 0, 1, \dots, n$, $\underline{f}_i \leq \bar{f}_i$ для значений восстанавливаемой функции $g(x)$ некоторым интервалам $[\underline{f}_i, \bar{f}_i]$. Наглядно-геометрически это означает построение функции $g(x)$ из за-




Рис. 2.11. Интерполяция функции, заданной с погрешностью

данного класса $\mathcal{G}$, которая в каждом узле сетки x_i , $i = 0, 1, \dots, n$, проходит через некоторый «коридор» $[\underline{f}_i, \bar{f}_i]$, см. Рис. 2.11.

Более общая постановка этой задачи предусматривает наличие некоторой метрики (расстояния), которую мы будем обозначать через dist , и с помощью которой можно измерять отклонение вектора значений $(g(x_0), g(x_1), \dots, g(x_n))^T$ функции $g(x)$ в узлах сетки от вектора заданных значений $(f_0, f_1, \dots, f_n)^T$. Фактически, здесь dist — это какое-то расстояние на пространстве $\mathbb{R}^{n+1}$ всех $(n+1)$ -мерных вещественных векторов. Соответствующая постановка задачи приближения (аппроксимации) будет звучать тогда так:

Для заданных ϵ , набора узлов x_i , $i = 0, 1, \dots, n$, на интервале $[a, b]$ и соответствующих им значений f_i , $i = 0, 1, \dots, n$, найти функцию $g(x)$ из класса функций $\mathcal{G}$, такую что $\text{dist}(f, g) < \epsilon$, где $f = (f_0, f_1, \dots, f_n)^T$ и $g = (g(x_0), g(x_1), \dots, g(x_n))^T$.

При этом $g(x)$ называют *приближающей* (аппроксимирующей) функцией, а сама эта новая задача является задачей приближения функции. Её важнейшей модификацией служит задача наилучшего приближения, когда ищут приближающую (аппроксимирующую) функцию $g(x)$, которая доставляет минимум расстоянию $\text{dist}(f, g)$.

Наконец, выписанные выше формулировки являются дискретными вариантами общей задачи о приближении функции:

Для заданных $\epsilon > 0$, функции $f(x)$ из $\mathcal{F}$ и метрики dist найти функцию $g(x)$ из класса функций $\mathcal{G}$, такую что $\text{dist}(f, g) < \epsilon$.

Соответствующая общая формулировка задачи о наилучшем приближении ставится так:

Для заданных функции $f(x)$ из $\mathcal{F}$ и метрики dist найти функцию $g(x)$ из класса функций $\mathcal{G}$, на которой достигается нижняя грань расстояний $\inf_{h \in \mathcal{G}} \text{dist}(f, h)$, т.е. удовлетворяющую $\text{dist}(f, g) = \inf_{h \in \mathcal{G}} \text{dist}(f, h)$.

Решение g этой задачи обычно называется *наилучшим приближением* для f . Отметим, что в каждом конкретном случае существование элемента наилучшего приближения требует отдельного исследования.

Формула Тейлора — хороший и весьма важный в практическом отношении инструмент локального приближения функций. Но для больших интервалов она не очень хороша.

До сих пор ничего не было сказано о выборе классов функций $\mathcal{F}$ и $\mathcal{G}$, и в наших формулировках на их месте могут быть весьма произвольные множества. Но чаще всего $\mathcal{F}$ и $\mathcal{G}$ являются линейными пространствами, на которых определена некоторая норма $\|\cdot\|$. Именно в ней измеряют отклонение функций (непрерывного или дискретного аргумента) друг от друга, так что

$$\text{dist}(f, g) = \|f - g\|.$$

Соответственно, в задаче наилучшего приближения функции f ищется такой элемент $g \in \mathcal{G}$, на котором достигается $\inf_{h \in \mathcal{G}} \|f - h\|$.

Рассмотренные выше постановки задач дают начало большим и важным математическим теориям, в совокупности образующим теорию приближения функций (или теорию аппроксимации). Её ветвью является, в частности, теория равномерного приближения, когда отклонение функций оценивается в норме $\|f\| = \max_{x \in [a, b]} |f(x)|$. Выбор различных норм (т.е. различных мер отклонения функций друг от друга) и различных функциональных классов обуславливает огромное разнообразие задач теории приближения.

2.56 Метод наименьших квадратов

Рассмотрим подробно частный, но очень важный случай задачи о наилучшем приближении, в котором

- линейное нормированное пространство функций $\mathcal{F}$ таково, что на нём задано скалярное произведение $\langle \cdot, \cdot \rangle$, и норма в $\mathcal{F}$ определяется с его помощью как $\|f\| = \sqrt{\langle f, f \rangle}$,
- функциональный класс $\mathcal{G} \subseteq \mathcal{F}$, из которого выбирается искомый элемент наилучшего приближения, является конечномерным подпространством в $\mathcal{F}$.

Метод наименьших квадратов — это общее название целого семейства идейно близких методов построения приближений, которые основаны на минимизации суммы квадратов отклонений компонент исходного вектора от приближающего. В случае, когда рассматривается приближение функций (или вообще элементов) каких-то абстрактных пространств естественным обобщением минимизации суммы квадратов является нахождение минимума нормы, порождённой скалярным произведением.

Напомним, что конечномерные линейные векторные пространства со скалярным произведением называются *евклидовыми пространствами*. Бесконечномерные линейные векторные пространства с выписанной нами нормой называются *гильбертовыми пространствами* при дополнительном условии полноты, т. е. существования в них предела всякой фундаментальной последовательности.

Приближение функций в норме, порождённой скалярным произведением, часто называют *среднеквадратичным приближением*, так как в конечномерной ситуации, когда имеем $f = (f_0, f_1, \dots, f_n)^\top$ и $g = (g_0, g_1, \dots, g_n)^\top$, обычно

$$\langle f, g \rangle = \frac{1}{n+1} \sum_{i=0}^n \varrho_i f_i g_i, \quad (2.40)$$

для некоторого положительного весового вектора $\varrho = (\varrho_0, \varrho_1, \dots, \varrho_n)^\top$, $\varrho_i > 0$. То есть, в соответствующей норме отклонение одной функции от другой есть

$$\|f - g\| = \left(\frac{1}{n+1} \sum_{i=0}^n \varrho_i (f_i - g_i)^2 \right)^{1/2},$$

— усреднение квадратов разностей компонент с какими-то весовыми множителями ϱ_i , $i = 0, 1, \dots, n$. В частности, если известна информация о точности задания отдельных значений функции f_i , то веса ϱ_i

можно назначать так, чтобы отразить величину этой точности, сопоставляя значениям f_i с большей точностью больший вес.

Нормирующий множитель $\frac{1}{n+1}$ при сумме в (2.40) удобно взять для того, чтобы с ростом размерности n (при росте количества наблюдений, измельчении сетки и т. п.) ограничить рост величины скалярного произведения и обеспечить соизмеримость результатов при различных n . В общем случае, когда f и g — функции непрерывного аргумента, обычно полагают

$$\langle f, g \rangle = \int_a^b \varrho(x) f(x) g(x) dx, \quad (2.41)$$

для некоторой весовой функции $\varrho(x) > 0$, и при этом

$$\|f - g\| = \left(\int_a^b \varrho(x) (f(x) - g(x))^2 dx \right)^{1/2}.$$

Линейное пространство всех функций, квадрат которых интегрируем на заданном интервале $[a, b]$, со скалярным произведением, задаваемым посредством (2.41), называют пространством $\mathcal{L}_2[a, b]$. В курсах функционального анализа показывается, что это гильбертово пространство. По этой причине оно очень популярно в самых различных математических дисциплинах, от теории уравнений в частных производных до статистики.

Итак, в ситуации, описанной в начале пункта, ищем приближение g для функции f в виде

$$g(x) = \sum_{j=1}^m c_j \varphi_j(x),$$

где $\{\varphi_j(x)\}_{j=1}^m$ — базис m -мерного линейного подпространства $\mathcal{G} \subseteq \mathcal{F}$. Если через Φ обозначить квадрат нормы отклонения f от g , то имеем

$$\begin{aligned} \Phi &= \|f(x) - g(x)\|^2 = \langle f - g, f - g \rangle \\ &= \langle f, f \rangle - 2\langle f, g \rangle + \langle g, g \rangle \\ &= \langle f, f \rangle - 2 \sum_{j=1}^m c_j \langle f, \varphi_j \rangle + \sum_{j=1}^m \sum_{k=1}^m c_j c_k \langle \varphi_j, \varphi_k \rangle. \end{aligned} \quad (2.42)$$

Как видим, Φ есть квадратичная форма от аргументов $c_1, c_2, \dots, c_m$ плюс ещё некоторые линейные члены относительно c_j и постоянное слагаемое $\langle f, f \rangle$. Так как для всех значений аргументов функция Φ принимает только неотрицательные значения, то ясно, что она должна достигать своего минимума.

Действительно, после приведения к «главным осям» квадратичная форма в составе Φ обязательно должна получить вид суммы квадратов, так как иначе вся Φ была бы неограниченной снизу. Но сумма квадратов неограниченно возрастает при росте нормы аргумента $c = (c_0, c_1, \dots, c_m)$ и растёт быстрее линейных членов. Следовательно, при достаточно больших значениях $\|c\|$ значение Φ также сколь угодно велико. Более точно, для любого достаточно большого K существует такое C , что $\Phi(x) > K$ при $\|x\| > C$. Получается, что минимум непрерывной функции Φ находится где-то в компактном шаре $\|c\| \leq C$, т. е. действительно достигается функцией.

Для определения минимума функции Φ продифференцируем её по c_j , $j = 1, 2, \dots, m$, и приравняем полученные производные к нулю:

$$\frac{\partial \Phi}{\partial c_j} = -2\langle f, \varphi_j \rangle + 2 \sum_{k=1}^m c_k \langle \varphi_j, \varphi_k \rangle = 0.$$

Множитель 2 при сумме $c_k \langle \varphi_j, \varphi_k \rangle$ появляется оттого, что в двойной сумме из выражения (2.42) слагаемое с c_j возникает дважды, один раз с коэффициентом $\langle \varphi_j, \varphi_k \rangle$, а другой раз — с коэффициентом $\langle \varphi_k, \varphi_j \rangle$.

В целом, получаем систему линейных уравнений

$$\sum_{k=1}^m \langle \varphi_j, \varphi_k \rangle c_k = \langle f, \varphi_j \rangle, \quad j = 1, 2, \dots, m, \quad (2.43)$$

с матрицей коэффициентов

$$\Gamma(\varphi_1, \varphi_2, \dots, \varphi_m) = \begin{pmatrix} \langle \varphi_1, \varphi_1 \rangle & \langle \varphi_1, \varphi_2 \rangle & \dots & \langle \varphi_1, \varphi_m \rangle \\ \langle \varphi_2, \varphi_1 \rangle & \langle \varphi_2, \varphi_2 \rangle & \dots & \langle \varphi_2, \varphi_m \rangle \\ \vdots & \vdots & \ddots & \vdots \\ \langle \varphi_m, \varphi_1 \rangle & \langle \varphi_m, \varphi_2 \rangle & \dots & \langle \varphi_m, \varphi_m \rangle \end{pmatrix},$$

которая называется, как известно, *матрицей Грама* системы векторов $\varphi_1, \varphi_2, \dots, \varphi_m$. Из курса линейной алгебры и аналитической геометрии

читателю должно быть известно, что матрица Грама — это симметричная матрица, неособенная тогда и только тогда, когда векторы $\varphi_1, \varphi_2, \dots, \varphi_m$ линейно независимы. При выполнении этого условия матрица Грама является ещё и положительно определённой. Таким образом, решение задачи наилучшего среднеквадратичного приближения существует и единственно в случае, когда $\varphi_1, \varphi_2, \dots, \varphi_m$ образуют базис в подпространстве $\mathcal{G}$.

Обратимся к практическим аспектам реализации метода наименьших квадратов. Каковы свойства системы уравнений (2.43) в смысле устойчивости её решения к возмущениям в данных и погрешностям вычислений на ЭЦВМ?

Наиболее простой вид матрица Грама имеет в случае, когда базисные функции φ_j ортогональны друг другу, т. е. когда $\langle \varphi_j, \varphi_k \rangle = 0$ при $j \neq k$. При этом соответствующая система линейных уравнений (2.43) становится диагональной и решается тривиально —

$$c_k = \frac{\langle f, \varphi_k \rangle}{\langle \varphi_k, \varphi_k \rangle}, \quad k = 1, 2, \dots, m. \quad (2.44)$$

Соответствующее наилучшее приближение имеет вид суммы

$$g = \sum_{k=1}^m c_k \varphi_k$$

и называется (конечным) *рядом Фурье* для f по ортогональной системе векторов $\{\varphi_j(x)\}_{j=1}^m$, а коэффициенты (2.44) называют при этом *коэффициентами Фурье* разложения f .

Кроме того, в случае ортогонального и близкому к ортогональному базиса $\{\varphi_j(x)\}_{j=1}^m$ решение системы (2.43) устойчиво к возмущениям в правой части и неизбежным погрешностям вычислений. Но в общем случае базис линейного подпространства $\mathcal{G}$ может быть неортогональным, и тогда свойства системы уравнений (2.43) могут быть очень плохими в том смысле, что её решение будет чрезвычайно чувствительным к возмущениям и погрешностям.

Пример 2.5.1 Рассмотрим задачу о среднеквадратичном приближении непрерывных функций на интервале $[0, 1]$ полиномами фиксированной степени m , беря нормой

$$\|f\| = \int_0^1 (f(x))^2 dx.$$

Если в качестве базиса в линейном пространстве полиномов мы возьмём обычные степени

$$1, \quad x, \quad x^2, \quad \dots, \quad x^m,$$

то на месте (i, j) в соответствующей матрице Грама размера $(m+1) \times (m+1)$ будет стоять элемент

$$\int_0^1 x^{i-1} x^{j-1} dx = \left. \frac{x^{i+j-1}}{i+j-1} \right|_0^1 = \frac{1}{i+j-1}, \quad i, j = 1, 2, \dots, m+1$$

(сдвиг показателей степени на (-1) вызван тем, что строки и столбцы матрицы нумеруются, начиная с единицы). Матрица $H = (h_{ij})$ с элементами $h_{ij} = 1/(i+j-1)$ называется *матрицей Гильберта*, и она является исключительно плохо обусловленной матрицей (см. §3.23).

В то же время базис из тригонометрических полиномов вида

$$1, \quad \cos(2\pi kx), \quad \sin(2\pi kx), \quad k = 1, 2, \dots,$$

является ортогональным на $[0, 1]$, т. е. в вычислительном отношении очень хорошим для построения среднеквадратичных приближений. ■

Более детальный теоретический анализ и практический опыт показывают, что в методе наименьших квадратов в качестве базиса $\varphi_1, \varphi_2, \dots, \varphi_n$ линейного подпространства $\mathcal{G} \subset \mathcal{F}$ имеет смысл брать системы элементов, ортогональных, возможно, по отношению к другому скалярному произведению, так как это служит гарантией «разумной малости» внедиагональных элементов матрицы Грама и, как следствие, её не слишком плохой обусловленности.

Отметим, что задачу приближения функций, значения которых заданы приближённо, часто называют (особенно в практических приложениях) *задачей сглаживания*, поскольку получаемая приближающая функция, как правило, действительно «сглаживает» выбросы данных, вызванные случайными ошибками и т.п.

2.5в Полиномы Лежандра

Если базис, образованный последовательными степенями переменной $-1, x, x^2, \dots, x^m$ — является плохим для среднеквадратичного приближения функций полиномами, то каков хороший ортогональный базис?

Для его конструктивного построения можно воспользоваться, к примеру, известным из курса линейной алгебры процессом *ортogonalизации Грама-Шмидта* (см. также §3.3л). Напомним, что по данной конечной линейно независимой системе векторов $v_1, v_2, \dots, v_n$ этот процесс строит ортогональный базис $q_1, q_2, \dots, q_n$ линейной оболочки векторов $v_1, v_2, \dots, v_n$ по следующим расчётным формулам:

$$q_k \leftarrow v_k - \sum_{i=1}^{k-1} \frac{\langle v_k, q_i \rangle}{\langle q_i, q_i \rangle} q_i, \quad k = 1, 2, \dots, n. \quad (2.45)$$

Иногда получающийся ортогональный базис дополнительно нормируют.

Конкретный вид ортогональных полиномов, которые получаются из $1, x, x^2, \dots$, зависит от интервала $[a, b]$, на котором решается задача наилучшего среднеквадратичного приближения. Но мы можем существенно облегчить свою задачу, если найдём семейство ортогональных полиномов для какого-нибудь одного, канонического, интервала $[\alpha, \beta]$, а затем для любого другого интервала будем пользоваться формулой линейной замены переменной $y = kx + l$. Тогда для $a = k\alpha + l, b = k\beta + l$ в силу равенства

$$\int_a^b f(y) dy = k \int_\alpha^\beta f(kx + l) dy,$$

вытекающего из формулы замены переменных в определённом интеграле, получающиеся полиномы будут ортогональны на $[a, b]$. В качестве такого канонического интервала $[\alpha, \beta]$ обычно берётся $[-1, 1]$, и тогда формула замены переменных принимает вид

$$y = \frac{1}{2}(b - a)x + \frac{1}{2}(a + b),$$

так что переменная y пробегает интервал $[a, b]$, если $x \in [-1, 1]$. Обратное преобразование даётся формулой

$$x = \frac{1}{b - a}(2y - (a + b)),$$

которая позволяет заново построить ортогональные полиномы для любого интервала.

Полиномами Лежандра называют полиномы, которые образуют ортогональную систему относительно скалярного произведения (2.41) с

простейшим весом $\varrho(x) = 1$ на интервале $[-1, 1]$. Они были введены в широкий оборот французским математиком А. Лежандром ещё в 1785 году. Из общей теории скалярного произведения в линейных пространствах следует, что такие полиномы существуют и единственны. Если мы не требуем их нормированности, то они оказываются определёнными с точностью до постоянного множителя.

Применяя последовательно формулы (2.45), получим

$$1, \quad x, \quad x^2 - \frac{1}{3}, \quad x^3 - \frac{3}{5}x, \quad \dots$$

(два первых полинома ортогональны с самого начала).

Обычно вводят полиномы Лежандра с помощью *формулы Родрига*

$$L_n(x) = \frac{1}{2^n n!} \frac{d^n}{dx^n} (x^2 - 1)^n, \quad n = 0, 1, 2, \dots, \quad (2.46)$$

которая даёт альтернативное представление для полиномов Лежандра. Очевидно, что $L_n(x)$, определяемый этой формулой, является алгебраическим полиномом n -ой степени со старшим коэффициентом, не равным нулю, так как при n -кратном дифференцировании полинома $(x^2 - 1)^n = x^{2n} - nx^{2(n-1)} + \dots$ степень понижается в точности на n . Коэффициент $1/(2^n n!)$ перед производной в (2.46) взят затем, чтобы удовлетворить условию $L_n(1) = 1$.

Из (2.46) с помощью применения n -кратного интегрирования по частям можно вывести и свойство ортогональности полиномов $L_n(x)$. Действительно, обозначая

$$\psi(x) = (x^2 - 1)^n,$$

можно заметить, что

$$\psi^{(k)}(x) = \frac{d^k}{dx^k} (x^2 - 1)^n = 0 \quad \text{при } x = \pm 1, \quad k = 0, 1, 2, \dots, n-1.$$

Поэтому, если $Q(x)$ является n раз непрерывно дифференцируемой

функцией на $[-1, 1]$, то получим

$$\begin{aligned}
 \int_{-1}^1 Q(x) L_n(x) dx &= \frac{1}{2^n n!} \int_{-1}^1 Q(x) \psi^{(n)}(x) dx \\
 &= \frac{1}{2^n n!} \left(Q(x) \psi^{(n-1)}(x) \right) \Big|_{-1}^1 - \frac{1}{2^n n!} \int_{-1}^1 Q'(x) \psi^{(n-1)}(x) dx \\
 &= -\frac{1}{2^n n!} \int_{-1}^1 Q'(x) \psi^{(n-1)}(x) dx \\
 &= \dots \\
 &= (-1)^n \frac{1}{2^n n!} \int_{-1}^1 Q^{(n)}(x) \psi(x) dx.
 \end{aligned}$$

Если $Q(x)$ — любой полином степени меньше n , то его n -ая производная $Q^{(n)}(x)$ равна тождественному нулю, а потому из полученной формулы следует

$$\int_{-1}^1 Q(x) L_n(x) dx = 0.$$

В частности, это верно и в случае, когда вместо $Q(x)$ берётся полином Лежандра степени, меньшей n , что доказывает наше утверждение.

С другой стороны, если $Q(x) = L_n(x)$, то

$$Q^{(n)}(x) = \frac{1}{2^n n!} \frac{d^{2n}}{dx^{2n}} (x^2 - 1)^n = \frac{1}{2^n n!} (2n)!$$

По этой причине

$$\begin{aligned}
 \int_{-1}^1 L_n(x) L_n(x) dx &= (-1)^n \frac{(2n)!}{(2^n n!)^2} \int_{-1}^1 \psi(x) dx \\
 &= 2 \frac{(2n)!}{(2^n n!)^2} \int_0^1 (1 - x^2)^n dx.
 \end{aligned}$$

Для вычисления последнего интеграла воспользуемся заменой переменных $x = \sin \varphi$, получим

$$\int_0^1 (1-x^2)^n dx = \int_0^{\pi/2} (\cos \varphi)^{2n+1} d\varphi = \frac{(2^n n!)^2}{(2n+1)!}.$$

Следовательно, скалярное произведение $L_n(x)$ на себя равно

$$\frac{2}{2n+1}.$$

Выпишем первые полиномы Лежандра, как они даются формулой Родрига (2.46):

$$\begin{aligned} L_0(x) &= 1, \\ L_1(x) &= x, \\ L_2(x) &= \frac{1}{2}(3x^2 - 1), \\ L_3(x) &= \frac{1}{2}(5x^3 - 3x), \\ L_4(x) &= \frac{1}{8}(35x^4 - 30x^2 + 3), \\ L_5(x) &= \frac{1}{8}(63x^5 - 70x^3 + 15x), \\ &\dots \end{aligned}$$

Важнейшие свойства полиномов Лежандра:

- 1) $L_n(1) = 1$, $L_n(-1) = (-1)^n$, $n = 0, 1, 2, \dots$
- 2) Полином Лежандра L_n имеет n различных вещественных корней, которые расположены на интервале $[-1, 1]$.
- 3) Для полиномов Лежандра справедливо рекуррентное представление

$$(n+1)L_{n+1}(x) = (2n+1)xL_n(x) - nL_{n-1}(x).$$

- 4) Полиномы Лежандра ортогональны друг другу на интервале $[-1, 1]$:

$$\int_{-1}^1 L_i(x)L_j(x) dx = \begin{cases} 0, & \text{если } i \neq j, \\ \frac{2}{2i+1}, & \text{если } i = j. \end{cases}$$




Рис. 2.12. Графики первых полиномов Лежандра на интервале $[-1.2, 1.2]$.

Предложение 2.5.1 *Все нули полиномов Лежандра $L_n(x)$ вещественны, различны и находятся на интервале $[-1, 1]$.*

Доказательство. Предположим, что среди корней полинома $L_n(x)$, лежащих на $[-1, 1]$, имеется s штук различных корней $\eta_1, \eta_2, \dots, \eta_s$ нечётной кратности $\alpha_1, \alpha_2, \dots, \alpha_s$, так что

$$L_n(x) = (x - \eta_1)^{\alpha_1} (x - \eta_2)^{\alpha_2} \cdots (x - \eta_s)^{\alpha_s} \gamma(x),$$

где в полиноме $\gamma(x)$ присутствуют корни $L_n(x)$, не лежащие на $[-1, 1]$, а также те корни $L_n(x)$ из $[-1, 1]$, которые имеют чётную кратность. Таким образом, $\gamma(x)$ уже не меняет знака на интервале $[-1, 1]$.

Ясно, что $s \leq n$, и наша задача — установить равенство $s = n$.

Рассмотрим интеграл

$$\begin{aligned} J &= \int_a^b L_n(x) (x - \eta_1)(x - \eta_2) \cdots (x - \eta_s) dx \\ &= \int_a^b (x - \eta_1)^{\alpha_1+1} (x - \eta_2)^{\alpha_2+1} \cdots (x - \eta_s)^{\alpha_s+1} \gamma(x) dx. \end{aligned}$$

Теперь $\alpha_1 + 1, \alpha_2 + 1, \dots, \alpha_s + 1$ — чётные числа, так что подынтегральное выражение не меняет знак на $[-1, 1]$. Это выражение не равно тождественному нулю, и потому определено $I \neq 0$.

С другой стороны, выражение для J есть скалярное произведение, в смысле $\mathcal{L}_2[-1, 1]$, полинома $L_n(x)$ на полином $(x - \eta_1)(x - \eta_2) \cdots (x - \eta_s)$ степени не более $n - 1$, если выполнено условие $s < n$. Следовательно, при этом должно быть $J = 0$.

Полученное противоречие снимается лишь при условии $s = n$, т. е. когда все корни полинома $L_n(x)$ различны и лежат на интервале $[-1, 1]$. ■

Можно показать дополнительно, что нули полинома $L_n(x)$ перемежаются с нулями полинома $L_{n+1}(x)$.

Помимо полиномов Лежандра существуют и другие семейства ортогональных полиномов, широко используемые в практических вычислениях. В частности, введённые в §2.1е полиномы Чебышёва образуют семейство полиномов, ортогональных на интервале $[-1, 1]$ с весом $(1 - x^2)^{-1/2}$.

Часто возникает необходимость воспользоваться ортогональными полиномами на бесконечных интервалах $[0, +\infty]$ или даже $[-\infty, \infty]$. Естественно, единичным весом $\varrho(x) = 1$ тут не обойтись. Полиномы, ортогональные на этих бесконечных интервалах с весами e^{-x} и e^{-x^2} называются полиномами Лагерра и полиномами Эрмита соответственно. Они также находят многообразные применения в задачах приближения.

2.6 Численное интегрирование

Задачей численного интегрирования мы называем задачу нахождения определённого интеграла

$$\int_a^b f(x) dx,$$

на основе знания значений функции $f(x)$, без привлечения её первообразных и известной формулы Ньютона-Лейбница.

Подобная задача нередко возникает на практике, например, если подынтегральная функция $f(x)$ задана таблично, т. е. набором своих значений в дискретном наборе точек, а не аналитической формулой. В




Рис. 2.13. Вычисление определённого интеграла необходимо при нахождении площадей фигур с криволинейными границами

некоторых случаях численное нахождение интеграла приходится выполнять потому, что применение формулы Ньютона-Лейбница требует знания первообразной для интегрируемой функции, которая может не выражаться через элементарные функции. Но даже если эта первообразная может быть найдена в конечном виде, её вычисление не всегда осуществляется просто (длинное и неустойчивое к ошибкам округления выражение и т. п.).

Наибольшее распространение в вычислительной практике получили формулы вида

$$\int_a^b f(x) dx \approx \sum_{k=0}^n c_k f(x_k), \quad (2.47)$$

где c_k — некоторые постоянные коэффициенты, x_k — точки из интервала интегрирования $[a, b]$, $k = 0, 1, \dots, n$. Подобные формулы называют *квадратурными формулами*, коэффициенты c_k — это *веса* квадратурной формулы, а точки x_k — её *узлы*. В многомерном случае аналогичные приближённые равенства

$$\int_{\Omega} f(x) dx \approx \sum_{k=0}^n c_k f(x_k),$$

где $x, x_k \in \mathbb{R}^m$, Ω — область в $\mathbb{R}^m$, $m \geq 2$,

называют *кубатурными формулами*. То, что квадратурные и кубатурные формулы являются линейными выражениями от значений интегрируемой функции в узлах, объясняется линейной зависимостью са-

мого интеграла от подынтегральной функции. С другой стороны, квадратурные формулы можно рассматривать как обобщения интегральных сумм Римана (через которые интеграл Римана и определяется), так как простейшие квадратурные формулы прямоугольников просто совпадают с этими интегральными суммами.

Как и ранее, совокупность узлов квадратурной (кубатурной) формулы называют *сеткой*. Разность

$$\Psi = \int_a^b f(x) dx - \sum_{k=0}^n c_k f(x_k)$$

называется *погрешностью квадратурной формулы* или её *остаточным членом*.

Условие устойчивости вычислений по квадратурной формуле при значительном количестве узлов n вызывает требование положительности весов c_k (см. подробнее [32], §4.2.4). В частности, тогда при интегрировании функций, принимающих значения одного знака, мы избегаем потери точности при вычитании близких значений.

2.6a Формулы Ньютона-Котеса.

Простейшие квадратурные формулы

Простейший приём построения квадратурных формул — замена подынтегральной функции $f(x)$ на интервале интегрирования $[a, b]$ на «более простую», легче интегрируемую функцию, которая интерполирует или приближает $f(x)$ по узлам $x_0, x_1, \dots, x_n$. В случае, когда $f(x)$ заменяется интерполантом, говорят о квадратурных формулах интерполяционного типа, или, что равносильно, об *интерполяционных квадратурных формулах*.

Наконец, наиболее часто подынтегральную функцию интерполируют полиномами, и подобные интерполяционные квадратурные формулы, полученные с помощью алгебраической интерполяции на равномерной сетке с простыми узлами, называют *формулами Ньютона-Котеса*. В зависимости от того, включаются ли концы интервала интегрирования $[a, b]$ в число узлов квадратурной формулы, различают формулы Ньютона-Котеса *замкнутого типа* и *открытого типа*.

Построим формулы Ньютона-Котеса для $n = 0, 1, 2$, причём для простоты будем строить формулы замкнутого типа за исключением случая $n = 0$, когда замкнутая формула просто невозможна.

Если $n = 0$, то подынтегральная функция $f(x)$ интерполируется полиномом нулевой степени, т. е. какой-то константой, равной значению $f(x)$ в узле x_0 .

Наиболее естественно взять

$$x_0 = \frac{1}{2}(a + b),$$

т. е. серединой интервала интегрирования $[a, b]$. При этом получаем квадратурную формулу

$$\int_a^b f(x) dx \approx (b - a) \cdot f\left(\frac{a + b}{2}\right),$$

называемую *формулой прямоугольников*, так как согласно ей интеграл берётся равным площади прямоугольника с основанием $(b - a)$ и высотой $f((a + b)/2)$. Эту формулу иногда называют также формулой *средних прямоугольников*, поскольку существуют формула «левых прямоугольников» и формула «правых прямоугольников», соответствующие случаям $x_0 = a$ и $x_0 = b$.

Оценим погрешность формулы прямоугольников методом локальных разложений, который ранее был использован при исследовании численного дифференцирования. Разлагая $f(x)$ в окрестности точки $x_0 = (a + b)/2$ по формуле Тейлора, получим

$$f(x) = f\left(\frac{a + b}{2}\right) + f'\left(\frac{a + b}{2}\right) \cdot \left(x - \frac{a + b}{2}\right) + \frac{f''(\xi)}{2} \cdot \left(x - \frac{a + b}{2}\right)^2,$$

где $\xi \in [a, b]$, и далее

$$\begin{aligned} \Psi &= \int_a^b f(x) dx - (b - a) \cdot f\left(\frac{a + b}{2}\right) \\ &= \int_a^b \left(f(x) - f\left(\frac{a + b}{2}\right) \right) dx \\ &= \int_a^b \frac{f''(\xi)}{2} \cdot \left(x - \frac{a + b}{2}\right)^2 dx, \end{aligned}$$

поскольку

$$\int_a^b \left(x - \frac{a + b}{2}\right) dx = \int_{-(a+b)/2}^{(a+b)/2} t dt = 0,$$

— интеграл от первого члена разложения зануляется. Следовательно, с учётом принятого нами обозначения

$$M_p = \max_{x \in [a, b]} |f^{(p)}(x)|$$

можно выписать оценку

$$|\Psi| \leq \frac{M_2}{2} \int_a^b \left(x - \frac{a+b}{2}\right)^2 dx = \frac{M_2(b-a)^3}{24}.$$

Отсюда, в частности, следует, что для полиномов степени не выше 1 формула (средних) прямоугольников даёт точное значение интеграла, коль скоро вторая производная подынтегральной функции тогда зануляется и $M_2 = 0$.

Полученная оценка точности неулущаема, так как достигается на функции $g(x) = \left(x - \frac{1}{2}(a+b)\right)^2$. При этом

$$M_2 = \max_{x \in [a, b]} |g''(x)| = 2, \quad g\left(\frac{a+b}{2}\right) = 0,$$

и потому

$$\int_a^b g(x) dx - (b-a) \cdot g\left(\frac{a+b}{2}\right) = \frac{(b-a)^3}{12} = \frac{M_2(b-a)^3}{24},$$

т. е. имеем точное равенство на погрешность.

Рассмотрим теперь квадратурную формулу Ньютона-Котеса, соответствующую случаю $n = 1$, когда подынтегральная функция приближается интерполяционным полиномом первой степени. Построим его по узлам $x_0 = a$ и $x_1 = b$:

$$P_1(x) = \frac{1}{b-a} ((x-a)f(a) - (x-b)f(b)).$$

Интегрируя это равенство, получим *квадратурную формулу трапеций*

$$\int_a^b f(x) dx \approx (b-a) \cdot \frac{f(a) + f(b)}{2},$$

название которой также навеяно геометрическим образом. Именно, точное значение интеграла заменяется на значение площади трапеции (стоящей боком на оси абсцисс) с высотой $(b-a)$ и основаниями, равными $f(a)$ и $f(b)$ (см. Рис. 2.14).




Рис. 2.14. Иллюстрация квадратурных формул средних прямоугольников и трапеций

Для оценивания погрешности формулы трапеций вспомним оценку (2.14) погрешности интерполяционного полинома, из которой следует, что

$$f(x) - P_1(x) = \frac{f''(\xi(x))}{2} \cdot (x-a)(x-b)$$

для некоторой точки $\xi(x) \in [a, b]$. Следовательно, для формулы трапеций

$$\Psi = \int_a^b \frac{f''(\xi(x))}{2} \cdot (x-a)(x-b) dx,$$

и окончательно

$$|\Psi| \leq \frac{M_2}{2} \left| \int_a^b (x-a)(x-b) dx \right| = \frac{M_2(b-a)^3}{12}.$$

Опять таки, эта оценка неулучшаема, поскольку достигается на функции $g(x) = (x-a)^2$.

2.66 Квадратурная формула Симпсона

Построим квадратурную формулу типа Ньютона-Котеса для $n = 2$, т. е. для трёх узлов

$$x_0 = a, \quad x_1 = \frac{a+b}{2}, \quad x_2 = b,$$




Рис. 2.15. Иллюстрация квадратурной формулы Симпсона

по которым строится интерполяционный полином второй степени

$$P(x) = \frac{2}{(b-a)^2} \left(\left(x - \frac{a+b}{2} \right) (x-b) f(a) + 2(x-a)(x-b) f\left(\frac{a+b}{2}\right) + (x-a) \left(x - \frac{a+b}{2} \right) f(b) \right).$$

Интегрируя его по $[a, b]$, получим приближённое равенство

$$\int_a^b f(x) dx \approx \frac{b-a}{6} \cdot \left(f(a) + 4f\left(\frac{a+b}{2}\right) + f(b) \right), \quad (2.48)$$

которое называется *квадратурной формулой Симпсона* или *формулой парабол* (см. Рис. 2.15), коль скоро она основана на приближении подынтегральной функции подходящей параболой.

Покажем, что формула Симпсона является точной для любого полинома третьей степени.

Отметим прежде всего, что для полиномов степени не выше второй этот факт следует прямо из того, что формула строилась нами как интерполяционная квадратурная формула, основанная на интерполяции подынтегральной функции полиномом второй степени. Поэтому достаточно показать, что формула Симпсона точна для монома x^3 . Имеем

$$\int_a^b x^3 dx = \frac{b^4 - a^4}{4},$$

а с другой стороны

$$\begin{aligned}
 \frac{b-a}{6} \left(a^3 + 4 \left(\frac{a+b}{2} \right)^3 + b^3 \right) &= \frac{b-a}{6} \left(a^3 + \frac{a^3 + 3a^2b + 3ab^2 + b^3}{2} + b^3 \right) \\
 &= \frac{b-a}{6} \cdot \frac{3a^3 + 3a^2b + 3ab^2 + 3b^3}{2} \\
 &= \frac{b-a}{4} (a^3 + a^2b + ab^2 + b^3) = \frac{b^4 - a^4}{4},
 \end{aligned}$$

что совпадает с результатом точного интегрирования.

Следовательно, несмотря на то, что интерполяционный полином в формуле Симпсона строился нами по трём точкам, его фактическая точность более высока, чем та, что обычно обеспечивается полиномом второй степени. Для правильной оценки погрешности формулы Симпсона в этой ситуации нужно взять интерполяционный полином более высокой степени — третьей. При наличии всего 3 узлов мы находимся в условиях задачи интерполяции с кратными узлами. Можно считать, к примеру, что кратным является узел $x_1 = (a+b)/2$, формально решая задачу построения такого интерполяционного полинома $H_3(x)$, что

$$H_3(a) = f(a), \quad H_3(b) = f(b), \quad (2.49)$$

$$H_3\left(\frac{a+b}{2}\right) = f\left(\frac{a+b}{2}\right), \quad H_3'\left(\frac{a+b}{2}\right) = f'\left(\frac{a+b}{2}\right), \quad (2.50)$$

в которой значение производной в средней точке $(a+b)/2$ даже не используется.

В §2.1ж мы установили существование и единственность решения подобных задач, а также привели оценку (2.25) его погрешности:

$$f(x) - H_m(x) = \frac{f^{(m+1)}(\xi(x))}{(m+1)!} \prod_{i=0}^n (x - x_i)^{N_i}.$$

В случае решения задачи (2.49)–(2.50)

$$f(x) - H_3(x) = \frac{f^{(4)}(\xi(x))}{24} \cdot (x-a) \left(x - \frac{a+b}{2} \right)^2 (x-b).$$

Далее, из того, что формула Симпсона точна для полиномов третьей

степени, следует равенство

$$\begin{aligned}\int_a^b H_3(x) \, dx &= \frac{b-a}{6} \cdot \left(H_3(a) + 4H_3\left(\frac{a+b}{2}\right) + H_3(b) \right) \\ &= \frac{b-a}{6} \cdot \left(f(a) + 4f\left(\frac{a+b}{2}\right) + f(b) \right).\end{aligned}$$

Отсюда уже нетрудно вывести выражение для погрешности квадратурной формулы

$$\begin{aligned}\Psi &= \int_a^b f(x) \, dx - \frac{b-a}{6} \cdot \left(f(a) + 4f\left(\frac{a+b}{2}\right) + f(b) \right) \\ &= \int_a^b (f(x) - H_3(x)) \, dx \\ &= \int_a^b \frac{f^{(4)}(\xi(x))}{24} \cdot (x-a) \left(x - \frac{a+b}{2}\right)^2 (x-b) \, dx,\end{aligned}$$

из которого следует оценка

$$\begin{aligned}|\Psi| &\leq \left| \int_a^b \frac{f^{(4)}(\xi(x))}{24} \cdot (x-a) \left(x - \frac{a+b}{2}\right)^2 (x-b) \, dx \right| \\ &\leq \int_a^b \left| \frac{f^{(4)}(\xi(x))}{24} \right| \cdot \left| (x-a) \left(x - \frac{a+b}{2}\right)^2 (x-b) \right| \, dx \\ &\leq \frac{M_4}{24} \cdot \left| \int_a^b (x-a) \left(x - \frac{a+b}{2}\right)^2 (x-b) \, dx \right|,\end{aligned}\tag{2.51}$$

коль скоро подынтегральное выражение $(x-a)(x-(a+b)/2)^2(x-b)$ не меняет знак на интервале интегрирования $[a, b]$. Здесь обозначено $M_4 = \max_{x \in [a, b]} |f^{(4)}(x)|$.

Для вычисления фигурирующего в (2.51) интеграла сделаем замену переменных

$$t = x - \frac{a+b}{2}$$

тогда

$$\begin{aligned}
 & \int_a^b (x-a) \left(x - \frac{a+b}{2}\right)^2 (x-b) dx \\
 &= \int_{-(b-a)/2}^{(b-a)/2} \left(t + \frac{b-a}{2}\right) t^2 \left(t - \frac{b-a}{2}\right) dt \\
 &= \int_{-(b-a)/2}^{(b-a)/2} t^2 \left(t^2 - \frac{(b-a)^2}{4}\right) dt = -\frac{(b-a)^5}{120}.
 \end{aligned}$$

Окончательно

$$|\Psi| \leq \frac{M_4 (b-a)^5}{2880}.$$

Как видим, более тонкие рассуждения позволили получить действительно более точную оценку погрешности.

2.6в Дальнейшие формулы Ньютона-Котеса

Из других формул квадратурных формул Ньютона-Котеса отметим формулу «трёх восьмых»

$$\int_a^b f(x) dx \approx \frac{b-a}{8} \cdot \left(f(a) + 3f\left(\frac{2a+b}{3}\right) + 3f\left(\frac{a+2b}{3}\right) + f(b) \right), \quad (2.52)$$

погрешность которой оценивается как

$$|\Psi| \leq \frac{M_4 (b-a)^5}{6480}.$$

Можно показать, что формулы Ньютона-Котеса с нечётным числом узлов, один из узлов которых приходится на середину интервала интегрирования, имеют (как формула Симпсона) повышенный порядок точности.

Формулы Ньютона-Котеса высоких порядков не очень употребительны, так как они проигрывают по точности формулам Гаусса (изучаемым далее в §§2.6ж–2.6з) и другим квадратурным формулам. Кроме того, среди весов формул Ньютона-Котеса при $n = 8, 10$ и больших значениях n встречаются отрицательные, что снижает ценность соответствующих формул.

2.6г Общие интерполяционные квадратурные формулы

Квадратурные формулы интерполяционного типа были определены как формулы, получающиеся в результате замены подынтегральной функции $f(x)$ интерполяционным полиномом $P_n(x)$. Выпишем его в форме Лагранжа

$$P_n(x) = \sum_{i=0}^n f(x_i) \phi_i(x),$$

где

$$\phi_i(x) = \frac{\omega_n(x)}{(x - x_i) \omega'_n(x_i)},$$

— базисные полиномы Лагранжа (стр. 29), а функция $\omega_n(x)$ определена в (2.7):

$$\omega_n(x) = (x - x_0)(x - x_1) \cdots (x - x_n).$$

Тогда коэффициенты квадратурной формулы (2.47) должны иметь вид

$$c_i = \int_a^b \phi_i(x) dx = \int_a^b \frac{\omega_n(x)}{(x - x_i) \omega'_n(x_i)} dx, \quad i = 0, 1, \dots, n, \quad (2.53)$$

и эти значения весов c_i , определяемых по узлам $x_0, x_1, \dots, x_n$, является характеристическим признаком интерполяционной квадратурной формулы.

Погрешность квадратурной формулы будет при этом равна

$$\Psi = \int_a^b R_n(f, x) dx,$$

где $R_n(f, x)$ — остаточный член интерполяционной формулы. В §2.1д была получена оценка для $R_n(f, x)$ в виде (2.14)

$$R_n(f, x) = \frac{f^{(n+1)}(\xi(x))}{(n+1)!} \cdot \omega_n(x),$$

где $\xi(x) \in [a, b]$, и поэтому

$$\Psi = \frac{1}{(n+1)!} \int_a^b f^{(n+1)}(\xi(x)) \omega_n(x) dx.$$

В целом справедлива оценка

$$|\Psi| \leq \frac{M_{n+1}}{(n+1)!} \int_a^b |\omega_n(x)| dx,$$

где $M_{n+1} = \max_{x \in [a,b]} |f^{(n+1)}(x)|$. Из неё можно ещё раз заключить, что квадратурная формула интерполяционного типа, построенная по $(n+1)$ узлу, является точной для любого полинома степени не более n .

Верно и обратное утверждение: если квадратурная формула (2.47), построенная по $(n+1)$ узлу, является точной для любого полинома степени не выше n , то она является квадратурной формулой интерполяционного типа, и потому её веса (коэффициенты) вычисляются по формулам (2.53).

В самом деле, для базисных интерполяционных полиномов $\phi_i(x)$ выполнено свойство (2.5)

$$\phi_i(x_j) = \delta_{ij} = \begin{cases} 0, & \text{при } i \neq j, \\ 1, & \text{при } i = j, \end{cases}$$

и они имеют степень n . Следовательно, получаем

$$\int_a^b \phi_i(x) dx = \sum_{k=0}^n c_k \phi_i(x_k) = \sum_{l=0}^n c_k \delta_{ik} = c_i,$$

т. е. имеет место равенство (2.53), что и требовалось доказать.

Итак, нами обоснована

Теорема 2.6.1 *Для того, чтобы квадратурная формула (2.47), построенная по $(n+1)$ попарно различному узлу, была интерполяционной, необходимо и достаточно, чтобы она являлась точной на полиномах степени n .*

Отметим, что при этом квадратурная формула может быть более точной также и для полиномов степени выше n , как, например, формула Симпсона.

2.6д Сходимость квадратур

С теоретической точки зрения весьма важен вопрос о сходимости квадратур при неограниченном возрастании числа узлов. Похожий вопрос

вставал при исследовании о сходимости интерполяционного процесса, и мы обсуждали его в §2.13. Но в случае квадратурных формул помимо бесконечной треугольной матрицы узлов

$$\begin{pmatrix} x_0^{(1)} & & & \cdots \\ x_0^{(2)} & x_1^{(2)} & & 0 & \cdots \\ x_0^{(3)} & x_1^{(3)} & x_2^{(3)} & & \cdots \\ \vdots & \vdots & \vdots & \ddots & \ddots \end{pmatrix}, \quad (2.54)$$

таких что $x_k^{(n)}$ лежат на интервале интегрирования $[a, b]$, необходимо задавать ещё и треугольную матрицу весовых коэффициентов квадратурных формул

$$\begin{pmatrix} c_0^{(1)} & & & \cdots \\ c_0^{(2)} & c_1^{(2)} & & 0 & \cdots \\ c_0^{(3)} & c_1^{(3)} & c_2^{(3)} & & \cdots \\ \vdots & \vdots & \vdots & \ddots & \ddots \end{pmatrix}. \quad (2.55)$$

Определение 2.6.1 Будем говорить, что квадратурный процесс, задаваемый зависящим от натурального параметра n семейством квадратурных формул

$$\int_a^b f(x) dx \approx \sum_{k=0}^n c_k^{(n)} f(x_k^{(n)}), \quad n = 0, 1, 2, \dots,$$

которые определяются матрицами узлов (2.54) и весов (2.55), сходится для функции $f(x)$ на интервале $[a, b]$, если

$$\lim_{n \rightarrow \infty} \sum_{k=0}^n c_k^{(n)} f(x_k^{(n)}) = \int_a^b f(x) dx,$$

т. е. если при неограниченном возрастании n предел результатов квадратурных формул равен точному интегралу.

Весьма общие достаточные условия для сходимости квадратур были сформулированы и обоснованы В.А.Стекловым [47], а впоследствии Д. Поля [48] доказал также необходимость условий Стеклова.

Теорема 2.6.2 (теорема Стеклова-Пойа) *Для того, чтобы квадратурный процесс, порождаемый матрицами узлов (2.54) и весов (2.55) сходился для непрерывной на $[a, b]$ функции, необходимо и достаточно, чтобы*

- (1) *этот процесс сходился для полиномов,*
- (2) *суммы абсолютных значений весов были равномерно по n ограничены, т. е. существовала такая константа C , что*

$$\sum_{k=0}^n |c_k^{(n)}| \leq C \quad (2.56)$$

для всех $n = 0, 1, 2, \dots$

Покажем достаточность условий теоремы Стеклова-Пойа. С этой целью, задавшись каким-то $\epsilon > 0$, найдём полином $P_N(x)$, который равномерно с точностью ϵ приближает непрерывную подынтегральную функцию $f(x)$ на рассматриваемом интервале $[a, b]$. Существование такого полинома обеспечивается теоремой Вейерштрасса (см. §2.13). Далее преобразуем выражение для остаточного члена квадратурной формулы:

$$\begin{aligned} R_n(f) &= \int_a^b f(x) dx - \sum_{k=0}^n c_k^{(n)} f(x_k^{(n)}) \\ &= \int_a^b (f(x) - P_N(x)) dx + \int_a^b P_N(x) dx - \sum_{k=0}^n c_k^{(n)} f(x_k^{(n)}) \\ &= \int_a^b (f(x) - P_N(x)) dx \\ &\quad + \left(\int_a^b P_N(x) dx - \sum_{k=0}^n c_k^{(n)} P_N(x_k^{(n)}) \right) \\ &\quad + \sum_{k=0}^n c_k^{(n)} \left(P_N(x_k^{(n)}) - f(x_k^{(n)}) \right) \end{aligned}$$

Отдельные слагаемые полученной суммы оцениваются следующим образом:

$$\left| \int_a^b (f(x) - P_N(x)) \, dx \right| \leq \epsilon (b - a),$$

$$\left| \int_a^b P_N(x) \, dx - \sum_{k=0}^n c_k^{(n)} P_N(x_k^{(n)}) \right| \leq \epsilon,$$

так как квадратурный процесс сходится на полиномах,

$$\left| \sum_{k=0}^n c_k^{(n)} (P_N(x_k^{(n)}) - f(x_k^{(n)})) \right| \leq \epsilon \sum_{k=0}^n |c_k^{(n)}|.$$

Поэтому в целом для достаточно больших значений n имеем

$$|R_n(x)| \leq \epsilon (b - a + C + 1),$$

откуда и следует сходимость рассматриваемого квадратурного процесса.

Доказательство необходимости условия теоремы Стеклова-Пойа можно найти помимо оригинальной статьи [48] также в книге [29].

В формулировке теоремы фигурирует величина

$$\sum_{k=0}^n |c_k|,$$

— сумма абсолютных значений весов, которая играет очень важную роль при оценке качества различных квадратурных формул, будучи коэффициентом увеличения погрешности в данных.

2.6e Составные квадратурные формулы

Рассмотренные выше квадратурные формулы дают приемлемую погрешность при небольших длинах интервала интегрирования $[a, b]$ в случае, когда подынтегральная функция не претерпевает сильных и резких изменений. Но если величина $(b - a)$ относительно велика или интегрируемая функция имеет большие производные, то погрешность

вычисления интеграла делается значительной или даже большой. Тогда для получения требуемой точности вычисления интеграла применяют *составные квадратурные формулы*, основанные на разбиении интервала интегрирования на подынтервалы меньшей длины, по каждому из которых вычисляется значение «элементарной квадратуры», а затем искомый интеграл приближается их суммой.⁵

Будем считать, что погрешность Ψ используемой квадратурной формулы имеет оценку

$$|\Psi| \leq C(b-a)^p,$$

где C — константа, зависящая от типа квадратурной формулы и интегрируемой функции, причём в любом случае $p > 1$. К примеру, для формулы средних прямоугольников $C = M_2/24$ и $p = 3$, а для формулы Симпсона $C = M_4/2880$ и $p = 5$. Если интервал интегрирования разбит точками $r_1, r_2, \dots, r_{N-1}$ на N равных частей $[a, r_1], [r_1, r_2], \dots, [r_{N-1}, b]$ длины $h = (b-a)/N$, то можно вычислить по рассматриваемой формуле интегралы

$$\int_{r_i}^{r_{i+1}} f(x) dx, \quad i = 0, 1, \dots, N-1,$$

где $r_0 = a$, $b = r_N$, а затем положить

$$\int_a^b f(x) dx \approx \sum_{i=0}^{N-1} \int_{r_i}^{r_{i+1}} f(x) dx. \quad (2.57)$$

Тогда на каждом подынтервале

$$|\Psi| \leq C \left(\frac{b-a}{N} \right)^p = Ch^p,$$

а полная погрешность интегрирования при использовании представления (2.57) есть такая величина $\tilde{\Psi}$, что

$$|\tilde{\Psi}| \leq CN \left(\frac{b-a}{N} \right)^p = C \frac{(b-a)^p}{N^{p-1}} = C(b-a)h^{p-1}.$$

Как видим, эта погрешность уменьшилась в N^{p-1} раз, и потенциально таким способом погрешность вычисления интеграла можно сделать сколь угодно малой.

⁵Интересно, что при этом подынтегральная функция интерполируется на всём интервале интегрирования $[a, b]$ при помощи сплайна.




Рис. 2.16. Составная квадратурная формула трапеций

Число $(p-1)$ часто называют *порядком точности* (составной) квадратурной формулы. Ясно, что основная идея составных квадратурных формул работает и в случае неравномерного разбиения интервала интегрирования на более мелкие части, но анализ погрешности проводить тогда труднее.

Для равномерного разбиения интервала интегрирования составные квадратурные формулы выглядят особенно просто. Выпишем их явный вид для рассмотренных выше простейших квадратур Ньютона-Котеса и равномерного разбиения интервала интегрирования $[a, b]$ на N равных частей длины h каждая.

Составная формула прямоугольников

$$\int_a^b f(x) dx \approx h \sum_{i=1}^N f(r_{i-1/2}).$$

где $r_{i-1/2} = r_i - h/2$. Её полная погрешность

$$|\tilde{\Psi}| \leq M_2 \frac{(b-a)h^2}{24},$$

т. е. она имеет второй порядок точности.

Составная формула трапеций

$$\int_a^b f(x) dx \approx h \left(\frac{1}{2} f(a) + \sum_{i=1}^{N-1} f(r_i) + \frac{1}{2} f(b) \right).$$

Её полная погрешность

$$|\tilde{\Psi}| \leq M_2 \frac{(b-a)h^2}{12},$$

т. е. порядок точности тоже второй.

Составная формула Симпсона

$$\int_a^b f(x) dx \approx \frac{h}{6} \sum_{i=1}^N (f(r_{i-1}) + 4f(r_{i-1/2}) + f(r_i)),$$

где $r_{i-1/2} = r_i - h/2$. Её полная погрешность

$$|\tilde{\Psi}| \leq M_4 \frac{(b-a)h^4}{2880},$$

т. е. формула имеет четвёртый порядок точности.

Как видим, при использовании составных квадратурных формул увеличение точности вычисления интеграла достигается ценой дополнительных трудозатрат. В рассматриваемом нами одномерном случае эти трудозатраты растут всего лишь линейно, хотя и здесь необходимость вычисления сложной подынтегральной функции может иногда быть обременительной. Но при возрастании размерности интеграла, когда необходимо прибегнуть к составным кубатурным формулам, рост трудозатрат делается уже значительным, имея тот же порядок, что и размерность пространства. Так же растёт и погрешность суммирования результатов интегрирования по отдельным подобластям общей области интегрирования. Поэтому и эффект увеличения точности составной формулы при возрастании размерности становится всё менее ощутимым.

2.6ж Квадратурные формулы Гаусса

Параметрами квадратурной формулы (2.47)

$$\int_a^b f(x) dx \approx \sum_{k=0}^n c_k f(x_k)$$

являются узлы x_k и веса (коэффициенты) c_k . Однако, строя квадратурные формулы Ньютона-Котеса, в частности, формулу трапеций и

формулу Симпсона, мы заранее задавали положение узлов и по ним находили веса. Таким образом, возможности общей формулы (2.47) были использованы не полностью, так как для достижения наилучших результатов можно было бы управлять положением её узлов. Только в формуле прямоугольников положение единственного узла было выбрано из соображений симметрии, и это привело к существенному улучшению точности.

Здесь, правда, возникает весьма важный методический вопрос: как измерять это «улучшение» квадратурной формулы? Что брать критерием её точности? В идеальном случае желательно было бы минимизировать погрешность квадратурной формулы для тех или иных классов функций, но в такой общей постановке задача делается сложной (хотя и не неразрешимой).

Один из естественных ответов на этот вопрос состоит в том, чтобы в качестве меры точности квадратурной формулы брать степень полиномов, на которых она даёт точные результаты.

Определение 2.6.2 Алгебраической степенью точности квадратурной формулы называют наибольшую степень алгебраических полиномов, для которых эта квадратурная формула является точной.

Как следствие, сформулированную в начале пункта задачу оптимизации узлов можно переформулировать следующим образом: для заданного фиксированного числа узлов из интервала интегрирования нужно построить квадратурную формулу, которая имеет наивысшую алгебраическую степень точности, т. е. является точной на полиномах наиболее высокой степени. Удовлетворяющие поставленному требованию формулы действительно существуют и называются *квадратурными формулами Гаусса*, поскольку впервые были рассмотрены в начале XIX века К.Ф. Гауссом.

Далее для удобства мы будем записывать квадратурные формулы Гаусса не в виде (2.47), а как

$$\int_a^b f(x) dx \approx \sum_{k=1}^n c_k f(x_k), \quad (2.58)$$

нумеруя узлы с $k = 1$, а не с нуля. Требование точного равенства для любого полинома степени m в этой формуле равносильно в силу её линейности тому, что формула является точной для одночленов $f(x) =$

x^l , $l = 0, 1, 2, \dots, m$, т. е.

$$\int_a^b x^l dx = \sum_{k=1}^n c_k x_k^l, \quad l = 0, 1, 2, \dots, m. \quad (2.59)$$

Это система из $(m+1)$ нелинейных уравнений с $2n$ неизвестными величинами $c_1, c_2, \dots, c_n, x_1, x_2, \dots, x_n$. Число уравнений совпадает с числом неизвестных при $m+1 = 2n$, т. е. $m = 2n-1$, и это в общем случае есть максимальное возможное значение для m , так как при больших значениях m получающаяся система уравнений переопределена и, скорее всего, окажется неразрешимой.

Итак, наивысшая алгебраическая степень точности квадратурной формулы, построенной по n узлам, в общем случае может быть равна $2n-1$. Для двух узлов это 3, при трёх узлах имеем 5, и т. д. Для сравнения напомним, что алгебраическая точность формул трапеций и Симпсона, построенных по двум и трём узлам соответственно, равна всего 1 и 3. При возрастании числа узлов этот выигрыш в алгебраической степени точности формул Гаусса, достигнутый за счёт разумного расположения узлов, нарастает.

При небольших n система уравнений (2.59) может быть решена с помощью несложных аналитических преобразований.

Пусть $n = 1$, тогда система уравнений (2.59) принимает вид

$$\begin{cases} c_1 = b - a, \\ c_1 x_1 = \frac{1}{2}(b^2 - a^2). \end{cases}$$

Отсюда

$$\begin{aligned} c_1 &= b - a, \\ x_1 &= \frac{1}{2c_1}(b^2 - a^2) = \frac{1}{2}(a + b). \end{aligned}$$

Как легко видеть, получающаяся квадратурная формула — это формула (средних) прямоугольников

$$\int_a^b f(x) dx \approx (b - a) \cdot f\left(\frac{a + b}{2}\right).$$

Действительно, нам известно, что она резко выделяется своей точностью среди родственных квадратурных формул.

Пусть $n = 2$, тогда алгебраическая степень точности $m = 2n - 1 = 3$. Система уравнений (2.59) для узлов и весов принимает вид

$$\begin{cases} c_1 + c_2 = b - a, \\ c_1 x_1 + c_2 x_2 = \frac{1}{2}(b^2 - a^2), \\ c_1 x_1^2 + c_2 x_2^2 = \frac{1}{3}(b^3 - a^3), \\ c_1 x_1^3 + c_2 x_2^3 = \frac{1}{4}(b^4 - a^4). \end{cases}$$

Пользуясь симметричностью этой системы уравнений можно положить $c_1 = c_2$, что даёт

$$c_1 = c_2 = \frac{1}{2}(b - a),$$

а из первого и второго уравнений позволяет получить

$$x_1 + x_2 = a + b. \quad (2.60)$$

В то же время из первого и третьего уравнений следует

$$x_1^2 + x_2^2 = \frac{2}{3}(b^2 + ab + b^2). \quad (2.61)$$

Возводя (2.60) в квадрат и вычитая из результата уравнение (2.61), будем иметь

$$x_1 x_2 = \frac{1}{6}(b^2 + 4ba + a^2). \quad (2.62)$$

Соотношения (2.60) и (2.62) на основе теоремы Виета позволяют сделать вывод, что x_1 и x_2 являются корнями квадратного уравнения

$$x^2 - (a + b)x + \frac{1}{6}(b^2 + 4ba + a^2) = 0,$$

так что

$$x_{1,2} = \frac{1}{2}(a + b) \pm \frac{\sqrt{3}}{6}(b - a). \quad (2.63)$$

Удовлетворение полученными решениями четвёртого уравнения системы проверяется прямой подстановкой. В целом мы получили квадратурную формулу Гаусса

$$\int_a^b f(x) dx = \frac{b - a}{2} \cdot (f(x_1) + f(x_2)), \quad (2.64)$$

где узлы x_1 и x_2 определяются из формулы (2.63).

Пример 2.6.1 Вычислим по выведенной выше формуле Гаусса с двумя узлами интеграл

$$\int_0^{\pi/2} \cos x \, dx,$$

точное значение которого равно 1. Согласно (2.63) и (2.64) имеем

$$\begin{aligned} \int_0^{\pi/2} \cos x \, dx &\approx \frac{\pi/2}{2} \cdot \left(\cos\left(\frac{\pi}{4} - \frac{\sqrt{3}}{6} \frac{\pi}{2}\right) + \cos\left(\frac{\pi}{4} + \frac{\sqrt{3}}{6} \frac{\pi}{2}\right) \right) \\ &= 0.998473. \end{aligned}$$

Формула Ньютона-Котеса с двумя узлами 0 и $\pi/2$ — формула трапеций — даёт для этого интеграла значение

$$\int_0^{\pi/2} \cos x \, dx \approx \frac{\pi}{2} \cdot \left(\cos 0 + \cos \frac{\pi}{2} \right) = 0.785398,$$

точность которого весьма низка.

Чтобы получить с формулами Ньютона-Котеса точность вычисления рассматриваемого интеграла, сравнимую с той, что даёт формула Гаусса, приходится брать больше узлов. Так, формула Симпсона (2.48), использующая три узла — 0, $\pi/4$ и $\pi/2$, — приводит к результату

$$\begin{aligned} \int_0^{\pi/2} \cos x \, dx &\approx \frac{\pi/2}{6} \cdot \left(\cos 0 + 4 \cos \frac{\pi}{4} + \cos \frac{\pi}{2} \right) \\ &= \frac{\pi}{12} (1 + 2\sqrt{2}) = 1.00228, \end{aligned}$$

погрешность которого по порядку величины примерно равна погрешности ответа по формуле Гаусса (2.64), но всё-таки превосходит её в полтора раза. ■

С ростом n сложность системы уравнений (2.59) для узлов и весов быстро нарастает, так что в общем случае остаётся неясным, будет ли разрешима эта система (2.59) при любом наперёд заданном n . Будут ли у неё вещественные решения? Будут ли эти решения принадлежать интервалу $[a, b]$, чтобы служить удобными узлами квадратурной формулы?

Получение ответов на эти вопросы непосредственно из системы уравнений (2.59) представляется громоздким и малоперспективным. Обычно следуют другим путём, расчленив получившуюся задачу на отдельные подзадачи

- 1) исследования выбора узлов и
- 2) построения весов по формулам (2.53), путём интегрирования коэффициентов интерполяционного полинома Лагранжа.

В последнем случае мы пользуемся тем фактом, что конструируемая квадратурная формула Гаусса оказывается квадратурной формулой интерполяционного типа. Это прямо следует из Теоремы 2.6.1.

2.63 Выбор узлов для квадратурных формул Гаусса

Теорема 2.6.3 *Квадратурная формула (2.58)*

$$\int_a^b f(x) dx \approx \sum_{k=1}^n c_k f(x_k)$$

точна на полиномах степени $(2n - 1)$ тогда и только тогда, когда

- 1) формула (2.58) является формулой интерполяционного типа;
- 2) её узлы $x_1, x_2, \dots, x_n$ являются корнями такого полинома

$$\omega(x) = (x - x_1)(x - x_2) \cdots (x - x_n),$$

что

$$\int_a^b \omega(x) q(x) dx = 0$$

для любого полинома $q(x)$ степени не выше $(n - 1)$.

Выражение

$$\int_a^b \omega(x) q(x) dx$$

— интеграл от произведения двух функций, уже встречались нам в §2.5б. Мы могли видеть в §2.5б, что на пространстве $\mathcal{L}_2[a, b]$ всех интегрируемых с квадратом функций оно задаёт *скалярное произведение*, т. е. симметричную билинейную форму. По этой причине утверждение

Теоремы 2.6.3 часто формулируют так: для того, чтобы квадратурная формула

$$\int_a^b f(x) dx \approx \sum_{k=1}^n c_k f(x_k)$$

была точна на полиномах степени $(2n - 1)$, необходимо и достаточно, чтобы эта формула имела интерполяционный тип, а её узлы $x_1, x_2, \dots, x_n$ были корнями полинома $\omega(x)$, который ортогонален на $[a, b]$ любому полиному $q(x)$ степени не выше $(n - 1)$.

Доказательство. Необходимость. Пусть рассматриваемая квадратурная формула точна на полиномах степени $(2n - 1)$. Таковым является, в частности, полином $\omega(x)q(x)$, имеющий степень $n + (n - 1)$. Тогда

$$\int_a^b \omega(x) q(x) dx = \sum_{k=1}^n c_k \omega(x_k) q(x_k) = 0,$$

поскольку все $\omega(x_k) = 0$. И это соотношение верно для любого полинома $q(x)$ степени не выше $n - 1$.

Справедливость условия 1) следует из того доказанного в §2.6г факта, что если квадратурная формула (2.58) является точной для любого полинома степени не выше $n - 1$, то она является квадратурной формулой интерполяционного типа.

Достаточность. Пусть имеется полином $\omega(x)$ степени n , имеющий n различных корней на интервале $[a, b]$ и удовлетворяющий условию ортогональности с любым полиномом $q(x)$ степени не выше $(n - 1)$. Покажем, что интерполяционная квадратурная формула, построенная по узлам $x_1, x_2, \dots, x_n$, которые являются корнями $\omega(x)$, будет точна на полиномах степени $2n - 1$.

Пусть $f(x)$ — произвольный полином степени $2n - 1$. Тогда после деления его на $\omega(x)$ получим представление

$$f(x) = \omega(x) q(x) + r(x),$$

где $q(x)$ и $r(x)$ — соответственно частное и остаток от деления $f(x)$ на $\omega(x)$. При этом оба полинома $q(x)$ и $r(x)$ имеют степени меньше n . Отсюда

$$\int_a^b f(x) dx = \int_a^b \omega(x) q(x) dx + \int_a^b r(x) dx = \int_a^b r(x) dx,$$

в силу сделанного нами предположения об ортогональности $\omega(x)$ всем полиномам степени не выше $n - 1$.

Но рассматриваемая квадратурная формула имеет интерполяционный тип и построена по n узлам, и потому она является точной на полиномах степени не выше $n - 1$, в частности на полиноме $r(x)$. Следовательно,

$$\int_a^b r(x) dx = \sum_{k=1}^n c_k r(x_k) = \sum_{k=1}^n c_k (f(x_k) - \omega(x_k) q(x_k)) = \sum_{k=1}^n c_k f(x_k),$$

коль скоро $\omega(x_k) = 0$. Итак,

$$\int_a^b f(x) dx = \sum_{k=1}^n c_k f(x_k),$$

т.е. исследуемая квадратурная формула действительно является точной на полиномах степени $2n - 1$. ■

Подведём промежуточные итоги. Процедура построения квадратурных формул Гаусса разделена нами на две отдельные задачи нахождения узлов и вычисления весов. В свою очередь, узлы квадратурной формулы, как выясняется, можно взять корнями некоторых специальных полиномов $\omega(x)$ из формулировки Теоремы 2.6.3. В этих полиномах легко угадываются знакомые нам с §2.5 ортогональные полиномы, являющиеся полиномами Лежандра для $[a, b] = [-1, 1]$, и соответствующим образом преобразованные для произвольного интервала интегрирования $[a, b]$.

Обращаясь к построению квадратурных формул Гаусса, отметим, что отдельное нахождение их узлов и весов для каждого конкретного интервала интегрирования $[a, b]$ является весьма трудозатратным, и если бы нам нужно было проделывать эту процедуру всякий раз при смене интервала $[a, b]$, то практическое применение формул Гаусса значительно потеряло бы свою привлекательность. Естественная идея состоит в том, чтобы в этой ситуации воспользоваться формулой замены переменных в определённом интеграле

$$\int_a^b f(x) dx = \int_\alpha^\beta f(\varphi(y)) \varphi'(y) dy \quad (2.65)$$

для $a = \varphi(\alpha)$, $b = \varphi(\beta)$, и свести задачу вычисления определённого интеграла от $f(x)$ по $[a, b]$ к задаче вычисления интеграла по некоторому

«каноническому» интервалу. В качестве такового обычно берут $[-1, 1]$, т. е. тот интервал, для которого строятся ортогональные полиномы Лежандра. Но при замене переменных не должно портиться свойство ортогональности полиномов, требуемое Теоремой 2.6.3. Нетрудно понять, что это условие будет соблюдено при простейшей линейной замене переменных, когда $\varphi' = \text{const}$. Именно, если

$$x = \frac{1}{2}(a+b) + \frac{1}{2}(b-a)y,$$

то переменная x пробегает интервал $[a, b]$, если $y \in [-1, 1]$. Обратное преобразование даётся формулой

$$y = \frac{1}{b-a}(2x - (a+b)).$$

В частности, если y_k , $k = 0, 1, \dots, n$, — корни полинома Лежандра, лежащие на интервале $[-1, 1]$, то узлы нашей квадратурной формулы на интервале интегрирования $[a, b]$ суть $x_k = \frac{1}{2}(a+b) + \frac{1}{2}(b-a)y_k$.

Наконец, веса c_k любой интерполяционной квадратурной формулы выражаются в виде интегралов (2.53), которые в случае формул Гаусса (когда узлы нумеруются с единицы), принимают вид

$$c_k = \int_a^b \phi_k(x) dx, \quad k = 1, 2, \dots, n,$$

где $\phi_k(x)$ — базисный полином Лагранжа (стр. 29). Тогда в силу формулы замены переменных (2.65)

$$c_k = \int_a^b \phi_k(x) dx = \frac{1}{2}(b-a) \int_{-1}^1 \phi(y) dy,$$

$k = 0, 1, \dots, n$, коль скоро

$$dx = d\left(\frac{1}{2}(a+b) + \frac{1}{2}(b-a)y\right) = \frac{1}{2}(b-a) dy.$$

Получается, что веса квадратурной формулы Гаусса для произвольного интервала интегрирования $[a, b]$ вычисляются простым умножением весов для канонического интервала $[-1, 1]$ на множитель $\frac{1}{2}(b-a)$.

Для интервала $[-1, 1]$ узлы квадратурных формул Гаусса (т. е. корни полиномов Лежандра) и веса тщательно затабулированы для первых натуральных чисел n , и их конкретные значения могут быть найдены, к примеру, в подробных руководствах по численным методам

[3, 5, 11, 19, 44] или в специальных справочниках, например, в [21]. В частности, в [5] значения весов и узлов формул Гаусса приведены для небольших n с 16 значащими цифрами, а в справочнике [21] — с 15 значащими цифрами вплоть до $n = 48$. Таким образом, практическое применение квадратур Гаусса обычно не встречает затруднений.

Приведём для примера квадратурную формулу Гаусса для трёх узлов и интервала $[-1, 1]$:

$$\int_{-1}^1 f(x) \, dx \approx \frac{5}{9} f(x_1) + \frac{8}{9} f(x_2) + \frac{5}{9} f(x_3),$$

$$x_{1,3} = \mp 0.774596669240, \quad x_2 = 0.$$

Погрешность квадратурной формулы Гаусса, построенной по n узлам $x_1, x_2, \dots, x_n \in [a, b]$ может быть оценена по *формуле Маркова*

$$\Psi(f) = \frac{f^{(2n)}(\xi)}{(2n)!} \int_a^b (\omega(x))^2 \, dx,$$

где $\xi \in]a, b[$, $\omega(x) = (x - x_1)(x - x_2) \cdots (x - x_n)$. Её доказательство несложно и может быть найдено, например, в [44, 29]. Из формулы Маркова следует, что формулы Гаусса с большим числом узлов целесообразно применять лишь для достаточно гладких функций.

В заключение темы отметим, что на практике нередко требуется включение во множество узлов квадратурной формулы каких-либо фиксированных точек интервала интегрирования, например, его концов (одного или обоих), либо каких-то выделенных внутренних точек. Основная идея формул Гаусса может быть применена и в этом случае, что приводит к *квадратурам Маркова*.

Построение квадратурных формул Гаусса основывалось на оптимизации алгебраического порядка точности квадратур. Эта идея может быть модифицирована и приспособлена к другим ситуациям, когда алгебраические полиномы и их степень уже не являются наиболее адекватным мериллом точности квадратурной формулы. Например, можно развивать квадратуры наивысшего *тригонометрического порядка точности*, которые окажутся практичнее при вычислении интегралов от осциллирующих функций [44].

2.7 Правило Рунге для оценки погрешности

Предположим, что нам необходимо численно найти интеграл или производную функции, либо найти решение дифференциального или интегрального уравнения, т. е. какой-либо задачи, где фигурирует сетка на некотором интервале вещественной оси. Пусть для решения этой задачи имеется численный метод порядка p , так то его погрешность равна Ch^p , где h — шаг рассматриваемой сетки, а C — величина, напрямую от h не зависящая. Как правило, значение C не известно точно и его нахождение непосредственно из задачи является делом трудным и малоперспективным. Мы могли видеть, к примеру, что для задачи численного интегрирования выражение для этой константы вовлекает оценки для производных высоких порядков от подынтегральной функции. Во многих случаях их практическое вычисление не представляется возможным, так что оценки эти носят, главным образом, теоретический характер.

К. Рунге принадлежит идея использовать для определения значения C результаты нескольких расчётов на различных сетках. Далее, после того как величина C будет определена, мы можем использовать её значение для практической оценки погрешности приближённых решений нашей задачи, которые получаются с помощью численного метода.

Предположим для простоты анализа, что численные решения рассматриваемой задачи рассчитаны на сетках с шагом h и $h/2$ и равны соответственно J_h и $J_{h/2}$, а точное решение есть J . Тогда

$$\begin{aligned} J_h - J &= Ch^p, \\ J_{h/2} - J &= C \left(\frac{h}{2} \right)^p = C \frac{h^p}{2^p}. \end{aligned}$$

Вычитая второе равенство из первого, получим

$$J_h - J_{h/2} = Ch^p - C \frac{h^p}{2^p} = Ch^p \frac{2^p - 1}{2^p},$$

так что

$$C = \frac{2^p}{2^p - 1} \cdot \frac{J_h - J_{h/2}}{h^p}.$$

Зная константу C , можно уже находить оценку погрешности рассчитанных решений J_h , $J_{h/2}$ или любых других

Литература к Главе 2

Основная

- [1] БАРАХНИН В.Б., ШАПЕЕВ В.П. *Введение в численный анализ*. – Санкт-Петербург–Москва– Краснодар: Лань, 2005.
- [2] БАБЕНКО К.И. *Основы численного анализа*. – Москва: Наука, 1986.
- [3] БАХВАЛОВ Н.С., ЖИДКОВ Н.П., КОБЕЛЬКОВ Г.М. *Численные методы*. – Москва: Бином, 2003, а также другие издания этой книги.
- [4] БАХВАЛОВ Н.С., КОРНЕВ А.А., ЧИЖОНКОВ Е.В. *Численные методы. Решения задач и упражнения*. – Москва: Дрофа, 2008.
- [5] БЕРЕЗИН И.С., ЖИДКОВ Н.П. *Методы вычислений. Т. 1–2*. – Москва: Наука, 1966.
- [6] ВЕРЖБИЦКИЙ В.М. *Численные методы. Части 1–2*. – Москва: «Оникс 21 век», 2005.
- [7] ВОЛКОВ Е.А. *Численные методы*. – Москва: Наука, 1987.
- [8] ГЕЛЬФОНД А.О. *Исчисление конечных разностей*. – Москва: Наука, 1967.
- [9] ГОНЧАРОВ В.Л. *Теория интерполирования и приближения функций*. – Москва: ГИТТЛ, 1954.
- [10] ДАУГАВЕТ И.К. *Введение в теорию приближения функций*. – Ленинград: Издательство Ленинградского университета, 1977.
- [11] ДЕМИДОВИЧ Б.П., МАРОН А.А. *Основы вычислительной математики*. – Москва: Наука, 1970.
- [12] ЗАВЬЯЛОВ Ю.С., КВАСОВ Б.И., МИРОШНИЧЕНКО В.Л. *Методы сплайн-функций*. – Москва: Наука, 1980.
- [13] КАЛИТКИН Н.Н. *Численные методы*. – Москва: Наука, 1978.
- [14] КАНТОРОВИЧ Л.В., АКИЛОВ Г.П. *Функциональный анализ*. – Москва: Наука, 1984.
- [15] КОВКОВ В.В., ШОКИН Ю.И. *Сплайн-функции в численном анализе*. – Новосибирск: Издательство НГУ, 1983.
- [16] КОЛЛАТЦ Л. *Функциональный анализ и вычислительная математика*. – Москва: Мир, 1969.
- [17] КОСТРИКИН А.Н. *Введение в алгебру. Часть 1. Основы алгебры*. – Москва: Физматлит, 2001.
- [18] КРОНРОД А.С. *Узлы и веса квадратурных формул*. – Москва: Наука, 1964.
- [19] КРЫЛОВ А.Н. *Лекции о приближённых вычислениях*. – Москва: ГИТТЛ, 1954, а также более ранние издания.
- [20] КРЫЛОВ В.И., БОВКОВ В.В., МОНАСТЫРНЫЙ П.И. *Вычислительные методы. Т. 1–2*. – Москва: Наука, 1976.
- [21] КРЫЛОВ В.И., ШУЛЬГИНА Л.Т. *Справочная книга по численному интегрированию*. – Москва: Наука, 1966.

- [22] Кунц К.С. Численный анализ. – Киев: Техника, 1964.
- [23] Люстерник Л.А., Червоненкис О.А., Янпольский А.Р. Математический анализ. Вычисление элементарных функций. – Москва: ГИФМЛ, 1963.
- [24] Мак-Кракен Д., Дорн У. Численные методы и программирование на ФОР-ТРАНе. – Москва: Мир, 1977.
- [25] Мацокин А.М. Численный анализ. Вычислительные методы линейной алгебры. Конспекты лекций для преподавания в III семестре ММФ НГУ. – Новосибирск: НГУ, 2009–2010.
- [26] Мацокин А.М., Сорокин С.Б. Численные методы. Часть 1. Численный анализ. – Новосибирск: НГУ, 2006.
- [27] Миньков С.Л., Миньков Л.Л. Основы численных методов. – Томск: Издательство научно-технической литературы, 2005.
- [28] Мысовских И.П. Интерполяционные кубатурные формулы. – Москва: Наука, 1981.
- [29] Натансон И.П. Конструктивная теория функций. – Москва–Ленинград: ГИТТЛ, 1949.
- [30] Никольский С.М. Квадратурные формулы. – Москва: Наука, 1988.
- [31] Ортега Дж., Пул У. Введение в численные методы решения дифференциальных уравнений. – Москва: Наука, 1986.
- [32] Самарский А.А., Гулин А.В. Численные методы. – Москва: Наука, 1989.
- [33] Стефенсен И.Ф. Теория интерполяции. – Москва: Объединённое научно-техническое издательство НКТП СССР, 1935.
- [34] Стечкин С.Б., Субботин Ю.Н. Сплайны в вычислительной математике. – Москва: Наука, 1976.
- [35] Тихонов А.Н., Арсенин В.Я. Методы решения некорректных задач. – Москва: Наука, 1974.
- [36] Тыртышников Е.Е. Методы численного анализа. – Москва: Академия, 2007.
- [37] Фихтенгольц Г.М. Курс дифференциального и интегрального исчисления. Т. 1. – Москва: Наука, 1966.

Дополнительная

- [38] Абрамовиц , Стиган И. Таблицы специальных функций. – Москва: Наука, .
- [39] КАХАНЕР Д., МОУЛЕР К., НЭШ С. Численные методы и программное обеспечение. – Москва: Мир, 1998.
- [40] Квасов Б.И. Методы изогеоетрической аппроксимации сплайнами. – Москва: Физматлит, 2006.
- [41] Меньшиков Г.Г. Локализирующие вычисления. Конспект лекций. – Санкт-Петербург: СПбГУ, Факультет прикладной математики–процессов управления, 2003.

- [42] МИКЕЛАДЗЕ Ш.Е. Численные методы математического анализа. – Москва: ГИТТЛ, 1953.
- [43] МИЛН В.Э. Численный анализ. – Москва: Издательство иностранной литературы, 1951.
- [44] МЫСОВСКИХ И.П. Лекции по методам вычислений. – Санкт-Петербург: Издательство Санкт-Петербургского университета, 1998.
- [45] СЕГЁ Г. Ортогональные многочлены. – Москва: Физматлит, 1962.
- [46] СОБОЛЕВ С.Л. Введение в теорию кубатурных формул. – Москва: Наука, 1974.
- [47] СТЕКЛОВ В.А. О приближённом вычислении определённых интегралов // *Известия Академии Наук*. – 1916. – Т. 10, №6. – С. 169–186.
- [48] POLYA G. Über Konvergenz von Quadraturverfahren // *Mathematische Zeitschrift*. – 1933. – Bd. 37. – S. 264–286.
- [49] АВЕРТН О. *Precise numerical methods using C++*. – San Diego: Academic Press, 1998.
- [50] MOORE R.E., KEARFOTT R.B., CLOUD M. *Introduction to interval analysis*. – Philadelphia: SIAM, 2009.

Глава 3

Численные методы линейной алгебры

3.1 Задачи вычислительной линейной алгебры

3.1a Особенности постановок задач

Численные методы линейной алгебры — это один из классических разделов вычислительной математики, который вычленился даже в отдельное научное направление в середине прошлого века в связи с бурным развитием математических вычислений на ЭВМ. Традиционный, исторически сложившийся список задач вычислительной линейной алгебры по состоянию на 50–60-е годы прошлого века можно найти в капитальной книге Д.К. Фаддеева и В.Н. Фаддеевой, и он включал

- решение систем линейных алгебраических уравнений,
- вычисление определителей матриц,
- нахождение обратной матрицы
- нахождение собственных значений и собственных векторов матриц,

а также многочисленные разновидности этих задач.

Но «всё течёт, всё меняется». По мере развития науки и технологий в фокусе развития вычислительной линейной алгебры оказались новые задачи. Вот как формулирует список важнейших задач в 2001 году американский специалист Дж. Деммель в книге [14]:

- решение систем линейных алгебраических уравнений;
- линейная задача о наименьших квадратах:
найти вектор x , минимизирующий $\langle Ax - b, Ax - b \rangle$
для заданных $m \times n$ -матрицы A и m -вектора b ;
- нахождение собственных значений и собственных векторов матриц;
- нахождение сингулярных чисел и сингулярных векторов матриц.

Постановку последней задачи мы будем обсуждать ниже в §3.16. Вторая задача из этого списка — линейная задача о наименьших квадратах — возникает в связи с решением переопределённых СЛАУ, которые, к примеру, получаются при обработке экспериментальных данных.

С точки зрения классических разделов математики решение выписанных задач не встречает затруднений:

- решение квадратной СЛАУ получается покомпонентно по формуле Крамера, как частное двух определителей;
- для вычисления собственных значений матрицы нужно выписать характеристическое уравнение и найти его корни.

И так далее. Но практическая реализация этих теоретических рецептов наталкивается на почти непреодолимые трудности. К примеру, явная формула для определителя $n \times n$ -матрицы выражает его как сумму $n!$ слагаемых, каждое из которых есть произведение n элементов из разных строк и столбцов матрицы. Раскрытие определителя по этой формуле требует $n!(n-1) + (n-1) \approx n!(n-1)$ арифметических операций, и потому из-за взрывного роста факториала¹ решение СЛАУ по правилу Крамера при $n \approx 20$ –30 делается уже невозможным даже на самых современных ЭВМ.

¹Напомним в этой связи известную в математическом анализе асимптотическую формулу Стирлинга — $n! \approx \sqrt{2\pi n} (n/e)^n$, где $e = 2.7182818 \dots$

Производительность современных ЭВМ принято выражать в так называемых *флопах* (сокращение от английской фразы floating point operation), и 1 флоп — это одна усреднённая арифметическая операция с плавающей точкой в секунду. Для наиболее мощных на сегодняшний день ЭВМ скорость работы измеряется так называемым терафлопами, 10^{12} операций с плавающей точкой в секунду. Для круглого счёта можно даже взять производительность нашего гипотетического компьютера равной 1 петафлоп = 10^{15} операций с плавающей точкой в секунду. Решение на такой вычислительной машине системы линейных алгебраических уравнений размера 30×30 по правилу Крамера потребует примерно

$$30 \text{ компонент решения} \cdot \frac{29 \cdot 30! \text{ операций}}{10^{15} \text{ флоп} \cdot 3600 \frac{\text{сек}}{\text{час}} \cdot 24 \frac{\text{час}}{\text{сутки}} \cdot 365 \text{ суток}}$$

лет, т. е. около $7.3 \cdot 10^{12}$ лет. Для сравнения, возраст Земли в настоящее время оценивается в $4.5 \cdot 10^9$ лет.

Помимо неприемлемой трудоёмкости ещё одной причиной непригодности для реальных вычислений некоторых широко известных алгоритмов из «чистой математики» является сильное влияние на их результаты неизбежных погрешностей счёта (округлений и т.п.). Например, решение СЛАУ по правилу Крамера очень неустойчиво к ошибкам.

3.16 Сингулярные числа и сингулярные векторы матрицы

Для квадратной матрицы A собственные значения λ и собственные векторы x удовлетворяют матричному уравнению

$$Ax = \lambda x$$

Часто эти собственные векторы называют *правыми собственными векторами*, поскольку иногда возникает необходимость рассмотрения *левых собственных векторов* y , таких что

$$y^{\top} A = \mu y^{\top}.$$

Транспонируя это соотношение, получим

$$A^{\top} y = \mu y,$$

т. е. левые собственные векторы матрицы A совпадают с правыми собственными векторами матрицы $A^\top$ (что объясняет редкость самостоятельного использования понятия левого собственного вектора). Кроме того, транспонирование векового уравнения $\det(A - \lambda I) = 0$ приводит к соотношению

$$\det(A^\top - \lambda I) = 0,$$

которое показывает, что $\lambda = \mu$ — собственные значения матриц A и $A^\top$ совпадают. Таким образом, для определения собственных значений матрицы и её левых и правых собственных векторов необходимо решить систему уравнений

$$\begin{cases} Ax = \lambda x, \\ A^\top y = \lambda y, \end{cases} \quad (3.1)$$

или, в матричной форме,

$$\begin{pmatrix} A & 0 \\ 0 & A^\top \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \lambda \begin{pmatrix} x \\ y \end{pmatrix}.$$

Система уравнений (3.1) является «распавшейся»: в ней первые n уравнений и последние n уравнений не зависят друг от друга. Поэтому решать её также можно по частям, что обычно и делают на практике.

Изменим соотношения (3.1), чтобы они «завязались» друг на друга, поменяв в правых частях векторы x и y :

$$\begin{cases} Ax = \sigma y, \\ A^\top y = \sigma x, \end{cases} \quad (3.2)$$

или, в матричной форме,

$$\begin{pmatrix} 0 & A^\top \\ A & 0 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \sigma \begin{pmatrix} x \\ y \end{pmatrix}.$$

Фигурально можно сказать, что при этом векторы x и y становятся «право-левыми» или «лево-правыми» собственными векторами матрицы A . Аналоги собственных чисел матрицы A , которые мы переобозначили через σ , также получают новое содержание.

Определение 3.1.1 Неотрицательные решения σ системы матричных уравнений (3.2) называются сингулярными числами матрицы A . Удовлетворяющие системе (3.2) векторы x называются правыми сингулярными векторами матрицы A , а векторы y — левыми сингулярными векторами A .

Отметим, что это определение имеет смысл уже для произвольных прямоугольных матриц, а не только для квадратных, как было в случае собственных значений и собственных векторов.

Предложение 3.1.1 Сингулярные числа матрицы A суть неотрицательные квадратные корни из собственных чисел матрицы $A^T A$ или матрицы AA^T .

Формулировка этого утверждения требует разъяснений, так как в случае прямоугольной $m \times n$ -матрицы A размеры квадратных матриц $A^T A$ и AA^T различны: первая из них — это $n \times n$ -матрица, а вторая $m \times m$ -матрица. Соответственно, количество собственных чисел у них будет различным.

Из известного неравенства для ранга произведения матриц следует, что если $m < n$, то $n \times n$ -матрица $A^T A$ имеет неполный ранг, не превосходящий m , а потому её собственные числа с $(m + 1)$ -го по n -ое заведомо нулевые. Аналогично, если $m > n$, то $m \times m$ -матрица AA^T также имеет неполный ранг, который не превосходит n , и её собственные числа с $(n + 1)$ -го по m -ое равны нулю. Таким образом, для $m \times n$ -матрицы содержательный смысл имеет рассмотрение лишь $\min\{m, n\}$ штук сингулярных чисел, что устраняет вышеотмеченную кажущуюся неоднозначность.

Доказательство. Умножая обе части второго уравнения из (3.2) на σ , получим $A^T(\sigma y) = \sigma^2 x$. Теперь подставим сюда значение σy из первого уравнения (3.2): $A^T A x = \sigma^2 x$.

С другой стороны, умножая на σ обе части первого уравнения (3.2), получим $A(\sigma x) = \sigma^2 y$. Подставив сюда значение σx из второго уравнения (3.2), получим $AA^T y = \sigma^2 y$.

Осталось показать, что собственные значения у матриц $A^T A$ и AA^T неотрицательны, чтобы иметь возможность извлекать из них квадратные корни. Очевидно, это достаточно сделать лишь для одной из выписанных матриц.

Коль скоро матрица $A^T A$ симметрична, любое её собственное значение λ вещественно. Кроме того, если v — соответствующий собственный вектор, то $0 \leq (Av)^T(Av) = v^T(A^T Av) = v^T \lambda v = \lambda v^T v$, откуда в силу $v^T v \geq 0$ следует $\lambda \geq 0$. ■

Итак, задаваемые Определением 3.1.1 сингулярные числа $m \times n$ -матрицы — это набор из $\min\{m, n\}$ неотрицательных вещественных чисел, которые обычно нумеруют в порядке убывания:

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_{\min\{m, n\}} \geq 0.$$

Из доказательства Предложения 3.1.1 следует также, что правыми сингулярными векторами матрицы A являются правые собственные векторы матрицы $A^T A$, а левыми сингулярными векторами матрицы A — левые собственные векторы для $A^T A$ или, что равносильно, правые собственные векторы матрицы AA^T .

Пример 3.1.1 Для 2×2 -матрицы

$$A = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix} \quad (3.3)$$

нетрудно выписать характеристическое уравнение

$$\det \begin{pmatrix} 1 - \lambda & 2 \\ 3 & 4 - \lambda \end{pmatrix} = \lambda^2 - 4\lambda - 2 = 0,$$

и найти его корни $\frac{1}{2}(5 \pm \sqrt{33})$ — собственные значения матрицы, приблизительно равные -0.372 и 5.372 . Для определения сингулярных чисел образуем

$$A^T A = \begin{pmatrix} 10 & 14 \\ 14 & 20 \end{pmatrix},$$

и вычислим её собственные значения, равные $15 \pm \sqrt{221}$. Получается, что сингулярные числа матрицы A суть $\sqrt{15 \pm \sqrt{221}}$, т.е. примерно 0.366 и 5.465 (с точностью до трёх знаков после запятой).

С другой стороны, для матрицы

$$\begin{pmatrix} 1 & 2 \\ -3 & 4 \end{pmatrix}, \quad (3.4)$$

которая отличается от матрицы (3.3) лишь противоположным знаком элемента на месте $(2, 1)$, собственные значения — это комплексно-сопряжённая пара $\frac{1}{2}(5 \pm i\sqrt{15}) \approx 2.5 \pm 1.936i$, а сингулярные числа суть $\sqrt{15} \pm \sqrt{125}$, т. е. приблизительно 1.954 и 5.117. ■

Можно заметить, что максимальные сингулярные числа рассмотренных матриц превосходят наибольшие из модулей собственных чисел. Мы увидим ниже (см. §3.2д), что это не случайно, и наибольшее сингулярное число всегда превосходит максимум модулей собственных чисел матрицы.

Важнейший результат, касающийся сингулярных чисел и сингулярных векторов матриц, который служит одной из основ их широкого применения в разнообразных вопросах математического моделирования — это

Теорема 3.1.1 (теорема о сингулярном разложении матрицы)

Для любой матрицы $A \in \mathbb{R}^{m \times n}$ существуют ортогональные матрицы $U \in \mathbb{R}^{m \times m}$ и $V \in \mathbb{R}^{n \times n}$, такие что $A = U \Sigma V^T$ с $m \times n$ -матрицей Σ диагонального вида

$$\Sigma = \begin{pmatrix} \sigma_1 & 0 & 0 & \cdots & 0 \\ 0 & \sigma_2 & 0 & \cdots & 0 \\ 0 & 0 & \sigma_3 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & \ddots \end{pmatrix},$$

где $\sigma_1, \sigma_2, \dots, \sigma_{\min\{m,n\}}$ — сингулярные числа матрицы A .

Для квадратных матриц доказательство этого факта может быть легко выведено из известного полярного разложения матрицы, т. е. её представления в виде $A = QS$, где Q — ортогональная матрица, S — симметричная (см., к примеру, [9, 21]). Симметричную матрицу S можно ортогональными преобразованиями подобия привести к диагональному виду: $S = T^T D T$, где T — ортогональна, а D — диагональная. Поэтому $A = (Q T^T) D T$. Это уже почти требуемое представление для A , поскольку произведение ортогональных матриц Q и T^T тоже ортогонально. Нужно лишь убедиться в том, что по диагонали в D стоят сингулярные числа матрицы A .

Рассмотрим произведение $A^T A$:

$$\begin{aligned} A^T A &= ((QT^T)DT)^T (QT^T)DT = T^T D^T (QT^T)^T (QT^T)DT \\ &= T^T D^T DT = T^T D^2 T. \end{aligned}$$

Как видим, матрица $A^T A$ подобна диагональной матрице D^2 , их собственные числа потому совпадают и, следовательно, собственные числа $A^T A$ суть квадраты диагональных элементов D . Это и требовалось доказать.

В общем случае доказательство Теоремы 3.1.1 не очень сложно и может быть найдено, к примеру, в книгах [12, 36, 38]. Фактически, этот результат показывает, как с помощью сингулярных чисел матрицы элегантно представляется действие соответствующего линейного оператора из одного векторного пространства в другое, возможно с отличающимися друг от друга размерностями.

Задача нахождения сингулярных чисел и сингулярных векторов матриц, последняя из списка на стр. 119, по видимости является частным случаем третьей задачи, относящейся к нахождению собственных чисел и собственных векторов. Но, с одной стороны, она сделалась очень важной и в теории, и в приложениях вычислительной линейной алгебры, а, с другой, численные методы для её решения весьма специализированы, так что она рассматривается в списке задач уже «отдельной строкой». Рассказ об истории сингулярного разложения и его многочисленных применений можно найти, к примеру, в живо написанной статье [68].

Как видим, в современном списке задач на первые места выдвинулась линейная задача о наименьших квадратах. А некоторые старые и уважаемые задачи как бы отошли на второй план.

3.1в Матрицы с диагональным преобладанием

В приложениях линейной алгебры и теории матриц часто возникают матрицы, в которых диагональные элементы в том или ином смысле «преобладают» над остальной, недиагональной частью матрицы. Это обстоятельство может быть, к примеру, следствием особенностей рассматриваемой математической модели, в которой связи составляющих её частей с самими собой (они и выражаются диагональными элементами) сильнее, чем с остальными. Такие матрицы обладают рядом замечательных свойств, изложению одного из которых и посвящён

этот пункт. Следует отметить, что сам смысл, вкладываемый в понятие «преобладания» может быть различен, и ниже мы рассмотрим простейший и наиболее популярный.

Определение 3.1.2 *Квадратную $n \times n$ -матрицу $A = (a_{ij})$ называют матрицей с диагональным преобладанием, если для любого $i = 1, 2, \dots, n$ имеет место*

$$|a_{ii}| > \sum_{j \neq i} |a_{ij}|.$$

В условиях этого определения некоторые авторы говорят о «строгом диагональном преобладании». Со своей стороны, мы будем говорить о *нестрогом диагональном преобладании* в случае выполнения неравенств

$$|a_{ii}| \geq \sum_{j \neq i} |a_{ij}| \quad (3.5)$$

для любого $i = 1, 2, \dots, n$. Иногда при этом необходимо уточнять, что речь идёт о диагональном преобладании «по строкам», поскольку имеет также смысл диагональное преобладание «по столбцам», которое определяется совершенно аналогичным образом.

Теорема 3.1.2 (признак Адамара) *Матрица с диагональным преобладанием неособенна.*

Доказательство. Предположим, что, вопреки доказываемому, рассматриваемая матрица $A = (a_{ij})$ является особенной. Тогда для некоторого ненулевого вектора $y \in \mathbb{R}^n$, $y = (y_1, y_2, \dots, y_n)^\top$, выполняется равенство $Ay = 0$, т. е.

$$\sum_{j=1}^n a_{ij} y_j = 0, \quad i = 1, 2, \dots, n. \quad (3.6)$$

Выберем среди компонент вектора y ту, которая имеет наибольшее абсолютное значение. Пусть она имеет номер l , так что $|y_l| = \max_{1 \leq j \leq n} |x_j|$, причём в силу сделанного выше предположения $|y_l| > 0$. Следствием l -го из равенств (3.6) является соотношение

$$-a_{ll} y_l = \sum_{j \neq l} a_{lj} y_j,$$

что влечёт

$$\begin{aligned} |a_{ll}| |y_l| &= \left| \sum_{j \neq l} a_{lj} y_j \right| \leq \sum_{j \neq l} |a_{lj}| |y_j| \\ &\leq \left(\max_{1 \leq j \leq n} |y_j| \right) \sum_{j \neq l} |a_{lj}| \leq |y_l| \sum_{j \neq l} |a_{lj}|. \end{aligned}$$

Сокращая теперь обе части полученного неравенства на $|y_l| > 0$, будем иметь

$$|a_{ll}| \leq \sum_{j \neq l} |a_{lj}|,$$

что противоречит наличию диагонального преобладания в матрице A по условию теоремы. Итак, A действительно должна быть неособенной матрицей. ■

Доказанный выше результат часто именуют также «теоремой Леви-Деспланка» (см., к примеру, [39]), но мы придерживаемся в этом пункте терминологии, принятой в [9, 32]. В книге М. Пароди [32] можно прочесть, в частности, некоторые сведения об истории вопроса.

Внимательное изучение доказательства признака Адамара показывает, что в нём нигде не использовался факт принадлежности элементов матрицы и векторов какому-то конкретному числовому полю — $\mathbb{R}$ или $\mathbb{C}$. Таким образом, признак Адамара справедлив и для комплексных матриц. Кроме того, он может быть обобщен на матрицы, удовлетворяющие нестрогому диагональному преобладанию (3.5).

Вещественная или комплексная $n \times n$ -матрица $A = (a_{ij})$ называется *разложимой*, если существует разбиение множества $\{1, 2, \dots, n\}$ первых n натуральных чисел на два непересекающихся подмножества I и J , таких что $a_{ij} = 0$ при $i \in I$ и $j \in J$. Эквивалентное определение: матрица $A \in \mathbb{R}^{n \times n}$ разложима, если путём перестановок строк и столбцов она может быть приведена к блочно-треугольному виду

$$\begin{pmatrix} A_{11} & A_{12} \\ 0 & A_{22} \end{pmatrix}$$

с квадратными блоками A_{11} и A_{22} . Матрицы, не являющиеся разложимыми, называются *неразложимыми*. Важнейший пример неразложимых матриц — это матрицы, все элементы которых не равны нулю, в частности, неотрицательны.

Обобщением признака Адамара является

Теорема 3.1.3 (теорема Таусски) *Если для квадратной неразложимой матрицы A выполнены условия нестрогого диагонального преобладания (3.5), причём хотя бы одно из этих неравенств выполнено строго, то матрица A неособенна.*

Доказательство можно найти, к примеру, в [9].

3.2 Нормы векторов и матриц

3.2a Векторные нормы

Норму можно рассматривать как обобщение на многомерный и абстрактный случаи понятия абсолютной величины числа. Вообще, и норма, и абсолютная величина являются понятиями, которые формализуют интуитивно ясное свойство «размера» объекта, его «величины», т. е. того, насколько он мал или велик безотносительно к его расположению на прямой, плоскости или в пространстве. Такова, например, длина вектора как направленного отрезка в привычном нам трёхмерном евклидовом пространстве $\mathbb{R}^3$.

Формальное определение даётся следующим образом.

Определение 3.2.1 *Нормой в вещественном или комплексном линейном пространстве X называется функция $\|\cdot\| : X \rightarrow \mathbb{R}_+$, удовлетворяющая следующим свойствам (аксиомам нормы):*

$$(BN1) \quad \|a\| \geq 0 \quad \text{для любого } a \in X, \text{ причём } \|a\| = 0 \Leftrightarrow a = 0$$

— неотрицательность,

$$(BN2) \quad \|\alpha a\| = |\alpha| \cdot \|a\| \quad \text{для любых } a \in X \text{ и } \alpha \in \mathbb{R} \text{ или } \mathbb{C}$$

— абсолютная однородность,

$$(BN3) \quad \|a + b\| \leq \|a\| + \|b\| \quad \text{для любых } a, b, c \in X$$

— «неравенство треугольника».

Само пространство X называется при этом нормированным линейным пространством.

Далее в качестве линейного пространства $\mathcal{X}$ у нас всюду рассматриваются $\mathbb{R}^n$ или $\mathbb{C}^n$.

Не все нормы, удовлетворяющие выписанным аксиомам одинаково практичны, и часто от нормы требуют выполнения ещё тех или иных дополнительных условий. К примеру, удобно иметь дело с *абсолютной нормой*, значение которой зависит лишь от абсолютных значений компонент векторов. В общем случае норма вектора этому условию может и не удовлетворять.

Примеры наиболее часто используемых норм векторов в $\mathbb{R}^n$ и $\mathbb{C}^n$:

$$\|a\|_1 = \sum_{i=1}^n |a_i|,$$

$$\|a\|_2 = \left(\sum_{i=1}^n |a_i|^2 \right)^{1/2} = \sqrt{\langle a, a \rangle},$$

$$\|a\|_\infty = \max_{1 \leq i \leq n} |a_i|.$$

Вторая из этих норм часто называется *евклидовой*, а третья — *чебышёвской*. Замечательность евклидовой нормы состоит в том, что она порождена скалярным произведением в $\mathbb{R}^n$. Иногда можно встретить и другие названия этих норм.




Рис. 3.1. Шары единичного радиуса в различных нормах.

Первая и вторая нормы — это частные случаи более общей кон-

струкции p -нормы

$$\|a\|_p = \left(\sum_{i=1}^n |a_i|^p \right)^{1/p} \quad \text{для } p \geq 1.$$

Чебышёвская норма также может быть получена из p -нормы с помощью предельного перехода $p \rightarrow \infty$, что и объясняет индекс « ∞ » в её обозначении.

Ещё одной важной и популярной конструкцией нормы является так называемая *энергетическая норма* векторов, которая порождается какой-либо симметричной положительно-определённой матрицей (эрмитовой в комплексном случае). Если A — такая матрица, то выражение $\langle Ax, y \rangle$, как нетрудно проверить, есть симметричная билинейная положительно-определённая форма, т. е. скалярное произведение векторов x и y . Следовательно, можно определить норму вектора x , как $\sqrt{\langle Ax, x \rangle}$, т. е. как корень из произведения x на себя в этом новом скалярном произведении. Это и есть энергетическая норма x относительно матрицы A , обычно обозначаемая как $\|x\|_A := \langle Ax, x \rangle^{1/2}$. Её часто называют также A -нормой векторов, если в задаче имеется в виду какая-то конкретная симметричная положительно определённая матрица A .




Рис. 3.2. Шар единичного радиуса в энергетической норме при большом разбросе спектра порождающей матрицы

Характерная особенность энергетической нормы, которая в ряде случаев оборачивается её недостатком, — возможность существенного искажения обычного геометрического масштаба «величины» объектов.

Она вызывается разбросом собственных значений порождающей матрицы A и приводит к тому, что векторы из $\mathbb{R}^n$, имеющие одинаковую энергетическую норму, существенно различны по обычной евклидовой длине (Рис. 3.2). С другой стороны, использование энергетической нормы, которая порождена матрицей, фигурирующей в постановке задачи (системе линейных алгебраических уравнений, задаче на собственные значения и т. п.) часто является удобным и оправданным, альтернативы ему очень ограничены. Примеры будут рассмотрены в §3.5б и §3.5в.

Нормы будут нужны нам как сами по себе, для оценивания «величины» тех или иных объектов, так и для измерения «отклонения» одного вектора от другого. Как уже отмечалось ранее, на нормированном пространстве $\mathcal{X}$ расстояние (метрика) может быть естественно заданы как

$$\text{dist}(a, b) = \|a - b\|.$$

В этом смысле задание на некотором линейном пространстве $\mathcal{X}$ нормы автоматически определяет на нём и топологию, т. е. запас открытых и замкнутых множеств, структуру близости, с помощью которой можно будет, в частности, выполнять предельные переходы. Более точно, мы считаем, что переменная $a \in \mathcal{X}$ сходится к пределу a^* относительно рассматриваемой нормы, если $\|a - a^*\| \rightarrow 0$.

3.2б Матричные нормы

Помимо векторов основным объектом вычислительной линейной алгебре являются также матрицы, и потому нам будут нужны матричные нормы — для того, чтобы оценивать «величину» той или иной матрицы, а также для того, чтобы измерять «отклонение» одной матрицы от другой как

$$\text{dist}(A, B) := \|A - B\|. \quad (3.7)$$

Множество матриц само является линейным (векторным) пространством, а матрица — это составной многомерный объект, во многом аналогичный вектору. Поэтому вполне естественно прежде всего потребовать от матричной нормы тех же свойств, что и для векторной нормы. Формально, матричной нормой мы будем называть функцию $\|\cdot\| : \mathbb{R}^{m \times n} \rightarrow \mathbb{R}_+$ или $\|\cdot\| : \mathbb{C}^{m \times n} \rightarrow \mathbb{R}_+$, удовлетворяющую следующим аксиомам:

- (МН1) $\|A\| \geq 0$ для любой матрицы A , причём $\|A\| = 0 \Leftrightarrow A = 0$
 — неотрицательность,

(МН2) $\|\alpha A\| = |\alpha| \cdot \|A\|$ для любых матрицы A и $\alpha \in \mathbb{R}$ или $\mathbb{C}$
 — абсолютная однородность,

(МН3) $\|A + B\| \leq \|A\| + \|B\|$ для любых матриц A, B, C
 — «неравенство треугольника».

Эти три условия выражают взгляд на матрицу, как на «вектор размерности $m \times n$ », и должны быть признаны недостаточными, если мы хотим учесть специфику матриц как объектов, между которыми определена также операция умножения. В частности, множество всех квадратных матриц фиксированного размера наделено более богатой структурой, нежели линейное векторное пространство, и обычно в связи с ним используют уже термин «кольцо», обозначающее множество с двумя взаимносогласованными бинарными операциями — сложением и умножением.

Свойства матриц, как элементов кольца, обычно отражает четвёртая аксиома матричной нормы:

(МН4) $\|AB\| \leq \|A\| \cdot \|B\|$ для любых матриц A, B
 — «субмультипликативность».

Она фиксирует связь нормы матриц с операцией их умножения и иногда формулируется расширительно — для всех матриц, которые можно перемножать друг с другом.

Особый интерес и в теории и на практике представляют ситуации, когда нормы векторов пространства $\mathbb{R}^n$ или $\mathbb{C}^n$ и нормы матриц, действующих на этом пространстве, существуют не сами по себе, но в некотором смысле согласованы друг с другом. Инструментом такого согласования может как раз-таки выступать аксиома субмультипликативности, понимаемая в расширенном смысле, т. е. для любых матриц A и B таких размеров, что произведение AB имеет смысл. В частности, для $n \times 1$ -матриц B , являющихся векторами из $\mathbb{R}^n$.

Определение 3.2.2 *Векторная и матричная нормы называются согласованными, если для любой матрицы $A \in \mathbb{R}^{m \times n}$ (или $\mathbb{C}^{m \times n}$)*

$$\|Ax\| \leq \|A\| \cdot \|x\| \quad (3.8)$$

для всех $x \in \mathbb{R}^n$ (или $\mathbb{C}^n$).

Рассмотрим примеры конкретных матричных норм. *Фробениусова норма* матрицы $A = (a_{ij})$ определяется как

$$\|A\|_F = \left(\sum_{i,j} |a_{ij}|^2 \right)^{1/2}.$$

Ясно, что она удовлетворяет первым трём аксиомам матричной нормы просто потому, что задаётся совершенно так же, как евклидова векторная норма. Свойство субмультипликативности устанавливается несложной проверкой. Кроме того, фробениусова норма согласована с евклидовой векторной нормой $\|\cdot\|_2$. Матричная норма

$$\|A\|_{\max} = n \max_{i,j} |a_{ij}|,$$

определённая на множестве квадратных $n \times n$ -матриц, согласована с евклидовой и чебышёвской нормами векторов.

Оказывается, что для любой нормы квадратных матриц можно подобрать подходящую векторную норму, с которой она будет согласована. Иными словами, среди матричных норм квадратных матриц нет таких, которые не были бы ни с чем согласованными. Действительно, если для данной матричной нормы $\|\cdot\|$ определить норму $\|v\|$ вектора v как $\|(v, v, \dots, v)\|$, т. е. как норму матрицы $(v, v, \dots, v)$, составленной из n штук векторов v как из столбцов, то

$$\begin{aligned} \|Av\| &= \|(Av, Av, \dots, Av)\| = \|A \cdot (v, v, \dots, v)\| \\ &\leq \|A\| \cdot \|(v, v, \dots, v)\| = \|A\| \cdot \|v\|, \end{aligned}$$

так что требуемое согласование действительно будет достигнуто.

3.2в Подчинённые матричные нормы

В предшествующем пункте мы могли видеть, что с заданной векторной нормой могут быть согласованы различные матричные нормы. И наоборот, для матричной нормы возможна согласованность со многими векторными нормами. В этих условиях при проведении различных выкладок и выводе оценок наиболее выгодно оперировать как можно меньшими из согласованных матричных норм: огрубить оценку (3.8) всегда можно, а вот сделать её более точной гораздо труднее! Конкретная величина нормы, к примеру, может оказать сильное влияние на

количество итераций, которые мы вынуждены будем сделать в итерационных численных методах для достижения той или иной расчётной точности.

Ясно, что для фиксированной матрицы A и заданной векторной нормы $\|\cdot\|$ значения всех согласованных с ней матричных норм от A ограничены снизу выражением

$$\sup_{x \neq 0} \frac{\|Ax\|}{\|x\|},$$

поскольку из требования согласованности вытекает $\|A\| \geq \|Ax\|/\|x\|$.

Предложение 3.2.1 *Соотношением*

$$\|A\|' = \sup_{x \neq 0} \frac{\|Ax\|}{\|x\|} \quad (3.9)$$

задаётся матричная норма.

Доказательство. Отметим, прежде всего, что вместо «sup» в выражении (3.9) можно брать «max», так как

$$\sup_{x \neq 0} \frac{\|Ax\|}{\|x\|} = \sup_{x \neq 0} \left\| A \frac{x}{\|x\|} \right\| = \sup_{\|y\|=1} \|Ay\|,$$

а единичная сфера любой нормы компактна в конечномерном пространстве $\mathbb{R}^n$ [38, 48]. Непрерывная функция $\|Ay\|$ достигает на этом компактном множестве своего максимума.

Проверим теперь для нашей конструкции выполнение аксиом нормы. Если $A \neq 0$, то найдётся ненулевой вектор y , такой что $Ay \neq 0$. Ясно, что его можно считать нормированным, т.е. $\|y\| = 1$. Тогда $\|Ay\| > 0$, и потому $\max_{\|y\|=1} \|Ay\| > 0$, что доказывает первую аксиому нормы.

Абсолютная однородность доказывается тривиально, покажем для (3.9) справедливость неравенства треугольника. Очевидно,

$$\|(A + B)y\| \leq \|Ay\| + \|By\|,$$

и потому

$$\max_{\|y\|=1} \|(A + B)y\| \leq \max_{\|y\|=1} \|Ay\| + \max_{\|y\|=1} \|By\|.$$

Приступая к обоснованию субмультипликативности, отметим, что по самому построению $\|Ax\| \leq \|A\|' \|x\|$ для любого вектора x . По этой причине

$$\begin{aligned} \|AB\|' &= \max_{\|y\|=1} \|(AB)y\| = \|(AB)\tilde{y}\| \quad \text{для некоторого } \tilde{y} \text{ с } \|\tilde{y}\| = 1 \\ &\leq \|A\|' \cdot \|B\tilde{y}\| \leq \|A\| \cdot \max_{\|y\|=1} \|By\| = \|A\|' \|B\|'. \end{aligned}$$

Это завершает доказательство предложения. ■

Доказанный результат мотивирует

Определение 3.2.3 Матричная норма, определяемая для заданной векторной нормы $\|\cdot\|$ на линейном векторном пространстве X как

$$\|A\|' = \sup_{x \neq 0} \frac{\|Ax\|}{\|x\|} = \sup_{\|y\|=1} \|Ay\|,$$

называется подчинённой к $\|\cdot\|$ матричной нормой (или индуцированной, или операторной нормой).

Последний термин — операторная норма, популярен потому, что конструкция этой нормы хорошо отражает взгляд на матрицу как на оператор, задающий отображения линейных векторных пространств $\mathbb{R}^n \rightarrow \mathbb{R}^m$ или $\mathbb{C}^n \rightarrow \mathbb{C}^m$.

Какими являются подчинённые матричные нормы для наших векторных норм $\|\cdot\|_1$, $\|\cdot\|_2$ и $\|\cdot\|_\infty$? Вообще, существуют ли простые выражения для этих подчинённых норм? Являются ли матричные нормы $\|A\|_F$ (фробениусова) и $\|A\|_{\max}$ подчинёнными для каких-либо векторных норм?

Ответ на последний вопрос отрицателен. В самом деле, для единичной $n \times n$ -матрицы I имеем

$$\|I\|_{\max} = n, \quad \|I\|_F = \sqrt{n},$$

тогда как из определения подчинённой нормы следует, что должно быть

$$\|I\| = \sup_{\|y\|=1} \|Iy\| = \max_{\|y\|=1} \|y\| = 1.$$

Ответом на первые вопросы является

Предложение 3.2.2 Для векторной 1-нормы подчинённой матричной нормой для $m \times n$ -матрицы является

$$\|A\|_1 = \max_{1 \leq j \leq n} \left(\sum_{i=1}^m |a_{ij}| \right)$$

— максимальная сумма модулей элементов по столбцам.

Для чебышёвской векторной нормы (∞ -нормы) подчинённой матричной нормой для $m \times n$ -матрицы является

$$\|A\|_\infty = \max_{1 \leq i \leq m} \left(\sum_{j=1}^n |a_{ij}| \right)$$

— максимальная сумма модулей элементов по строкам.

Матричная норма, подчинённая евклидовой норме векторов $\|x\|_2$, есть $\|A\|_2 = \sigma_{\max}(A)$ — наибольшее сингулярное число матрицы A .

Доказательство. Первая часть предложения обосновывается следующей выкладкой:

$$\begin{aligned} \|Ax\|_1 &= \sum_{i=1}^m |(Ax)_i| = \sum_{i=1}^m \left| \sum_{j=1}^n a_{ij} x_j \right| \leq \sum_{i=1}^m \sum_{j=1}^n |a_{ij} x_j| \\ &= \sum_{i=1}^m \sum_{j=1}^n |a_{ij}| |x_j| = \sum_{j=1}^n \sum_{i=1}^m |a_{ij}| |x_j| = \sum_{j=1}^n \left(|x_j| \sum_{i=1}^m |a_{ij}| \right) \\ &\leq \left(\max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}| \right) \cdot \sum_{j=1}^n |x_j| = \|A\|_1 \|x\|_1, \end{aligned}$$

причём все неравенства в этой цепочке достижимы на векторе x в виде столбца единичной матрицы с тем номером j , на котором достигается $\max_j \sum_{i=1}^m |a_{ij}|$. Аналогичным образом доказывается и вторая часть предложения.

Для доказательства последней части предложения рассмотрим $n \times n$ -матрицу $A^T A$. Она симметрична, её собственные числа вещественны и неотрицательны, будучи квадратами сингулярных чисел матрицы A . Кроме того, ортогональным преобразованием подобия $A^T A$ может быть приведена к диагональному виду: $A^T A = Q^T \Lambda Q$, где Q — ортогональная $n \times n$ -матрица, Λ — диагональная $n \times n$ -матрица, имеющая на диагонали собственные значения $A^T A$, т. е. числа $\sigma_i^2(A)$, $i = 1, 2, \dots, n$.

Далее имеем

$$\begin{aligned}
 \|A\|_2 &= \max_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2} = \max_{x \neq 0} \frac{\sqrt{x^\top A^\top A x}}{\|x\|_2} = \max_{x \neq 0} \frac{\sqrt{x^\top Q^\top \Lambda Q x}}{\|x\|_2} \\
 &= \max_{x \neq 0} \frac{\sqrt{(Qx)^\top \Lambda (Qx)}}{\|Qx\|_2} = \max_{y \neq 0} \frac{\sqrt{y^\top \Lambda y}}{\|y\|_2} = \max_{y \neq 0} \sqrt{\frac{\sum_i \sigma_i^2 y_i^2}{\sum_i y_i^2}} \\
 &\leq \max_{y \neq 0} \left(\sigma_{\max} \sqrt{\frac{\sum_i y_i^2}{\sum_i y_i^2}} \right) = \sigma_{\max},
 \end{aligned}$$

где мы воспользовались в выкладках тем, что $\|Qx\|_2 = \|x\|_2$ для любой ортогональной матрицы Q . С другой стороны, эта оценка достижима: достаточно взять в качестве вектора $y \in \mathbb{R}^n$ столбец единичной матрицы с номером, равным месту элемента $\sigma_{\max}^2$ на диагонали в Λ , а в самом начале выкладок положить $x = Q^\top y$. ■

Норму матриц $\|\cdot\|_2$, подчинённую евклидовой векторной норме, часто называют также *спектральной нормой* матриц. Отметим, что она не является абсолютной нормой (см. Пример 3.1.1), т.е. зависит не только от абсолютных значений элементов матрицы. В то же время, $\|\cdot\|_1$ и $\|\cdot\|_\infty$ — это абсолютные матричные нормы, что следует из вида их выражений.

3.2г Топология на множествах векторов и матриц

Термином *топология* для заданного множества обычно обозначают семейство всех открытых подмножеств данного множества, позволяющее определять окрестности и, как следствие, близость одно элемента множества к другому, сходимость и т.п. понятия.² Топологию можно задавать различными способами, например, простым описанием того, какие именно множества считаются открытыми. Наиболее популярно задание топологии с помощью функции расстояния (метрики) или же с помощью различных норм.

²Топологией называется также математическая дисциплина, изучающая, главным образом, свойства объектов, инвариантные относительно непрерывных отображений.

Говорят, что векторные нормы *топологически эквивалентны* (или просто *эквивалентны*), если эквивалентны порождаемые ими в пространстве топологии, т.е. любое открытое (замкнутое) относительно одной нормы множество является открытым (замкнутым) и в другой норме, и наоборот. При этом, в частности, предельный переход в одной норме влечёт существование предела в другой, и обратно. Из математического анализа известен простой критерий эквивалентности двух норм:

Предложение 3.2.3 *Нормы $\|\cdot\|'$ и $\|\cdot\|''$ на пространстве X эквивалентны тогда и только тогда, когда существуют положительные константы C_1 и C_2 , такие что для любых $a \in X$*

$$C_1 \|a\|' \leq \|a\|'' \leq C_2 \|a\|'. \quad (3.10)$$

Формулировка этого предложения имеет кажущуюся асимметрию, так как для значений одной из эквивалентных норм предъявляется двусторонняя «вилка» из значений другой нормы с подходящими множителями-константами. Но нетрудно видеть, что из (3.10) немедленно следует

$$\frac{1}{C_2} \|a\|'' \leq \|a\|' \leq \|a\|'',$$

так что существование «вилки» для одной нормы автоматически подразумевает существование аналогичной «вилки» и для другой.

Предложение 3.2.4 *В линейных пространствах $\mathbb{R}^n$ или $\mathbb{C}^n$*

$$\|a\|_2 \leq \|a\|_1 \leq \sqrt{n} \|a\|_2,$$

$$\|a\|_\infty \leq \|a\|_2 \leq \sqrt{n} \|a\|_\infty,$$

$$\frac{1}{n} \|a\|_1 \leq \|a\|_\infty \leq \|a\|_1,$$

т.е. все три рассмотренные выше векторные нормы эквивалентны друг другу.

Доказательство. Справедливость правого из первых неравенств следует из известного неравенства Коши-Буняковского $|\langle a, b \rangle| \leq \|a\|_2 \|b\|_2$, применённого к случаю $b = (\operatorname{sgn} a_1, \operatorname{sgn} a_2, \dots, \operatorname{sgn} a_n)^\top$. Для обоснования левого из первых неравенств заметим, что в силу определений

2-нормы и 1-нормы

$$\begin{aligned}\|a\|_2^2 &= |a_1|^2 + |a_2|^2 + \dots + |a_n|^2, \\ \|a\|_1^2 &= |a_1|^2 + |a_2|^2 + \dots + |a_n|^2 \\ &\quad + 2|a_1a_2| + 2|a_1a_3| + \dots + 2|a_{n-1}a_n|,\end{aligned}$$

и все слагаемые $2|a_1a_2|, 2|a_1a_3|, \dots, 2|a_{n-1}a_n|$ неотрицательны. В частности, равенство $\|a\|_2^2 = \|a\|_1^2$ и ему равносильное $\|a\|_2^2 = \|a\|_1^2$ возможны лишь в случае, когда у вектора a все компоненты равны нулю за исключением одного.

Обоснование остальных неравенств даётся следующими несложными выкладками:

$$\begin{aligned}\|a\|_2 &= \sqrt{|a_1|^2 + |a_2|^2 + \dots + |a_n|^2} \\ &\geq \sqrt{\max_i |a_i|^2} = \max_i |a_i| = \|a\|_\infty, \\ \|a\|_2 &= \sqrt{|a_1|^2 + |a_2|^2 + \dots + |a_n|^2} \\ &\leq \sqrt{n \max_i |a_i|^2} = \sqrt{n} \max_i |a_i| = \sqrt{n} \|a\|_\infty, \\ \|a\|_\infty &= \max_i |a_i| \leq |a_1| + |a_2| + \dots + |a_n| = \|a\|_1 \\ \|a\|_1 &= |a_1| + |a_2| + \dots + |a_n| \leq n \max_i |a_i| \leq n \|a\|_\infty\end{aligned}$$

Нетрудно видеть, что все эти неравенства достижимые (точные). ■

В действительности, этот факт является частным случаем общего результата анализа о том, что в конечномерном векторном пространстве все нормы топологически эквивалентны друг другу.

Коль скоро векторы являются сложными объектами, составленными из своих компонент, то помимо определённой выше сходимости по норме имеет смысл рассматривать покомпонентную сходимость, при которой один вектор сходится к другому тогда и только тогда, когда все компоненты первого вектора сходятся к соответствующим компонентам второго:

$$a \rightarrow a^* \quad \Leftrightarrow \quad a_k \rightarrow a_k^* \quad \text{для всех индексов } k = 1, 2, \dots, n.$$

Интересен вопрос о том, как соотносятся между собой сходимость по норме и сходимость всех компонент вектора. Нетрудно показать, что

в случае конечномерных пространств эти понятия равносильны друг другу.

Совершенно аналогично случаю векторных норм можно рассмотреть понятие эквивалентности норм матриц, и критерием эквивалентности матричных норм будет служить Предложение 3.2.3. В силу известного факта из математического анализа в конечномерном линейном пространстве всех $m \times n$ -матриц все нормы эквивалентны. Тем не менее, конкретные константы эквивалентности играют огромную роль при выводе различных оценок, и их значения даёт следующее

Предложение 3.2.5 *Во множествах матриц $\mathbb{R}^{n \times n}$ и $\mathbb{C}^{n \times n}$*

$$\begin{aligned}\frac{1}{\sqrt{n}} \|A\|_2 &\leq \|A\|_1 \leq \sqrt{n} \|A\|_2, \\ \frac{1}{\sqrt{n}} \|A\|_\infty &\leq \|A\|_2 \leq \sqrt{n} \|A\|_\infty, \\ \frac{1}{n} \|A\|_1 &\leq \|A\|_\infty \leq n \|A\|_1.\end{aligned}$$

Доказательство. Докажем первую пару неравенств:

$$\|A\|_2 = \max_{\|y\|_2=1} \|Ay\|_2 \leq \max_{\|y\|_2=1} (\sqrt{n} \|Ay\|_2)$$

Кроме того,

$$\|A\|_2 = \max_{\|y\|_2=1} \|Ay\|_2 \geq \max_i \|Ae_i\|_2$$

где e_i — i -ый столбец единичной матрицы. ■

Из эквивалентности матричных норм следует, в частности, существование для любой нормы $\|\cdot\|$ такой константы C , что

$$\max_{i,j} |a_{ij}| \leq \max_{1 \leq j \leq n} \left(\sum_{i=1}^m |a_{ij}| \right) = \|A\|_1 \leq C \|A\|$$

(вместо 1-нормы матриц в этой выкладке можно было бы взять, к примеру, ∞ -норму). Поэтому $|a_{ij}| \leq C \|A\|$, так что сходимость последовательности матриц в любой норме равносильна сходимости последовательностей всех элементов этих матриц.

В целом множество матриц с введённым на нём посредством (3.7) расстоянием для любой матричной нормы является полным метрическим пространством, т. е. любая фундаментальная («сходящаяся в себе») последовательность имеет в нём предел. Это следует из предшествующего рассуждения и из факта полноты вещественной оси $\mathbb{R}$ и комплексной плоскости $\mathbb{C}$.

3.2д Спектральный радиус

Определение 3.2.4 *Спектральным радиусом квадратной матрицы называется наибольший из модулей её собственных чисел.*

Эквивалентное определение: спектральным радиусом матрицы называется наименьший из радиусов кругов комплексной плоскости $\mathbb{C}$ с центром в начале координат, который содержит весь спектр матрицы. Эта трактовка хорошо объясняет и сам термин. Обычно спектральный радиус матрицы A обозначают $\rho(A)$.




Рис. 3.3. Иллюстрация спектрального радиуса матрицы: крестиками обозначены точки спектра.

Предложение 3.2.6 *Спектральный радиус матрицы не превосходит любой её нормы.*

Доказательство. Рассмотрим сначала случай, когда основным линейным пространством является $\mathbb{C}^n$, и рассматриваемая $n \times n$ -матрица A , вообще говоря, также комплексная.

Пусть λ — собственное значение матрицы, а $v \neq 0$ — соответствующий собственный вектор A , так что $Av = \lambda v$. Воспользуемся тем установленным в §3.26 фактом, что любая матричная норма согласована с некоторой векторной нормой, и возьмём от обеих частей равенства $Av = \lambda v$ норму, согласованную с рассматриваемой $\|A\|$. Получим

$$\|A\| \cdot \|v\| \geq \|Av\| = \|\lambda v\| = |\lambda| \cdot \|v\|, \quad (3.11)$$

где $\|v\| \geq 0$, и потому сокращение на эту величину обеих частей неравенства (3.11) даёт $\|A\| \geq |\lambda|$. Коль скоро наше рассуждение справедливо для любого собственного значения, то в самом деле $\rho(A) \leq \|A\|$.

Рассмотрим теперь случай вещественной матрицы A , действующей на $\mathbb{R}^n$. Если λ — её вещественное собственное значение, то проведённые выше рассуждения остаются полностью справедливыми. Если λ — комплексное собственное значение матрицы A , то комплексифицируем рассматриваемое линейное пространство, т.е. перейдём от $\mathbb{R}$ к пространству $\mathbb{R} \oplus i\mathbb{R}$, где i — мнимая единица, а « $\oplus$ » означает прямую сумму линейных пространств (см. [10, 33]).

Элементами $\mathbb{R} \oplus i\mathbb{R}$ служат упорядоченные пары $(x, y)^\top$, где $x, y \in \mathbb{R}$. Сложение и умножение на скаляр $(a + ib) \in \mathbb{C}$ определяются для них следующим образом

$$\begin{aligned} (x, y)^\top + (x', y')^\top &= (x + x', y + y')^\top, \\ (a + ib) \cdot (x, y)^\top &= (ax - by, ay + bx)^\top. \end{aligned}$$

Введённые пары векторов $(x, y)^\top$ обычно записывают в виде $x + iy$, причём x и y называются соответственно вещественной и мнимой частями вектора из $\mathbb{R} \oplus i\mathbb{R}$. Оператор, действующий на $\mathbb{R} \oplus i\mathbb{R}$ и порождаемый матрицей A , может быть представлен в матричном виде как

$$\mathcal{A} = \begin{pmatrix} A & 0 \\ 0 & A \end{pmatrix}. \quad (3.12)$$

Его диагональность объясняется тем, что вещественная матрица A независимо действует на вещественную и мнимую части векторов из $\mathbb{R} \oplus i\mathbb{R}$.

Без ущерба для общности можно считать, что рассматриваемая нами норма матрицы, т.е. $\|A\|$, является подчинённой (операторной) нормой, так как такие нормы являются наименьшими из всех согласованных матричных норм. Пусть $\|\cdot\|$ — векторная норма в $\mathbb{R}$, которой подчинена наша матричная норма. Зададим в $\mathbb{R} \oplus i\mathbb{R}$ норму векторов как

$\|(x, y)^\top\| = \|x\| + \|y\|$. Тогда ввиду (3.12) и с помощью рассуждений, аналогичных доказательству Предложения 3.2.2, нетрудно показать, что подчинённая матричная норма для $\mathcal{A}$ во множестве комплексных матриц есть $\|\mathcal{A}\| = \max\{\|A\|, \|A\|\} = \|A\|$. Кроме того, теперь для $\mathcal{A}$ справедливы рассуждения, проведённые выше в случае комплексной матрицы. ■

Спектральный радиус в общем случае не является матричной нормой. Хотя для любого скаляра

$$\rho(\alpha A) = |\alpha| \rho(A),$$

т.е. спектральный радиус обладает абсолютной однородностью, аксиомы (МН1) и (МН3) матричной нормы для него не выполняются. Во-первых, для ненулевой матрицы

$$\begin{pmatrix} 0 & 1 & & 0 \\ & 0 & 1 & \\ & & \ddots & \ddots \\ 0 & & & 0 & 1 \end{pmatrix} \quad (3.13)$$

— жордановой клетки, отвечающей собственному значению 0, спектральный радиус равен нулю. Во-вторых, если A — матрица вида (3.13), то $\rho(A^\top) = \rho(A) = 0$, но $\rho(A + A^\top) > 0$, и потому неверно неравенство треугольника

$$\rho(A + A^\top) \leq \rho(A) + \rho(A^\top).$$

Тем не менее, для симметричных матриц спектральный радиус есть норма, которая совпадает со спектральной нормой $\|\cdot\|_2$. Это было доказано в Предложении 3.2.2.

Менее очевидная связь между спектральным радиусом и нормами матриц выражается *формулой Гельфанда*

$$\rho(A) = \lim_{n \rightarrow \infty} \|A^n\|^{1/n},$$

которая справедлива для любой из матричных норм. Доказательство можно найти, к примеру, в [48]. Формула Гельфанда показывает, в частности, что с помощью спектрального радиуса адекватно описывается асимптотическое поведение норм степеней матрицы. Это подтверждает и следующий результат.

Предложение 3.2.7 *Для сходимости степеней $A^k \rightarrow 0$ при $k \rightarrow \infty$ необходимо, чтобы $\rho(A) < 1$, т. е. чтобы спектральный радиус матрицы A был меньше 1.*

Доказательство. Пусть λ — собственное число матрицы A (возможно, комплексное), а $v \neq 0$ — соответствующий ему собственный вектор (который также может быть комплексным). Тогда $Av = \lambda v$, и потому

$$\begin{aligned} A^2 v &= A(Av) = A(\lambda v) = \lambda(Av) = \lambda^2 v, \\ A^3 v &= A(A^2 v) = A(\lambda^2 v) = \lambda^2(Av) = \lambda^3 v, \\ &\dots \quad \dots \quad, \end{aligned}$$

так что в целом

$$(A^k)v = (\lambda^k)v. \quad (3.14)$$

Если последовательность степеней A^k , $k = 0, 1, 2, \dots$, сходится к нулевой матрице, то нулевой предел имеет и вся левая часть выписанного равенства. Как следствие, к нулевому вектору должна сходиться и правая часть в (3.14). Это возможно лишь в случае $|\lambda| < 1$. ■

Ниже в §3.4а мы увидим, что условие $\rho(A) < 1$ является, в действительности, также достаточным для сходимости к нулю степеней матрицы A .

3.2е Матричный ряд Неймана

Как известно из математического анализа, операцию суммирования можно обобщить на суммы бесконечного числа слагаемых, которые называются *рядами*. Суммой ряда называется при этом предел (если он существует) сумм конечного числа слагаемых, когда количество слагаемых неограниченно возрастает. Совершенно аналогичная конструкция применима также к суммированию векторов и матриц, а не только чисел. Именно, суммой матричного ряда

$$\sum_{k=0}^{\infty} A^{(k)},$$

где $A^{(k)}$ — матрицы одного размера, мы будем называть предел частичных сумм $\sum_{k=0}^N A^{(k)}$ при $N \rightarrow \infty$.

Предложение 3.2.8 Пусть X — $n \times n$ -матрица и в некоторой матричной норме $\|X\| < 1$. Тогда матрица $(I - X)$ неособенна, для обратной матрицы справедливо представление

$$(I - X)^{-1} = \sum_{k=0}^{\infty} X^k, \quad (3.15)$$

и имеет место оценка

$$\|(I - X)^{-1}\| \leq \frac{1}{1 - \|X\|}. \quad (3.16)$$

Фигурирующий в (3.15) аналог геометрической прогрессии для матриц называется *матричным рядом Неймана*.

Доказательство. Обозначим $S_N = \sum_{k=0}^N X^k$ — частичную сумму матричного ряда Неймана. Коль скоро

$$\begin{aligned} \|S_{N+p} - S_N\| &= \left\| \sum_{k=N+1}^{N+p} X^k \right\| \leq \sum_{k=N+1}^{N+p} \|X^k\| \leq \sum_{k=N+1}^{N+p} \|X\|^k \\ &= \|X\|^{N+1} \cdot \frac{1 - \|X\|^{N+p}}{1 - \|X\|} \rightarrow 0 \end{aligned}$$

при $N \rightarrow \infty$ и любых целых положительных p , то последовательность S_N является фундаментальной (последовательностью Коши) в полном метрическом пространстве $n \times n$ -матриц с расстоянием, порождённым рассматриваемой нормой $\|\cdot\|$. Следовательно, частичные суммы S_N ряда Неймана имеют предел $S = \lim_{N \rightarrow \infty} S_N$, причём

$$(I - X)S_N = (I - X)(I + X + X^2 + \dots + X^N) = I - X^{N+1} \rightarrow I$$

при $N \rightarrow \infty$, поскольку тогда $\|X^{N+1}\| \leq \|X\|^{N+1} \rightarrow 0$. Этот предел S удовлетворяет соотношению $(I - X)S = I$, и потому $S = (I - X)^{-1}$.

Наконец,

$$\|(I - X)^{-1}\| = \left\| \sum_{k=0}^{\infty} X^k \right\| \leq \sum_{k=0}^{\infty} \|X^k\| \leq \sum_{k=0}^{\infty} \|X\|^k = \frac{1}{1 - \|X\|},$$

где для бесконечных сумм неравенство треугольника может быть обосновано предельным переходом по аналогичным неравенствам для конечных сумм. Это завершает доказательство предложения. $\blacksquare$

Матричный ряд Неймана является простейшим из матричных степенных рядов, т. е. сумм вида

$$\sum_{k=0}^{\infty} c_k X^k$$

для какого-то счётного набора коэффициентов c_k , $k = 0, 1, 2, \dots$. С помощью матричных степенных рядов можно определять значения аналитических функций от матриц, например, логарифм от матрицы. Мы далее не будем касаться этой важной и интересной темы, находящей многочисленные приложения: она развивается в рамках так называемой теории представлений линейных операторов.

3.2ж Число обусловленности матриц

Рассмотрим систему линейных алгебраических уравнений

$$Ax = b$$

с неособенной квадратной матрицей A и вектором правой части $b \neq 0$, а также систему

$$(A + \Delta A) \tilde{x} = b + \Delta b,$$

где $\Delta A \in \mathbb{R}^{n \times n}$ и $\Delta b \in \mathbb{R}^n$ — возмущения матрицы и вектора правой части. Насколько сильно решение $\tilde{x}$ возмущённой системы может отличаться от решения x исходной системы уравнений?

Пусть $\tilde{x} = x + \Delta x$, так что

$$(A + \Delta A)(x + \Delta x) = b + \Delta b.$$

Вычитая из этого уравнения исходное невозмущённое уравнение, получим

$$(\Delta A)x + (A + \Delta A)\Delta x = \Delta b, \quad (3.17)$$

или

$$(\Delta A)(x + \Delta x) + A\Delta x = \Delta b,$$

так что

$$\Delta x = A^{-1}(-(\Delta A)\tilde{x} + \Delta b).$$

Беря нормы от обеих частей этого соотношения, получаем

$$\|\Delta x\| \leq \|A^{-1}\| \cdot (\|\Delta A\| \|\tilde{x}\| + \|\Delta b\|)$$

при согласовании векторных и матричных норм. Поделив обе части на $\|\tilde{x}\| > 0$, придём к неравенству

$$\begin{aligned} \frac{\|\Delta x\|}{\|\tilde{x}\|} &\leq \|A^{-1}\| \cdot \left(\|\Delta A\| + \frac{\|\Delta b\|}{\|\tilde{x}\|} \right) \\ &= \|A^{-1}\| \|A\| \cdot \left(\frac{\|\Delta A\|}{\|A\|} + \frac{\|\Delta b\|}{\|A\| \cdot \|\tilde{x}\|} \right). \end{aligned} \quad (3.18)$$

Это весьма практичная апостериорная³ оценка относительной ошибки решения в зависимости от относительных ошибок в матрице A и правой части b , коль скоро $\|A\| \cdot \|\tilde{x}\| \geq \|A\tilde{x}\| \approx \|b\|$ и потому знаменатель второго слагаемого в скобках из правой части неравенства примерно равен $\|b\|$. Эту оценку удобно применять после того, как приближённое решение системы уже найдено. Фигурирующая в оценке (3.18) величина $\|A^{-1}\| \|A\|$, на которую суммарно умножаются ошибки в матрице и правой части, имеет своё собственное название, так как играет важнейшую роль в вычислительной линейной алгебре.

Определение 3.2.5 Для квадратной неособенной матрицы A величина $\|A^{-1}\| \|A\|$ называется её числом обусловленности (относительно выбранной нормы матриц).

Мы будем обозначать число обусловленности матрицы A посредством $\text{cond}(A)$, иногда с индексом, указывающим выбор нормы. Если же матрица A особенна, то удобно положить $\text{cond}(A) = +\infty$.

Выведем теперь *априорную* оценку погрешности, которая не будет опираться на знание вычисленного решения и годится для получения оценки *до* решения СЛАУ.⁴

После вычитания точного уравнения из приближённого мы получили (3.17)

$$(\Delta A)x + (A + \Delta A)\Delta x = \Delta b.$$

³От латинского словосочетания «a posteriori», означающего знание, полученное из опыта.

⁴От латинского словосочетания «a priori», означающего в философии знание, полученное до опыта и независимо от него.

Отсюда

$$\begin{aligned}\Delta x &= (A + \Delta A)^{-1}(-(\Delta A)x + \Delta b) \\ &= (A(I + A^{-1}\Delta A))^{-1}(-(\Delta A)x + \Delta b) \\ &= (I + A^{-1}\Delta A)^{-1}A^{-1}(-(\Delta A)x + \Delta b).\end{aligned}$$

Беря нормы от обеих частей этого равенства и пользуясь субмультипликативностью нормы и неравенством треугольника, получим

$$\|\Delta x\| \leq \|I + A^{-1}\Delta A\|^{-1} \cdot \|A^{-1}\| \cdot (\|\Delta A\| \|x\| + \|\Delta b\|),$$

откуда после деления обеих частей на $\|x\| > 0$:

$$\frac{\|\Delta x\|}{\|x\|} \leq \|(I + A^{-1}\Delta A)^{-1}\| \cdot \|A^{-1}\| \cdot \left(\|\Delta A\| + \frac{\|\Delta b\|}{\|x\|}\right).$$

Если возмущение ΔA матрицы A не слишком велико, так что

$$\|A^{-1}\Delta A\| \leq \|A^{-1}\| \|\Delta A\| < 1,$$

то обратная матрица $(I + A^{-1}\Delta A)^{-1}$ разлагается в матричный ряд Неймана (3.15), и мы можем воспользоваться вытекающей из этого оценкой (3.16). Тогда

$$\begin{aligned}\frac{\|\Delta x\|}{\|x\|} &\leq \frac{\|A^{-1}\|}{1 - \|A^{-1}\| \|\Delta A\|} \cdot \left(\|\Delta A\| + \frac{\|\Delta b\|}{\|x\|}\right) \\ &= \frac{\|A^{-1}\| \cdot \|A\|}{1 - \|A^{-1}\| \|\Delta A\|} \cdot \left(\frac{\|\Delta A\|}{\|A\|} + \frac{\|\Delta b\|}{\|A\| \|x\|}\right) \\ &\leq \frac{\text{cond}(A)}{1 - \text{cond}(A) \cdot \frac{\|\Delta A\|}{\|A\|}} \cdot \left(\frac{\|\Delta A\|}{\|A\|} + \frac{\|\Delta b\|}{\|b\|}\right),\end{aligned}\tag{3.19}$$

поскольку $\|A\| \|x\| \geq \|Ax\| = \|b\|$.

Оценка (3.19) — важная априорная оценка относительной погрешности численного решения системы линейных алгебраических уравнений через оценки относительных погрешностей матриц и правой части.

Если величина $\|\Delta A\|$ достаточно мала, то множитель усиления относительной ошибки в данных

$$\frac{\text{cond}(A)}{1 - \text{cond}(A) \cdot \frac{\|\Delta A\|}{\|A\|}}$$

близок к числу обусловленности матрицы A .

Понятие числа обусловленности матрицы и полученные с его помощью оценки имеют большое теоретическое значение, но их практическая полезность напрямую зависит от наличия эффективных способов вычисления или хотя бы оценивания числа обусловленности матриц. Фактически, определение числа обусловленности требует знания некоторых характеристик обратной матрицы, и в случае общих матричных норм удовлетворительного решения задачи оценивания $\text{cond}(A)$ не существует до сих пор.

Тем не менее, существует практически важный частный случай, когда нахождение числа обусловленности матрицы может быть вполне достаточно эффективно. Это случай спектральной матричной нормы $\|\cdot\|_2$, подчинённой евклидовой норме векторов.

Напомним, что если λ — собственное значение квадратной неособенной матрицы, то λ^{-1} — это собственное значение обратной матрицы, отвечающее тому же собственному вектору: если C — $n \times n$ -матрица и $Cv = \lambda v$, то $v = \lambda C^{-1}v \Rightarrow C^{-1}v = \lambda^{-1}v$. Применяя это соображение к матрице $A^T A$, можем заключить, что если $\lambda_1, \lambda_2, \dots, \lambda_n$ — её собственные значения, то у обратной матрицы $(A^T A)^{-1} = A^{-1}(A^T)^{-1}$ собственными значениями являются $\lambda_1^{-1}, \lambda_2^{-1}, \dots, \lambda_n^{-1}$. Но $A^{-1}(A^T)^{-1} = A^{-1}(A^{-1})^T$, а потому в силу Предложения 3.1.1 выписанные числа $\lambda_1^{-1}, \lambda_2^{-1}, \dots, \lambda_n^{-1}$ образуют набор квадратов сингулярных чисел матрицы A^{-1} . Следовательно, сингулярные числа матрицы A суть обратные величины для сингулярных чисел матрицы A^{-1} .

В частности, для любой неособенной квадратной матрицы A справедливо равенство $\sigma_{\max}(A^{-1}) = \sigma_{\min}^{-1}(A)$, и поэтому относительно спектральной нормы число обусловленности матрицы есть

$$\text{cond}_2(A) = \frac{\sigma_{\max}(A)}{\sigma_{\min}(A)}.$$

Этот результат помогает понять большую роль сингулярных чисел и важность алгоритмов для их нахождения в современной вычислитель-

ной линейной алгебре. В совокупности с ясным геометрическим смыслом евклидовой векторной нормы (2-нормы) это вызывает преимущество использования этих норм для ряда задач, как в теории, так и на практике.

Наконец, если матрица A симметрична, то её сингулярные числа совпадают с модулями собственных значений, и тогда

$$\text{cond}_2(A) = \frac{\max_i |\lambda_i(A)|}{\min_i |\lambda_i(A)|} \quad (3.20)$$

— спектральное число обусловленности равно отношению наибольшего и наименьшего по модулю собственных значений матрицы. Для симметричных положительно определённых матриц эта формула принимает совсем простой вид

$$\text{cond}_2(A) = \frac{\lambda_{\max}(A)}{\lambda_{\min}(A)}.$$

3.23 Примеры хорошообусловленных и плохообусловленных матриц

Условимся называть матрицу *хорошо обусловленной*, если её число обусловленности невелико. Напротив, если число обусловленности матрицы велико, станем говорить, что матрица *плохо обусловлена*. Естественно, что эти определения имеют неформальный характер, так как зависят от нестрогих понятий «невелико» и «велико». Тем не менее, они весьма полезны в практическом отношении, в частности, потому, что позволяют сделать наш язык более выразительным.

Отметим, что для любой подчинённой матричной нормы

$$\text{cond}(A) = \|A^{-1}\| \|A\| \geq \|A^{-1}A\| = \|I\| = 1,$$

так что соответствующее число обусловленности матрицы всегда не меньше единицы.

Примером матриц, обладающих наилучшей возможной обусловленностью относительно спектральной нормы, являются ортогональные матрицы, для которых $\text{cond}_2 Q = 1$. Действительно, если Q ортогональна, то $\|Qx\|_2 = \|x\|_2$ для любого вектора x . Следовательно, $\|Q\|_2 = 1$. Кроме того, $Q^{-1} = Q^T$ и тоже ортогональна, а потому $\|Q^{-1}\|_2 = 1$.

Самым популярным примером плохообусловленных матриц являются, пожалуй, матрицы Гильберта $H_n = (h_{ij})$, которые встретились

нам в §2.5б при обсуждении среднеквадратичного приближения алгебраическими полиномами на интервале $[0, 1]$. Это симметричные матрицы, образованные элементами

$$h_{ij} = \frac{1}{i+j-1}, \quad i, j = 1, 2, \dots, n,$$

так что, к примеру,

$$H_3 = \begin{pmatrix} 1 & \frac{1}{2} & \frac{1}{3} \\ \frac{1}{2} & \frac{1}{3} & \frac{1}{4} \\ \frac{1}{3} & \frac{1}{4} & \frac{1}{5} \end{pmatrix}.$$

Число обусловленности матриц Гильберта исключительно быстро растёт в зависимости от их размера n . Воспользовавшись какими-либо системами компьютерной математики (например, Scilab, МАТЛАВ и им подобными), нетрудно найти следующие числовые данные:

$$\text{cond}_2 H_2 = 19.3,$$

$$\text{cond}_2 H_3 = 524,$$

$$\dots$$

$$\text{cond}_2 H_{10} = 1.6 \cdot 10^{13},$$

$$\dots$$

Существует общая формула [70, 69] :

$$\text{cond}_2 H_n = O\left(\frac{(1+\sqrt{2})^{4n}}{\sqrt{n}}\right) \approx O(34^n/\sqrt{n}),$$

где O — «о большое», известный из математического анализа символ Э.Ландау. Интересно, что матрицы, обратные к матрицам Гильберта имеют целочисленные элементы [65], которые также очень быстро растут с размерностью.

На этом фоне для матрицы Вандермонда (2.3) оценка числа обусловленности (см. [50])

$$\text{cond}_2 V(x_0, x_1, \dots, x_n) \geq \sqrt{2} \frac{(1+\sqrt{2})^{n-1}}{\sqrt{n+1}}$$

представляется даже не слишком плохой.⁵ Но она и не хороша, а опыт реальных вычислений свидетельствует о том, что ошибки в линейных системах с матрицей Вандермонда могут весьма сильно влиять на ответ.

3.2и Практическое применение числа обусловленности матриц

Оценки (3.18) и (3.19) на возмущения решений систем линейных алгебраических уравнений являются неумлучшаемыми на всём множестве матриц, векторов правых частей и их возмущений. Но «плохая обусловленность» матрицы не всегда означает высокую чувствительность решения конкретной системы по отношению к тем или иным конкретным возмущениям. Если, к примеру, правая часть имеет нулевые компоненты в направлении сингулярных векторов, отвечающих наименьшим сингулярным числам матрицы системы, то решение СЛАУ зависит от возмущений этой правой части гораздо слабее, чем показывает оценка (3.19) (см., к примеру, §3.7 книги [39]). И определение того, какая конкретно у нас правая часть — плохая или не очень — не менее трудно, чем само решение данной системы линейных уравнений.

Из сказанного должна вытекать известная осторожность и осмотрительность по отношению к выводам, которые делаются о практической разрешимости и достоверности решений какой-либо системы линейных уравнений лишь на основании того, велико или мало число обусловленности их матрицы.

Тривиальный пример: число обусловленности диагональной матрицы может быть сколь угодно большим, но решение СЛАУ с такими матрицами почти никаких проблем не вызывает!

Наконец, число обусловленности малоприспособно для оценки разброса решения СЛАУ при значительных и больших изменениях элементов матрицы и правой части (скажем, начиная с нескольких процентов от исходного значения). Получаемые при этом с помощью оценок (3.18) и (3.19) результаты типично завышены во много раз, и для решения упомянутой задачи более предпочтительны методы интервального анализа (см., к примеру, [64]).

⁵ Аналогичные по смыслу, но более слабые экспоненциальные оценки снизу для числа обусловленности матрицы Вандермонда выводятся также в книге [39].

Пример 3.2.1 Рассмотрим 2×2 -систему линейных уравнений

$$\begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix} x = \begin{pmatrix} b_1 \\ b_2 \end{pmatrix}$$

в которой элементы матрицы и правой части заданы приближённо и могут принимать значения из интервалов

$$\begin{aligned} a_{11} &\in [2, 4], & a_{12} &\in [-2, 0], & b_1 &\in [-1, 1] \\ a_{21} &\in [-1, 1], & a_{22} &\in [2, 4], & b_2 &\in [0, 2]. \end{aligned}$$

При этом обычно говорят [64], что задана *интервальная система линейных алгебраических уравнений*

$$\begin{pmatrix} [2, 4] & [-2, 0] \\ [-1, 1] & [2, 4] \end{pmatrix} x = \begin{pmatrix} [-1, 1] \\ [0, 2] \end{pmatrix} \quad (3.21)$$




Рис. 3.4. Множество решений интервальной линейной системы (3.21).

Множеством её решений называют множество, образованное всевозможными решениями систем линейных алгебраических уравнений той же структуры, коэффициенты матрицы и компонентны правой части которой принадлежат заданным интервалам. В частности, множество решений рассматриваемой нами системы (3.21) изображено на Рис. 3.4. Мы более подробно рассматриваем интервальные линейные системы уравнений в §4.5.

Подсчитаем оценки возмущений решения системы (3.21), которые получаются на основе числа обусловленности. Её можно рассматривать, как систему, получающуюся путём возмущения «средней системы»

$$\begin{pmatrix} 3 & -1 \\ 0 & 3 \end{pmatrix} x = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$$

на величину

$$\Delta A = \begin{pmatrix} \Delta a_{11} & \Delta a_{12} \\ \Delta a_{21} & \Delta a_{22} \end{pmatrix}, \quad \|\Delta A\|_{\infty} \leq 2,$$

в матрице и величину

$$\Delta b = \begin{pmatrix} \Delta b_1 \\ \Delta b_2 \end{pmatrix}, \quad \|\Delta b\|_{\infty} \leq 1,$$

в правой части.

Обусловленность средней матрицы относительно ∞ -нормы равна 1.778, ∞ -норма средней матрицы равна 4, а ∞ -норма средней правой части — это 1. Следовательно, по формуле (3.19) получаем

$$\frac{\|\Delta x\|}{\|x\|} \lesssim 24.$$

Поскольку решение средней системы есть $\tilde{x} = (1/3, 1/9)^T$, имеющее ∞ -норму $\frac{1}{3}$, то оценкой разброса решений рассматриваемой системы уравнений является $\tilde{x} \pm \Delta x$, где $\|\Delta x\|_{\infty} \leq 8$, т. е. двумерный брус

$$\begin{pmatrix} [-7.667, 8.333] \\ [-7.889, 8.111] \end{pmatrix}.$$

По размерам он в более чем в 4 (четыре) раза превосходит оптимальные (точные) покоординатные оценки множества решений, равные

$$\begin{pmatrix} [-1, 3] \\ [-0.5, 2.5] \end{pmatrix}.$$

При использовании других норм результаты, даваемые формулой (3.19), совершенно аналогичны своей грубостью оценивания возмущений решений. ■

Отметим в заключение этой темы, что задача оценивания разброса решений СЛАУ при вариациях входных данных является в общем случае NP-трудной, т. е. требует для своего решения экспоненциально больших трудозатрат [66, 67].

3.3 Прямые методы решения систем линейных алгебраических уравнений

Решение систем линейных алгебраических уравнений вида

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n = b_1, \\ a_{21}x_1 + a_{22}x_2 + \dots + a_{2n}x_n = b_2, \\ \vdots \quad \quad \quad \ddots \quad \quad \quad \vdots \quad \quad \quad \vdots \\ a_{n1}x_1 + a_{n2}x_2 + \dots + a_{nn}x_n = b_n, \end{cases} \quad (3.22)$$

с коэффициентами a_{ij} и свободными членами b_i , или, в краткой форме,

$$Ax = b \quad (3.23)$$

с $m \times n$ -матрицей $A = (a_{ij})$ и m -вектором правой части $b = (b_i)$, является важной математической задачей. Она встречается как сама по себе, так и в качестве составного элемента в технологической цепочке решения более сложных задач. Например, решение нелинейных уравнений или систем уравнений часто сводится к последовательности решений линейных систем (метод Ньютона).

По характеру вычислительного алгоритма методы решения уравнений и систем уравнений традиционно разделяют на *прямые* и *итерационные*. В прямых методах искомое решение получается в результате выполнения конечной последовательности действий, так что эти методы нередко называют ещё *конечными* или даже *точными*. Напротив, в итерационных методах решение достигается как предел некоторой последовательности приближений, которая конструируется по решаемой системе.

Идея, лежащая в основе большинства прямых методов для решения систем линейных алгебраических уравнений, состоит в том, чтобы эквивалентными преобразованиями привести решаемую систему к наиболее простому виду, из которого решение находится уже непосредственно. В качестве простейших могут выступать системы с диагональными, двухдиагональными, треугольными и т. п. матрицами. Чем меньше

ненулевых элементов остаётся в матрице преобразованной системы, тем проще и устойчивее её решение, но, с другой стороны, тем сложнее и неустойчивее приведение к такому виду. На практике обычно стремятся к компромиссу между этими взаимно противоположными требованиями. Мы, в основном, рассмотрим методы, основанные на приведении к треугольному виду.

Наконец, для простоты мы далее подробно разбираем случай систем уравнений, в которых число неизвестных n равно числу уравнений m , т. е. имеющих квадратную $n \times n$ -матрицу коэффициентов.

3.3а Решение треугольных линейных систем

Напомним, что *треугольными матрицами* называют матрицы, у которых все элементы ниже главной диагонали либо все элементы выше главной диагонали нулевые (так что ненулевые элементы образуют треугольник):

$$U = \begin{pmatrix} \times & \times & \cdots & \times & \times \\ & \times & \ddots & \times & \times \\ & & \ddots & \vdots & \vdots \\ 0 & & & \times & \times \\ & & & & \times \end{pmatrix}, \quad L = \begin{pmatrix} \times & & & & \\ \times & \times & & & 0 \\ \times & \times & \ddots & & \\ \vdots & \vdots & \ddots & \times & \\ \times & \times & \cdots & \times & \times \end{pmatrix},$$

где крестиками « $\times$ » обозначены ненулевые элементы. В первом случае говорят о *верхней* (или *правой*) треугольной матрице, а во втором — о *нижней* (или *левой*) треугольной матрице. Соответственно, *треугольными* называются системы линейных алгебраических уравнений, матрицы которых имеют треугольный вид — верхний или нижний.

Рассмотрим для определённости линейную систему $Lx = b$ с нижней треугольной матрицей $L = (l_{ij})$, $l_{ij} = 0$ при $j > i$. Её первое уравнение содержит только одну неизвестную переменную x_1 . Найдём её значение и подставим его во второе уравнение системы, в котором в результате останется также всего одна неизвестная переменная x_2 . Вычислим x_2 и затем подставим известные значения x_1 и x_2 . И так далее. Решение линейной системы с нижней треугольной матрицей выполняется по следующему простому алгоритму

```
DO FOR  i = 1 TO  n

      
$$x_i \leftarrow \left( b_i - \sum_{j < i} l_{ij} x_j \right) / l_{ii}$$


END DO
```

(3.24)

позволяющему последовательно друг за другом вычислить искомые значения неизвестных переменных, начиная с первой. Естественнo назвать этот процесс *прямой подстановкой*, коль скоро он выполняется по возрастанию индексов компонент вектора неизвестных x . Аналогичный процесс для верхних треугольных систем называется *обратной подстановкой* — он идёт в обратном направлении, т. е. от x_n к x_1 .

3.36 Метод Гаусса для решения линейных систем уравнений

Хорошо известно, что умножение какого-либо уравнения системы на ненулевое число, а также сложение уравнений системы приводят к равносильной системе уравнений. Воспользуемся этими свойствами для преобразования решаемой системы линейных алгебраических уравнений к более простому виду.

Предположим, что в системе линейных уравнений $Ax = b$ коэффициент $a_{11} \neq 0$. Умножим первое уравнение системы на $(-a_{21}/a_{11})$ и сложим со вторым уравнением. При этом коэффициент a_{21} во втором уравнении занулится, а получившаяся система будет совершенно равносильна исходной.

Проделаем подобное преобразование с остальными — 3-м, 4-м и т. д. до n -го уравнения системы, т. е. будем умножать первое уравнение на $(-a_{i1}/a_{11})$ и складывать с i -ым уравнением системы. В результате получим равносильную исходной систему линейных алгебраических уравнений, в которой неизвестная переменная x_1 присутствует лишь в первом уравнении. Матрица получившейся СЛАУ станет выглядеть

следующим образом

$$\left(\begin{array}{c|ccccc} \times & \times & \times & \cdots & \times \\ \hline 0 & \times & \times & \cdots & \times \\ 0 & \times & \times & \ddots & \vdots \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & \times & \times & \cdots & \times \end{array} \right).$$

Рассмотрим теперь в преобразованной системе уравнения со 2-го по n -е. Они образуют квадратную $(n-1) \times (n-1)$ -систему линейных уравнений, к которой, если элемент на месте $(2, 2)$ не сделался равным нулю, можно заново применить вышеописанную процедуру исключения. Её результатом будет обнуление поддиагональных элементов 2-го столбца матрицы СЛАУ. И так далее.

Выполнив $(n-1)$ шагов подобного процесса — с 1-м, 2-м, $\dots$, $n-1$ -м столбцами матрицы данной системы, мы получим, в конце концов, линейную систему с верхней треугольной матрицей, которая несложно решается с помощью обратной подстановки. Описанное преобразование системы линейных алгебраических уравнений к равносильному треугольному виду называется *прямым ходом* метода Гаусса, и его псевдокод выглядит следующим образом:

```

DO FOR  $j = 1$  TO  $n - 1$ 
    DO FOR  $i = j + 1$  TO  $n$ 
         $r_{ij} \leftarrow a_{ij} / a_{jj}$ 
        DO FOR  $k = j + 1$  TO  $n$ 
             $a_{ik} \leftarrow a_{ik} - r_{ij} a_{jk}$ 
        END DO
         $b_i \leftarrow b_i - r_{ij} b_j$ 
    END DO
END DO

```

(3.25)

Он выражает процесс последовательного обнуления поддиагональных элементов j -го столбца матрицы системы A , $j = 1, 2, \dots, n-1$, и со-

ответствующие преобразования вектора b . Матрица системы при этом приводится к верхнему треугольному виду. Далее следует *обратный ход* метода Гаусса, который является процессом обратной подстановки для решения полученной верхней треугольной системы:

```
DO FOR  i = n  TO  1  STEP  (-1)

      
$$x_i \leftarrow \left( b_i - \sum_{j>i} a_{ij}x_j \right) / a_{ii} ,$$


END DO
```

(3.26)

Он позволяет последовательно вычислить, в обратном порядке, искоемые значения неизвестных, начиная с n -ой. Отметим, что в нашем псевдокоде прямого хода метода Гаусса зануление поддиагональных элементов уже учтено нижними границами внутренних циклов.

Отметим, что существует много различных версий метода Гаусса. Весьма популярной является, к примеру, вычислительная *схема единственного деления*. При её выполнении сначала делят первое уравнение системы на $a_{11} \neq 0$, что даёт

$$x_1 + \frac{a_{12}}{a_{11}}x_2 + \cdots + \frac{a_{1n}}{a_{11}}x_n = \frac{b_1}{a_{11}}. \quad (3.27)$$

Умножая затем уравнение (3.27) на a_{i1} и вычитая результат из i -го уравнения системы для $i = 2, 3, \dots, n$, добиваются обнуления поддиагональных элементов первого столбца. Затем процедура повторяется в отношении 2-го уравнения и 2-го столбца полученной СЛАУ, и так далее.

Схема единственного деления совершенно эквивалентна алгоритму (3.25) и отличается от него лишь тем, что для каждого столбца деление в ней выполняется действительно только один раз, тогда как все остальные операции — это умножение и сложение. С другой стороны, уравнения преобразуемой системы в схеме единственного деления дополнительно масштабируются диагональными коэффициентами при неизвестных, и иногда это бывает нежелательно.

3.3в Матричная интерпретация метода Гаусса

Заметим, что умножение первого уравнения системы на $r_{i1} = -a_{i1}/a_{11}$ и сложение его с i -ым уравнением могут быть представлены в матричном виде как умножение системы $Ax = b$ слева на матрицу

$$\begin{pmatrix} 1 & & & & \\ 0 & 1 & & & \\ \vdots & & \ddots & & \\ r_{i1} & & & 1 & \\ \vdots & & & & 1 \\ 0 & & 0 & & 1 \end{pmatrix},$$

которая отличается от единичной матрицы наличием одного дополнительного ненулевого элемента r_{i1} на месте $(i, 1)$. Исключение поддиагональных элементов первого столбца матрицы СЛАУ — это последовательное домножение системы слева на матрицы

$$\begin{pmatrix} 1 & & & & \\ r_{21} & 1 & & & \\ 0 & & \ddots & & \\ \vdots & & & 1 & \\ 0 & 0 & & & 1 \end{pmatrix}, \quad \begin{pmatrix} 1 & & & & \\ 0 & 1 & & & \\ r_{31} & 0 & \ddots & & \\ \vdots & & & 1 & \\ 0 & 0 & & & 1 \end{pmatrix},$$

$$\text{и т. д. до } \begin{pmatrix} 1 & & & & \\ 0 & 1 & & & \\ \vdots & & \ddots & & \\ 0 & 0 & & 1 & \\ r_{n1} & 0 & & & 1 \end{pmatrix}.$$

Нетрудно убедиться, что умножение матриц выписанного выше ви-

да выполняется по простому правилу:

$$\begin{pmatrix} 1 & & & 0 \\ & 1 & & \\ r_{i1} & & \ddots & \\ & & & 1 \\ 0 & & & \ddots \\ & & & & 1 \end{pmatrix} \cdot \begin{pmatrix} 1 & & & 0 \\ & 1 & & \\ & & \ddots & \\ r_{k1} & & & 1 \\ 0 & & & \ddots \\ & & & & 1 \end{pmatrix} \\ = \begin{pmatrix} 1 & & & 0 \\ & 1 & & \\ r_{i1} & & \ddots & \\ & & & 1 \\ r_{k1} & 0 & & \ddots \\ & & & & 1 \end{pmatrix}.$$

Оно также остаётся верным в случае, когда у сомножителей в первом столбце на взаимнодополнительных местах присутствует более одного ненулевого элемента. Следовательно, обнуление поддиагональных элементов первого столбца и соответствующие преобразования правой части — это не что иное, как умножение обеих частей СЛАУ слева на матрицу

$$E_1 = \begin{pmatrix} 1 & & & 0 \\ r_{21} & 1 & & \\ r_{31} & 0 & 1 & \\ \vdots & & & \ddots \\ r_{n1} & 0 & & 1 \end{pmatrix}. \quad (3.28)$$

Аналогично, обнуление поддиагональных элементов j -го столбца матрицы СЛАУ и соответствующие преобразования правой части мож-

но интерпретировать как умножение системы слева на матрицу

$$E_j = \begin{pmatrix} 1 & & & & 0 \\ & \ddots & & & \\ & & 1 & & \\ 0 & r_{j+1,j} & 1 & & \\ & \vdots & & \ddots & \\ & r_{nj} & & & 1 \end{pmatrix}, \quad (3.29)$$

а в целом метод Гаусса представляется как последовательность умножений решаемой СЛАУ слева на матрицы E_j , $j = 1, 2, \dots, n-1$. При этом

$$E_{n-1} \cdots E_2 E_1 A = U \quad (3.30)$$

— верхней треугольной матрице.

Коль скоро все E_j — нижние треугольные матрицы, их произведение также является нижним треугольным. Кроме того, все E_j неособенны (нижние треугольные с единичной главной диагональю). Поэтому неособенно и их произведение $E_{n-1} \cdots E_2 E_1$. Обозначим

$$L = (E_{n-1} \cdots E_2 E_1)^{-1},$$

— нижняя треугольная матрица, для которой в силу (3.30) справедливо

$$A = LU$$

т. е. исходная матрица СЛАУ оказалась представленной в виде произведения нижней треугольной L и верхней треугольной U матриц. Это представление называют *LU-разложением матрицы* или *треугольным разложением*.

Соответственно, преобразования матрицы A в прямом ходе метода Гаусса можно трактовать как её разложение на нижний треугольный L и верхний треугольный U множители. В результате вместо решения исходной СЛАУ, равносильной

$$(LU)x = b,$$

мы можем выполнить два несложных решения треугольных систем линейных алгебраических уравнений

$$\begin{cases} Ly = b, \\ Ux = y \end{cases} \quad (3.31)$$

с помощью прямой и обратной подстановок соответственно.

Отметим, что при реализации метода Гаусса на компьютере можно хранить треугольные сомножители L и U на месте A , так как у L по диагонали стоят единицы.

3.3г Существование LU-разложения

И в прямом, и в обратном ходе метода Гаусса встречаются операции деления, которые не выполнимы в случае, если делитель равен нулю. Тогда не может быть выполнен и метод Гаусса в целом. Естественно задаться вопросом о достаточных условиях реализуемости метода Гаусса, или, иначе, условиях существования LU-разложения матрицы. Следующий простой результат даёт частичный ответ на него.

Теорема 3.3.1 Пусть $A = (a_{ij})$ — квадратная матрица и все её ведущие миноры отличны от нуля, т. е.

$$a_{11} \neq 0, \quad \det \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix} \neq 0, \quad \dots, \quad \det A \neq 0.$$

Тогда матрица A представима в виде

$$A = LU$$

— произведения нижней треугольной матрицы L и верхней треугольной матрицы U . Это разложение единственно при условии, что диагональными элементами в L являются единицы.

Доказательство мы проведём индукцией по размеру n матрицы A .

Если $n = 1$, то утверждение теоремы очевидно. Тогда матрицы $L = (l_{ij})$ и $U = (u_{ij})$ являются просто числами, и достаточно взять $l_{11} = 1$ и $u_{11} = a_{11}$.

Пусть теорема верна для матриц размера $(n - 1) \times (n - 1)$. Тогда представим $n \times n$ -матрицу A в блочном виде

$$A = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{pmatrix} = \begin{pmatrix} A_{n-1} & z \\ v & a_{nn} \end{pmatrix},$$

где A_{n-1} — $(n-1) \times (n-1)$ -подматрица A ,

z — вектор-столбец размера $n-1$,

v — вектор-строка размера $n-1$,

такие что

$$z = \begin{pmatrix} a_{1n} \\ a_{2n} \\ \vdots \\ a_{n-1,n} \end{pmatrix}, \quad v = (a_{n1} \ a_{n2} \ \dots \ a_{n,n-1}).$$

Требование разложения A на треугольные множители диктует равенство

$$A = \begin{pmatrix} A_{n-1} & z \\ v & a_{nn} \end{pmatrix} = \begin{pmatrix} L_{n-1} & 0 \\ x & l_{nn} \end{pmatrix} \cdot \begin{pmatrix} U_{n-1} & y \\ 0 & u_{nn} \end{pmatrix},$$

где L_{n-1}, U_{n-1} — $(n-1) \times (n-1)$ -матрицы,

x — вектор-строка размера $n-1$,

y — вектор-столбец размера $n-1$.

Следовательно, используя правила перемножения матриц по блокам,

$$A_{n-1} = L_{n-1}U_{n-1},$$

$$z = L_{n-1}y, \tag{3.32}$$

$$v = xU_{n-1}, \tag{3.33}$$

$$a_{nn} = xy + l_{nn}u_{nn}. \tag{3.34}$$

Первое из этих соотношений выполнено в силу индукционного предположения, причём оно должно однозначно определять L_{n-1} и U_{n-1} , если потребовать по диагонали в L_{n-1} единичные элементы. Далее, по условию теоремы $\det A_{n-1} \neq 0$, а потому матрицы L_{n-1} и U_{n-1} также должны быть неособенны. По этой причине системы линейных уравнений относительно x и y —

$$xU_{n-1} = v \quad \text{и} \quad L_{n-1}y = z,$$

которыми являются равенства (3.32)–(3.33), однозначно разрешимы. Найдя из них векторы x и y , мы сможем из соотношения (3.34) восстановить l_{nn} и u_{nn} . Если дополнительно потребовать $l_{nn} = 1$, то значение u_{nn} находится однозначно и совпадает с $(a_{nn} - xy)$. ■

В формулировке Теоремы 3.3.1 ничего не говорится о том, реализуем ли метод Гаусса для соответствующей системы линейных алгебраических уравнений. Но нетрудно понять, что в действительности требуемое Теоремой 3.3.1 условие отличия от нуля ведущих миноров в матрице СЛАУ является достаточным признаком выполнимости рассмотренного в §3.3б простейшего варианта метода Гаусса.

В самом деле, к началу j -го шага прямого хода, на котором предстоит обнулить поддиагональные элементы j -го столбца матрицы СЛАУ, её ведущей (верхней угловой) $j \times j$ -подматрицей является треугольная матрица, которая получена из исходной ведущей подматрицы преобразованиями метода Гаусса предыдущих $j - 1$ шагов. Эти преобразования — линейное комбинирование строк — не изменяют определителя, а потому неравенство нулю всех ведущих миноров влечёт отличие от нуля всех диагональных элементов ведущих подматриц преобразованной матрицы. В частности, при этом всегда $a_{jj} \neq 0$, так что деление на этот элемент в (3.25) выполнимо.

3.3д Метод Гаусса с выбором ведущего элемента

Ведущим элементом в методе Гаусса называют элемент матрицы решаемой системы, на который выполняется деление при исключении поддиагональных элементов очередного столбца.⁶ В алгоритме, описанном в §3.3б, ведущим всюду брался диагональный элемент a_{jj} , но, вообще говоря, при решении конкретных СЛАУ более предпочтительным может оказаться другой выбор ведущего элемента.

Условия Теоремы 3.3.1 заведомо выполнены, к примеру, для СЛАУ с положительно определёнными матрицами (в силу известного критерия Сильвестера), или если матрица СЛАУ имеет диагональное преобладание. Но в общем случае проверка условий этой теоремы является весьма непростой, поскольку вычисление ведущих миноров матрицы требует немалых трудозатрат, и, по существу, ничуть не проще самого метода Гаусса.

С другой стороны, зануление какого-либо ведущего минора может произойти и в неособенной матрице, так что сформулированный Теоремой 3.3.1 признак — это достаточное и довольно грубое условие. Вообще, желательно уметь выполнять метод Гаусса для СЛАУ с произволь-

⁶Иногда в русской математической литературе его называют *главным* элементом.

ными неособенными матрицами, что равносильно его модификации таким образом, чтобы ведущий элемент всегда был отличен от нуля.

Отметим, что изменение порядка уравнений в системе приводит к равносильной системе уравнений. При этом в матрице СЛАУ переставляются строки, так что она существенно меняется. Нельзя ли воспользоваться этим изменением для организации успешного выполнения метода Гаусса?

Частичным выбором ведущего элемента на j -ом шаге прямого хода метода Гаусса называют процесс его выбора, как максимального по модулю элемента из всех элементов столбца с тем же j -ым номером, лежащих на диагонали и ниже, и сопровождаемый соответствующей перестановкой строк матрицы и компонент правой части (т. е. уравнений СЛАУ).




Рис. 3.5. Структура матрицы СЛАУ перед началом j -го шага прямого хода метода Гаусса

Метод Гаусса с частичным выбором ведущего элемента всегда реализуем для системы линейных алгебраических уравнений с неособенной матрицей. В самом деле, в преобразованиях прямого хода метода Гаусса не изменяется свойство определителя матрицы быть равным нулю или не быть равным нулю и, как следствие, правая нижняя подматрица, которой предстоит быть преобразованной на оставшихся шагах метода Гаусса, имеет ненулевой определитель, т. е. в первом её столбце обязан найтись ненулевой элемент. Его и можно сделать ведущим.

Каково матричное представление метода Гаусса с выбором ведущего элемента?

Введём *матрицы транспозиции*

$$P = \begin{pmatrix} 1 & & & & & \\ & \ddots & & & & \\ & & 0 & \cdots & 1 & \\ & & 1 & & & \\ & \vdots & & \ddots & \vdots & \\ & 1 & \cdots & & 0 & \\ & & & & & \ddots \\ & & & & & & 1 \end{pmatrix} \begin{matrix} \\ \\ \leftarrow i\text{-ая строка} \\ \\ \\ \leftarrow j\text{-ая строка} \\ \\ \end{matrix}$$

— элементарные матрицы перестановок, которые получаются из единичной матрицы перестановкой двух её строк (или столбцов) с номерами i и j . Умножение на такую матрицу слева приводит к перестановке i -ой и j -ой строк, а умножение справа — к перестановке i -го и j -го столбцов. Тогда для метода Гаусса с частичным выбором ведущего элемента справедливо следующее матричное представление

$$(E_{n-1}P_{n-1}) \cdots (E_1P_1)A = U,$$

где $E_1, E_2, \dots, E_{n-1}$ — матрицы перестановок, при помощи которых выполняется перестановка строк на 1-м, 2-м, $\dots$, $(n-1)$ -м шагах метода Гаусса.

Несмотря на то, что метод Гаусса с частичным выбором ведущего элемента теоретически спасает положение, на практике для некоторых плохих СЛАУ он может работать не очень хорошо. По этой причине для обеспечения устойчивости вычислительного процесса по методу Гаусса иногда имеет смысл выбирать ведущий элемент более тщательно, чем это делается при частичном выборе

Ещё одним простым способом системы равносильного преобразования системы уравнений является перенумерация переменных. Ей соответствует перестановка строк матрицы, а вектор правых частей при этом неизменен.

Полным выбором ведущего элемента называют его выбор, как максимального по модулю элемента из всей правой нижней подматрицы, которой предстоит быть преобразованной на оставшихся шагах метода

Гаусса (а не только из её первого столбца, как было при частичном выборе), и сопровождаемый соответствующей перестановкой строк и столбцов матрицы и компонент правой части.

Напомним, что *матрицей перестановки* называется матрица, получающаяся из единичной матрицы перестановкой произвольного числа её строк (столбцов).

Теорема 3.3.2 *Для неособенной матрицы A существуют матрицы перестановок $\hat{P}$ и $\hat{P}$, такие что*

$$\hat{P}A\hat{P} = LU,$$

где L , U — нижняя и верхняя треугольные матрицы, причём диагональными элементами в L являются единицы. В этом представлении можно ограничиться лишь одной из матриц $\hat{P}$ или $\hat{P}$.

3.3е Число обусловленности и матричные преобразования

Пусть матрица A умножается на матрицу B . Как при этом изменяется число обусловленности получающейся матрицы?

Имеем

$$\begin{aligned}\|AB\| &\leq \|A\| \|B\|, \\ \|(AB)^{-1}\| &= \|B^{-1}A^{-1}\| \leq \|A^{-1}\| \|B^{-1}\|,\end{aligned}$$

и поэтому

$$\text{cond}(AB) = \|(AB)^{-1}\| \|AB\| \leq \text{cond } A \cdot \text{cond } B. \quad (3.35)$$

С другой стороны, если $C = AB$, то $A = CB^{-1}$, и в силу доказанного неравенства

$$\text{cond}(A) \leq \text{cond}(C) \cdot \text{cond}(B^{-1}) = \text{cond}(AB) \cdot \text{cond}(B),$$

когда скоро $\text{cond}(B^{-1}) = \text{cond}(B)$. Поэтому

$$\text{cond}(AB) \geq \text{cond}(A)/\text{cond}(B).$$

Аналогичным образом из $B = CA^{-1}$ следует

$$\text{cond}(AB) \geq \text{cond}(B)/\text{cond}(A).$$

Объединяя полученные неравенства, в целом получаем оценку

$$\text{cond}(AB) \geq \max \left\{ \frac{\text{cond}(A)}{\text{cond}(B)}, \frac{\text{cond}(B)}{\text{cond}(A)} \right\}. \quad (3.36)$$

Неравенства (3.35)–(3.36) кажутся грубыми, но они достижимы. В самом деле, пусть A — неособенная симметричная матрица с собственными значениями $\lambda_1, \lambda_2, \dots$ и числом обусловленности (стр. 150)

$$\frac{\max_i |\lambda_i(A)|}{\min_i |\lambda_i(A)|}.$$

Ясно, что у матрицы A^2 собственные векторы будут теми же, а собственные значения равны $\lambda_1^2, \lambda_2^2, \dots$, так что число обусловленности матрицы A^2 равно

$$\frac{\max_i (\lambda_i(A))^2}{\min_i (\lambda_i(A))^2} = \frac{\max_i |\lambda_i(A)|^2}{\min_i |\lambda_i(A)|^2} = \left(\frac{\max_i |\lambda_i(A)|}{\min_i |\lambda_i(A)|} \right)^2,$$

и в верхней оценке (3.35) получаем равенство. Нижняя оценка (3.36) достигается, к примеру, при $B = A^{-1}$.

Оценка (3.35) показывает, в частности, что при преобразованиях и разложениях матриц число обусловленности может существенно расти. Рассмотрим, к примеру, решение системы линейных алгебраических уравнений $Ax = b$ методом Гаусса в его матричной интерпретации. Обнуление поддиагональных элементов первого столбца матрицы A — это умножение исходной СЛАУ слева на матрицу E_1 , имеющую вид (3.28), так что мы получаем систему

$$(E_1 A) x = E_1 b \quad (3.37)$$

с матрицей $E_1 A$, число обусловленности которой оценивается как

$$\text{cond}(E_1 A) \leq \text{cond}(E_1) \text{cond}(A).$$

Далее мы обнуляем поддиагональные элементы второго, третьего и т. д. столбцов матрицы системы (3.37), умножая её слева на матрицы $E_2, E_3, \dots, E_{n-1}$ вида (3.29). В результате получаем верхнюю треугольную систему линейных уравнений

$$Ux = y,$$

в которой $U = E_{n-1} \dots E_2 E_1 A$, $y = E_{n-1} \dots E_2 E_1 b$, и число обусловленности матрицы U оценивается сверху как

$$\text{cond}(U) \leq \text{cond}(E_{n-1}) \cdot \dots \cdot \text{cond}(E_2) \cdot \text{cond}(E_1) \cdot \text{cond}(A). \quad (3.38)$$

Если E_j отлична от единичной матрицы, то $\text{cond}(E_j) > 1$, причём несмотря на специальный вид матриц E_j правая и левая части неравенства (3.38) могут отличаться не очень сильно (см. примеры ниже). Как следствие, обусловленность верхней треугольной матрицы U , а также матриц, в которые преобразуется матрица A исходной СЛАУ на промежуточных шагах прямого хода метода Гаусса, может быть существенно хуже, чем у исходной матрицы A .

Пример 3.3.1 Для 2×2 -матрицы (3.3)

$$A = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}$$

число обусловленности равно $\text{cond}_2(A) = 14.93$. Выполнение для неё преобразований прямого хода метода Гаусса приводит к матрице

$$\tilde{A} = \begin{pmatrix} 1 & 2 \\ 0 & -2 \end{pmatrix},$$

число обусловленности которой $\text{cond}_2(\tilde{A}) = 4.27$, т. е. уменьшается.

С другой стороны, для матрицы (3.4)

$$B = \begin{pmatrix} 1 & 2 \\ -3 & 4 \end{pmatrix},$$

число обусловленности $\text{cond}_2(B) = 2.62$. Преобразования метода Гаусса превращают её в матрицу

$$\tilde{B} = \begin{pmatrix} 1 & 2 \\ 0 & 10 \end{pmatrix},$$

для которой число обусловленности уже равно $\text{cond}_2(\tilde{B}) = 10.4$, т. е. существенно возрастает.

Числовые данные этого примера читатель может проверить с помощью систем компьютерной математики, таких как Scilab, MATLAB и им аналогичные. ■

Фактически, ухудшение обусловленности и, как следствие, всё большая чувствительность решения к погрешностям в данных — это дополнительная плата за приведение матрицы (и всей СЛАУ) к удобному для решения виду. Можно ли уменьшить эту плату? И если да, то как?

Хорошей идеей является привлечение для матричных преобразований ортогональных матриц, которые имеют наименьшую возможную обусловленность в спектральной норме (и небольшие числа обусловленности в других нормах). Умножение на такие матрицы, по крайней мере, не будет ухудшать обусловленность получающихся систем линейных уравнений и устойчивость их решений к ошибкам вычислений.

3.3ж QR-разложение матриц

Определение 3.3.1 Для матрицы A представление $A = QR$ в виде произведения ортогональной матрицы Q и правой треугольной матрицы R называется QR-разложением.

По поводу этого определения следует пояснить, что правая треугольная матрица — это то же самое, что верхняя треугольная матрица, которую мы условились обозначать U . Другая терминология обусловлена здесь историческими причинами, и частичное её оправдание состоит в том, что QR-разложение матрицы действительно «совсем другое», нежели LU-разложение. Впрочем, в математической литературе можно встретить тексты, где LU-разложение матрицы называется «LR-разложением» (от английских слов left-right), т. е. разложением на левую и правую треугольные матрицы.

Теорема 3.3.3 QR-разложение существует для любой квадратной матрицы.

Доказательство. Если A — неособенная матрица, то, как было показано при доказательстве Теоремы 3.3.4, $A^T A$ — симметричная положительно определённая матрица. Следовательно, существует её разложение Холесского

$$A^T A = R^T R,$$

где R — правая (верхняя) треугольная матрица. При этом R очевидно

неособенна. Тогда матрица $Q := AR^{-1}$ ортогональна, поскольку

$$\begin{aligned} Q^T Q &= (AR^{-1})^T AR^{-1} = (R^{-1})^T A^T A R^{-1} \\ &= (R^{-1})^T (R^T R) R^{-1} = ((R^{-1})^T R^T)(RR^{-1}) = I. \end{aligned}$$

Следовательно, в целом $A = QR$, где определённые выше сомножители Q и R удовлетворяют условиям теоремы.

Рассмотрим теперь случай особенной матрицы A . Известно, что любую особенную матрицу можно приблизить последовательностью неособенных. Например, это можно сделать с помощью матриц $A_k = A + \frac{1}{k}I$, начиная с достаточно больших натуральных номеров k . При этом собственные значения A_k суть $\lambda(A_k) = \lambda(A) + \frac{1}{k}$, и если величина $\frac{1}{k}$ меньше расстояния от нуля до ближайшего собственного значения A , то A_k неособенна.

В силу уже доказанного для всех матриц из последовательности $\{A_k\}$ существуют QR-разложения:

$$A_k = Q_k R_k,$$

где все Q_k ортогональны, а R_k — правые треугольные матрицы. В качестве ортогонального разложения для A можно было бы взять пределы матриц Q_k и R_k , если таковые существуют. Но сходятся ли куда-нибудь последовательности этих матриц при $k \rightarrow \infty$, когда $A_k \rightarrow A$? Ответ на это вопрос может быть отрицательным, а потому приходится действовать более тонко, выделяя из $\{A_k\}$ подходящую подпоследовательность.

Множество ортогональных матриц компактно, поскольку является замкнутым (прообраз единичной матрицы I при непрерывном отображении $X \mapsto X^T X$) и ограничено ($\|X\|_2 \leq 1$). Поэтому из последовательности ортогональных матриц $\{Q_k\}$ можно выбрать сходящуюся подпоследовательность $\{Q_{k_l}\}_{l=1}^\infty$. Ей соответствуют подпоследовательности $\{A_{k_l}\}$ и $\{R_{k_l}\}$, причём первая из них также сходится.

Обозначим $Q := \lim_{l \rightarrow \infty} Q_{k_l}$, и это также ортогональная матрица. Тогда

$$\lim_{l \rightarrow \infty} (Q_{k_l}^T A_{k_l}) = \lim_{l \rightarrow \infty} Q_{k_l}^T \cdot \lim_{l \rightarrow \infty} A_{k_l} = Q^T A = R$$

— правой треугольной матрице, поскольку все $Q_{k_l}^T A_{k_l}$ были правыми треугольными матрицами R_{k_l} . Таким образом, в целом снова $A = QR$ с ортогональной Q и правой треугольной R , как и требовалось. ■

Если известно QR-разложение матрицы A , то решение исходной СЛАУ, равносильной

$$(QR)x = b$$

сводится к решению треугольной системы линейных алгебраических уравнений

$$Rx = Q^T b. \quad (3.39)$$

Ниже в §3.8и мы встретимся и с другими важными применениями QR-разложения матриц — при численном решении проблемы собственных значений.

Хотя для неособенных матриц доказательство Теоремы 3.3.3 носит конструктивный характер, оно существенно завязано на разложение Холецкого, а потому находить с его помощью QR-разложение неудобно. На практике основным инструментом получения QR-разложения является техника, использующая так называемые матрицы отражения и матрицы вращения, описанию которых посвящены следующие пункты.

3.3з Ортогональные матрицы отражения

Определение 3.3.2 Для вектора $u \in \mathbb{R}^n$ с единичной евклидовой нормой, $\|u\|_2 = 1$, матрица $H = H(u) = I - 2uu^T$ называется матрицей отражений или матрицей Хаусхолдера. Вектор u называется порождающим для матрицы отражений $H(u)$ или вектором Хаусхолдера.

Предложение 3.3.1 Матрицы отражений являются ортогональными симметричными матрицами, причём

$$H(u) \cdot u = -u,$$

$$H(u) \cdot v = v \quad \text{для любого вектора } v \in \mathbb{R}^n, \text{ ортогонального } u.$$

Доказательство проводится непосредственной проверкой.

Симметричность матрицы $H(u)$:

$$\begin{aligned} H^T &= (I - 2uu^T)^T = I^T - (2uu^T)^T \\ &= I - 2(u^T)^T u^T = I - 2uu^T = H. \end{aligned}$$

Ортогональность:

$$\begin{aligned} H^T H &= (I - 2uu^T)(I - 2uu^T) \\ &= I - 2uu^T - 2uu^T + 4uu^T uu^T \\ &= I - 4uu^T + 4u(u^T u)u^T = I. \end{aligned}$$

Собственные векторы:

$$H(u) \cdot u = (I - 2uu^T)u = u - 2u(u^T u) = u - 2u = -u,$$

т. е. порождающий вектор u является собственным вектором матрицы отражения, отвечающим собственному значению -1 . Далее, если $u^T v = 0$, то

$$H(u) \cdot v = (I - 2uu^T)v = v - 2u(u^T v) = v,$$

т. е. любой вектор v , ортогональный порождающему вектору u , является собственным вектором матрицы отражения, отвечающим собственному значению 1 . ■




Рис. 3.6. Геометрическая интерпретация действия матрицы отражения.

Из последних двух свойств матриц отражения следует геометрическая интерпретация, которая мотивирует их название. Эти матрицы действительно осуществляют преобразование отражения вектора относительно гиперплоскости, ортогональной порождающему вектору u .

Чтобы убедиться в этом, представим произвольный вектор x в виде $\alpha u + v$, где u — порождающий матрицу отражения вектор, а v — ему ортогональный, т. е. $u^T v = 0$ (см. Рис. 3.6). Тогда

$$H(u) \cdot x = H(u) \cdot (\alpha u + v) = -\alpha u + v.$$

Предложение 3.3.2 Для любого ненулевого вектора $x \in \mathbb{R}^n$ существует матрица отражений, переводящая его в вектор, коллинеарный заданному вектору e единичной длины, $\|e\|_2 = 1$.

Доказательство. Если H — искомая матрица отражений, и u — порождающий её вектор Хаусхолдера, то утверждение предложения требует равенства

$$Hx = x - 2(uu^\top)x = \gamma e \quad (3.40)$$

с некоторым коэффициентом $\gamma \neq 0$. Отдельно рассмотрим два случая — когда векторы x и e неколлинеарны, и когда они коллинеарны друг другу.

В первом случае можно переписать (3.40) в виде равенства

$$2u(u^\top x) = x - \gamma e, \quad (3.41)$$

правая часть которого заведомо не равна нулю. Тогда и числовой множитель $u^\top x$ в левой части обязан быть ненулевым, и из соотношения (3.41) можно заключить, что

$$u = \frac{1}{2u^\top x}(x - \gamma e),$$

т.е. что вектор u , порождающий искомую матрицу отражения, должен быть коллинеарен вектору $(x - \gamma e)$.

Коэффициент γ можно определить из того соображения, что ортогональная матрица H не изменяет длин векторов, а потому, взяв евклидову норму от обеих частей равенства (3.40), получим

$$\|Hx\|_2 = \|x\|_2 = |\gamma|, \quad \text{т.е. } \gamma = \pm \|x\|_2.$$

Следовательно, вектор Хаусхолдера u коллинеарен вектору

$$\tilde{u} = x \pm \|x\|_2 e,$$

и для окончательного определения u остаётся лишь применить нормировку:

$$u = \frac{\tilde{u}}{\|\tilde{u}\|_2}.$$

Тогда $H = I - 2uu^\top$ — искомая матрица отражений.

Обсудим теперь случай, когда x коллинеарен e . Тогда предшествующая конструкция частично теряет смысл, так как вектор $\tilde{u} = x - \gamma e$

может занулиться при подходящем выборе знака множителя γ . Но даже если это произойдёт, существует ещё возможность выбора другого знака для γ , что спасает положение, поскольку при этом наверняка $x - \gamma e \neq 0$. Более строго можно сказать, что тогда конкретный знак у множителя $\gamma = \pm \|x\|_2$ выбирается из условия максимизации нормы вектора $(x - \gamma e)$.

С другой стороны, в случае коллинеарных векторов x и e мы можем указать явную формулу для вектора Хаусхолдера:

$$u = \frac{x}{\|x\|_2}.$$

При этом

$$u^\top x = \frac{x^\top x}{\|x\|_2} = \|x\|_2 \neq 0,$$

и для соответствующей матрицы отражений имеет место

$$Hx = x - 2(uu^\top)x = x - 2u(u^\top x) = x - 2\|x\|_2 \frac{x}{\|x\|_2} = -x.$$

Итак, условие предложения удовлетворено и в этом случае. ■

В доказательстве предложения присутствовала неоднозначность в выборе знака в выражении $\tilde{u} = x \pm \|x\|_2 e$, если x и e неколлинеарны. В действительности, годится любой знак, и его конкретный выбор может определяться, как мы увидим, удобством реализации.

3.3и Метод Хаусхолдера

В основе *метода Хаусхолдера* для решения систем линейных алгебраических уравнений (называемого также *методом отражений*) лежит та же идея, что и в методе Гаусса: привести эквивалентными преобразованиями исходную систему к треугольному виду, а затем воспользоваться обратной подстановкой (3.26). Но теперь это приведение выполняется более глубокими, чем в методе Гаусса, преобразованиями матрицы, именно, путём последовательного умножения на специальным образом подобранные матрицы отражений.

Предложение 3.3.3 *Для любой квадратной матрицы A существует конечная последовательность $H_1, H_2, \dots, H_{n-1}$ из матриц отражения u , возможно, единичных матриц, таких что матрица*

$$H_{n-1}H_{n-2} \cdots H_2H_1A = R$$

является правой треугольной матрицей.

Для формального описания алгоритма очень удобно применять систему обозначений матрично-векторных объектов, укоренившуюся в языках программирования высокого уровня Fortran, MATLAB, Scilab и др. В частности, посредством $A(p : q, r : s)$ обозначается *сечение* массива A , которое определяется как массив той же размерности с элементами, стоящими на пересечении строк с номерами с p по q и столбцов с номерами с r по s . То есть, диапазоны изменения индексов элементов A , из которых образована новая матрица, указаны в соответствующих позициях.

Доказательство предложения конструктивно.

Действительно, используя результат Предложения 3.3.2, возьмём в качестве H_1 матрицу отражений, которая переводит 1-й столбец A в вектор, коллинеарный $(1, 0, \dots, 0)^T$, если хотя бы один из элементов $a_{21}, a_{31}, \dots, a_{n1}$ не равен нулю. Иначе полагаем $H_1 = I$. Затем переходим к следующему шагу.

В результате выполнения первого шага матрица СЛАУ приводится, как и в методе Гаусса, к виду

$$\left(\begin{array}{c|cccc} \times & \times & \times & \cdots & \times \\ \hline 0 & \times & \times & \cdots & \times \\ 0 & \times & \times & \ddots & \vdots \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & \times & \times & \cdots & \times \end{array} \right).$$

где крестиками « $\times$ » обозначены ненулевые элементы. Прделаем теперь то же самое с матрицей $A(2 : n, 2 : n)$, обнулив у неё поддиагональные элементы первого столбца, который является вторым в исходной матрице. И т. д.

Далее определим $H_i, i = 2, 3, \dots, n-1$, как матрицу отражений, порождаемую вектором Хаусхолдера u_i , который имеет нулевыми первые $i-1$ компонент и подобран так, что H_i аннулирует поддиагональные элементы i -го столбца в матрице $H_{i-1} \cdots H_2 H_1 A$.

Можно положить

$$H_i = \left(\begin{array}{c|c} I & 0 \\ \hline 0 & \tilde{H}_i \end{array} \right),$$

где в верхнем левом углу стоит единичная матрица размера $(j-1) \times (j-1)$, а $\tilde{H}_i$ — матрица отражений размера $(n-j+1) \times (n-j+1)$, которая переводит вектор $A(j:n, j)$ в $(n-j+1)$ -вектор $(1, 0, \dots, 0)^T$, т. е. обнуляет поддиагональные элементы j -го столбца в A . ■

Таблица 3.1. Треугольное разложение матрицы
с помощью отражений Хаусхолдера

```
DO FOR  j = 1 TO  n - 1
    вычислить вектор Хаусхолдера u, отвечающий
    отражению, которое переводит вектор A(j : n, j)
    в (n - j + 1)-вектор (1, 0, ..., 0)T;
     $\tilde{H} \leftarrow I - 2uu^T$ ;
     $A(i : n, i : n) \leftarrow \tilde{H} A(i : n, i : n)$ 
END DO
```

При реализации описанного алгоритма даже не нужно формировать в явном виде матрицу отражений $\tilde{H}$, так как умножение на неё можно выполнить по экономичной формуле

$$(I - 2uu^T)A(i:n, i:n) = A(i:n, i:n) - 2u(u^T A(i:n, i:n)).$$

Определённым недостатком метода Хаусхолдера и описываемого в следующем пункте метода вращений в сравнении с методом Гаусса является привлечение неарифметической операции извлечения квадратного корня, которая приводит к иррациональностям. Это не позволяет реализовать алгоритмы в поле рациональных чисел, к примеру, в программных системах так называемых «безошибочных вычислений», которые оперируют рациональными дробями с целочисленными числителем и знаменателем.

3.3к Матрицы вращения

Матрицей вращения называется матрица $G(k, l, \theta)$ вида

$$\begin{pmatrix} 1 & & & & & \\ & \ddots & & & & \\ & & \cos \theta & \cdots & -\sin \theta & \\ & & & 1 & & \\ & & \vdots & & \ddots & \vdots \\ & & & & & 1 \\ \sin \theta & \cdots & & \cos \theta & & \\ & & & & \ddots & \\ & & & & & 1 \end{pmatrix}, \quad \begin{array}{l} \leftarrow k\text{-ая строка} \\ \leftarrow l\text{-ая строка} \end{array}$$

где все не выписанные явно элементы вне главной диагонали равны нулю. Таким образом, $G(k, l, \theta)$ — это матрица, которая отличается от единичной матрицы лишь элементами, находящимися в позициях (k, k) , (k, l) , (l, k) и (l, l) для данных натуральных индексов k, l . Нетрудно проверить, что она ортогональна.

Матрица

$$\begin{pmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{pmatrix}$$

задаёт, как известно, вращение плоскости на угол θ вокруг начала координат. Матрица $G(k, l, \theta)$ также задаёт вращение пространства $\mathbb{R}^n$ на угол θ вокруг оси, проходящей через начало координат и ортогональной гиперплоскости $0x_kx_l$. Матрицы вращения $G(k, l, \theta)$ называют также *матрицами Гивенса*, и мы будем обозначать их иногда посредством $G(k, l)$, если конкретная величина угла θ несущественна.

Если вектор $a = (a_1 \ a_2)^\top$ — ненулевой, то, взяв

$$\cos \theta = \frac{a_1}{\|a\|_2}, \quad \sin \theta = \frac{-a_2}{\|a\|_2}, \quad \text{где } \|a\|_2 = \sqrt{a_1^2 + a_2^2},$$

мы можем с помощью матрицы двумерного вращения занулить вторую компоненту вектора:

$$\begin{pmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{pmatrix} \begin{pmatrix} a_1 \\ a_2 \end{pmatrix} = \begin{pmatrix} \|a\|_2 \\ 0 \end{pmatrix}.$$




Рис. 3.7. Подходящим вращением можно занулить любую из компонент двумерного вектора.

Аналогично может быть занулена первая компонента a , путём домножения на матрицу вращения с

$$\cos \theta = \frac{a_2}{\|a\|_2}, \quad \sin \theta = \frac{a_1}{\|a\|_2}.$$

В общем случае умножение матрицы вращения $G(k, l, \theta)$ слева на любую матрицу A приводит к тому, что в произведении $G(k, l, \theta) A$ строки k -ая и l -ая становятся линейными комбинациями строк с этими же номерами из A . Как следствие рассуждений предшествующего абзаца, при умножении матрицы A слева на матрицу вращения $G(k, l, \theta)$ со специально подобранным θ можно получить нуль в произвольной наперёд заданной позиции k -ой или l -ой строки. Поэтому любая данная матрица A может быть приведена к правому треугольному виду R с помощью последовательности умножений на матрицы вращения. К примеру, мы можем один за другим занулить поддиагональные элементы первого столбца, потом второго, третьего и т.д., аналогично тому, как это делалось в методе Гаусса. При этом зануление поддиагональных элементов второго и последующих столбцов никак не испортит полученные ранее нулевые элементы предшествующих столбцов, так как линейное комбинирование нулей даст снова нуль. В целом, существует набор матриц вращения $G(1, 2)$, $G(1, 3)$, $\dots$, $G(1, n)$, $\dots$, $G(n-1, n)$, таких что

$$G(n-1, n) \cdots G(1, n) \cdots G(1, 3) G(1, 2) A = R$$

— правой треугольной матрице.

Это ещё один конструктивный способ получения QR-разложения, реализуемый даже более просто, чем метод отражений Хаусхолдера. Но для плотно заполненных матриц он в полтора раза более трудоёмок, чем разложение с помощью матриц отражения, хотя для разреженных матриц более предпочтителен в силу своей большей гибкости при занулении отдельных элементов.

3.3л Ортогонализация Грама-Шмидта

Ортогонализацией называют процесс построения по заданному базису линейного пространства некоторого ортогонального базиса, который имеет ту же самую линейную оболочку

по конечной линейно независимой системе векторов $v_1, v_2, \dots, v_n$ процесс Грама-Шмидта строит ортогональный базис $q_1, q_2, \dots, q_n$ линейной оболочки векторов $v_1, v_2, \dots, v_n$ в соответствии со следующими расчётными формулами:

$$q_k \leftarrow v_k - \sum_{i=1}^{k-1} \frac{\langle v_k, q_i \rangle}{\langle q_i, q_i \rangle} q_i, \quad k = 1, 2, \dots, n. \quad (3.42)$$

3.3м Метод Холесского

Напомним, что $n \times n$ -матрица называется положительно определённой, если $\langle Ax, x \rangle > 0$ для любых n -векторов x .

Теорема 3.3.4 *Матрица A является симметричной положительно определённой тогда и только тогда, когда существует неособенная нижняя треугольная матрица C , такая что $A = CC^\top$. При этом матрица C из выписанного представления единственна.*

Определение 3.3.3 *Представление $A = CC^\top$ называется разложением Холесского, а нижняя треугольная матрица C — множителем Холесского для A .*

Доказательство. Если $A = CC^\top$, причём C неособенна, то

$$\begin{aligned} \langle Ax, x \rangle &= (Ax)^\top x = x^\top A^\top x = x^\top (CC^\top)^\top x \\ &= x^\top CC^\top x = (C^\top x)^\top (C^\top x) = \|C^\top x\|_2^2 > 0 \end{aligned}$$

для всех ненулевых $x \in \mathbb{R}^n$. Кроме того, A симметрична по построению. Таким образом, она является симметричной положительно определённой матрицей.⁷

Обратно, пусть матрица A симметрична и положительно определена. В силу критерия Сильвестера все её ведущие миноры положительны, а потому на основании Теоремы 3.3.1 о существовании LU-разложения мы можем заключить, что $A = LU$ для некоторых неособенных нижней треугольной матрицы $L = (l_{ij})$ и верхней треугольной матрицы U . Мы дополнительно потребуем, чтобы все диагональные элементы l_{ii} в L были единицами, так что это разложение будет даже однозначно определённым.

Так как

$$LU = A = A^\top = (LU)^\top = U^\top L^\top,$$

то

$$U = L^{-1}U^\top L^\top,$$

и далее

$$U(L^\top)^{-1} = L^{-1}U^\top. \quad (3.43)$$

Слева в этом равенстве стоит произведение верхних треугольных матриц, а справа — произведение нижних треугольных. Равенство, следовательно, возможно, лишь в случае, когда левая и правая его части — это диагональная матрица, которую мы обозначим через $D = \text{diag}\{d_1, d_2, \dots, d_n\}$. Тогда из (3.43) вытекает

$$U = L^{-1}U^\top L^\top = DL^\top,$$

и потому

$$A = LU = LDL^\top. \quad (3.44)$$

Ясно, что в силу неособенности L и U матрица D также должна быть неособенна, так что по диагонали у неё стоят ненулевые элементы d_i , $i = 1, 2, \dots, n$. Более того, все d_i должны быть положительными. Если предположить противное, т.е. что $d_i \leq 0$ для некоторого i , то, беря i -ый столбец единичной матрицы в качестве вектора x , получим

$$\langle Ax, x \rangle = x^\top Ax = x^\top LDL^\top x = d_i \sum_{j \leq i} l_{ij}^2 \leq 0. \quad (3.45)$$

⁷Это рассуждение никак не использует факт треугольности C и обосновывает, в действительности, более общее утверждение: произведение матрицы на её транспонированную является положительно определённым.

Неравенство (3.45) очевидно противоречит положительной определённости матрицы A .

Как следствие, из диагональных элементов матрицы D можем извлекать квадратные корни. Если обозначить получающуюся при этом диагональную матрицу через $D^{1/2} = \text{diag} \{ \sqrt{d_1}, \sqrt{d_2}, \dots, \sqrt{d_n} \}$, то окончательно можем взять $C = LD^{1/2}$. Это представление для множителя Холецкого, в действительности, единственно, так как по A при сделанных нами предположениях единственным образом определяется нижняя треугольная матрица L , а матричные преобразования, приведшие к формуле (3.44) и её следствиям, также дают однозначно определённый результат. ■

Доказанная теорема мотивирует следующий прямой метод решения систем линейных уравнений, аналогичный (3.31). Если разложение Холецкого уже найдено, то решение исходной СЛАУ $Ax = b$, равносильной $CC^T x = b$, сводится к решению двух систем линейных уравнений с треугольными матрицами:

$$\begin{cases} Cy = b, \\ C^T x = y. \end{cases} \quad (3.46)$$

Для решения первой системы применяем прямую подстановку, а для решения второй системы — обратную.

Как конструктивно найти разложение Холецкого?

Для определения расчётных формул нового метода рассмотрим равенство

$$A = CC^T,$$

где

$$A = (a_{ij}), \quad C = \begin{pmatrix} c_{11} & & & 0 \\ c_{21} & c_{22} & & \\ \vdots & \vdots & \ddots & \\ c_{n1} & c_{n2} & \cdots & c_{nn} \end{pmatrix}.$$

В силу правил умножения матриц имеем

$$a_{ij} = \sum_{k=1}^j c_{ik}c_{jk} \quad \text{при } i \geq j,$$

или, в подробной записи,

$$\begin{aligned} c_{j1}^2 + c_{j2}^2 + \dots + c_{j,j-1}^2 + c_{jj}^2 &= a_{jj}, \\ c_{i1}c_{j1} + c_{i2}c_{j2} + \dots + c_{ij}c_{jj} &= a_{ij}, \quad i = j+1, \dots, n, \\ j &= 1, 2, \dots, n. \end{aligned} \quad (3.47)$$

Из выписанной системы уравнений, в действительности, можно находить в матрице C элементы c_{ij} последовательно друг за другом по столбцам. Именно,

$$\begin{aligned} \text{при } j = 1 \quad & \begin{cases} c_{11} = \sqrt{a_{11}}, \\ c_{i1} = a_{i1}/c_{11}, \quad i = 2, 3, \dots, n, \end{cases} \\ \text{при } j = 2 \quad & \begin{cases} c_{22} = \sqrt{a_{22} - c_{21}^2}, \\ c_{i2} = (a_{i2} - c_{i1}c_{21})/c_{22}, \quad i = 3, 4, \dots, n, \end{cases} \\ \dots & \quad \dots \end{aligned}$$

Псевдокод этого процесса выглядит следующим образом

```

DO FOR j = 1 TO n
    cjj ← (ajj - ∑k=1j-1 cjk2)1/2
    DO FOR i = j + 1 TO n
        cij ← (aij - ∑k=1j-1 cikcjk) / cjj
    END DO
END DO

```

(3.48)

Если A — симметричная положительно определённая матрица, то в силу доказанных выше результатов система (3.47) обязана иметь решение, и этот алгоритм успешно прорабатывает до конца, находя его. Если же матрица A не является положительно определённой, то алгоритм (3.48) аварийно прекращает работу при попытке извлечь корень

из отрицательного числа либо разделить на нуль. Это самый экономичный способ проверки положительной определённости симметричной матрицы.

Метод решения СЛАУ, основанный на разложении Холецкого и использующий соотношения (3.46) и алгоритм (3.48), называют *методом Холецкого*. Он был предложен в 1910 году А.-Л. Холецким в неопубликованной рукописи, которая, тем не менее, сделалась широко известной во французской геодезической службе. Позднее метод неоднократно переоткрывался, и потому иногда в связи с ним используются также термины «метод квадратного корня» или «метод квадратных корней», данные другими его авторами.

Замечательным свойством метода Холецкого является то, что обусловленность множителей Холецкого, вообще говоря, является лучшей, чем у исходной СЛАУ, так как равна корню квадратному из обусловленности исходной матрицы СЛАУ. То есть, в отличие от метода Гаусса, треугольные системы линейных уравнений из (3.46), к решению которых сводится задача, менее чувствительны к ошибкам, чем исходная линейная система.

3.3н Метод прогонки

До сих пор не делалось никаких дополнительных предположений о структуре нулевых и ненулевых элементов в матрице системы. Но для большого числа систем линейных уравнений, встречающихся в практике математического моделирования ненулевые элементы заполняют матрицу не полностью, образуя в ней те или иные правильные структуры — ленты, блоки, их комбинации и т. п. Естественно попытаться использовать это обстоятельство при конструировании более эффективных численных методов для решения СЛАУ с такими матрицами.

Метод прогонки, предложенный в 1952–53 годах И.М. Гельфандом и О.В. Локуциевским, предназначен для решения линейных систем уравнений с трёхдиагональными матрицами. Это важный в приложениях случай СЛАУ, возникающий, к примеру, при решении многих краевых задач для дифференциальных уравнений. По определению, трёхдиагональными называются матрицы, все ненулевые элементы которых сосредоточены на трёх диагоналях — главной и двух соседних с ней. Иными словами, для трёхдиагональной матрицы $A = (a_{ij})$ неравенство $a_{ij} \neq 0$ имеет место лишь при $i = j$ и $i = j \pm 1$.

Обычно трёхдиагональные системы линейных уравнений записыва-

ют в некотором каноническом виде, даже без обращения к матрично-векторной форме:

$$a_i x_{i-1} + b_i x_i + c_i x_{i+1} = d_i, \quad 1 \leq i \leq n, \quad (3.49)$$

причём полагают $a_1 = c_n = 0$. Подобный вид и обозначения оправдываются тем, что соответствующие СЛАУ получаются действительно «локально», как дискретизация дифференциальных уравнений, связывающих значения искомых величин также локально, в окрестности какой-либо рассматриваемой точки.

Например, в §2.4 мы могли видеть, что

$$u''(x) \approx \frac{u_{i-1} - 2u_i + u_{i+1}}{h^2},$$

и потому решение конечно-разностными методами краевых задач для различных дифференциальных уравнений второго порядка приводит к трёхдиагональным матрицам и системам с такими матрицами. Соотношения вида (3.49)

$$a_i x_{i-1} + b_i x_i + c_i x_{i+1} = d_i, \quad i = 1, 2, \dots,$$

называют также *трёхточечными разностными уравнениями* или *разностными уравнениями второго порядка*.

Для СЛАУ с трёхдиагональной матрицей прямой ход метода Гаусса без выбора ведущего элемента (т.е. без перестановок строк и столбцов матрицы) приводит к системе с двухдиагональной матрицей вида

$$\begin{pmatrix} \times & \times & & 0 \\ & \times & \ddots & \\ & & \ddots & \times \\ 0 & & & \times & \times \\ & & & & \times \end{pmatrix},$$

в которой ненулевые элементы присутствуют лишь на главной и первой верхней побочной диагоналях. Следовательно, формулы обратного хода метода Гаусса вместо (3.26) должны иметь следующий двучленный вид

$$x_i = \xi_{i+1} x_{i+1} + \eta_{i+1}, \quad i = n, n-1, \dots, 1, \quad (3.50)$$

где для единообразия формул рассматривается вспомогательная фиктивная компонента x_{n+1} вектора неизвестных. Оказывается, что величины ξ_i и η_i в соотношениях (3.50) можно несложным образом выразить через элементы исходной системы уравнений.

Уменьшим в (3.50) все индексы на единицу —

$$x_{i-1} = \xi_i x_i + \eta_i$$

— и подставим полученное соотношение в i -ое уравнение системы, получим

$$a_i(\xi_i x_i + \eta_i) + b_i x_i + c_i x_{i+1} = d_i.$$

Отсюда

$$x_i = -\frac{c_i}{a_i \xi_i + b_i} x_{i+1} + \frac{d_i - a_i \eta_i}{a_i \xi_i + b_i}.$$

Сравнивая эту формулу с двучленными расчётными формулами (3.50), можем заключить, что

$$\xi_{i+1} = -\frac{c_i}{a_i \xi_i + b_i}, \quad (3.51)$$

$$\eta_{i+1} = \frac{d_i - a_i \eta_i}{a_i \xi_i + b_i}, \quad (3.52)$$

для $i = 1, 2, \dots, n$. Это — формулы *прямого хода* прогонки. Вместе с формулами *обратного хода* (3.50) они определяют метод прогонки для решения систем линейных алгебраических уравнений с трёхдиагональной матрицей.

Для начала расчётов требуется знать величины ξ_1 и η_1 в прямом ходе и x_{n+1} — в обратном. Формально они неизвестны, но фактически полностью определяются условием $a_1 = c_n = 0$. Действительно, конкретные значения ξ_1 и η_1 не влияют на результаты решения, потому что в формулах прямого хода прогонки они встречаются с множителем $a_1 = 0$. Кроме того, из формул прямого хода следует, что

$$\xi_{n+1} = -\frac{c_n}{a_n \xi_n + b_n} = -\frac{0}{a_n \xi_n + b_n} = 0,$$

а это коэффициент при x_{n+1} в обратном ходе прогонки. Поэтому и x_{n+1} может быть произвольным. Итак, для начала прогонки можно положить

$$\xi_1 = \eta_1 = x_{n+1} = 0. \quad (3.53)$$

Дадим теперь достаточные условия осуществимости метода прогонки, т. е. того, что знаменатели в расчётных формулах прямого хода не обращаются в нуль.

Предложение 3.3.4 *Если в системе линейных алгебраических уравнений с трёхдиагональной матрицей (3.49) имеет место диагональное преобладание, т. е.*

$$|b_i| > |a_i| + |c_i|, \quad i = 1, 2, \dots, n,$$

то метод прогонки с выбором начальных значений в соответствии с (3.53) является реализуемым.

Доказательство. Покажем по индукции, что в рассматриваемой реализации прогонки неравенство $|\xi_i| < 1$ справедливо для всех i . Прежде всего, $\xi_1 = 0$ и потому $|\xi_1| < 1$. Далее, предположим, что для некоторого индекса i уже установлена оценка $|\xi_i| < 1$. Если соответствующее $c_i = 0$, то из (3.51) следует $\xi_{i+1} = 0$, и индукционный переход доказан. Поэтому пусть $c_i \neq 0$. Тогда справедлива следующая цепочка соотношений

$$\begin{aligned} |\xi_{i+1}| &= \left| -\frac{c_i}{a_i \xi_i + b_i} \right| = \frac{|c_i|}{|a_i \xi_i + b_i|} \\ &\leq \frac{|c_i|}{||b_i| - |a_i| \cdot |\xi_i||} \quad \text{из оценки снизу для модуля суммы} \\ &< \frac{|c_i|}{|a_i| + |c_i| - |a_i| \cdot |\xi_i|} \quad \text{в силу диагонального преобладания} \\ &= \frac{|c_i|}{|a_i|(1 - |\xi_i|) + |c_i|} \leq \frac{|c_i|}{|c_i|} = 1, \end{aligned}$$

где при переходе ко второй строке мы воспользовались известным неравенством для модуля суммы двух чисел:

$$|x + y| \geq ||x| - |y||. \quad (3.54)$$

Итак, $|\xi_i| < 1$ оказывается доказанным для всех прогоночных коэффициентов ξ_i , $i = 1, 2, \dots, n + 1$.

Как следствие, для знаменателей прогоночных коэффициентов ξ_i и η_i в формулах (3.51)–(3.52) имеем

$$\begin{aligned}
 |a_i \xi_i + b_i| &\geq ||b_i| - |a_i \xi_i|| \quad \text{по неравенству (3.54)} \\
 &= |b_i| - |a_i \xi_i| \quad \text{из-за диагонального преобладания} \\
 &> |a_i| + |c_i| - |a_i| \cdot |\xi_i| \quad \text{из-за диагонального преобладания} \\
 &= |a_i|(1 - |\xi_i|) + |c_i| \\
 &\geq |c_i| \geq 0 \quad \text{в силу оценки } |\xi_i| < 1,
 \end{aligned}$$

то есть строгое отделение от нуля. Это и требовалось доказать. ■

Отметим, что существуют и другие условия реализуемости метода прогонки. Например, некоторые из них требуют «более мягкое» нестрогое диагональное преобладание в матрице, но зато другие более жёсткие условия на коэффициенты системы. Весьма полужарна, в частности, такая формулировка [16]:

Предложение 3.3.5 *Если в трёхдиагональной системе линейных алгебраических уравнений (3.49) побочные диагонали не содержат нулей, т. е. $a_i \neq 0$, $i = 2, 3, \dots, n$, и $c_i \neq 0$, $i = 1, 2, \dots, n - 1$, имеет место нестрогое диагональное преобладание*

$$|b_i| \geq |a_i| + |c_i|, \quad i = 1, 2, \dots, n,$$

но хотя бы для одного i это неравенство является строгим, то метод прогонки реализуем.

Разработано немало различных модификаций метода прогонки, которые хорошо приспособлены для решения тех или иных специальных систем уравнений, как трёхдиагональных, так и более общих, имеющих ленточные или даже блочно-ленточные матрицы [16]. В частности, существует матричная прогонка.

Нетрудно убедиться, что реализация прогонки требует линейного в зависимости от размера системы количества арифметических операций (примерно $8n$), т. е. весьма экономична.

3.4 Стационарные итерационные методы решения систем линейных уравнений

В *итерационных методах* решения уравнений и систем уравнений решение x^* получается как предел некоторой последовательности приближений $\{x^{(k)}\}_{k=0}^{\infty}$, так что

$$x^* = \lim_{k \rightarrow \infty} x^{(k)}.$$

Естественно, что на практике переход к пределу невозможен в силу конечности наших вычислений, и потому при реализации итерационных методов вместо x^* обычно довольствуются нахождением какого-то достаточно хорошего приближения $x^{(k)}$ к x^* . Подробнее мы рассмотрим этот вопрос в §3.4ж.

Общая схема итерационных методов выглядит следующим образом: выбираем одно или несколько *начальных приближений* $x^{(0)}, x^{(1)}, \dots, x^{(m)}$, а затем по их известным значениям последовательно вычисляем

$$x^{(k+1)} \leftarrow T_k(x^{(0)}, x^{(1)}, \dots, x^{(k)}), \quad k = m, m+1, m+2, \dots, \quad (3.55)$$

где T_k — отображение, называемое *оператором перехода* или *оператором шага* (k -го). Конечно, в реальных итерационных процессах каждое следующее приближение, как правило, зависит не от всех предшествующих приближений, а лишь от какого-то их фиксированного конечного числа. Более точно, итерационный процесс (3.55) называют *p -шаговым*, если его последующее приближение $x^{(k+1)}$ является функцией только от $x^{(k)}, x^{(k-1)}, \dots, x^{(k-p+1)}$. В частности, наиболее простыми в этом отношении являются *одношаговые* итерационные методы

$$x^{(k+1)} \leftarrow T_k(x^{(k)}), \quad k = 0, 1, 2, \dots,$$

в которых $x^{(k+1)}$ зависит лишь от значения одной предшествующей итерации $x^{(k)}$. Для начала работы одношаговых итерационных процессов нужно знать лишь одно начальное приближение $x^{(0)}$.

Итерационный процесс называется *стационарным*, если оператор перехода T_k не зависит от номера шага k , т. е. $T_k = T$, и *нестационарным* в противном случае. *Линейным итерационным процессом* будут называться итерации, в которых оператор перехода имеет вид

$$\begin{aligned} T_k(x^{(k)}, x^{(k-1)}, \dots, x^{(k-p+1)}) \\ = C^{(k,k)}x^{(k)} + C^{(k,k-1)}x^{(k-1)} + \dots + C^{(k,k-p+1)}x^{(k-p+1)} + d \end{aligned}$$

с какими-то матрицами $C^{(k,k)}, C^{(k,k-1)}, \dots, C^{(k,k-p+1)}$ подходящих размеров.

Причины, по которым для решения систем линейных уравнений итерационные методы могут оказаться более предпочтительными, чем прямые, заключаются в следующем. Большинство итерационных методов являются *самоисправляющимися*, т. е. такими, в которых погрешность, допущенная в вычислениях, при сходимости исправляется в ходе итерирования и не отражается на окончательном результате. Это следует из конструкции оператора перехода, в котором обычно по самому его построению присутствует информация о решаемой системе, что мы увидим далее на примерах. При выполнении алгоритма эта информация на каждом шаге вносится в итерационный процесс и оказывает влияние на его ход. Напротив, прямые методы решения СЛАУ этим свойством не обладают, так как, оттолкнувшись от исходной системы, мы далее уже не возвращаемся к ней, а оперируем с её следствиями, которые никакой обратной связи от исходной системы не получают.

Нередко итерационные процессы сравнительно несложно программируются, так как представляют собой повторяющиеся единообразные процедуры, применённые к последовательным приближениям к решению. При решении СЛАУ с разреженными матрицами в итерационных процессах можно легче, чем в прямых методах, учитывать структуру нулевых и ненулевых элементов матрицы и основывать на этом упрощённые формулы матрично-векторного умножения, которые существенно уменьшают общую трудоёмкость алгоритма. Наконец, быстро сходящиеся итерационные методы могут обеспечивать выигрыш по времени и для СЛАУ общего вида, если требуют число итераций, меньшее размерности системы.

3.4а Условие сходимости стационарных одношаговых итерационных методов

Теорема 3.4.1 *Стационарный одношаговый итерационный процесс*

$$x^{(k+1)} \leftarrow Cx^{(k)} + d, \quad k = 0, 1, 2, \dots, \quad (3.56)$$

сходится при любом начальном приближении $x^{(0)}$ тогда и только тогда, когда спектральный радиус матрицы C меньше единицы, т. е. $\rho(C) < 1$.

Доказательство этого утверждения будет разбито на две части, результат каждой из которых представляет самостоятельный интерес.

Предложение 3.4.1 Если $\|C\| < 1$ в какой-нибудь матричной норме, то стационарный одношаговый итерационный процесс

$$x^{(k+1)} \leftarrow Cx^{(k)} + d, \quad k = 0, 1, 2, \dots,$$

сходится при любом начальном приближении $x^{(0)}$.

Доказательство. Если $\|C\| < 1$ для какой-нибудь матричной нормы, то в силу Предложения 3.2.8 матрица $(I - C)$ неособенна и имеет обратную. Следовательно, система уравнений $(I - C)x = d$, как и равносильная ей

$$x = Cx + d,$$

имеют единственное решение, которое мы обозначим x^* :

$$x^* = Cx^* + d.$$

Вычтем это равенство из соотношения $x^{(k)} = Cx^{(k-1)} + d$, $k = 0, 1, 2, \dots$, получим

$$x^{(k)} - x^* = C(x^{(k-1)} - x^*).$$

Взятие нормы от обеих частей приводит к цепочке неравенств

$$\begin{aligned} \|x^{(k)} - x^*\| &\leq \|C\| \cdot \|x^{(k-1)} - x^*\| \\ &\leq \|C\|^2 \cdot \|x^{(k-2)} - x^*\| \\ &\leq \dots \dots \\ &\leq \|C\|^k \cdot \|x^{(0)} - x^*\|, \end{aligned} \tag{3.57}$$

при выводе которой мы пользуемся тем фактом, что всякая матричная норма согласована с некоторой векторной нормой и именно в этой норме оцениваем отклонение $x^{(k)}$ от x^* .

Правая часть неравенства (3.57) сходится к нулю при $k \rightarrow \infty$ в силу условия $\|C\| < 1$, поэтому последовательность приближений $\|x^{(k)}\|$ действительно сходится к пределу x^* . ■

Побочным следствием доказательства Предложения 3.4.1 является демонстрация роли нормы матрицы перехода $\|C\|$ как коэффициента подавления погрешности приближений к решению СЛАУ, что следует из неравенств (3.57): чем меньше $\|C\|$, тем быстрее убывает эта погрешность на каждом отдельном шаге итерационного процесса.

Предложение 3.4.2 Для любой квадратной матрицы A и любого $\epsilon > 0$ существует такая подчинённая матричная норма $\|\cdot\|_\epsilon$, что

$$\rho(A) \leq \|A\|_\epsilon \leq \rho(A) + \epsilon.$$

Доказательство. Левое из выписанных неравенств было обосновано ранее в Предложении 3.2.6, и потому содержанием сформулированного результата является, фактически, правое неравенство, дающее оценку сверху для нормы матрицы через спектральный радиус.

С помощью преобразования подобия приведём матрицу A к жордановой канонической форме

$$S^{-1}AS = J,$$

где

$$J = \left(\begin{array}{ccc|ccc|ccc} \lambda_1 & 1 & & & & & & & \\ & \lambda_1 & \ddots & & & & & & \\ & & \ddots & 1 & & & & & \\ & & & \lambda_1 & & & & & \\ \hline & & & & \lambda_2 & 1 & & & \\ & 0 & & & & \ddots & \ddots & & \\ & & & & & & \lambda_2 & & \\ \hline & & & & & & & & \\ & 0 & & & 0 & & & & \\ \hline & & & & & & & \ddots & \\ & & & & & & & & \ddots \end{array} \right),$$

а S — некоторая неособенная матрица, осуществляющая преобразование подобия.

Положим

$$D_\epsilon := \text{diag}\{1, \epsilon, \epsilon^2, \dots, \epsilon^{n-1}\}$$

— диагональной матрице с числами $1, \epsilon, \epsilon^2, \dots, \epsilon^{n-1}$ по главной диа-

гонали. Тогда нетрудно проверить, что

$$(SD_\epsilon)^{-1}A(SD_\epsilon) = D_\epsilon^{-1}(S^{-1}AS)D_\epsilon = D_\epsilon^{-1}JD_\epsilon$$

$$= \left(\begin{array}{ccc|ccc|ccc} \lambda_1 & \epsilon & & & & & & & \\ & \lambda_1 & \ddots & & & & & & \\ & & \ddots & \epsilon & & & & & \\ & & & \lambda_1 & & & & & \\ \hline & & & & \lambda_2 & \epsilon & & & \\ & & & & & \ddots & \ddots & & \\ & & & & & & \lambda_2 & & \\ \hline & & & & & & & \ddots & \\ & & & & & & & & \ddots \end{array} \right),$$

— матрица в «модифицированной» жордановой форме, которая отличается от обычной жордановой формы присутствием ϵ вместо 1 на верхней побочной диагонали. Действительно, умножение на диагональную матрицу слева — это умножение строк матрицы на соответствующие диагональные элементы, а умножение на диагональную матрицу справа равносильно умножению столбцов на элементы диагонали. Два таких умножения — на D_ϵ^{-1} слева и на D_ϵ справа — компенсируют друг друга на главной диагонали матрицы. Но на верхней побочной диагонали от этих умножений остаётся множитель $\epsilon = \epsilon^{i+1}\epsilon^{-i}$, $i = 0, 1, \dots, n-1$.

Определим векторную норму

$$\|x\|_\epsilon := \|(SD_\epsilon)^{-1}x\|_\infty.$$

Тогда для подчинённой ей матричной нормы имеет место

$$\begin{aligned}
 \|A\|_\epsilon &= \max_{x \neq 0} \frac{\|Ax\|_\epsilon}{\|x\|_\epsilon} = \max_{x \neq 0} \frac{\|(SD_\epsilon)^{-1}Ax\|_\infty}{\|(SD_\epsilon)^{-1}x\|_\infty} \\
 &= \max_{x \neq 0} \frac{\|(SD_\epsilon)^{-1}A(SD_\epsilon)y\|_\infty}{\|y\|_\infty} \quad \text{после замены } y = (SD_\epsilon)^{-1}x \\
 &= \max_{x \neq 0} \frac{\|(D_\epsilon^{-1}JD_\epsilon)y\|_\infty}{\|y\|_\infty} = \|D_\epsilon^{-1}JD_\epsilon\|_\infty \\
 &= \text{максимум сумм модулей элементов в } D_\epsilon^{-1}JD_\epsilon \text{ по строкам} \\
 &\leq \max_i |\lambda_i(A)| + \epsilon = \rho(A) + \epsilon,
 \end{aligned}$$

где $\lambda_i(A)$ — i -ое собственное значение матрицы A . ■

Доказательство теоремы о сходимости одношагового стационарного итерационного процесса. Сначала покажем необходимость условия теоремы.

Пусть порождаемая в итерационном процессе последовательность $\{x^{(k)}\}$ сходится. Её пределом при этом может быть только решение x^* системы $x = Cx + d$, т. е. должно быть $\lim_{k \rightarrow \infty} x^{(k)} = x^*$, в чём можно убедиться, переходя в соотношении $x^{(k+1)} = Cx^{(k)} + d$ к пределу по $k \rightarrow \infty$. Тогда, вычитая из расчётной формулы итерационного процесса равенство для решения, получим

$$x^{(k)} - x^* = C(x^{(k-1)} - x^*),$$

откуда

$$\begin{aligned}
 x^{(k)} - x^* &= C(x^{(k-1)} - x^*) \\
 &= C^2(x^{(k-2)} - x^*) \\
 &= \dots \dots \\
 &= C^k(x^{(0)} - x^*).
 \end{aligned}$$

Так как левая часть этих равенств при $k \rightarrow \infty$ сходится к нулю, то должна сходиться к нулю и правая, причём при любом векторе $x^{(0)}$. Это возможно лишь когда $C^k \rightarrow 0$, и потому в силу Предложения 3.2.7

можем заключить, что спектральный радиус C должен быть строго меньше 1.

Достаточность. Если $\rho(C) < 1$, то, согласно Предложению 3.4.2, можно выбрать подчинённую (а, значит, и согласованную) норму $\|\cdot\|$ так, чтобы выполнялось неравенство $\|C\| < 1$. Теперь мы находимся в условиях Предложения 3.4.1, которое утверждает сходимость итерационного процесса (3.56)

$$x^{(k+1)} \leftarrow Cx^{(k)} + d, \quad k = 0, 1, 2, \dots$$

Это завершает доказательство Теоремы 3.4.1. ■

Доказанные результаты — теорема и предложения — проясняют роль спектрального радиуса среди различных характеристик матрицы. Мы могли видеть в §3.2д, что спектральный радиус не является матричной нормой, но, как выясняется, его с любой степенью точности можно приблизить некоторой подчинённой матричной нормой. Кроме того, понятие спектрального радиуса оказывается чрезвычайно полезным при исследовании итерационных процессов и вообще степеней матрицы. К примеру, ранее мы установили (Предложение 3.2.7), что из сходимости степеней матрицы A^k при $k \rightarrow \infty$ к нулевой матрице вытекает $\rho(A) < 1$. Теперь результат Предложения 3.4.2 позволяет сказать, что это условие на спектральный радиус является и достаточным. Кроме того, более точно можно переформулировать условия сходимости матричного ряда Неймана: он сходится для матрицы A тогда и только тогда, когда $\rho(A) < 1$.

3.4б Подготовка линейной системы к итерационному процессу

В этом параграфе мы исследуем различные способы приведения системы линейных алгебраических уравнений

$$Ax = b \tag{3.58}$$

к системе в *рекуррентном виде*

$$x = Cx + d, \tag{3.59}$$

отталкиваясь от которого можно организовывать итерационный процесс. Фактически, это равносильно рассмотрению вопроса о том, как

связан предел стационарного одношагового итерационного процесса (3.56) с интересующим нас решением системы линейных алгебраических уравнений $Ax = b$. При этом нас будет интересовать не всякое приведение системы (3.58) к виду (3.59), но лишь такое, которое удовлетворяет условию сходимости стационарного одношагового итерационного процесса, выведенному в предшествующем пункте.

Простейший способ состоит в том, чтобы добавить к обеим частям исходной системы по вектору неизвестной переменной x , т. е.

$$x + Ax = x + b, \quad (3.60)$$

а затем член Ax перенести в правую часть:

$$x = (I - A)x + b.$$

Весьма часто он непригоден, так как спектральный радиус матрицы $C = I - A$ оказывается больше 1. К примеру, это происходит, если у A есть отрицательные собственные значения, или если у A имеются собственные значения большие по модулю, чем 2.

Итак, необходим активный способ управления свойствами матрицы C в получающейся системе рекуррентного вида $x = Cx + d$. Одним из важнейших инструментов такого управления служит *предобуславливание* исходной системы.

Определение 3.4.1 *Предобуславливанием системы линейных алгебраических уравнений $Ax = b$ называется умножение слева обеих её частей на некоторую матрицу Λ . Сама эта матрица Λ называется предобуславливающей матрицей или, коротко, предобуславливателем.*

Цель предобуславливания — изменение (вообще говоря, улучшение) свойств матрицы системы, так как теперь вместо

$$Ax = b$$

мы получаем

$$(\Lambda A)x = \Lambda b.$$

Продуманный выбор предобуславливателя может, к примеру, изменить выгодным нам образом расположение спектра матрицы A , так необходимое для организации сходящихся итерационных процессов.

Хорошая идея состоит в том, чтобы выполнить предобуславливание до перехода к системе (3.60), т. е. до добавления вектора неизвестных x к обеим частям исходной СЛАУ. Тогда вместо $Ax = b$ будем иметь $(\Lambda A)x = \Lambda b$, и далее получаем

$$x = (I - \Lambda A)x + \Lambda b.$$

Теперь в полученном рекуррентном виде можно с помощью подходящего выбора Λ добиваться требуемых свойств матрицы $(I - \Lambda A)$.

Каким образом следует выбирать предобуславливатели? Совершенно общего рецепта на этот счёт не существует, и теория разбивается здесь на набор рекомендаций для ряда более или менее конкретных важных случаев.

Например, если в качестве предобуславливающей матрицы взять $\Lambda = A^{-1}$ или хотя бы приближённо равную обратной к A , то вместо системы $Ax = b$ получим $(A^{-1}A)x = A^{-1}b$, т. е. систему уравнений

$$Ix = A^{-1}b$$

(или близкую к ней), матрица которой обладает всеми возможными достоинствами (малой обусловленностью и т. п.). Ясно, что нахождение подобного предобуславливателя не менее трудно, чем решение исходной системы, но сама идея примера весьма плодотворна, и на практике в качестве предобуславливателей часто берут несложно вычисляемые обратные матрицы к той или иной части матрицы A . Например, к главной диагонали матрицы или же к трём диагоналям — главной и двум побочным.

Другой способ приведения СЛАУ к рекуррентному виду основан на *расщеплении* матрицы системы.

Определение 3.4.2 *Расщеплением матрицы A называется её представление в виде $A = G + (-H) = G - H$, где G — неособенная матрица.*

Если известно некоторое расщепление матрицы A , $A = G - H$, то вместо исходной системы $Ax = b$ мы можем рассмотреть

$$(G - H)x = b,$$

равносильную

$$Gx = Hx + b,$$

так что

$$x = G^{-1}Hx + G^{-1}b.$$

На основе полученного рекуррентного вида можно организовать итерации

$$x^{(k+1)} \leftarrow G^{-1}Hx^{(k)} + G^{-1}b, \quad (3.61)$$

задавшись каким-то начальным приближением $x^{(0)}$. Таким образом, всякое расщепление помогает конструированию итерационных процессов.

Но практическое значение имеют не все расщепления, а лишь те, в которых матрица G обращается «относительно просто», чтобы организация итерационного процесса не сделалась более сложной задачей, чем решение исходной СЛАУ. Другое требование к матрицам, образующим расщепление, состоит в том, чтобы норма обратной для G , т. е. $\|G^{-1}\|$, была «достаточно маленькой», поскольку $\|G^{-1}H\| \leq \|G^{-1}\| \|H\|$. В абсолютной норме $\|H\| \leq \|A\|$, но вот если G^{-1} имеет большую норму, то может оказаться $\rho(G^{-1}H) > 1$ и для итерационного процесса (3.61) не будут выполнены условия сходимости.

Несложно обрабатываемыми матрицами являются

- 1) диагональные матрицы,
- 2) треугольные матрицы,
- 3) трёхдиагональные матрицы,
- 4) ...

Ниже мы подробно рассмотрим итерационные процессы, соответствующие первым двум пунктам этого списка.

3.4в Оптимизация скалярного предобуславливателя

Напомним, что *скалярной матрицей* называется матрица, кратная единичной (из-за своего родства скалярам, т. е. числам из $\mathbb{R}$ или $\mathbb{C}$). Сейчас мы исследуем подробно описанную в предшествующем параграфе возможность управления итерационным процессом на простейшем примере предобуславливания с помощью скалярной матрицы, когда $A = \tau I$, $\tau \in \mathbb{R}$.

Итак, рассматриваем итерационный процесс

$$x^{(k+1)} \leftarrow (I - \tau A)x^{(k)} + \tau b, \quad (3.62)$$

$\tau = \text{const}$, который часто называют *методом простой итерации*. Если $\lambda_i, i = 1, 2, \dots, n$ — собственные числа матрицы A (вообще говоря, они комплексны), то собственные числа матрицы $(I - \tau A)$ равны $(1 - \tau \lambda_i)$. Ясно, что в случае, когда среди λ_i имеются числа с разным знаком $\text{Re } \lambda_i$, добиться их локализации в единичном круге никаким выбором τ невозможно.

Далее рассмотрим практически важный частный случай, когда A — симметричная положительно определённая матрица, так что все $\lambda_i, i = 1, 2, \dots, n$, вещественны и положительны. Они нечасто бывают известны точно, но нередко более или менее точно известен интервал их расположения на вещественной оси $\mathbb{R}$. Будем предполагать, что $\lambda_i \in [\mu, M], i = 1, 2, \dots, n$.

Матрица $(I - \tau A)$ также симметрична, и потому её спектральный радиус совпадает с 2-нормой. Чтобы обеспечить сходимость итерационного процесса и добиться её наибольшей скорости, нам нужно минимизировать величину

$$\|I - \tau A\|_2 = \max_{\lambda_i \in [\mu, M]} |1 - \tau \lambda_i|,$$

т.е. найти τ , при котором достигается

$$\min_{\tau} \max_{\lambda_i \in [\mu, M]} |1 - \tau \lambda_i|.$$

Обозначив


$$g(\tau) = \max_{\mu \leq \lambda \leq M} |1 - \tau \lambda|,$$

обратимся для минимизации функции $g(\tau)$ к геометрической иллюстрации Рис. 3.8.

При $\tau \leq 0$ функция $(1 - \tau \lambda)$ не убывает по λ , и при положительных λ , очевидно, не меньше 1 по абсолютной величине. Следовательно, в нашем анализе имеет смысл ограничиться значениями $\tau > 0$.

При $0 < \tau \leq M^{-1}$ функция $1 - \tau \lambda$ на интервале $\lambda \in [\mu, M]$ неотрицательна и монотонно убывает. Поэтому $g(\tau) = \max |1 - \tau \lambda| = 1 - \tau \mu$ и достигается на левом конце интервала $[\mu, M]$.

При $\tau > M^{-1}$ величина $1 - \tau M$ отрицательна, так что график функции $1 - \tau \lambda$ на интервале $\lambda \in [\mu, M]$ пересекает ось абсцисс. При этом на правом конце $|1 - \tau \lambda|$ растёт с ростом τ , а на левом конце $|1 - \tau \mu|$ убывает с ростом τ .

Рис. 3.8. Графики функций $1 - \tau\lambda$ для различных τ

При некотором $\tau = \tau_{\text{опт}}$ наступает момент, когда эти значения на концах интервала сравниваются друг с другом:

$$1 - \tau\mu = -(1 - \tau M).$$

Он и является моментом достижения оптимума, поскольку дальнейшее увеличение τ приводит к росту $-(1 - \tau M)$ на правом конце интервала, а уменьшение τ ведёт к росту $1 - \tau\mu$ на левом конце. Отсюда

$$\tau_{\text{опт}} = \frac{2}{M + \mu}, \quad (3.63)$$

а значение оптимума, равное коэффициенту подавления погрешности (как следствие из неравенств (3.57)), есть

$$\|I - \tau_{\text{опт}}A\|_2 = \min_{\tau} \max_{\lambda_i \in [\mu, M]} |1 - \tau\lambda_i| = 1 - \tau_{\text{опт}}\mu = \frac{M - \mu}{M + \mu}. \quad (3.64)$$

Ясно, что оно меньше единицы, т. е. даже с помощью простейшего скалярного предобуславливателя мы добились сходимости итерационного процесса.

Полезно переписать полученное выражение, используя число обусловленности матрицы A . Так как $\mu \leq \lambda_{\min}(A)$ и $\lambda_{\max}(A) \leq M$, то

$$\text{cond}(A) = \frac{\lambda_{\max}(A)}{\lambda_{\min}(A)} \leq \frac{M}{\mu}.$$

Поэтому, принимая во внимание тот факт, что функция

$$f(x) = \frac{x-1}{x+1} = 1 - \frac{2}{x+1}$$

возрастает при положительных x , можем заключить, что

$$\|I - \tau_{\text{опт}} A\|_2 = \frac{M/\mu - 1}{M/\mu + 1} \geq \frac{\text{cond}(A) - 1}{\text{cond}(A) + 1}.$$

Получается, что чем больше $\text{cond}(A)$, т. е. чем хуже обусловленность матрицы A исходной системы, тем медленнее сходимость нашего итерационного процесса. Мы увидим далее, что это характерно для поведения большинства итерационных методов.

3.4г Итерационный метод Якоби

Пусть в системе линейных алгебраических уравнений $Ax = b$ диагональные элементы матрицы $A = (a_{ij})$ отличны от нуля, т. е. $a_{ii} \neq 0$, $i = 1, 2, \dots, n$. Это условие не является обременительным, так как для неособенной матрицы A перестановкой строк (соответствующей перестановке уравнений системы) можно всегда добиться ненулевых диагональных элементов.

В развёрнутом виде рассматриваемая система имеет вид

$$\sum_{j=1}^n a_{ij} x_j = b_i, \quad i = 1, 2, \dots, n,$$

и, выражая из i -го уравнения i -ю компоненту вектора неизвестных, получим

$$x_i = \frac{1}{a_{ii}} \left(b_i - \sum_{j \neq i} a_{ij} x_j \right), \quad i = 1, 2, \dots, n.$$

Нетрудно понять, что полученные соотношения дают представление исходной СЛАУ в рекуррентном виде, необходимое для организации итераций:

$$x = T(x), \quad T(x) = (T_1(x), T_2(x), \dots, T_n(x))^T,$$

$$\text{где } T_i(x) = \frac{1}{a_{ii}} \left(b_i - \sum_{j \neq i} a_{ij} x_j \right), \quad i = 1, 2, \dots, n.$$

Псевдокод этого итерационного процесса выписан в Табл. 3.2, где вспомогательная переменная k — счётчик числа итераций.

Таблица 3.2. Итерационный метод Якоби для решения СЛАУ

```
 $k \leftarrow 0;$   
выбираем начальное приближение  $x^{(0)}$ ;  
DO WHILE ( метод не сошёлся )  
    DO FOR  $i = 1$  TO  $n$   
        
$$x_i^{(k+1)} \leftarrow \frac{1}{a_{ii}} \left( b_i - \sum_{j \neq i} a_{ij} x_j^{(k)} \right)$$
  
    END DO  
     $k \leftarrow k + 1;$   
END DO
```

(3.65)

Он был предложен ещё в середине XIX века К.Г.Якоби и часто (особенно в старых книгах по численным методам) называется «методом одновременных смещений». Под «смещениями» здесь имеются в виду коррекции компонент очередного приближения к решению, выполняемые на каждом шаге итерационного метода. Смещения-коррекции «одновременны» потому, что все компоненты следующего приближения $x^{(k+1)}$ насчитываются по единообразным формулам, основанным лишь на известном предыдущем приближении. В следующем параграфе будет рассмотрен итерационный процесс, устроенный несколько по-другому, в котором смещения-коррекции компонент приближения к решению не одновременны в том смысле, что последовательно находятся не только из предыдущего приближения, но ещё и одна через другую.

Пусть $A = D + \tilde{L} + \tilde{U}$, где

$$\tilde{U} = \begin{pmatrix} 0 & a_{12} & \cdots & a_{1,n-1} & a_{1n} \\ & 0 & \ddots & a_{2,n-1} & a_{2n} \\ & & \ddots & \vdots & \vdots \\ & \mathbf{0} & & 0 & a_{n-1,n} \\ & & & & 0 \end{pmatrix} \quad \text{— строго верхняя} \\ \text{треугольная матрица,}$$

$$D = \text{diag} \{a_{11}, a_{22}, \dots, a_{nn}\} \quad \text{— диагональ матрицы,}$$

$$\tilde{L} = \begin{pmatrix} 0 & & & \mathbf{0} \\ a_{21} & 0 & & \\ a_{31} & a_{32} & \ddots & \\ \vdots & \vdots & \ddots & 0 \\ a_{n1} & a_{n2} & \cdots & a_{n,n-1} & 0 \end{pmatrix} \quad \text{— строго нижняя} \\ \text{треугольная матрица.}$$

Тогда итерационный метод Якоби может быть представлен как метод, основанный на таком расщеплении матрицы системы $A = G - H$, что

$$G = D, \quad H = -(\tilde{L} + \tilde{U}).$$

Соответственно, в матричном виде метод Якоби записывается как

$$x^{(k+1)} \leftarrow -D^{-1}(\tilde{L} + \tilde{U})x^{(k)} + D^{-1}b.$$

Теперь нетрудно дать условия его сходимости, основываясь на общем результате о сходимости стационарных одношаговых итераций (Теорема 3.4.1). Именно, метод Якоби сходится тогда и только тогда, когда

$$\rho(D^{-1}(\tilde{L} + \tilde{U})) < 1.$$

Матрица $D^{-1}(\tilde{L} + \tilde{U})$ просто выписывается по исходной системе и имеет вид

$$\begin{pmatrix} 0 & a_{12}/a_{11} & \cdots & a_{1n}/a_{11} \\ a_{21}/a_{22} & 0 & \cdots & a_{2n}/a_{22} \\ \vdots & \vdots & \ddots & \vdots \\ a_{1n}/a_{nn} & a_{n2}/a_{nn} & \cdots & 0 \end{pmatrix}. \quad (3.66)$$

Но нахождение её спектрального радиуса является задачей, сравнимой по сложности с выполнением самого итерационного процесса и потому непрактично. Для быстрой и грубой оценки спектрального радиуса можно воспользоваться какой-нибудь матричной нормой и результатом Предложения 3.2.6. Полезен также следующий достаточный признак сходимости:

Предложение 3.4.3 *Если в системе линейных алгебраических уравнений $Ax = b$ матрица A имеет диагональное преобладание, то метод Якоби для этой системы сходится при любом начальном приближении.*

Доказательство. Диагональное преобладание в матрице $A = (a_{ij})$ означает, что

$$|a_{ii}| > \sum_{j \neq i} |a_{ij}|, \quad i = 1, 2, \dots, n.$$

Следовательно,

$$\sum_{j \neq i} \left| \frac{a_{ij}}{a_{ii}} \right| < 1, \quad i = 1, 2, \dots, n,$$

что равносильно

$$\max_{1 \leq i \leq n} \left(\sum_{j \neq i} \left| \frac{a_{ij}}{a_{ii}} \right| \right) < 1.$$

В выражении, стоящем в левой части неравенства, легко угадать подчинённую чебышёвскую норму (∞ -норму) матрицы $D^{-1}(\tilde{L} + \tilde{U})$, выписанной нами в (3.66). Таким образом,

$$\|D^{-1}(\tilde{L} + \tilde{U})\|_{\infty} < 1,$$

откуда, ввиду результата Предложения 3.4.1, следует доказываемое. ■

3.4д Итерационный метод Гаусса-Зейделя

В итерационном методе Якоби при организации вычислений по инструкции

$$x_i^{(k+1)} \leftarrow \frac{1}{a_{ii}} \left(b_i - \sum_{j \neq i} a_{ij} x_j^{(k)} \right), \quad i = 1, 2, \dots, n, \quad (3.67)$$

Таблица 3.3. Итерационный метод Гаусса-Зейделя
для решения линейных систем уравнений

```

 $k \leftarrow 0;$ 
выбираем начальное приближение  $x^{(0)}$ ;
DO WHILE ( метод не сошёлся )
  DO FOR  $i = 1$  TO  $n$ 
    
$$x_i^{(k+1)} \leftarrow \frac{1}{a_{ii}} \left( b_i - \sum_{j=i}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right)$$

  END DO
   $k \leftarrow k + 1;$ 
END DO

```

компоненты очередного приближения $x^{(k+1)}$ находятся последовательно одна за другой, так что к моменту вычисления i -ой компоненты вектора $x^{(k+1)}$ уже найдены $x_1^{(k+1)}, x_2^{(k+1)}, \dots, x_{i-1}^{(k+1)}$. Но метод Якоби никак не использует эти новые значения, и при вычислении любой компоненты следующего приближения всегда опирается только на вектор $x^{(k)}$ предшествующего приближения. Если итерационный процесс сходится к решению, то естественно ожидать, что все компоненты $x^{(k+1)}$ ближе к искомому решению, чем $x^{(k)}$, а посему немедленное вовлечение их в процесс вычисления будет способствовать ускорению сходимости.

На этой идее основан *итерационный метод Гаусса-Зейделя*⁸, псевдокод которого представлен в Табл. 3.3 (где, как и ранее, k — счётчик итераций). В нём суммирование в формуле (3.67) для вычисления i -ой компоненты очередного приближения $x^{(k+1)}$ к решению разбито на две части — по индексам, предшествующим i , и по индексам, большим i . Первая часть суммы использует новые вычисленные значения $x_1^{(k+1)}, \dots, x_{i-1}^{(k+1)}$, тогда как вторая — компоненты $x_{i+1}^{(k)}, \dots, x_n^{(k)}$ из старого приближения. Метод Гаусса-Зейделя иногда называют также итерационным методом «последовательных смещений», а его основная идея

⁸В отечественной литературе по вычислительной математике нередко используется также термин *метод Зейделя*.

немедленного вовлечения уже полученной информации в вычислительный процесс с успехом применима и для нелинейных итерационных схем.

Чтобы получить для метода Гаусса-Зейделя матричное представление, перепишем его расчётные формулы в виде

$$\sum_{j=1}^i a_{ij} x_j^{(k+1)} = - \sum_{j=i+1}^n a_{ij} x_j^{(k)} + b_i, \quad i = 1, 2, \dots, n.$$

Используя введённые в предыдущем пункте матрицы D , $\tilde{L}$ и $\tilde{U}$, можем записать эти формулы в виде

$$(D + \tilde{L})x^{(k+1)} = -\tilde{U}x^{(k)} + b,$$

т. е.

$$x^{(k+1)} = -(D + \tilde{L})^{-1}\tilde{U}x^{(k)} + (D + \tilde{L})^{-1}b. \quad (3.68)$$

Таким образом, необходимое и достаточное условие сходимости метода Гаусса-Зейделя из любого начального приближения — это неравенство

$$\rho((D + \tilde{L})^{-1}\tilde{U}) < 1.$$

Предложение 3.4.4 *Если в системе линейных алгебраических уравнений $Ax = b$ матрица A имеет диагональное преобладание, то метод Гаусса-Зейделя для этой системы сходится при любом начальном приближении.*

Доказательство. Отметим, прежде всего, что в условиях диагонального преобладания в A решение x^* рассматриваемой линейной системы существует (вспомним признак признака неособенности Адамара). Пусть, как и ранее, $x^{(k)}$ — его приближение, полученное на k -ом шаге итерационного процесса. Исследуем поведение погрешности решения $z^{(k)} = x^{(k)} - x^*$ в зависимости от номера итерации k .

Чтобы получить формулу для $z^{(k)}$, предварительно перепишем соотношение, которым удовлетворяет точное решение x^* : вместо

$$\sum_{j=1}^n a_{ij} x_j^* = b_i, \quad i = 1, 2, \dots, n.$$

можно придать им следующий эквивалентный вид

$$x_i^* = \frac{1}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij} x_j^* - \sum_{j=i+1}^n a_{ij} x_j^* \right), \quad i = 1, 2, \dots, n.$$

Вычитая затем почленно эти равенства из расчётных формул метода Гаусса-Зейделя, т. е. из

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right), \quad i = 1, 2, \dots, n,$$

получим

$$z_i^{(k+1)} = \frac{1}{a_{ii}} \left(- \sum_{j=1}^{i-1} a_{ij} z_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} z_j^{(k)} \right), \quad i = 1, 2, \dots, n,$$

Беря абсолютное значение от обеих частей этого равенства и пользуясь неравенством треугольника для абсолютных значений, будем иметь для $i = 1, 2, \dots, n$

$$\begin{aligned} |z_i^{(k+1)}| &\leq \sum_{j=1}^{i-1} \left| \frac{a_{ij}}{a_{ii}} \right| \cdot |z_j^{(k+1)}| + \sum_{j=i+1}^n \left| \frac{a_{ij}}{a_{ii}} \right| \cdot |z_j^{(k)}| \\ &\leq \sum_{j=1}^{i-1} \left| \frac{a_{ij}}{a_{ii}} \right| \cdot \|z^{(k+1)}\|_{\infty} + \sum_{j=i+1}^n \left| \frac{a_{ij}}{a_{ii}} \right| \cdot \|z^{(k)}\|_{\infty}. \end{aligned} \quad (3.69)$$

С другой стороны, условие диагонального преобладания в матрице A , т. е. то, что

$$\sum_{j \neq i} |a_{ij}| < |a_{ii}|, \quad i = 1, 2, \dots, n,$$

означает существование константы $\varkappa$, $0 \leq \varkappa < 1$, такой что

$$\sum_{j \neq i} |a_{ij}| \leq \varkappa |a_{ii}|, \quad i = 1, 2, \dots, n. \quad (3.70)$$

По этой причине

$$\sum_{j \neq i} \left| \frac{a_{ij}}{a_{ii}} \right| \leq \varkappa, \quad i = 1, 2, \dots, n,$$

и, следовательно,

$$\sum_{j=i+1}^n \left| \frac{a_{ij}}{a_{ii}} \right| \leq \varkappa - \sum_{j=1}^{i-1} \left| \frac{a_{ij}}{a_{ii}} \right| \leq \varkappa - \varkappa \sum_{j=1}^{i-1} \left| \frac{a_{ij}}{a_{ii}} \right| = \varkappa \left(1 - \sum_{j=1}^{i-1} \left| \frac{a_{ij}}{a_{ii}} \right| \right).$$

$i = 1, 2, \dots, n$. Подставляя полученную оценку в неравенства (3.69), приходим к соотношениям

$$\|z_i^{(k+1)}\| \leq \sum_{j=1}^{i-1} \left| \frac{a_{ij}}{a_{ii}} \right| \cdot \|z^{(k+1)}\|_\infty + \varkappa \left(1 - \sum_{j=1}^{i-1} \left| \frac{a_{ij}}{a_{ii}} \right| \right) \|z^{(k)}\|_\infty, \quad (3.71)$$

$i = 1, 2, \dots, n$.

Предположим, что $\max_{1 \leq i \leq n} |z_i^{(k)}|$ достигается при $i = m$, так что

$$\|z^{(k+1)}\|_\infty = \|z_m^{(k)}\|. \quad (3.72)$$

Рассмотрим теперь отдельно m -ое неравенство из (3.71). Привлекая равенство (3.72), можем написать

$$\|z^{(k+1)}\|_\infty \leq \sum_{j=1}^{m-1} \left| \frac{a_{mj}}{a_{mm}} \right| \cdot \|z^{(k+1)}\|_\infty + \varkappa \left(1 - \sum_{j=1}^{m-1} \left| \frac{a_{mj}}{a_{mm}} \right| \right) \|z^{(k)}\|_\infty,$$

то есть

$$\left(1 - \sum_{j=1}^{m-1} \left| \frac{a_{mj}}{a_{mm}} \right| \right) \|z^{(k+1)}\|_\infty \leq \varkappa \left(1 - \sum_{j=1}^{m-1} \left| \frac{a_{mj}}{a_{mm}} \right| \right) \|z^{(k)}\|_\infty. \quad (3.73)$$

Коль скоро

$$1 - \sum_{j=1}^{m-1} \left| \frac{a_{mj}}{a_{mm}} \right| > 0$$

в силу диагонального преобладания в матрице A , то мы можем сократить на эту величину обе части неравенства (3.73). Окончательно получаем

$$\|z^{(k+1)}\|_\infty \leq \varkappa \|z^{(k)}\|_\infty,$$

что при $|\varkappa| < 1$ означает сходимость метода Гаусса-Зейделя. ■

Фактически, в доказательстве Предложения 3.4.4 мы получили даже оценку уменьшения чебышёвской нормы погрешности через «меру диагонального преобладания», в качестве которой может выступать величина $\varkappa$, определённая посредством (3.70).

Теорема 3.4.2 Если в системе линейных алгебраических уравнений $Ax = b$ матрица A является симметричной положительно определённой, то метод Гаусса-Зейделя сходится к решению из любого начального приближения.

Доказательство опускается.

Метод Гаусса-Зейделя был сконструирован как модификация метода Якоби, и, казалось бы, должен работать лучше. Так оно и есть «в среднем», на случайно выбранных системах — метод Гаусса-Зейделя работает несколько быстрее, что можно показать математически строго при определённых допущениях на систему. Но в целом ситуация не столь однозначна. Для СЛАУ размера 3×3 и более существуют примеры, на которых метод Якоби расходится, но метод Гаусса-Зейделя сходится, так же как существуют и примеры другого свойства, когда метод Якоби сходится, а метод Гаусса-Зейделя расходится.

3.4е Методы релаксации

Одним из принципов, который кладётся в основу итерационных методов решения систем уравнений, является так называемый *принцип релаксации*.⁹ Под это понимается такая организация итераций, при которой на каждом шаге процесса уменьшается какая-либо величина, характеризующая погрешность решения системы.

Поскольку само решение x^* нам неизвестно, то оценить напрямую погрешность $x^{(k)} - x^*$ не представляется возможным. По этой причине о степени близости $x^{(k)}$ к x^* судят на основании косвенных признаков, важнейшим среди которых является величина *невязки* решения. Невязка определяется как разность левой и правой частей уравнения после подстановки в него приближения к решению, и в нашем случае это $Ax^{(k)} - b$.

В этих условиях конкретное применение принципа релаксации может заключаться в том, что на каждом шаге итерационного процесса стремятся уменьшить абсолютные значения компонент вектора невязки либо её норму. В этом смысле итерационные процессы Якоби и Гаусса-Зейделя можно также рассматривать как релаксационные, в которых на каждом шаге компоненты очередного приближения вычисляются из условия зануления соответствующих компонент невязки на

⁹От латинского слова «relaxatio» — уменьшение напряжения, ослабление.

основе уже полученной информации о решении. Правда, это делается «локально», для отдельно взятой компоненты, и без учёта влияния результатов вычисления этой компоненты на другие компоненты невязки.

Различают релаксацию *полную* и *неполную*, в зависимости от того, добиваемся ли мы на каждом отдельном шаге итерационного процесса (или его подшаге) наибольшего возможного улучшения рассматриваемой функции от погрешности или нет. Локально полная релаксация может казаться наиболее выгодной, но глобально, с точки зрения сходимости процесса в целом, тщательно подобранная неполная релаксация нередко приводит к более эффективным методам.

Очень популярной реализацией высказанных выше общих идей является метод решения систем линейных алгебраических уравнений, в котором для улучшения сходимости берётся «взвешенное среднее» значений компонент предшествующей $x^{(k)}$ и последующей $x^{(k+1)}$ итераций метода Гаусса-Зейделя. Более точно, зададимся вещественным числом ω , которое будем называть *параметром релаксации*, и i -ую компоненту очередного $k + 1$ -го приближения положим равной

$$\omega x_i^{(k+1)} + (1 - \omega)x_i^{(k)},$$

где $x_i^{(k)}$ — приближение, полученное в результате k -го шага алгоритма, а $x_i^{(k+1)}$ — приближение, которое было бы получено на основе $x_1^{(k+1)}, \dots, x_{i-1}^{(k+1)}, x_{i+1}^{(k)}, \dots, x_n^{(k)}$ с помощью метода Гаусса-Зейделя. Псевдокод метода релаксации для решения систем линейных алгебраических уравнений представлен в Табл. 3.4.

Рсчётные формулы нового метода можно записать в виде

$$a_{ii}x_i^{(k+1)} + \omega \sum_{j=1}^{i-1} a_{ij}x_j^{(k+1)} = (1 - \omega) a_{ii}x_i^{(k)} - \omega \sum_{j=i+1}^n a_{ij}x_j^{(k)} + \omega b_i,$$

для $i = 1, 2, \dots, n$. Применяя введённые выше в §3.4д матрицы $D, \tilde{L}, \tilde{U}$, можно придать этим соотношениям более компактный вид

$$(D - \omega \tilde{L}) x^{(k+1)} = ((1 - \omega)D + \omega \tilde{U}) x^{(k)} + \omega b,$$

откуда

$$x^{(k+1)} = (D - \omega \tilde{L})^{-1} ((1 - \omega)D + \omega \tilde{U}) x^{(k)} + (D - \omega \tilde{L})^{-1} \omega b,$$

Таблица 3.4. Псевдокод метода релаксации
для решения систем линейных уравнений

```

 $k \leftarrow 0;$ 
выбираем начальное приближение  $x^{(0)}$ ;
DO WHILE ( метод не сошёлся )
  DO FOR  $i = 1$  TO  $n$ 
    
$$x_i^{(k+1)} \leftarrow (1 - \omega) x_i^{(k)} +$$


$$\frac{\omega}{a_{ii}} \left( b_i - \sum_{j=i}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right)$$

  END DO
   $k \leftarrow k + 1;$ 
END DO

```

$k = 0, 1, 2, \dots$

В зависимости от конкретного значения параметра релаксации принято различать три случая:

- если $\omega < 1$, то говорят о «нижней релаксации»,
- если $\omega = 1$, то имеем итерации Гаусса-Зейделя,
- если $\omega > 1$, то говорят о «верхней релаксации».¹⁰

Последний случай может показаться экзотичным, но во многих ситуациях он действительно обеспечивает улучшение сходимости итераций в сравнении с методом Гаусса-Зейделя. Несколько упрощённое объяснение этого явления может состоять в том, что если направление от $x^{(k)}$ к $x^{(k+1)}$ оказывается удачным в том смысле, что приближает к искомому решению, то имеет смысл пройти по нему и дальше, за $x^{(k+1)}$. Это соответствует случаю $\omega > 1$.

Важно отметить, что метод релаксации также укладывается в изложенную в §3.46 схему итерационных процессов, порождаемых рас-

¹⁰В англоязычной литературе по вычислительной линейной алгебре этот метод обычно обозначают аббревиатурой SOR(ω), которая происходит от термина «Successive OverRelaxation» — последовательная верхняя релаксация.

щеплением матрицы решаемой системы уравнений. Именно, мы берём $A = G_\omega - H_\omega$ с матрицами

$$G_\omega = D - \omega\tilde{L}, \quad H_\omega = (1 - \omega)D + \omega\tilde{U}.$$

Необходимое и достаточное условие сходимости метода релаксации принимает поэтому вид

$$\rho(G_\omega^{-1}H_\omega) < 1.$$

Для некоторых специфичных, но очень важных задач математической физики значение релаксационного параметра ω , при котором величина $\rho(G_\omega^{-1}H_\omega)$ достигает минимума, находится относительно просто. В более сложных задачах для оптимизации ω требуется весьма трудный анализ спектра матрицы перехода $G_\omega^{-1}H_\omega$ из (3.61). Обзоры состояния дел в этой области читатель может найти в [63, 43, 47].

Предложение 3.4.5 Пусть $C_\omega = (D - \omega\tilde{L})^{-1}((1 - \omega)D + \omega\tilde{U})$ — матрица оператора перехода метода релаксации. Тогда $\rho(C_\omega) \geq |\omega - 1|$, и потому неравенство $0 < \omega < 2$ на параметр релаксации необходимо для сходимости метода.

Доказательство. Преобразуем матрицу C_ω для придания ей более удобного для дальнейших преобразований вида:

$$\begin{aligned} C_\omega &= (D - \omega\tilde{L})^{-1}((1 - \omega)D + \omega\tilde{U}) \\ &= (D(I - \omega D^{-1}\tilde{L}))^{-1}((1 - \omega)D + \omega\tilde{U}) \\ &= (I - \omega D^{-1}\tilde{L})^{-1}D^{-1}((1 - \omega)D + \omega\tilde{U}) \\ &= (I - \omega D^{-1}\tilde{L})^{-1}((1 - \omega)I + \omega D^{-1}\tilde{U}). \end{aligned}$$

Желая исследовать расположение собственных чисел $\lambda_i(C_\omega)$ матрицы C_ω , рассмотрим её характеристический полином

$$\begin{aligned} \phi(\lambda) &= \det(C_\omega - \lambda I) = \det\left((I - \omega D^{-1}\tilde{L})^{-1}((1 - \omega)I + \omega D^{-1}\tilde{U}) - \lambda I\right) \\ &= p_n \lambda^n + p_{n-1} \lambda^{n-1} + \dots + p_1 \lambda + p_0, \end{aligned}$$

в котором $p_n = (-1)^n$ по построению. Свободный член p_0 характери-

стического полинома может быть найден как $\phi(0)$:

$$\begin{aligned} p_0 &= \det\left((I - \omega D^{-1}\tilde{L})^{-1}((1 - \omega)I + \omega D^{-1}\tilde{U})\right) \\ &= \det((I - \omega D^{-1}\tilde{L})^{-1}) \cdot \det((1 - \omega)I + \omega D^{-1}\tilde{U}) \\ &= \det((1 - \omega)I + \omega D^{-1}\tilde{U}) = (1 - \omega)^n, \end{aligned}$$

коль скоро матрица $(I - \omega D^{-1}\tilde{L})$ — нижняя треугольная и диагональными элементами имеет единицы, а $((1 - \omega)I + \omega D^{-1}\tilde{U})$ — верхняя треугольная, с элементами $(1 - \omega)$ по главной диагонали.

С другой стороны, по теореме Виета свободный член характеристического полинома матрицы, делённый на старший коэффициент, равен произведению его корней, т. е. собственных чисел матрицы, умноженному на $(-1)^n$, и поэтому

$$\prod_{i=1}^n \lambda_i(C_\omega) = (1 - \omega)^n.$$

Отсюда необходимо следует

$$\max_{1 \leq i \leq n} |\lambda_i(C_\omega)| \geq |\omega - 1|,$$

что и доказывает Предложение. ■

Теорема 3.4.3 *Если в системе линейных алгебраических уравнений $Ax = b$ матрица A является симметричной положительно определённой, то для всех значений параметра ω , $0 < \omega < 2$, метод релаксации сходится к решению из любого начального приближения.*

Доказательство опускается.

3.4ж Оценка погрешности стационарного итерационного метода

Пусть задан сходящийся стационарный одношаговый итерационный метод

$$x^{(k+1)} \leftarrow Cx^{(k)} + d, \quad k = 0, 1, 2, \dots,$$

в котором некоторая норма матрицы C меньше единицы, т. е. $\|C\| < 1$. Ясно, что ввиду результатов §3.4а последнее допущение не ограничивает общности нашего рассмотрения. Как оценить отклонение по норме

очередного приближения $x^{(k)}$ от предела $x^* := \lim_{k \rightarrow \infty} x^{(k)}$, не зная самого этого предела и наблюдая лишь за итерационной последовательностью $x^{(0)}, x^{(1)}, \dots, x^{(k)}, \dots$?

Как и прежде, имеем

$$\begin{aligned}x^{(k)} &= Cx^{(k-1)} + d, \\x^* &= Cx^* + d.\end{aligned}$$

Вычитая второе равенство из первого, получим

$$x^{(k)} - x^* = C(x^{(k-1)} - x^*). \quad (3.74)$$

Перенесём $x^{(k)}$ в правую часть этого соотношения, а затем добавим к обеим частям по $x^{(k-1)}$:

$$x^{(k-1)} - x^* = x^{(k-1)} - x^{(k)} + C(x^{(k-1)} - x^*).$$

Беря нормы от обеих частей полученного равенства и применяя затем неравенство треугольника, приходим к оценке

$$\|x^{(k-1)} - x^*\| \leq \|x^{(k)} - x^{(k-1)}\| + \|C\| \cdot \|x^{(k-1)} - x^*\|,$$

где векторная норма согласована с используемой матричной нормой для C . Перенесение в левую часть второго слагаемого из правой части и последующее деление обеих частей неравенства на положительную величину $(1 - \|C\|)$ даёт

$$\|x^{(k-1)} - x^*\| \leq \frac{1}{1 - \|C\|} \|x^{(k)} - x^{(k-1)}\|. \quad (3.75)$$

Чтобы ещё улучшить вид этой оценки, вспомним, что из (3.74) следует

$$\|x^{(k)} - x^*\| \leq \|C\| \cdot \|x^{(k-1)} - x^*\|. \quad (3.76)$$

Домножая обе части неравенства (3.75) на $\|C\|$ и учитывая оценку (3.76), получаем окончательно

$$\|x^{(k)} - x^*\| \leq \frac{\|C\|}{1 - \|C\|} \|x^{(k)} - x^{(k-1)}\|. \quad (3.77)$$

Выведенная оценка может быть использована на практике как для оценки погрешности какого-то приближения из итерационной последовательности, так и для определения момента окончания итераций, т. е.

того, достигнута ли желаемая точность приближения к решению или нет.

Пример 3.4.1 Рассмотрим систему линейных алгебраических уравнений

$$\begin{pmatrix} 2 & 1 \\ 3 & 4 \end{pmatrix} x = \begin{pmatrix} 0 \\ 5 \end{pmatrix},$$

точное решение которой равно $(-1, 2)^\top$. Пусть для решения этой системы организован итерационный метод Гаусса-Зейделя с начальным приближением $x^{(0)} = (0, 0)^\top$. Через сколько итераций компоненты очередного приближения к решению станут отличаться от точного решения не более, чем на 10^{-3} ?

Исследуемый нами вопрос требует чебышёвской нормы $\|\cdot\|_\infty$ для измерения отклонения векторов друг от друга, подчинённая матричная норма задаётся выражением из Предложения 3.2.2. Матрица перехода метода Гаусса-Зейделя согласно (3.68) равна

$$-\begin{pmatrix} 2 & 0 \\ 3 & 4 \end{pmatrix}^{-1} \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 0 & -0.5 \\ 0 & 0.375 \end{pmatrix},$$

так что её ∞ -норма равна 0.5. Следовательно, в оценке (3.77) имеем

$$\frac{\|C\|}{1 - \|C\|} = \frac{0.5}{1 - 0.5} = 1,$$

и потому должно быть справедливым неравенство

$$\|x^{(k)} - x^*\|_\infty \leq \|x^{(k)} - x^{(k-1)}\|_\infty. \quad (3.78)$$

Оно показывает, что компоненты очередного приближения отличаются от компонент точного решения не более, чем компоненты приближений друг от друга.

Запустив итерации Гаусса-Зейделя, мы можем видеть, что

$$\begin{aligned} x^{(0)} &= (0, 0)^\top, \\ x^{(1)} &= (0, 1.25)^\top, \\ x^{(2)} &= (-0.625, 1.71875)^\top, \\ &\dots \quad \dots \\ x^{(8)} &= (-0.998957, 1.999218)^\top, \\ x^{(9)} &= (-0.999609, 1.999707)^\top, \end{aligned}$$

т. е. 9-я итерация отличается от предыдущей 8-й меньше чем на 10^{-3} , и потому согласно оценке (3.78) получаем требуемую погрешность. То, что она действительно выполняется, видно из сравнения $x^{(9)}$ с известным нам точным решением $(-1, 2)^T$. ■

3.5 Нестационарные итерационные методы для линейных систем

3.5а Краткая теория

В основу нестационарных итерационных методов для решения систем линейных алгебраических уравнений могут быть положены различные идеи.

В качестве первого примера рассмотрим метод простой итерации (3.62)

$$x^{(k+1)} \leftarrow (I - \tau A) x^{(k)} + \tau b, \quad k = 0, 1, 2, \dots,$$

исследованный нами в §3.4в. Если переписать его в виде

$$x^{(k+1)} \leftarrow x^{(k)} - \tau (Ax^{(k)} - b), \quad k = 0, 1, 2, \dots, \quad (3.79)$$

то расчёт каждой последующей итерации $x^{(k+1)}$ может трактоваться как вычитание из $x^{(k)}$ поправки, пропорциональной вектору текущей невязки $(Ax^{(k)} - b)$. Но при таком взгляде на итерационный процесс можно попытаться изменять параметр τ в зависимости от шага, т. е. взять $\tau = \tau_k$ переменным, рассмотрев итерации

$$x^{(k+1)} \leftarrow x^{(k)} - \tau_k (Ax^{(k)} - b), \quad k = 0, 1, 2, \dots \quad (3.80)$$

Эту нестационарную версию метода простой итерации часто связывают с именем Л.Ф. Ричардсона, предложившего её идею ещё в 1910 году. Он, к сожалению, не смог развить удовлетворительной теории выбора параметров τ_k , и для решения этого вопроса потребовалось ещё несколько десятилетий развития вычислительной математики. Отметим, что задача об оптимальном выборе параметров τ_k на группе из нескольких шагов приводит к так называемым чебышёвским циклическим итерационным методам (см. [63, 35, 43]).

Можно пойти по намеченному выше пути дальше, рассмотрев нестационарное обобщение итерационного процесса

$$x^{(k+1)} \leftarrow (I - \Lambda A) x^{(k)} + \Lambda b, \quad k = 0, 1, 2, \dots,$$

который получен в результате матричного предобуславливания исходной системы линейных алгебраических уравнений. Перепишав его вычислительную схему в виде

$$x^{(k+1)} \leftarrow x^{(k)} - \Lambda(Ax^{(k)} - b), \quad k = 0, 1, 2, \dots,$$

нетрудно увидеть возможность изменения предобуславливающей матрицы Λ в зависимости от номера шага. Таким образом, приходим к весьма общей схеме нестационарных линейных итерационных процессов

$$x^{(k+1)} \leftarrow x^{(k)} - \Lambda_k(Ax^{(k)} - b), \quad k = 0, 1, 2, \dots,$$

где $\{\Lambda_k\}_{k=0}^{\infty}$ — некоторая последовательность матриц, выбор которой зависит, вообще говоря, от начального приближения $x^{(0)}$.

Другой популярный путь построения нестационарных итерационных методов для решения уравнений — использование *вариационных принципов*.

Интуитивно понятный термин *вариация* был введён Ж.-Л. Лагранжем для обозначения малого изменения («шевеления») независимо переменного или функционала. Соответственно, метод вариаций — это метод исследования экстремальных задач, основанный на исследовании зависимости функционалов от вариаций аргументов. Но со временем «вариационными» стали называть методы решения различных уравнений, сводящие исходную постановку задачи к определённым задачам на нахождение экстремума. Соответственно, *вариационными принципами* называют переформулировки интересующих нас задач в виде каких-либо задач на нахождение экстремумов. Тогда итерационные методы решения СЛАУ могут конструироваться как итерационные процессы для отыскания экстремумов тех или иных функционалов.

Вариационные принципы получаются весьма различными способами. Некоторые из них вытекают из содержательного (физического, механического и пр.) смысла решаемой задачи. Например, в классической механике хорошо известны «принцип наименьшего действия Лагранжа», в оптике существует «принцип Ферма». В последнее столетие имеется тенденция всё меньше связывать вариационные принципы с конкретным физическим содержанием, они становятся абстрактным математическим инструментом решения разнообразных задач.

Строго говоря, в вычислительном отношении получающаяся в результате сведения оптимизационная задача может быть не вполне эквивалентна исходной, так как задача нахождения устойчивого решения уравнения может превратиться в неустойчивую задачу о проверке

точного равенства экстремума какому-то определённом значению (см. §4.1б). Но если существование решение уравнения известно априори, до начала процедуры численного исследования (например, на основе каких-либо теорем существования), то вариационные методы становятся важным подспорьем практических вычислений.

Как именно можно переформулировать задачу решения СЛАУ в виде экстремальной задачи? По-видимому, простейший способ может основываться на том факте, что точное решение x^* зануляет норму невязки $\|Ax - b\|$, доставляя ей, таким образом, наименьшее возможное значение. Желая приобрести гладкость получаемого функционала, обычно берут евклидову норму невязки, или даже её квадрат, т. е. скалярное произведение $\langle Ax - b, Ax - b \rangle$, чтобы не привлекать взятия корня. Получающаяся задача называется *линейной задачей о наименьших квадратах*, и мы рассмотрим её подробнее в §3.7.

Ещё одним фактом, который может служить теоретической основой для вариационных методов решения систем линейных алгебраических уравнений является

Предложение 3.5.1 *Вектор $x^* \in \mathbb{R}^n$ является решением системы линейных алгебраических уравнений $Ax = b$ с симметричной положительно определённой матрицей A тогда и только тогда, когда он доставляет минимум функционалу $\Phi(x) = \frac{1}{2}\langle Ax, x \rangle - \langle b, x \rangle$.*

Доказательство. Если A — симметричная положительно-определённая матрица, то, как мы видели в §3.2а, выражением $\frac{1}{2}\langle Ax, x \rangle$ задаётся так называемая *энергетическая норма* векторов на $\mathbb{R}^n$.

Далее, пусть x^* — решение рассматриваемой системы линейных алгебраических уравнений, так что $Ax^* = b$. В силу единственности x^* некоторый вектор $x \in \mathbb{R}^n$ является решением системы тогда и только тогда, когда $x - x^* = 0$, или, иными словами, $\|x - x^*\|_A^2 = 0$.

С другой стороны, учитывая симметричность матрицы A и равенство $Ax^* = b$, получаем

$$\begin{aligned} \|x - x^*\|_A^2 &= \frac{1}{2}\langle A(x - x^*), x - x^* \rangle \\ &= \frac{1}{2}\langle Ax, x \rangle - \frac{1}{2}\langle Ax^*, x \rangle - \frac{1}{2}\langle Ax, x^* \rangle + \frac{1}{2}\langle Ax^*, x^* \rangle \\ &= \frac{1}{2}\langle Ax, x \rangle - \langle b, x \rangle + \frac{1}{2}\langle Ax^*, x^* \rangle \\ &= \Phi(x) + \frac{1}{2}\langle Ax^*, x^* \rangle, \end{aligned} \tag{3.81}$$

т.е. энергетическая норма погрешности отличается от функционала $\Phi(x)$ лишь постоянным слагаемым $\frac{1}{2}\langle Ax^*, x^* \rangle$ (которое заранее неизвестно из-за незнания нами x^*). Следовательно, $\Phi(x)$ действительно достигает своего единственного минимума одновременно с $\|x - x^*\|_A^2$, т.е. на решении рассматриваемой линейной системы. ■

Функционал $\Phi(x) = \frac{1}{2}\langle Ax, x \rangle - \langle b, x \rangle$ является квадратичной формой от вектора переменных x , и его часто называют *функционалом энергии* из-за его сходства с выражениями для различных видов энергии в физических системах.¹¹

3.56 Метод наискорейшего спуска

В предшествующем пункте были предложены две вариационные переформулировки задачи решения системы линейных алгебраических уравнений. Как находить минимум соответствующих функционалов? Прежде, чем строить конкретные численные алгоритмы, рассмотрим общую схему.

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — некоторая функция, ограниченная снизу на всём пространстве $\mathbb{R}^n$ и принимающая своё наименьшее значение в x^* , так что

$$f(x) \geq f(x^*) = \min_{x \in \mathbb{R}^n} f(x) \quad \text{для любых } x \in \mathbb{R}^n.$$

Нам нужно найти точку x^* , в которой достигается наименьшее значение функции f . Типичным методом решения этой задачи является построение последовательности значений аргумента $\{x^{(k)}\}$, которая «минимизирует» функцию f в том смысле, что

$$\lim_{k \rightarrow \infty} f(x^{(k)}) = \min_{x \in \mathbb{R}^n} f(x).$$

Саму функцию f , для которой ищется экстремум, в теории оптимизации называют обычно *целевой функцией*. Если построенная последовательность $\{x^{(k)}\}$ сходится к некоторому пределу x^* , то он и является решением задачи в случае непрерывности функции f .

¹¹К примеру, кинетическая энергия тела массы m , движущегося со скоростью v , равна $mv^2/2$. Энергия упругой деформации пружины с жёсткостью k , растянутой или сжатой на величину x , равна $kx^2/2$. И т.д.




Рис. 3.9. График функционала энергии и его линии уровня.

Метод градиентного спуска, является способом построения последовательности, которая является минимизирующей для определённого класса дифференцируемых функций, и заключается в следующем. Пусть уже найдено какое-то приближение $x^{(k)}$, $k = 0, 1, 2, \dots$, к точке минимума функции $f(x)$. Естественная идея состоит в том, чтобы из $x^{(k)}$ сдвинуться по направлению наибольшего убывания целевой функции, которое противоположно направлению градиента $f'(x^{(k)})$, т. е. взять

$$x^{(k+1)} \leftarrow x^{(k)} - \Delta_k f'(x^{(k)}), \quad (3.82)$$

где Δ_k — величина шага, которая выбирается из условия убывания целевой функции на рассматриваемой итерации. Далее мы можем повторить этот шаг ещё раз и ещё ... столько, сколько требуется для достижения требуемого приближения к минимуму.

В интересующем нас случае минимизации функционала энергии $\Phi(x)$, порождаемого системой линейных уравнений с симметричной положительно определённой матрицей, имеем

$$\frac{\partial \Phi(x)}{\partial x_l} = \frac{\partial}{\partial x_l} \left(\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j - \sum_{i=1}^n b_i x_i \right) = \sum_{j=1}^n a_{lj} x_j - b_l,$$

$l = 1, 2, \dots, n$, так что

$$\Phi'(x) = Ax - b,$$

т.е. градиент функционала Φ равен невязке решаемой системы линейных уравнений в рассматриваемой точке. Важнейшим выводом из этого факта является тот, что метод простой итерации (3.62)–(3.79) является ни чем иным, как методом градиентного спуска (3.82) для минимизации функционала энергии Φ , в котором шаг Δ_k выбран постоянным и равным τ .

Вообще, выбор величины шага Δ_k является очень ответственным делом, так как от него зависит и наличие сходимости, и её скорость. Спуск по направлению антиградиента обеспечивает убывание целевой функции лишь при достаточно малых шагах, и потому при неудачно большой величине шага мы можем попасть в точку, где значение функционала не меньше, чем в текущей точке. С другой стороны, слишком малый шаг приведёт к медленному движению в сторону решения. Для градиентного метода с постоянным шагом его трактовка как метода простой итерации позволяет, опираясь на результат §3.4в, выбрать шаг $\Delta_k = \text{const}$, который наверняка обеспечивает сходимость процесса. Именно, если положительные числа μ и M — это нижняя и верхняя границы спектра положительно определённой матрицы A решаемой системы, то в соответствии с (3.63) следует взять

$$\Delta_k = \Delta = \frac{2}{M + \mu}.$$

Другой способ выбора шага состоит в том, чтобы потребовать Δ_k наибольшим возможным, обеспечивающим убывание функционала Φ вдоль выбранного направления спуска по антиградиенту. При этом получается разновидность градиентного спуска, называемая *методом наискорейшего спуска*, которая была развита в конце 40-х годов XX века Л.В. Канторовичем.

Для определения конкретной величины шага Δ_k в методе наискорейшего спуска нужно подставить выражение $x^{(k)} - \Delta_k \Phi'(x^{(k)}) = x^{(k)} - \Delta_k (Ax^{(k)} - b)$ в аргумент функционала энергии и продифференцировать получающееся отображение по Δ_k . Для удобства выкладок обо-

значим невязку $r^{(k)} := Ax^{(k)} - b$ и шаг $\tau_k := \Delta_k$. Имеем

$$\begin{aligned}\Phi(x^{(k)} - \tau_k r^{(k)}) &= \frac{1}{2} \langle A(x^{(k)} - \tau_k r^{(k)}), x^{(k)} - \tau_k r^{(k)} \rangle - \langle b, x^{(k)} - \tau_k r^{(k)} \rangle \\ &= \frac{1}{2} \langle Ax^{(k)}, x^{(k)} \rangle - \tau_k \langle Ax^{(k)}, r^{(k)} \rangle + \frac{1}{2} \tau_k^2 \langle Ar^{(k)}, r^{(k)} \rangle \\ &\quad - \langle b, x^{(k)} \rangle + \tau_k \langle b, r^{(k)} \rangle.\end{aligned}$$

При дифференцировании выписанного выражения по τ_k не зависящие от него члены исчезнут, мы получим

$$\begin{aligned}\frac{d}{d\tau_k} \Phi(x^{(k)} - \tau_k r^{(k)}) &= -\langle Ax^{(k)}, r^{(k)} \rangle + \tau_k \langle Ar^{(k)}, r^{(k)} \rangle + \langle b, r^{(k)} \rangle \\ &= \tau_k \langle Ar^{(k)}, r^{(k)} \rangle - \langle Ax^{(k)} - b, r^{(k)} \rangle \\ &= \tau_k \langle Ar^{(k)}, r^{(k)} \rangle - \langle r^{(k)}, r^{(k)} \rangle.\end{aligned}$$

Таким образом, в точке экстремума по τ_k из условия

$$\frac{d}{d\tau_k} \Phi(x^{(k)} - \tau_k r^{(k)}) = 0$$

необходимо следует

$$\tau_k = \frac{\langle r^{(k)}, r^{(k)} \rangle}{\langle Ar^{(k)}, r^{(k)} \rangle}.$$

Легко видеть, что при найденном значении τ_k функционалом энергии действительно достигается минимум по выбранному направлению спуска, так как тогда его вторая производная, равная $\langle Ar^{(k)}, r^{(k)} \rangle$, положительна. В целом, псевдокод метода наискорейшего градиентного спуска для решения системы линейных алгебраических уравнений $Ax = b$ представлен в Табл. 3.5.

Теорема 3.5.1 *Если A — симметричная положительно определённая матрица, то последовательность $\{x^{(k)}\}$, порождаемая методом наискорейшего спуска, сходится к решению x^* системы уравнений $Ax = b$ из любого начального приближения $x^{(0)}$, и быстрота этой сходимости оценивается неравенством*

$$\|x^{(k)} - x^*\|_A \leq \left(\frac{M - \mu}{M + \mu} \right)^k \|x^{(0)} - x^*\|_A, \quad (3.83)$$

где μ , M — нижняя и верхняя границы спектра матрицы A .

Таблица 3.5. Псевдокод метода наискорейшего спуска для решения систем линейных уравнений.

```

выбираем начальное приближение  $x^{(0)}$ ;
 $k \leftarrow 0$ ;
DO WHILE ( метод не сошёлся )
     $r^{(k)} \leftarrow Ax^{(k)} - b$ ;
     $\tau_k \leftarrow \frac{\langle r^{(k)}, r^{(k)} \rangle}{\langle Ar^{(k)}, r^{(k)} \rangle}$ ;
     $x^{(k+1)} \leftarrow x^{(k)} - \tau_k r^{(k)}$ ;
     $k \leftarrow k + 1$ ;
END DO

```

Доказательство оценки (3.83) и теоремы в целом будет получено путём сравнения метода наискорейшего спуска с методом градиентного спуска с постоянным оптимальным шагом. В самом деле, из равенства (3.81)

$$\|x - x^*\|_A^2 = \Phi(x) + \langle Ax^*, x^* \rangle,$$

следует, что метод, обеспечивающий лучшее убывание значения функционала энергии одновременно обеспечивает лучшее приближение к решению в энергетической норме.

В методе градиентного спуска с постоянным шагом — совпадающем с методом простой итерации (3.62) или (3.79) — имеем

$$x^{(k+1)} - x^* = (I - \tau A)(x^{(k)} - x^*).$$

По этой причине

$$\begin{aligned}
 \|x^{(k+1)} - x^*\|_A^2 &= \langle A(x^{(k+1)} - x^*), x^{(k+1)} - x^* \rangle \\
 &= \langle A(I - \tau A)(x^{(k)} - x^*), (I - \tau A)(x^{(k)} - x^*) \rangle \\
 &= \langle (I - \tau A)A(x^{(k)} - x^*), (I - \tau A)(x^{(k)} - x^*) \rangle \\
 &\leq \|I - \tau A\|_2^2 \langle A(x^{(k)} - x^*), (x^{(k)} - x^*) \rangle \\
 &\leq \|I - \tau A\|_2^2 \|x^{(k)} - x^*\|_A^2.
 \end{aligned}$$

При этом у метода наискорейшего спуска оценка заведомо не хуже этой оценки, в которой взято значение параметра шага $\tau = 2/(M + \mu)$, оптимальное для спуска с постоянным шагом. Тогда в соответствии с оценкой (3.64) для метода простой итерации получаем

$$\|x^{(k+1)} - x^*\|_A \leq \left(\frac{M - \mu}{M + \mu} \right) \|x^{(k)} - x^*\|_A,$$

откуда следует доказываемая оценка (3.83). ■




Рис. 3.10. Иллюстрация работы метода наискорейшего спуска.

Интересно и поучительно рассмотреть геометрическую иллюстрацию работы метода наискорейшего спуска.

Коль скоро A — симметричная матрица, она может быть приведена к диагональной форме D ортогональным преобразованием подобия:

$$A = Q^\top D Q,$$

причём в силу положительной определённости матрицы A по диагонали в D стоят положительные элементы — собственные значения A . Подставляя это представление в выражение для функционала энергии $\Phi(x)$, получим

$$\begin{aligned}\Phi(x) &= \langle Q^T D Q x, x \rangle - 2\langle b, x \rangle \\ &= \langle D(Qx), Qx \rangle - 2\langle Qb, Qx \rangle \\ &= \langle Dy, y \rangle - 2\langle Qb, y \rangle,\end{aligned}$$

где обозначено $y = Qx$. Видим, что в изменённой системе координат, которая получается с помощью ортогонального линейного преобразования переменных, выражение для функционала энергии есть сумма квадратов с коэффициентами, равными собственным значениям матрицы — член $\langle Dy, y \rangle$, минус линейный член $2\langle Qb, y \rangle$. Таким образом, график функционала энергии — это эллиптический параболоид, возможно, сдвинутый относительно начала координат и ещё повернутый, а его поверхности уровня (линии уровня в двумерном случае) — эллипсоиды (эллипсы), в центре которых находится искомое решение системы уравнений. При этом форма эллипсоидов уровня находится в зависимости от разброса коэффициентов при квадратах переменных, т. е. от числа обусловленности матрицы A . Чем больше эта обусловленность, тем сильнее сплюснены эллипсоиды уровня.

Градиент функционала энергии нормален к поверхностям уровня, и именно по этим направлениям осуществляется «спуск» — движение в сторону решения. Шаг в методе наискорейшего спуска идёт на максимально возможную величину — до пересечения с касательным эллипсоидом. Поэтому траектория метода наискорейшего спуска является ломаной, звенья которой перпендикулярны друг другу (см. Рис. 3.10).

Хотя доказательство Теоремы 3.5.1 основано на мажоризации наискорейшего спуска методом простой итерации и может показаться довольно грубым, в действительности оценка (3.83) весьма точно передаёт особенности поведения метода, а именно, замедление сходимости при $M \gg \mu$. Тот факт, что в случае плохой обусловленности матрицы системы движение к решению в методе наискорейшего спуска весьма далеко от оптимального, подтверждается вычислительной практикой и может быть понято на основе геометрической интерпретации. Искомое решение находится при этом на дне глубокого и вытянутого оврага, а метод «рыскает» от одного склона оврага к другому вместо того, чтобы идти напрямую к глубочайшей точке — решению.

Другой популярный подход к выбору итерационных параметров τ_k в нестационарном итерационном процессе (3.80), названный *методом минимальных невязок*, был предложен С.Г. Крейном и М.А. Красносельским в работе [22].

Если сходимость методов наискорейшего спуска и минимальных невязок принципиально не лучше сходимости метода простой итерации, то имеют ли они какое-либо практическое значение? Вспомним, что наша оптимизация метода простой итерации основывалась на знании границ спектра симметричной положительно определённой матрицы СЛАУ. Для работы методов наискорейшего спуска и минимальных невязок этой информации не требуется.

3.5в Метод сопряжённых градиентов

В практике вычислений для решения систем линейных алгебраических уравнений большое распространение получили *методы сопряжённых градиентов*, которые являются двухшаговыми нестационарными итерационными алгоритмами.

3.6 Вычисление обратной матрицы и определителя матрицы

Нечасто, но всё-таки иногда приходится вычислять обратную к данной матрице. Например, это необходимо при нахождении дифференциала операции обращения матрицы $A \mapsto A^{-1}$, равного

$$d(A^{-1}) = -A^{-1}(dA)A^{-1}.$$

Матрица A^{-1} , обратная к данной матрице A , является решением матричного уравнения

$$AX = I.$$

Но это уравнение распадается на n уравнений относительно векторных неизвестных, соответствующих отдельным столбцам неизвестной матрицы X , и мы можем решать получающиеся уравнения порознь.

Из сказанного следует способ нахождения обратной матрицы: нужно решить n штук систем линейных уравнений

$$Ax = e^{(j)}, \quad j = 1, 2, \dots, n, \quad (3.84)$$

где $e^{(j)}$ — j -ый столбец единичной матрицы I . Это можно сделать, к примеру, методом Гаусса или любым другим из рассмотренных выше методов, которые здесь особенно удобны в своей матричной трактовке. В самом деле, сначала мы можем выполнить один раз LU-разложение исходной матрицы A , а затем хранить его и использовать посредством схемы (3.31) для различных правых частей уравнений (3.84).

Другой подход — конструирование чисто матричных процедур, не опирающихся на методы решения систем линейных уравнений с векторными неизвестными. Известен итерационный *метод Шульца* для обращения матриц: задавшись специальным начальным приближением $X^{(0)}$, выполняют итерации

$$X^{(k+1)} \leftarrow X^{(k)} (2I - AX^{(k)}), \quad k = 0, 1, 2, \dots \quad (3.85)$$

Метод Шульца — это не что иное как метод Ньютона для решения системы уравнений, применённый к $X^{-1} - A = 0$. Его можно также рассматривать как матричную версию известной процедуры для вычисления обратной величины (см. [13], глава 3).

Отметим, что гораздо чаще встречается необходимость вычисления произведения обратной матрицы A^{-1} на какой-то вектор b , и это произведение всегда следует находить как решение системы уравнений $Ax = b$ какими-либо из методов для решения СЛАУ. Такой способ заведомо лучше, чем вычисление $A^{-1}b$ через нахождение обратной A^{-1} , как по точности, так и по трудоёмкости.

Рассмотрим теперь вычисление определителя матрицы.

Мы уже отмечали раньше, что выполняемые в методе Гаусса преобразования — линейное комбинирование строк — не изменяют величины определителя матрицы. Следовательно, $\det A$ равен определителю получающейся в итоге верхней треугольной матрицы U , т. е. $\det A$ есть произведение диагональных элементов U .

Другая возможная трактовка этого результата состоит в том, что если $A = LU$, то, как известно из линейной алгебры,

$$\det A = \det L \cdot \det U.$$

Определитель нижней треугольной матрицы L равен 1, коль скоро на её диагонали стоят все единицы. Следовательно, как и ранее, $\det A = \det U$, а точнее — произведению всех диагональных элементов в верхней треугольной матрице U .

Совершенно аналогичные выводы можно сделать и при использовании других матричных разложений. Например, если нам удалось получить $A = QR$ — разложение исходной матрицы в произведение ортогональной и правой треугольной, то, коль скоро $\det Q = 1$, искомым определитель $\det A = \det R$ и вычисляется по R как произведение её диагональных элементов.

3.7 Линейная задача о наименьших квадратах

Для заданных $m \times n$ -матрицы A и m -вектора b *линейной задачей о наименьших квадратах* называют задачу отыскания такого вектора x , который доставляет минимум квадратичной форме $\langle Ax - b, Ax - b \rangle$, или, что равносильно, квадрату евклидовой нормы невязки $\|Ax - b\|_2^2$. Ясно, что для матриц A полного ранга в случае $m \leq n$, когда число строк матрицы не превосходит числа столбцов, искомым минимум, как правило, равен нулю. Для квадратной матрицы A линейная задача о наименьших квадратах, фактически, равносильна решению системы линейных алгебраических уравнений $Ax = b$ и несёт особую специфику лишь когда A имеет неполный ранг, т.е. особенна. Теоретически и практически наиболее важный случай линейной задачи о наименьших квадратах соответствует $m > n$. Он находит многочисленные и разнообразные применения при обработке данных

Коль скоро

$$\begin{aligned} \langle Ax - b, Ax - b \rangle &= \langle Ax, Ax \rangle - \langle b, Ax \rangle - \langle Ax, b \rangle + \langle b, b \rangle \\ &= \langle Ax, Ax \rangle - 2\langle Ax, b \rangle + \langle b, b \rangle, \end{aligned}$$

то

$$\frac{\partial}{\partial x_i} \langle Ax - b, Ax - b \rangle = \frac{\partial}{\partial x_i} (\langle Ax, Ax \rangle - 2\langle Ax, b \rangle)$$

Система линейных алгебраических уравнений

$$A^T A x = A^T b \tag{3.86}$$

называется *нормальной системой уравнений* для линейной задачи о наименьших квадратах с матрицей A и вектором b . Её решение и доставляет искомым минимум выражению $\|Ax - b\|_2^2$

3.8 Численное решение проблемы собственных значений

3.8a Обсуждение постановки задачи

Ненулевой вектор называется *собственным вектором* квадратной матрицы, если в результате умножения на эту матрицу он переходит в коллинеарный ему, т. е. отличающийся от исходного только скалярным множителем. Сам скаляр, который является коэффициентом пропорциональности исходного вектора и его образа при действии матрицы, называют *собственным значением* матрицы. *Проблемой собственных значений* называют задачу определения собственных значений и собственных векторов матриц: для заданной $n \times n$ -матрицы A найти числа λ и n -векторы $v \neq 0$, удовлетворяющие условию

$$Av = \lambda v. \quad (3.87)$$

Как собственные числа λ , так и собственные векторы v являются, вообще говоря, комплексными. Из курса линейной алгебры читателю должно быть известно, что задача нахождения собственных значений матрицы A эквивалентна задаче нахождения корней характеристического (векового) уравнения матрицы $\det(A - \lambda I) = 0$.

Иногда при упоминании этой задачи подчёркивают — «алгебраическая проблема собственных значений», чтобы уточнить, что речь идёт о матрицах конечных размеров, конечномерной ситуации и т. п. в отличие, скажем, от задачи нахождения собственных значений операторов в бесконечномерных пространствах функций. Слово «проблема» также уместно в этом контексте, поскольку рассматриваемая задача сложна и имеет много аспектов.

Собственные значения матриц нужно знать во многих приложениях. Например, задача определения частот собственных колебаний механических систем (весьма важная при проектировании и механических конструкций и не только) сводится к нахождению собственных значений так называемых матриц жёсткости этих систем.

Пример 3.8.1 Линейные динамические системы с дискретным временем вида

$$x^{(k+1)} = Ax^{(k)} + b^{(k)}, \quad k = 0, 1, 2, \dots, \quad (3.88)$$

служат моделями разнообразных процессов окружающего нас мира, от биологии до экономики.

Общее решение такой системы есть сумма частного решения исходной системы (3.88) и общего решения однородной системы $x^{(k+1)} = Ax^{(k)}$ без свободного члена. Если искать нетривиальные решения однородной системы в виде $x^{(k)} = \lambda^k h$, где λ — ненулевой скаляр и $h \in \mathbb{R}^n$ — n -вектор, то нетрудно убедиться, что λ должно быть собственным значением A , а h — собственным вектором матрицы A . ■

Различают *полную проблему* собственных значений и *частичную проблему* собственных значений. В полной проблеме требуется нахождение всех собственных чисел и собственных векторов. Частичная проблема собственных значений — это задача нахождения некоторых собственных чисел матрицы и/или некоторых собственных векторов. К примеру, наибольшего по модулю собственного значения, или нескольких наибольших по модулю собственных значений и соответствующих им собственных векторов.

Ясно, что собственные векторы матрицы определяются неоднозначно, с точностью до скалярного множителя. В связи с этим часто говорят о нахождении одномерных *инвариантных подпространств* матрицы. Инвариантные подпространства матрицы могут иметь и большую размерность, и в любом случае их знание доставляет важную информацию о рассматриваемом линейном операторе, позволяя упростить его представление. В последние десятилетия задача определения для матрицы тех или иных инвариантных подпространств, не обязательно одномерных, также включается в «проблему собственных значений».

Особенности проблемы собственных значений, осложняющие её решение:

- необходимость выхода в комплексную плоскость $\mathbb{C}$, даже для вещественных матриц;
- нелинейный характер задачи, несмотря на традицию отнесения её к вычислительной линейной алгебре.

Последнее обстоятельство нетрудно осознать из рассмотрения основного соотношения (3.87)

$$Av = \lambda v,$$

которое является системой уравнений относительно λ и v , причём в его правой части суммарная степень неизвестных переменных равна *двум*: $2 = (1 \text{ при } \lambda) + (1 \text{ при } v)$.

Система уравнений (3.87) кажется недоопределённой, так как содержит $n + 1$ неизвестных, которые нужно найти из n уравнений. Но на

самом деле можно замкнуть её, к примеру, каким-нибудь условием нормировки собственных векторов ($\|v\| = 1$ в какой-то норме) или требованием, чтобы какая-нибудь компонента v принимала бы заданное значение. Последнее условие иногда даже более предпочтительно ввиду своей линейности.

Если собственное значение λ_i матрицы A уже найдено, то, как известно, определение соответствующих собственных векторов сводится к решению системы линейных алгебраических уравнений

$$(A - \lambda_i I)x = 0$$

с особой матрицей. Но на практике часто предпочитают пользоваться для нахождения собственных векторов специализированными вычислительными процедурами. Многие из них позволяют вычислять собственные векторы одновременно с собственными значениями матриц.

В заключение нашего обсуждения коснёмся алгоритмического аспекта проблемы собственных значений. Напомним известную в алгебре теорему Абеля-Руффини: для алгебраических полиномов степени выше 4 не существует прямых методов нахождения корней. Как следствие, мы не вправе ожидать существования прямых методов решения проблемы собственных значений для произвольных матриц размера более 4×4 , и потому рассматриваемые ниже методы — существенно итерационные.

3.86 Обусловленность проблемы собственных значений

Спектр матрицы, как множество точек комплексной плоскости $\mathbb{C}$, непрерывно зависит от элементов матрицы. Соответствующий результат часто называют теоремой Островского (читатель может увидеть детальное изложение этой теории в книгах [18, 24, 31, 39, 48]). Но собственные векторы (инвариантные подпространства) матрицы могут изменяться в зависимости от матрицы разрывным образом даже в совершенно обычных ситуациях.

Пример 3.8.2 [48] Рассмотрим матрицу

$$A = \begin{pmatrix} 1 + \varepsilon & \delta \\ 0 & 1 \end{pmatrix}.$$

Её собственные значения суть числа 1 и $1 + \varepsilon$, и при $\varepsilon\delta \neq 0$ соответствующими нормированными собственными векторами являются

$$\frac{1}{\sqrt{\varepsilon^2 + \delta^2}} \begin{pmatrix} -\delta \\ \varepsilon \end{pmatrix} \quad \text{и} \quad \begin{pmatrix} 1 \\ 0 \end{pmatrix}.$$

Выбирая подходящим образом отношение ε/δ , можно придать первому собственному вектору любое направление, сколь бы малыми ни являлись значения ε и δ .

Если положить $\varepsilon = 0$, то

$$A = \begin{pmatrix} 1 & \delta \\ 0 & 1 \end{pmatrix}.$$

При $\delta \neq 0$ у матрицы A будет всего один собственный вектор, хотя при надлежащем δ её можно сделать сколь угодно близкой к единичной матрице, имеющей два линейно независимых собственных вектора. ■

При более пристальном изучении проблемы собственных значений выясняется, что, несмотря на непрерывную зависимость собственных значений от элементов матрицы, скорость их изменения может быть сколь угодно большой (даже для матриц фиксированного размера), если они соответствуют так называемым нелинейным элементарным делителям матрицы — жордановым клеткам размера 2 и более.

Пример 3.8.3 Собственные значения матрицы

$$A = \begin{pmatrix} \lambda & 1 \\ \varepsilon & \lambda \end{pmatrix}$$

— возмущённой жордановой 2×2 -клетки — равны $\lambda \pm \sqrt{\varepsilon}$, так что мгновенная скорость их изменения, равная $\sqrt{\varepsilon}/\varepsilon$, при $\varepsilon = 0$ бесконечна. Это же явление имеет место и для произвольной жордановой клетки, размером более двух. ■

Всюду далее в этом параграфе большую роль будут играть матрицы, которые преобразованием подобия можно привести к диагональному виду — так называемые *матрицы простой структуры* или *диагонализуемые матрицы*.¹² Собственные числа таких матриц зависят от возмущений гораздо более «плавным образом», чем в общем случае.

¹²Такие матрицы называют также *недефектными*.

Теорема Бауэра-Файка. Если A — квадратная матрица простой структуры, $\lambda_i(A)$ — её собственные числа, V — матрица из собственных векторов A , а $\tilde{\lambda}$ — собственное число возмущённой матрицы $A + \Delta A$, то

$$\min_i |\tilde{\lambda} - \lambda_i(A)| \leq \text{cond}_2(V) \|\Delta A\|_2. \quad (3.89)$$

Доказательство. Если $\tilde{\lambda}$ совпадает с каким-то из собственных значений исходной матрицы A , то левая часть доказываемого неравенства зануляется, и оно, очевидно, справедливо. Будем поэтому предполагать, что $\tilde{\lambda}$ не совпадает ни с одним из $\lambda_i(A)$, $i = 1, 2, \dots, n$. Следовательно, если, согласно условию теоремы

$$V^{-1}AV = D,$$

где $D = \text{diag} \{\lambda_1, \lambda_2, \dots, \lambda_n\}$ — диагональная матрица с собственными числами матрицы A по диагонали, то матрица $D - \tilde{\lambda}I$ неособенна.

С другой стороны, матрица $A + \Delta A - \tilde{\lambda}I$ является особенной по построению, так что особенна и матрица $V^{-1}(A + \Delta A - \tilde{\lambda}I)V$. Но

$$\begin{aligned} V^{-1}(A + \Delta A - \tilde{\lambda}I)V &= (D - \tilde{\lambda}I) + V^{-1}(\Delta A)V \\ &= (D - \tilde{\lambda}I)(I + (D - \tilde{\lambda}I)^{-1}V^{-1}(\Delta A)V), \end{aligned}$$

откуда можно заключить о том, что особенной должна быть матрица $(I + (D - \tilde{\lambda}I)^{-1}V^{-1}(\Delta A)V)$. Как следствие, матрица

$$(D - \tilde{\lambda}I)^{-1}V^{-1}(\Delta A)V$$

имеет собственное значение -1 , и потому любая норма этой матрицы должна быть не меньшей 1. В частности, это верно для спектральной нормы:

$$\|(D - \tilde{\lambda}I)^{-1}V^{-1}(\Delta A)V\|_2 \geq 1.$$

Отсюда

$$\max_{1 \leq i \leq n} |(\lambda_i - \tilde{\lambda})^{-1}| \cdot \|V^{-1}\|_2 \|\Delta A\|_2 \|V\|_2 \geq 1.$$

Последнее неравенство равносильно

$$\min_{1 \leq i \leq n} |(\lambda_i - \tilde{\lambda})^{-1}| \leq \|V^{-1}\|_2 \|\Delta A\|_2 \|V\|_2,$$

или

$$\min_i |\tilde{\lambda} - \lambda_i(A)| \leq \text{cond}_2(V) \|\Delta A\|_2,$$

как и требовалось. ■

Теорема Бауэра-Файка показывает, что, каково бы ни было возмущение ΔA матрицы простой структуры A , для любого собственного значения $\tilde{\lambda}$ возмущённой матрицы $A + \Delta A$ найдётся собственное значение λ_i матрицы A , отличающееся от $\tilde{\lambda}$ не более чем на величину спектральной нормы возмущения $\|\Delta A\|_2$, умноженную на число обусловленности матрицы собственных векторов. Таким образом, обусловленность матрицы собственных векторов матрицы может служить мерой обусловленности проблемы собственных значений. Практическую ценность неравенства (3.89) и теоремы Бауэра-Файка в целом снижает то обстоятельство, что собственные векторы матрицы определены с точностью до скалярного множителя, и потому $\text{cond}_2(V)$ есть величина, заданная не вполне однозначно. Наилучшим выбором для $\text{cond}_2(V)$ в неравенстве был бы, очевидно, минимум чисел обусловленности матриц из собственных векторов, но его нахождение является сложной задачей. Тем не менее, прикидочные оценки и качественные выводы на основе теоремы Бауэра-Файка делать можно.

Предложение 3.8.1 *Матрицы простой структуры образуют открытое всюду плотное подмножество во множестве всех квадратных матриц.*

Как следствие, матрицы с нелинейными элементарными делителями, которые соответствуют жордановым клеткам размера 2 и более, составляют множество *первой бэровской категории* во множестве всех матриц. Подобные множества, называемые также *тощими*, являются в топологическом смысле наиболее разреженными и бедными множествами (см. [17, 46]). Но на долю таких матриц приходятся главные трудности, с которыми сталкиваются при решении проблемы собственных значений. В этом отношении задача нахождения сингулярных чисел и сингулярных векторов является принципиально другой, так как симметричная матрица $A^T A$ (эрмитова матрица $A^* A$ в комплексном случае) всегда имеет простую структуру, т. е. диагонализуема.

3.8в Коэффициенты перекоса матрицы

Целью этого пункта является детальное исследование устойчивости решения проблемы собственных значений в упрощённой ситуации, когда все собственные значения матрицы A различны. Именно в этом случае, как было отмечено в §3.8б, собственные векторы непрерывно зависят от элементов матрицы и, более того, существуют их конечные дифференциалы.

Нам будет необходим вспомогательный результат, касающийся так называемой *сопряжённой задачи* на собственные значения. Так называют задачу нахождения собственных чисел и собственных векторов для эрмитово сопряжённой матрицы A^* :

$$A^*y = \mu y,$$

где $\mu \in \mathbb{C}$ — собственное значение матрицы A^* и $y \in \mathbb{C}^n$ — соответствующий собственный вектор. Как связаны между собой собственные значения и собственные векторы исходной A и сопряжённой A^* матриц?

Два набора векторов $\{r_1, r_2, \dots, r_m\}$ и $\{s_1, s_2, \dots, s_m\}$ в евклидовом пространстве, состоящие из одного и того же их числа, называются *биортогональными*, если $\langle r_i, s_i \rangle = 0$ при $i \neq j$. Приставка «би» означает отнесение этого свойства к *двум* наборам векторов.

Ясно, что выполнение свойства биортогональности существенно зависит от порядка нумерации векторов в пределах каждого из наборов, так что в определении биортогональности неявно предполагается, что необходимые нумерации существуют и рассматриваемые наборы упорядочены в соответствии с ними. Нетрудно также понять, что если какой-либо набор векторов биортогонален сам себе, то он ортогонален в обычном смысле.

Предложение 3.8.2 *Собственные значения эрмитово-сопряжённых матриц попарно комплексно сопряжены друг другу. Собственные векторы сопряжённых задач биортогональны.*

Доказательство. Определитель матрицы не меняется при её транспонировании, $\det A^T = \det A$. Комплексное сопряжение элементов матрицы влечёт комплексное сопряжение её определителя, $\det \bar{A} = \overline{\det A}$. Следовательно,

$$\det(A - \lambda I) = \det(A^T - \lambda I) = \overline{\det(\bar{A}^T - \bar{\lambda} I)} = \overline{\det(A^* - \bar{\lambda} I)}.$$

Отсюда мы можем заключить, что комплексное число λ является корнем характеристического полинома $\det(A - \lambda I) = 0$ матрицы A тогда и только тогда, когда ему сопряжённое $\bar{\lambda}$ является корнем полинома $\det(A^* - \lambda I)$, который является характеристическим для матрицы A^* . Это доказывает первое утверждение.

Пусть x и y — собственные векторы матриц A и A^* соответственно, а λ и μ — отвечающие им собственные числа этих матриц. Для доказательства второго утверждения выпишем следующую цепочку преобразований:

$$\langle x, y \rangle = \frac{1}{\lambda} \langle \lambda x, y \rangle = \frac{1}{\lambda} \langle Ax, y \rangle = \frac{1}{\lambda} \langle x, A^* y \rangle = \frac{1}{\lambda} \langle x, \mu y \rangle = \frac{\bar{\mu}}{\lambda} \langle x, y \rangle.$$

Поэтому

$$\langle x, y \rangle - \frac{\bar{\mu}}{\lambda} \langle x, y \rangle = 0,$$

то есть

$$\langle x, y \rangle \left(1 - \frac{\bar{\mu}}{\lambda} \right) = 0.$$

Если x и y являются собственными векторами матриц A и A^* , отвечающими собственным значениям λ и μ , которые не сопряжены комплексно друг другу, то второй сомножитель $(1 - \bar{\mu}/\lambda) \neq 0$. По этой причине необходимо $\langle x, y \rangle = 0$, что и требовалось доказать. ■

Обратимся теперь к анализу возмущений собственных чисел и собственных векторов матриц. Пусть A — данная матрица и dA — дифференциал (главная линейная часть) её возмущения, так что $A + dA$ — это близкая к A возмущённая матрица. Как изменятся собственные значения и собственные векторы матрицы $A + dA$ в сравнении с собственными значениями и собственными векторами A ?

Имеем

$$Ax_i = \lambda_i x_i,$$

$$(A + dA)(x_i + dx_i) = (\lambda_i + d\lambda_i)(x_i + dx_i),$$

где через λ_i обозначены собственные значения A , x_i — собственные векторы, $i = 1, 2, \dots, n$, причём последние образуют базис в $\mathbb{R}^n$, коль скоро по предположению A является матрицей простой структуры. Пренебрегая членами второго порядка малости, можем выписать равенство

$$(dA)x_i + A(dx_i) = \lambda_i(dx_i) + (d\lambda_i)x_i. \quad (3.90)$$

Пусть $y_1, y_2, \dots, y_n$ — собственные векторы эрмитово-сопряжённой матрицы A^* , соответствующие её собственным значениям $\bar{\lambda}_1, \bar{\lambda}_2, \dots, \bar{\lambda}_n$. Умножая скалярно равенство (3.90) на y_j , получим

$$\langle (dA) x_i, y_j \rangle + \langle A(dx_i), y_j \rangle = \lambda_i \langle dx_i, y_j \rangle + (d\lambda_i) \langle x_i, y_j \rangle. \quad (3.91)$$

В частности, при $j = i$ имеем

$$\langle (dA) x_i, y_i \rangle + \langle A(dx_i), y_i \rangle = \lambda_i \langle dx_i, y_i \rangle + (d\lambda_i) \langle x_i, y_i \rangle,$$

где соседние со знаком равенства члены можно взаимно уничтожить: они оказываются одинаковыми, коль скоро

$$\langle A(dx_i), y_i \rangle = \langle dx_i, A^* y_i \rangle = \langle dx_i, \bar{\lambda}_i y_i \rangle = \lambda_i \langle dx_i, y_i \rangle.$$

Следовательно,

$$\langle (dA) x_i, y_i \rangle = (d\lambda_i) \langle x_i, y_i \rangle,$$

и потому

$$d\lambda_i = \frac{\langle (dA) x_i, y_i \rangle}{\langle x_i, y_i \rangle}.$$

Пусть теперь $j \neq i$. Тогда $\langle x_i, y_j \rangle = 0$ в силу Предложения 3.8.2, и потому

$$\langle A(dx_i), y_j \rangle = \langle dx_i, A^* y_j \rangle = \langle dx_i, \bar{\lambda}_j y_j \rangle = \lambda_j \langle dx_i, y_j \rangle.$$

Подставляя этот результат в (3.91), будем иметь

$$\langle (dA) x_i, y_j \rangle + \lambda_j \langle dx_i, y_j \rangle = \lambda_i \langle dx_i, y_j \rangle.$$

Поэтому

$$\langle dx_i, y_j \rangle = \frac{\langle (dA) x_i, y_j \rangle}{\lambda_i - \lambda_j}.$$

Разложим dx_i по базису из собственных векторов невозмущённой матрицы A :

$$dx_i = \sum_{j=1}^n \alpha_{ij} x_j.$$

Так как собственные векторы задаются с точностью до множителя, то в этом разложении коэффициенты α_{ii} содержательного смысла не

имеют, и можно считать, что $\alpha_{ii} = 0$ (напомним, что мы, в действительности, ищем возмущение одномерного инвариантного подпространства матрицы). Для остальных коэффициентов имеем $\langle dx_i, y_j \rangle = \alpha_{ij} \langle x_j, y_j \rangle$, опять таки в силу Предложения 3.8.2. Следовательно, для $i \neq j$

$$\alpha_{ij} = \frac{\langle (dA) x_i, y_j \rangle}{(\lambda_i - \lambda_j) \langle x_j, y_j \rangle}.$$

Перейдём теперь к оцениванию возмущений собственных значений и собственных векторов. Из формулы для дифференциала $d\lambda_i$ и из неравенства Коши-Буняковского следует

$$|d\lambda_i| \leq \frac{\|dA\|_2 \|x\|_2 \|y\|_2}{\langle x_i, y_i \rangle} = \nu_i \|dA\|_2,$$

где посредством

$$\nu_i = \frac{\|x_i\|_2 \|y_i\|_2}{\langle x_i, y_i \rangle}, \quad i = 1, 2, \dots, n,$$

обозначены величины, называемые *коэффициентами перекоса* матрицы A , отвечающие собственным значениям λ_i , $i = 1, 2, \dots, n$.

Ясно, что $\nu_i \geq 1$, и можно интерпретировать коэффициенты перекоса как

$$\nu_i = \frac{1}{\cos \varphi_i},$$

где φ_i угол между собственными векторами x_i и y_i исходной и сопряжённой матриц. Коэффициенты перекоса характеризуют, таким образом, обусловленность проблемы собственных значений в смысле второго подхода §1.2.

Для симметричной (или, более общо, эрмитовой) матрицы коэффициенты перекоса равны 1. В самом деле, сопряжённая к ней задача на собственные значения совпадает с ней самой, и потому в наших обозначениях $x_i = y_i$, $i = 1, 2, \dots, n$. Следовательно, $\langle x_i, y_i \rangle = \langle x_i, x_i \rangle = \|x_i\|_2^2$, откуда и следует $\nu_i = 1$.

Это наименьшее возможное значение коэффициентов перекоса, так что численное нахождение собственных значений симметричных (эрмитовых в комплексном случае) матриц является наиболее устойчивым.

Что касается возмущений собственных векторов, то коэффициенты α_{ij} их разложения оцениваются сверху как

$$|\alpha_{ij}| \leq \frac{\|(dA) x_i\|_2 \|y_j\|_2}{|\lambda_i - \lambda_j| \cdot |\langle x_j, y_j \rangle|} \leq \frac{\|dA\|_2}{|\lambda_i - \lambda_j|} \nu_j,$$

Величина возмущения, изменившего в рассмотренном примере наименьшее собственное значение с 1 до 0, примерно равна одинарной точности представления на ЭЦВМ машинных чисел в районе единицы. Как видим, несмотря на то, что все собственные числа матрицы различны и, следовательно, являются гладкими функциями от элементов матрицы, скорость их изменения настолько велика, что практически мы как будто бы имеем дело с разрывными функциями.

3.8г Круги Гершгорина

Пусть $A = (a_{ij})$ — квадратная матрица из $\mathbb{R}^{n \times n}$ или $\mathbb{C}^{n \times n}$. Если $\lambda \in \mathbb{C}$ — её собственное значение, то

$$Av = \lambda v \quad (3.93)$$

для некоторого собственного вектора $v \in \mathbb{C}^n$. Предположим, что в v наибольшее абсолютное значение имеет компонента с номером l , так что $|v_l| = \max_{1 \leq j \leq n} |v_j|$. Коль скоро собственные векторы матрицы определены с точностью до скалярного множителя, можно нормировать v так, чтобы

$$v = (x_1, \dots, x_{l-1}, 1, x_{l+1}, \dots, x_n)^T,$$

причём $|v_j| \leq 1$ для $j \neq l$.

Рассмотрим l -ую компоненту векторного равенства (3.93):

$$\sum_{j=1}^n a_{lj} v_j = \lambda v_l = \lambda.$$

Из неё следует при сделанных относительно вектора v предположениях, что

$$\lambda - a_{ll} = \sum_{j \neq l}^n a_{lj} v_j.$$

По этой причине

$$|\lambda - a_{ll}| = \left| \sum_{j \neq l}^n a_{lj} v_j \right| \leq \sum_{j \neq l}^n |a_{lj} v_j| = \sum_{j \neq l}^n |a_{lj}| |v_j| \leq \sum_{j \neq l}^n |a_{lj}|,$$

Не зная собственного вектора v , мы не располагаем и номером l его наибольшей по модулю компоненты. Но можно действовать наверняка, рассмотрев дизъюнкцию соотношений выписанного выше вида для

всех $l = 1, 2, \dots, n$, так как хотя бы для одного из них непременно справедливы выполненные нами рассуждения. Потому в целом, если λ — какое-либо собственное значение рассматриваемой матрицы A , должно выполняться хотя бы одно из неравенств

$$|\lambda - a_{ii}| \leq \sum_{j \neq i} |a_{ij}|, \quad i = 1, 2, \dots, n.$$

Каждое из этих соотношений на λ определяет на комплексной плоскости $\mathbb{C}$ круг с центром в точке a_{ii} и радиусом, равным $\sum_{j \neq i} |a_{ij}|$. Мы приходим, таким образом, к результату, который был установлен в 1931 году С.А. Гершгоринам:

Теорема 3.8.1 *Все собственные значения $\lambda(A)$ любой вещественной или комплексной $n \times n$ -матрицы $A = (a_{ij})$ расположены в объединении кругов комплексной плоскости с центрами a_{ii} и радиусами $\sum_{j \neq i} |a_{ij}|$, $i = 1, 2, \dots, n$, т. е.*

$$\lambda(A) \in \bigcup_{i=1}^n \left\{ z \in \mathbb{C} \mid |z - a_{ii}| \leq \sum_{j \neq i} |a_{ij}| \right\}.$$

Фигурирующие в условиях теоремы круги комплексной плоскости

$$\left\{ z \in \mathbb{C} \mid |z - a_{ii}| \leq \sum_{j \neq i} |a_{ij}| \right\}, \quad i = 1, 2, \dots, n,$$

называются *кругами Гершгорина*.

Пример 3.8.5 Для 2×2 -матрицы (3.3)

$$\begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix},$$

рассмотренной в Примере 3.1.1 (стр. 123), собственные значения суть $\frac{1}{2}(5 \pm \sqrt{33})$, они приблизительно равны -0.372 и 5.372 . На Рис. 3.11, показывающем соответствующие матрице круги Гершгорина, эти собственные значения выделены крестиками.

Для матрицы (3.4)

$$\begin{pmatrix} 1 & 2 \\ -3 & 4 \end{pmatrix},$$




Рис. 3.11. Круги Гершгорина для матриц (3.3) и (3.4).

которая отличается от матрицы (3.3) лишь противоположным знаком элемента на месте (2, 1), круги Гершгорина те же. Но собственные значения у неё комплексные, равные $\frac{1}{2}(5 \pm i\sqrt{15})$, т.е. приблизительно $2.5 \pm 1.936i$. Они выделены на Рис. 3.11 звёздочками. ■

Бросается в глаза «избыточность» кругов Гершгорина, которые в качестве области локализации собственных значений очерчивают очень большую область комплексной плоскости. Это характерно для матриц с существенной внедиагональной частью. Но если недиагональные элементы матрицы малы сравнительно с диагональными, то информация, даваемая кругами Гершгорина, становится весьма точной.

3.8д Степенной метод

Если для собственных значений λ_i , $i = 1, 2, \dots, n$, некоторой матрицы справедливо неравенство $|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \dots |\lambda_n|$, то λ_1 называют *доминирующим собственным значением*, а соответствующий ему собственный вектор — *доминирующим собственным вектором*. Степенной метод, описанию которого посвящён этот пункт, предназначен для решения частичной проблемы собственных значений — нахождения доминирующих собственного значения и собственного вектора матрицы.

Лежащая в его основе идея чрезвычайно проста и состоит в том, что если у матрицы A имеется собственное значение λ_1 , превосходящее

по модулю все остальные собственные значения, то при действии этой матрицей на произвольный вектор $x \in \mathbb{C}^n$ направление v_1 , отвечающее этому собственному значению λ_1 , скорее всего, будет растягиваться сильнее остальных (при $\lambda_1 \geq 1$) или сжиматься меньше остальных (при $\lambda_1 \leq 1$). При повторном умножении A на результат Ax предшествующего умножения эта компонента ещё более удлинится в сравнении с остальными. Повторив рассмотренную процедуру умножения достаточное количество раз, мы получим вектор, в котором полностью преобладает направление v_1 , т. е. практически будет получен приближённый собственный вектор.

В качестве приближённого собственного значения матрицы A можно при этом взять «отношение» двух последовательных векторов, порождённых нашим процессом — $x^{(k+1)} = A^{k+1}x^{(0)}$ и $x^{(k)} = A^k x^{(0)}$, $k = 0, 1, 2, \dots$. Слово «отношение» взято здесь в кавычки потому, что употреблено не вполне строго: ясно, что векторы $x^{(k+1)}$ и $x^{(k)}$ могут оказаться неколлинеарными, и тогда их «отношение» смысла иметь не будет. Возможны следующие пути решения этого вопроса:

- 1) рассматривать отношение каких-нибудь фиксированных компонент векторов $x^{(k+1)}$ и $x^{(k)}$, т. е. $x_i^{(k+1)} / x_i^{(k)}$ для некоторого $i \in \{1, 2, \dots, n\}$;
- 2) рассматривать отношение проекций последовательных приближений $x^{(k+1)}$ и $x^{(k)}$ на какое-нибудь направление $l^{(k)}$, т. е.

$$\frac{\langle x^{(k+1)}, l^{(k)} \rangle}{\langle x^{(k)}, l^{(k)} \rangle}. \quad (3.94)$$

Во втором случае мы обозначили направление проектирования через $l^{(k)}$, подчёркивая его возможную зависимость от номера шага k . Ясно также, что это направление $l^{(k)}$ не должно быть ортогональным вектору $x^{(k)}$, чтобы не занулился знаменатель в (3.94)).

Последний способ кажется более предпочтительным в вычислительном отношении, поскольку позволяет избегать капризного поведения в одной отдельно взятой компоненте вектора $x^{(k)}$, когда она может сделаться очень малой по абсолютной величине или совсем занулиться, хотя в целом вектор $x^{(k)}$ будет иметь значительную длину. Наконец, в качестве вектора, задающего направление проектирования во втором варианте, естественно взять сам $x^{(k)}$, вычисляя на каждом шаге отно-

шение

$$\frac{\langle x^{(k+1)}, x^{(k)} \rangle}{\langle x^{(k)}, x^{(k)} \rangle}, \quad (3.95)$$

где $x^{(k)} = A^k x^{(0)}$.

Для организации вычислительного алгоритма степенного метода требуется разрешить ещё два тонких момента, связанных с реализацией на ЭВМ.

Во-первых, это возможное неограниченное увеличение (при $\lambda_1 > 1$) или неограниченное уменьшение (при $\lambda_1 < 1$) норм векторов $x^{(k)}$ и $x^{(k+1)}$, участвующих в нашем процессе. Разрядная сетка современных цифровых ЭВМ, как известно, конечна и позволяет представлять числа из ограниченного диапазона. Чтобы избежать проблем, вызванных выходом за этот диапазон («переполнение» и «исчезновение порядка»), имеет смысл нормировать $x^{(k)}$. При этом наиболее удобна нормировка в евклидовой норме $\| \cdot \|_2$, так как тогда знаменатель отношения (3.95) делается равным единице.

Во-вторых, при выводе степенного метода мы неявно предполагали, что начальный вектор $x^{(0)}$ выбран так, что он имеет ненулевую проекцию на направление доминирующего собственного вектора v_1 матрицы A . В противном случае произведения любых степеней матрицы A на $x^{(0)}$ будут также иметь нулевую проекцию, и никакой дифференциации длины компонент $A^k x^{(0)}$, на которой собственно и основан степенной метод, не произойдёт. Это затруднение может быть преодолено на основе какой-нибудь априорной информации о доминирующем собственном векторе матрицы. Кроме того, при практической реализации степенного метода на цифровых ЭВМ неизбежные ошибки округления, как правило, приводят к появлению ненулевых компонент в направлении v_1 , которые затем в процессе итерирования растянутся на нужную величину. Но, строго говоря, это может не происходить в некоторых исключительных случаях, и потому при ответственных вычислениях рекомендуется многократный запуск степенного метода с различными начальными векторами (так называемый мультистарт).

В псевдокоде, представленном в Табл. 3.6, $\tilde{\lambda}$ — это приближённое доминирующее собственное значение матрицы A , а $x^{(k)}$ — текущее приближение к его нормированному собственному вектору.

Теорема 3.8.2 Пусть $n \times n$ -матрица A диагонализуема и у неё имеется доминирующее собственное значение, которое является простым,

Таблица 3.6. Степенной метод для нахождения доминирующего собственного значения матрицы

```

 $k \leftarrow 0;$ 
выбираем вектор  $x^{(0)} \neq 0;$ 
нормируем  $x^{(0)} \leftarrow x^{(0)} / \|x^{(0)}\|;$ 
DO WHILE ( метод не сошёлся )
     $y^{(k+1)} \leftarrow Ax^{(k)};$ 
     $\tilde{\lambda} \leftarrow \langle y^{(k+1)}, x^{(k)} \rangle;$ 
     $x^{(k+1)} \leftarrow y^{(k+1)} / \|y^{(k+1)}\|_2;$ 
     $k \leftarrow k + 1;$ 
END DO

```

т. е. ему соответствует один линейный элементарный делитель. Если начальный вектор $x^{(0)}$ не ортогонален доминирующему собственному вектору матрицы A , то степенной метод сходится.

Доказательство. При сделанных нами предположениях о матрице A она может быть представлена в виде

$$A = VDV^{-1},$$

где $D = \text{diag} \{ \lambda_1, \lambda_2, \dots, \lambda_n \}$ — диагональная матрица с собственными значениями $\lambda_1, \lambda_2, \dots, \lambda_n$ по диагонали, а V — матрица, осуществляющая преобразование подобия. Матрица V составлена из собственных векторов v_i матрицы A как из столбцов:

$$V = (v_1 \ v_2 \ \dots \ v_n) = \left(\begin{array}{c|c|c|c} (v_1)_1 & (v_2)_1 & \dots & (v_n)_1 \\ (v_1)_2 & (v_2)_2 & \dots & (v_n)_2 \\ \vdots & \vdots & \ddots & \vdots \\ (v_1)_n & (v_2)_n & \dots & (v_n)_n \end{array} \right),$$

где через $(v_i)_j$ обозначена j -ая компонента i -го собственного вектора

матрицы A . При этом можно считать, что $\|v_i\|_2 = 1$. Следовательно,

$$\begin{aligned}
 A^k x^{(0)} &= (VDV^{-1})^k x^{(0)} = \underbrace{(VDV^{-1})(VDV^{-1}) \dots (VDV^{-1})}_{k \text{ раз}} x^{(0)} \\
 &= VD(V^{-1}V)D(V^{-1}V) \dots (V^{-1}V)DV^{-1}x^{(0)} \\
 &= VD^k V^{-1}x^{(0)} = VD^k z \\
 &= V \begin{pmatrix} \lambda_1^k z_1 \\ \lambda_2^k z_2 \\ \vdots \\ \lambda_n^k z_n \end{pmatrix} = (\lambda_1^k z_1) V \begin{pmatrix} 1 \\ (\lambda_2/\lambda_1)^k (z_2/z_1) \\ \vdots \\ (\lambda_n/\lambda_1)^k (z_n/z_1) \end{pmatrix},
 \end{aligned}$$

где обозначено $z = V^{-1}x^{(0)}$. Необходимое условие проведения этой выкладки — $z_1 \neq 0$ — выполнено потому, что в условиях теоремы $x^{(0)}$ имеет ненулевую компоненту в направлении v_1 .

Коль скоро у матрицы A имеется доминирующее собственное значение, т. е.

$$|\lambda_1| > |\lambda_2| \geq \dots \geq |\lambda_n|,$$

то $\lambda_2/\lambda_1, \lambda_3/\lambda_1, \dots, \lambda_n/\lambda_1$ — все по модулю меньше единицы, и потому при $k \rightarrow \infty$ вектор

$$\begin{pmatrix} 1 \\ (\lambda_2/\lambda_1)^k (z_2/z_1) \\ \vdots \\ (\lambda_n/\lambda_1)^k (z_n/z_1) \end{pmatrix} \quad (3.96)$$

сходится к вектору $(1, 0, 0, \dots, 0)^\top$. Соответственно, произведение

$$V \begin{pmatrix} 1 \\ (\lambda_2/\lambda_1)^k (z_2/z_1) \\ \vdots \\ (\lambda_n/\lambda_1)^k (z_n/z_1) \end{pmatrix}$$

сходится к первому столбцу матрицы V , т. е. к собственному вектору, отвечающему λ_1 . Вектор $x^{(k)}$, который отличается от $A^k x^{(0)}$ лишь

нормировкой, сходится к собственному вектору v_1 , а величина $\tilde{\lambda} = \langle y^{(k+1)}, x^{(k)} \rangle$ сходится к $\langle Av_1, v_1 \rangle = \langle \lambda_1 v_1, v_1 \rangle = \lambda_1$. ■

Из проведённых выше выкладок следует, что быстрота сходимости степенного метода определяется отношениями $|\lambda_i/\lambda_1|$, $i = 2, 3, \dots, n$, — знаменателями геометрических прогрессий, стоящих в качестве элементов вектора (3.96). Фактически, решающее значение имеет наибольшее из этих отношений, т. е. $|\lambda_2/\lambda_1|$, зависящее от того, насколько модуль доминирующего собственного значения отделён от модуля остальной части спектра. Чем больше эта отделённость, тем быстрее сходимость.

Пример 3.8.6 Для матрицы (3.3)

$$\begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix},$$

при вычислениях с двойной точностью степенной метод с начальным вектором $x^{(0)} = (1, 1)^\top$ за 7 итераций даёт семь верных знаков доминирующего собственного значения $\frac{1}{2}(5 + \sqrt{33}) \approx 5.3722813$. Детальная картина сходимости показана в следующей табличке:

Номер итерации	Приближение к собственному значению
1	5.0
2	5.3448276
3	5.3739445
4	5.3721649
5	5.3722894
6	5.3722808
7	5.3722814

Быстрая сходимость объясняется малостью величины $|\lambda_2/\lambda_1|$, которая, как мы могли видеть в Примере 3.1.1, для рассматриваемой матрицы равна всего лишь 0.069.

Для матрицы (3.4)

$$\begin{pmatrix} 1 & 2 \\ -3 & 4 \end{pmatrix},$$

при тех же исходных условиях степенной метод порождает последовательность значений $\tilde{\lambda}$, которая случайно колеблется от примерно 0.9 до 4 и очевидным образом не имеет предела. Причина — наличие у матрицы двух одинаковых по абсолютной величине комплексносопряжённых собственных значений $2.5 \pm 1.936i$ (см. Пример 3.1.1). ■

Наконец, необходимое замечание о сходимости степенного метода в комплексном случае. Так как комплексные числа описываются парами вещественных чисел, то комплексные одномерные инвариантные пространства матрицы имеют вещественную размерность 2. Даже будучи нормированными, векторы из такого подпространства могут отличаться на скалярный множитель $e^{i\varphi}$, так что если не принять специальных мер, то в степенном методе видимой стабилизации координатных представлений комплексных собственных векторов может не наблюдаться. Тем не менее, о факте сходимости или расходимости можно при этом судить по стабилизации приближения к собственному значению. Либо кроме нормировки собственных векторов следует предусмотреть ещё приведение их к такой форме, в которой их координатные представления будут определяться более «жёстко», например, требованием, чтобы первая компонента вектора была бы чисто вещественной.

Пример 3.8.7 Рассмотрим работу степенного метода в применении к матрице

$$\begin{pmatrix} 1 & 2i \\ 3 & 4i \end{pmatrix},$$

имеющей собственные значения

$$\lambda_1 = -0.4308405 - 0.1485958i,$$

$$\lambda_2 = 1.4308405 + 4.1485958i.$$

Доминирующим собственным значением здесь является λ_2 .

Начав итерирование с вектора $x^{(0)} = (1, 1)^T$, уже через 7 итераций мы получим 6 правильных десятичных знаков в вещественной и мнимой частях собственного значения. Но вот в порождаемых алгоритмом нормированных векторах $x^{(k)}$ —

$$x^{(9)} = \begin{pmatrix} -0.0113198 - 0.4322252i \\ -0.1165906 - 0.8941252i \end{pmatrix},$$

$$x^{(10)} = \begin{pmatrix} 0.4049144 - 0.1516281i \\ 0.8072493 - 0.4017486i \end{pmatrix},$$

$$x^{(11)} = \begin{pmatrix} 0.2753642 + 0.3333485i \\ 0.6429975 + 0.6321451i \end{pmatrix},$$

$$x^{(12)} = \begin{pmatrix} 0.2253495 + 0.3690045i \\ -0.3879509 + 0.8139702i \end{pmatrix},$$

и так далее — нелегко «невооружённым глазом» узнать один и тот же собственный вектор, который «крутится» в одномерном комплексном инвариантном подпространстве. Но если поделить все получающиеся векторы на их первую компоненту, то получим один и тот же результат

$$\begin{pmatrix} 1. \\ 2.0742979 - 0.2154202i \end{pmatrix},$$

и теперь уже налицо факт сходимости собственных векторов. ■

Как ведёт себя степенной метод в случае, когда матрица A не является диагонализуемой? Полный анализ ситуации можно найти, например, в книгах [40, 42]. Наиболее неблагоприятен при этом случай, когда доминирующее собственное значение находится в жордановой клетке размера два и более. Теоретически степенной метод всё таки сходится к этому собственному значению, но уже медленнее любой геометрической прогрессии.

Пример 3.8.8 Рассмотрим работу степенного метода в применении к матрице

$$\begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix},$$

т. е. к жордановой 2×2 -клетке с собственным значением 1.

Запустив степенной метод из начального вектора $x^{(0)} = (1, 1)^\top$, будем иметь следующее

Номер итерации	Приближение к собственному значению
1	1.5
3	1.3
10	1.0990099
30	1.0332963
100	1.009999
300	1.0033333
1000	1.001

То есть, для получения n верных десятичных знаков собственного значения приходится делать примерно 10^n итераций, что, конечно же, непомерно много. При увеличении размера жордановой клетки сходимость степенного метода делается ещё более медленной. ■

3.8е Обратные степенные итерации

Обратными степенными итерациями для матрицы A называют описанный в прошлом параграфе степенной метод, применённый к обратной матрице A^{-1} . Явное нахождение обратной матрицы при этом не требуется, так как в степенном методе используется лишь результат $y^{(k+1)}$ её произведения на вектор $x^{(k)}$ очередного приближения, а это, как мы знаем, эквивалентно решению системы линейных уравнений $Ay^{(k+1)} = x^{(k)}$. Псевдокод получающегося метода представлен в Табл. 3.7.

Практическая реализация решения системы линейных уравнений (5-я строка псевдокода) может быть сделана достаточно эффективной, если предварительно выполнить LU- или QR-разложение матрицы A , а затем на каждом шаге метода использовать формулы (3.31) или (3.39).

Так как собственные значения матриц A и A^{-1} взаимно обратны, то обратные степенные итерации будут сходиться к наименьшему по абсолютной величине собственному значению A и соответствующему собственному вектору.

3.8ж Сдвиги спектра

Сдвигом матрицы называют прибавление к ней скалярной матрицы, т.е. матрицы, пропорциональной единичной матрице, так что вместо матрицы A мы получаем матрицу $A + \vartheta I$. Если $\lambda_i(A)$ — собственные

Таблица 3.7. Обратные степенные итерации для нахождения наименьшего по модулю собственного значения матрицы A

```

 $k \leftarrow 0$ ;
выбираем вектор  $x^{(0)} \neq 0$ ;
нормируем  $x^{(0)} \leftarrow x^{(0)} / \|x^{(0)}\|$ ;
DO WHILE ( метод не сошёлся )
    найти  $y^{(k+1)}$  из системы  $Ay^{(k+1)} = x^{(k)}$ ;
     $\tilde{\lambda} \leftarrow \langle y^{(k+1)}, x^{(k)} \rangle$ ;
     $x^{(k+1)} \leftarrow y^{(k+1)} / \|y^{(k+1)}\|_2$ ;
     $k \leftarrow k + 1$ ;
END DO

```

значения матрицы A , то для любого комплексного числа ϑ собственными значениями матрицы $A + \vartheta I$ являются числа $\lambda_i(A) + \vartheta$, тогда как собственные векторы остаются неизменными. Цель сдвига — преобразование спектра матрицы для того, чтобы улучшить работу тех или иных алгоритмов решения проблемы собственных значений.

Если, к примеру, у матрицы A наибольшими по абсолютной величине были два собственных значения -2 и 2 , то прямое применение к ней степенного метода не приведёт к успеху. Но у матрицы $A + I$ эти собственные значения перейдут в -1 и 3 , второе собственное число станет наибольшим по модулю, и теперь уже единственным. Соответственно, степенной метод делается применимым к новой матрице.

Пример 3.8.9 Для матрицы (3.4)

$$\begin{pmatrix} 1 & 2 \\ -3 & 4 \end{pmatrix},$$

как было отмечено в Примере 3.8д, простейший степенной метод расходится из-за существования двух наибольших по абсолютной величине собственных значений.

Но если сдвинуть эту матрицу на $2i$, то её спектр (см. Рис. 3.11) поднимется «вверх», абсолютные величины собственных значений перестанут совпадать, и степенной метод окажется применимым.

Степенные итерации для «сдвинутой» матрицы

$$\begin{pmatrix} 1 + 2i & 2 \\ -3 & 4 + 2i \end{pmatrix} \quad (3.97)$$

довольно быстро сходятся к наибольшему по модулю собственному значению $\frac{5}{2} + (2 + \frac{1}{2}\sqrt{15})i \approx 2.5 + 3.9364917i$. Детальная картина сходимости при вычислениях с двойной точностью и начальным вектором $x^{(0)} = (1, 1)^T$ показана в следующей табличке:

Номер итерации	Приближение к собственному значению
1	$2.0 + 2.0i$
3	$2.0413223 + 4.3140496i$
5	$2.7022202 + 3.9372711i$
10	$2.5004558 + 3.945456i$
20	$2.4999928 + 3.9364755i$

В данном случае для матрицы (3.97) имеем $|\lambda_2/\lambda_1| \approx 0.536$. ■

С помощью сдвигов матрицы можно любое её собственное значение, которое является крайней точкой выпуклой оболочки спектра, сделать наибольшим по модулю, обеспечив, таким образом, сходимость к нему итераций степенного метода. Но как добиться сходимости к другим собственным значениям, которые лежат «внутри» спектра, а не «с краю»? Здесь на помощь приходят обратные степенные итерации.

Другое важное следствие сдвигов — изменение отношения $|\lambda_2/\lambda_1|$, величина которого влияет на скорость сходимости степенного метода, и отношения λ_n/λ_{n-1} , которое определяет скорость сходимости обратных степенных итераций. Подбирая нужным образом ϑ , часто можно добиться того, чтобы

$$\left| \frac{\lambda_2 + \vartheta}{\lambda_1 + \vartheta} \right|$$

было меньшим, чем $|\lambda_2/\lambda_1|$, ускорив тем самым степенные итерации

Обратные степенные итерации особенно эффективны в случае, когда имеется хорошее приближение к собственному значению и требуется найти соответствующий собственный вектор.




Рис. 3.12. С помощью сдвигов любую крайнюю точку спектра можно сделать наибольшей по модулю.

3.83 Метод Якоби для решения симметричной проблемы собственных значений

В этом параграфе мы рассмотрим численный метод для решения симметричной проблемы собственных значений, т. е. для вычисления собственных чисел и собственных векторов симметричных матриц, который был впервые применён К.Г. Якоби в 1846 году к конкретной 7×7 -матрице. Затем он был забыт на целое столетие, и вновь переоткрыт лишь после Второй мировой войны, когда началось бурное развитие вычислительной математики.

Идея метода Якоби состоит в том, чтобы подходящими преобразованиями подобия от шага к шагу уменьшать величину

$$\left(\sum_{j \neq i} a_{ij}^2 \right)^{1/2}$$

— фробениусову норму внедиагональной части матрицы. Получающаяся при этом последовательность матриц $A^{(k)}$ будет стремиться к диагональной матрице с собственными значениями на главной диагонали. Инструментом реализации этого плана выступают элементарные ортогональные матрицы вращений, рассмотренные в §3.3к. Почему именно ортогональные матрицы и почему вращений? Ответ на эти вопросы станет ясен позднее при анализе работы алгоритма.

Итак, положим $A^{(0)} := A$. Если матрица $A^{(k)}$, $k = 0, 1, 2, \dots$, уже вычислена, то подберём матрицу $G(p, q, \theta)$ таким образом, чтобы сделать нулями пару внедиагональных элементов в позициях (p, q) и (q, p) в матрице $A^{(k+1)} := G(p, q, \theta)^\top A^{(k)} G(p, q, \theta)$. Желая сделать это, мы должны добиться выполнения равенства

$$\begin{pmatrix} a_{pp}^{(k+1)} & a_{pq}^{(k+1)} \\ a_{qp}^{(k+1)} & a_{qq}^{(k+1)} \end{pmatrix} = \begin{pmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{pmatrix}^\top \begin{pmatrix} a_{pp}^{(k)} & a_{pq}^{(k)} \\ a_{qp}^{(k)} & a_{qq}^{(k)} \end{pmatrix} \begin{pmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{pmatrix} \\ = \begin{pmatrix} \times & 0 \\ 0 & \times \end{pmatrix},$$

где, как обычно, посредством « $\times$ » обозначены какие-то элементы, конкретное значение которых несущественно. Строго говоря, в результате рассматриваемого преобразования подобия в матрице $A^{(k)}$ изменятся и другие элементы, находящиеся в строках и столбцах с номерами p и q . Этот эффект будет проанализирован ниже в Предложении 3.8.4.

Опуская индексы, обозначающие номер итерации и приняв сокращённые обозначения $c = \cos \theta$, $s = \sin \theta$, получим

$$\begin{pmatrix} \times & 0 \\ 0 & \times \end{pmatrix} = \begin{pmatrix} a_{pp}c^2 + a_{qq}s^2 + 2sca_{pq} & sc(a_{qq} - a_{pp}) + a_{pq}(c^2 - s^2) \\ sc(a_{qq} - a_{pp}) + a_{pq}(c^2 - s^2) & a_{pp}s^2 + a_{qq}c^2 - 2sca_{pq} \end{pmatrix}$$

Приравнивание внедиагональных элементов нулю даёт

$$\frac{a_{pp} - a_{qq}}{a_{pq}} = \frac{c^2 - s^2}{sc}.$$

Поделив обе части этой пропорции пополам, воспользуемся тригонометрическими формулами двойных углов

$$\frac{a_{pp} - a_{qq}}{2a_{pq}} = \frac{c^2 - s^2}{2sc} = \frac{\cos(2\theta)}{\sin(2\theta)} = \frac{1}{\operatorname{tg}(2\theta)} =: \tau.$$

Положим $t := \sin \theta / \cos \theta = \operatorname{tg} \theta$. Вспоминая далее тригонометрическую формулу для тангенса двойного угла

$$\operatorname{tg}(2\theta) = \frac{2 \operatorname{tg} \theta}{1 - \operatorname{tg}^2 \theta},$$

мы можем прийти к выводу, что t является корнем квадратного уравнения

$$t^2 + 2\tau t - 1 = 0$$

с положительным дискриминантом $(4\tau^2 + 4)$, которое, следовательно, всегда имеет вещественные корни. Отсюда находится сначала t , а затем c и s , подробные формулы для которых мы не будем выписывать, чтобы не загромождать изложения.

Займёмся теперь обоснованием сходимости метода Якоби для решения симметричной проблемы собственных значений.

Предложение 3.8.3 *Фробениусова норма матрицы A , т. е.*

$$\|A\|_F = \left(\sum_{i,j=1}^n a_{ij}^2 \right)^{1/2},$$

не изменяется при умножениях на ортогональные матрицы слева или справа.

Доказательство. Напомним, что *следом матрицы* $A = (a_{ij})$, обозначаемым $\text{tr } A$, называется сумма всех её диагональных элементов:

$$\text{tr } A = \sum_{i=1}^n a_{ii}.$$

Привлечение понятия следа позволяет переписать определение фробениусовой нормы матрицы таким образом

$$\|A\|_F = (\text{tr } (A^\top A))^{1/2}.$$

Следовательно, для любой ортогональной матрицы Q справедливо

$$\begin{aligned} \|QA\|_F &= \left(\text{tr } ((QA)^\top (QA)) \right)^{1/2} \\ &= \left(\text{tr } (A^\top Q^\top QA) \right)^{1/2} = (\text{tr } (A^\top A))^{1/2} = \|A\|_F. \end{aligned}$$

Для доказательства аналогичного соотношения с умножением на ортогональную матрицу справа заметим, что фробениусова норма не меняется при транспонировании матрицы. Следовательно,

$$\|AQ\|_F = \|(Q^\top A^\top)^\top\|_F = \|Q^\top A^\top\|_F = \|A^\top\|_F = \|A\|_F,$$

что завершает доказательство Предложения. ■

Следствие. Фробениусова норма матрицы не меняется при ортогональных преобразованиях подобия.

Для более точного описания меры близости матриц $A^{(k)}$, которые порождаются конструируемым нами методом, к диагональной матрице введём величину

$$ND(A) = \left(\sum_{j \neq i} a_{ij}^2 \right)^{1/2}$$

— фробениусову норму внедиагональной части матрицы. Ясно, что матрица A диагональна тогда и только тогда, когда $ND(A) = 0$.

Предложение 3.8.4 Пусть преобразование подобия матрицы A с помощью матрицы вращений J таково, что в матрице $B = J^T A J$ зануляются элементы в позициях (p, q) и (q, p) . Тогда

$$ND^2(B) = ND^2(A) - 2a_{pq}^2. \quad (3.98)$$

Итак, в сравнении с матрицей A в матрице B изменились элементы строк и столбцов с номерами p и q , но фробениусова норма внедиагональной части изменилась при этом так, как будто кроме зануления элементов a_{pq} и a_{qp} ничего не произошло.

Доказательство. Для 2×2 -подматрицы

$$\begin{pmatrix} a_{pp} & a_{pq} \\ a_{qp} & a_{qq} \end{pmatrix}$$

из матрицы A и соответствующей ей 2×2 -подматрицы

$$\begin{pmatrix} b_{pp} & 0 \\ 0 & b_{qq} \end{pmatrix}$$

в матрице B справедливо соотношение

$$a_{pp}^2 + a_{qq}^2 + 2a_{pq}^2 = b_{pp}^2 + b_{qq}^2,$$

так как ортогональным преобразованием подобия фробениусову норма матрицы не изменяется. Но, кроме того, $\|A\|_F^2 = \|B\|_F^2$, и потому

$$\begin{aligned} ND^2(B) &= \|B\|_F^2 - \sum_{i=1}^n b_{ii}^2 \\ &= \|A\|_F^2 - \left(\sum_{i=1}^n a_{ii}^2 - (a_{pp}^2 + a_{qq}^2) + (b_{pp}^2 + b_{qq}^2) \right) \\ &= ND^2(A) - 2a_{pq}^2, \end{aligned}$$

поскольку на диагонали у матрицы A изменились только два элемента — a_{pp} и a_{qq} . ■

Таблица 3.8. Метод Якоби для вычисления собственных значений симметричной матрицы

Вход Симметричная матрица A. Допуск ϵ на норму внедиагональных элементов.
Выход Матрица, на диагонали которой стоят приближения, к собственным значениям A.
Алгоритм DO WHILE ($ND(A) > \epsilon$) выбрать ненулевой внедиагональный элемент a_{pq} в A; обнулить a_{pq} и a_{qp} преобразованием подобия с матрицей вращения $G(p, q, \theta)$; END DO

Теперь можно ответить на вопрос о том, почему в методе Якоби для преобразований подобия применяются именно ортогональные мат-

рицы. Как следует из результатов Предложений 3.8.3 и 3.8.4, ортогональные матрицы обладают замечательным свойством сохранения общей нормы всех элементов матрицы и, как следствие, «перекачивания» величины с внедиагональных элементов на диагональ. При других преобразованиях подобия добиться этого было бы едва ли возможно.

Итак, всё готово для организации итерационного процесса приведения симметричной матрицы к диагональному виду, при котором внедиагональные элементы последовательно подавляются. Как уже отмечалось, занулённые на каком-то шаге алгоритма элементы могут впоследствии вновь сделаться ненулевыми. Но результат Предложения 3.8.4 показывает, что норма внедиагональной части матрицы при этом всё равно монотонно уменьшается.

Различные способы выбора ненулевых внедиагональных элементов, подлежащих обнулению, приводят к различным практическим версиям метода Якоби.

Выбор наибольшего по модулю внедиагонального элемента — наилучшее для отдельно взятого шага алгоритма решение. Но поиск этого элемента имеет трудоёмкость $n(n-1)/2$, что может оказаться весьма дорогостоящим, особенно для матриц больших размеров. Преобразование подобия с матрицей вращений обходится всего в $O(n)$ операций!

Чаще применяют циклический обход столбцов (или строк) матрицы, и наибольший по модулю элемент берут в пределах рассматриваемого столбца (строки).

Наконец, ещё одна популярная версия — это так называемый «барьерный метод Якоби», в котором назначают величину «барьера» на значение модуля внедиагональных элементов матрицы, и алгоритм обнуляет все элементы, модуль которых превосходит этот барьер. Затем барьер понижается, процесс обнуления повторяется заново, и так до тех пор, пока не будет достигнута требуемая точность.

3.8и Базовый QR-алгоритм

QR-алгоритм, изложению которого посвящён этот параграф, является одним из наиболее эффективных численных методов для решения полной проблемы собственных значений. Он был изобретён независимо В.Н. Кублановской (1960 год) и Дж. Фрэнсисом (1961 год). Публикация В.Н. Кублановской появилась раньше¹³, а Дж. Фрэнсис более пол-

¹³Упомянув о вкладе В.Н. Кублановской в изобретение QR-алгоритма, обычно ссылаются на её статью 1961 года в «Журнале вычислительной математики и мате-

но развил практичную версию QR-алгоритма.

Вспомним теорему о QR-разложении (Теорема 3.3.3, стр. 171): всякая квадратная матрица представима в виде произведения ортогональной и правой (верхней) треугольной матриц. Ранее в нашем курсе мы уже обсуждали конструктивные способы выполнения этого разложения — с помощью матриц отражения Хаусхолдера, а также с помощью матриц вращений. Следовательно, далее можно считать, что QR-разложение выполнимо и основывать свои построения на этом факте.

Вычислительная схема базового QR-алгоритма для решения проблемы собственных значений представлена в Табл. 3.9: мы разлагаем матрицу $A^{(k)}$, полученную на k -м шаге алгоритма, $k = 0, 1, 2, \dots$, на ортогональный $Q^{(k)}$ и правый треугольный $R^{(k)}$ сомножители и далее, поменяв их местами, умножаем друг на друга, образуя следующее приближение $A^{(k+1)}$.

Таблица 3.9. QR-алгоритм для нахождения собственных значений матрицы A

```

 $k \leftarrow 0$ ;
 $A^{(0)} \leftarrow A$ ;
DO WHILE ( метод не сошёлся )
    вычислить QR-разложение  $A^{(k)} = Q^{(k)} R^{(k)}$ ;
     $A^{(k+1)} \leftarrow R^{(k)} Q^{(k)}$ ;
     $k \leftarrow k + 1$ ;
END DO

```

Прежде всего отметим, что поскольку

$$A^{(k+1)} = R^{(k)} Q^{(k)} = (Q^{(k)})^\top (Q^{(k)} R^{(k)}) Q^{(k)} = (Q^{(k)})^\top A^{(k)} Q^{(k)},$$

то все матрицы $A^{(k)}$, $k = 0, 1, 2, \dots$, ортогонально подобны друг другу и исходной матрице A . Результат о сходимости QR-алгоритма неформальным образом может быть резюмирован в следующем виде: если A

матической физики» [62]. Но первое сообщение о QR-алгоритме было опубликовано ею раньше — в Дополнении к изданию 1960 года книги [42].

— неособенная вещественная матрица, то последовательность порождаемых QR-алгоритмом матриц $A^{(k)}$ сходится «по форме» к верхней блочно-треугольной матрице.

Это означает, что предельная матрица, к которой сходится QR-алгоритм, является верхней треугольной либо верхней блочно-треугольной, причём размеры диагональных блоков зависят, во-первых, от типа собственных значений матрицы (кратности и принадлежности вещественной оси $\mathbb{R}$), и, во-вторых, от того, в вещественной или комплексной арифметике выполняется QR-алгоритм.

Если алгоритм выполняется в вещественной (комплексной) арифметике и все собственные значения матрицы вещественны (комплексны) и различны по модулю, то предельная матрица — верхняя треугольная. Если алгоритм выполняется в вещественной (комплексной) арифметике и некоторое собственное значение матрицы вещественно (комплексно) и имеет кратность p , то в предельной матрице ему соответствует диагональный блок размера $p \times p$. Если алгоритм выполняется для вещественной матрицы в вещественной арифметике, то простым комплексно-сопряжённым собственным значениям (они имеют равные модули) отвечают диагональные 2×2 -блоки в предельной матрице. Наконец, если некоторое комплексное собственное значение вещественной матрицы имеет кратность p , так что ему соответствует ещё такое же комплексно-сопряжённое собственное значение кратности p , то при выполнении QR-алгоритма в вещественной арифметике предельная матрица получит диагональный блок размера $2p \times 2p$.

Пример 3.8.10 Проиллюстрируем работу QR-алгоритма на примере матрицы

$$\begin{pmatrix} 1 & -2 & 3 \\ 4 & 5 & -6 \\ -7 & 8 & 9 \end{pmatrix}, \quad (3.99)$$

имеющей собственные значения

$$\begin{aligned} &2.7584148 \\ &6.1207926 \pm 8.0478897i \end{aligned}$$

Читатель может провести на компьютере этот увлекательный эксперимент самостоятельно, воспользовавшись системами Scilab, MATLAB

или им подобными: все они имеют встроенную процедуру для QR-разложения матриц.¹⁴

■

Пример 3.8.11 Для ортогональной матрицы

$$\begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}, \quad (3.100)$$

QR-разложением является произведение её самой на единичную матрицу. Поэтому в результате одного шага QR-алгоритма мы снова получим исходную матрицу, которая, следовательно, и будет пределом итераций. В то же время, матрица (3.100) имеет собственные значения, равные ± 1 , так что в данном случае QR-алгоритм не работает.

■

3.8к Модификации QR-алгоритма

Представленная в Табл. 3.9 версия QR-алгоритма на практике обычно снабжается рядом модификаций, которые существенно повышают её эффективность. Главными из этих модификаций являются

- 1) сдвиги матрицы, рассмотренные нами в §3.8ж, и
- 2) предварительное приведение матрицы к специальной верхней почти треугольной форме.

Можно показать (см. теорию в книгах [14, 39]), что, аналогично степенному методу, сдвиги также помогают ускорению QR-алгоритма. Но в QR-алгоритме их традиционно организуют способом, представленным в Табл. 3.10.

Особенность организации сдвигов в этом псевдокоде — присутствие обратных сдвигов (в строке 6 алгоритма) сразу же вслед за прямыми (в 5-й строке). Из-за этого в получающемся алгоритме последовательно вычисляемые матрицы $A^{(k)}$ и $A^{(k+1)}$ ортогонально подобны, совершенно так же, как и в исходной версии QR-алгоритма:

$$\begin{aligned} A^{(k+1)} &= R^{(k)} Q^{(k)} + \vartheta_k I = (Q^{(k)})^\top Q^{(k)} R^{(k)} Q^{(k)} + \vartheta_k (Q^{(k)})^\top Q^{(k)} \\ &= (Q^{(k)})^\top (Q^{(k)} R^{(k)} + \vartheta_k I) Q^{(k)} = (Q^{(k)})^\top A^{(k)} Q^{(k)}. \end{aligned}$$

¹⁴B Scilab'e и MATLAB'e она так и называется — `qr`.

Таблица 3.10. QR-алгоритм со сдвигами для нахождения собственных значений матрицы A

```

 $k \leftarrow 0;$ 
 $A^{(0)} \leftarrow A;$ 
DO WHILE ( метод не сошёлся )
    выбрать сдвиг  $\vartheta_k$  вблизи собственного значения  $A$ ;
    вычислить QR-разложение  $A^{(k)} - \vartheta_k I = Q^{(k)} R^{(k)}$ ;
     $A^{(k+1)} \leftarrow R^{(k)} Q^{(k)} + \vartheta_k I$ ;
     $k \leftarrow k + 1$ ;
END DO

```

То есть, представленная организация сдвигов позволила сделать их в одно и то же время локальными и динамическими по характеру.

Пример 3.8.12 Проиллюстрируем работу QR-алгоритма со сдвигами на знакомой нам матрице (3.99)

$$\begin{pmatrix} 1 & -2 & 3 \\ 4 & 5 & -6 \\ -7 & 8 & 9 \end{pmatrix}$$

из предыдущего примера



Определение 3.8.1 Матрица $H = (h_{ij})$ называется верхней почти треугольной или хессенберговой матрицей (в форме Хессенберга), если $h_{ij} = 0$ при $i > j + 1$.

Наглядный «портрет» хессенберговой матрицы выглядит следующим образом:

$$H = \begin{pmatrix} \times & \times & \cdots & \times & \times \\ \times & \times & \cdots & \times & \times \\ & \times & \ddots & \vdots & \vdots \\ & & \ddots & \times & \times \\ 0 & & & \times & \times \end{pmatrix}.$$

Предложение 3.8.5 Любую $n \times n$ -матрицу A можно привести к ортогонально подобной хессенберговой матрице $H = QAQ^\top$, где Q — произведение конечного числа отражений или вращений.

Доказательство. Рассмотрим для определённости преобразования с помощью матриц отражения.

Возьмём матрицу отражения $Q_1 = I - 2uu^\top$ так, чтобы первая компонента вектора Хаусхолдера u была нулевой и при этом

$$Q_1 \begin{pmatrix} a_{11} \\ a_{21} \\ a_{31} \\ \vdots \\ a_{n1} \end{pmatrix} = \begin{pmatrix} a_{11} \\ a'_{21} \\ 0 \\ \vdots \\ 0 \end{pmatrix},$$

т.е. занулялись бы элементы $a_{31}, \dots, a_{n1}$ в первом столбце. Нетрудно видеть, что Q_1 выглядит следующим образом

$$Q_1 = \left(\begin{array}{c|cccc} 1 & 0 & \cdots & 0 & 0 \\ \hline 0 & \times & \cdots & \times & \times \\ 0 & \times & \ddots & \vdots & \vdots \\ \vdots & \vdots & \ddots & \times & \times \\ 0 & \times & \cdots & \times & \times \end{array} \right).$$

Далее, когда A умножается на такую матрицу Q_1 слева, то в ней не изменяются элементы первой строки. Когда матрица Q_1A умножается на $Q_1^\top = Q_1$ справа, то в ней не изменяются элементы первого столбца. Поэтому в матрице $Q_1AQ_1^\top$, как и в Q_1A , первый столбец имеет нули в позициях с 3-й по n -ую.

Далее выбираем матрицы отражения $Q_2, Q_3, \dots, Q_{n-2}$ так, чтобы умножение слева на Q_i давало нули в позициях с $(i+2)$ -ой по n -ую в i -ом столбце. При этом последующее умножения справа на Q_i также не портит возникающую почти треугольную структуру результирующей матрицы. Получающаяся в итоге матрица QAQ^T с $Q = Q_{n-2} \dots Q_1$ действительно является верхней почти треугольной. ■

Предложение 3.8.6 *Хессенбергова форма матрицы сохраняется при выполнении с ней QR-алгоритма.*

Доказательство. При QR-разложении хессенберговой матрицы в качестве ортогонального сомножителя Q для матрицы $A^{(k)} - \vartheta I$ получается также хессенбергова матрица, так как j -ый столбец в Q есть линейная комбинация первых j столбцов матрицы $A^{(k)} - \vartheta I$. В свою очередь, матрица RQ — произведение после перестановки сомножителей — также получается хессенберговой. Добавление диагонального слагаемого ϑI не изменяет верхней почти треугольной формы матрицы. ■

Смысл предварительного приведения к хессенберговой форме заключается в следующем. Хотя это приведение матрицы требует $O(n^3)$ операций, дальнейшее выполнение одной итерации QR-алгоритма с хессенберговой формой будет теперь стоить всего $O(n^2)$ операций, так что общая трудоёмкость алгоритма составит $O(n^3)$.

Литература к Главе 3

Основная

- [1] Бахвалов Н.С., Жидков Н.П., Кобельков Г.М. *Численные методы*. — Москва: Бином, 2003, а также другие издания этой книги.
- [2] Бахвалов Н.С., Корнев А.А., Чижонков Е.В. *Численные методы. Решение задач и упражнения*. — Москва: Дрофа, 2008.
- [3] Березин И.С., Жидков Н.П. *Методы вычислений. Т. 1–2*. — Москва: Наука, 1966.
- [4] Вержбицкий В.М. *Численные методы. Части 1–2*. — Москва: «Оникс 21 век», 2005.
- [5] Воеводин В.В. *Вычислительные основы линейной алгебры*. — Москва: Наука, 1977.

- [6] Воеводин В.В. *Линейная алгебра*. – Москва: Наука, 1980.
- [7] Воеводин В.В., Кузнецов Ю.А. *Матрицы и вычисления*. – Москва: Наука, 1984.
- [8] Волков Е.А. *Численные методы*. – Москва: Наука, 1987.
- [9] ГАНТМАХЕР Ф.Р. *Теория матриц*. – Москва: Наука, 1988.
- [10] ГЛАЗМАН И.М., ЛЮБИЧ Ю.И. *Конечномерный линейный анализ*. – Москва: Наука, 1969.
- [11] ГОДУНОВ С.К. *Современные аспекты линейной алгебры*. – Новосибирск: Научная книга, 1997.
- [12] ГОЛУВ ДЖ., ван ЛОУН Ч. *Матричные вычисления*. – Москва: Мир, 1999.
- [13] ДЕМИДОВИЧ Б.П., МАРОН А.А. *Основы вычислительной математики*. – Москва: Наука, 1970.
- [14] ДЕММЕЛЬ ДЖ. *Вычислительная линейная алгебра*. – Москва: Мир, 2001.
- [15] ИКРАМОВ Х.Д. *Численные методы линейной алгебры*. – Москва: Знание, 1987.
- [16] ИЛЬИН В.П., КУЗНЕЦОВ Ю.И. *Трёхдиагональные матрицы и их приложения*. – Москва: Наука, 1985.
- [17] КАНТОРОВИЧ Л.В., АКИЛОВ Г.П. *Функциональный анализ*. – Москва: Наука, 1984.
- [18] КАТО Т. *Теория возмущений линейных операторов*. – Москва: Мир, 1972.
- [19] КОЛЛАТЦ Л. *Функциональный анализ и вычислительная математика*. – Москва: Мир, 1969.
- [20] КОНОВАЛОВ А.Н. *Введение в вычислительные методы линейной алгебры*. – Новосибирск: Наука, 1993.
- [21] КОСТРИКИН А.Н. *Введение в алгебру. Часть 2. Линейная алгебра*. – Москва: Физматлит, 2001.
- [22] КРАСНОСЕЛЬСКИЙ М.А., КРЕЙН С.Г. Итеративный процесс с минимальными невязками // *Математический Сборник*. – 1952. – Т. 31 (73), №2. – С. 315–334.
- [23] КРЫЛОВ В.И., БОБКОВ В.В., МОНАСТЫРНЫЙ П.И. *Вычислительные методы. Т. 1–2*. – Москва: Наука, 1976.
- [24] ЛАНКАСТЕР П. *Теория матриц*. – Москва: Наука, 1978.
- [25] ЛОУСОН Ч., ХЕНСОН Р. *Численное решение задач методом наименьших квадратов*. – Москва: Наука, 1986.
- [26] МАРЧУК Г.И., КУЗНЕЦОВ Ю.А. *Итерационные методы и квадратичные функционалы*. – Новосибирск: Наука, 1972.
- [27] *Матрицы и квадратичные формы. Основные понятия. Терминология* / Академия Наук СССР. Комитет научно-технической терминологии. – Москва: Наука, 1990. – (Сборники научно-нормативной терминологии; Вып. 112).
- [28] МАЦОКИН А.М. *Численный анализ. Вычислительные методы линейной алгебры. Конспекты лекций для преподавания в III семестре ММФ НГУ*. – Новосибирск: НГУ, 2009–2010.

- [29] Миньков С.Л., Миньков Л.Л. *Основы численных методов*. – Томск: Издательство научно-технической литературы, 2005.
- [30] Мысовских И.П. *Лекции по методам вычислений*. – Санкт-Петербург: Издательство Санкт-Петербургского университета, 1998.
- [31] Островский А.М. *Решение уравнений и систем уравнений*. – Москва: Издательство иностранной литературы, 1963.
- [32] Пароди М. *Локализация характеристических чисел матриц и её применения*. – Москва: Издательство иностранной литературы, 1960.
- [33] Прасолов В.В. *Задачи и теоремы линейной алгебры*. – Москва: Наука-Физматлит, 1996.
- [34] Райс Дж. *Матричные вычисления и математическое обеспечение*. – Москва: Мир, 1984.
- [35] Самарский А.А., Гулин А.В. *Численные методы*. – Москва: Наука, 1989.
- [36] Стренг Г. *Линейная алгебра и её применения*. – Москва: Мир, 1980.
- [37] Тихонов А.Н., Арсенин В.Я. *Методы решения некорректных задач*. – Москва: Наука, 1974.
- [38] Тыртышников Е.Е. *Матричный анализ и линейная алгебра*. – Москва: Физматлит, 2007.
- [39] Тыртышников Е.Е. *Методы численного анализа*. – Москва: Академия, 2007.
- [40] Уилкинсон Дж. *Алгебраическая проблема собственных значений*. – Москва: Наука, 1970.
- [41] Уоткинс Д. *Основы матричных вычислений*. – Москва: «Бином. Лаборатория знаний», 2009.
- [42] Фаддеев Д.К., Фаддеева В.Н. *Вычислительные методы линейной алгебры*. – Москва–Ленинград: Физматлит, 1960 (первое издание) и 1963 (второе издание).
- [43] Федоренко Р.П. Итерационные методы решения разностных эллиптических уравнений // *Успехи Математических Наук*. – 1973. – Т. 28, вып. 2 (170). – С. 121–182.
- [44] Форсайт Дж.Э. Что представляют собой релаксационные методы? // *Современная математика для инженеров под ред Э.Ф.Беккенбаха*. – Москва: Издательство иностранной литературы, 1958. – С. 418–440.
- [45] Форсайт Дж., Молер К. *Численное решение систем линейных алгебраических уравнений*. – Москва: Мир, 1969.
- [46] Хаусдорф Ф. *Теория множеств*. – Москва: УРСС Эдиториал, 2007.
- [47] Хейгеман Л., Янг Д. *Прикладные итерационные методы*. – Москва: Мир, 1986.
- [48] Хорн Р., Джонсон Ч. *Матричный анализ*. – Москва: Мир, 1989.
- [49] Авертн О. *Precise numerical methods using C++*. – San Diego: Academic Press, 1998.

- [50] BECKERMANN B. The condition number of real Vandermonde, Krylov and positive definite Hankel matrices // *Numerische Mathematik*. – 2000. – Vol. 85, No. 4. – P. 553–577.
- [51] KELLEY C.T. *Iterative methods for linear and nonlinear equations*. – Philadelphia: SIAM, 1995.
- [52] SAAD Y. *Iterative methods for sparse linear systems*. – 2000.
- [53] Scilab — The Free Platform for Numerical Computation. <http://www.scilab.org>
- [54] TEMPLE G. The general theory of relaxation methods applied to linear systems // *Proceedings of the Royal Society of London. Series A, Mathematical and Physical Sciences*. – 1939. – Vol. 169, No. 939. – P. 476–500.
- [55] TREFETHEN L.N., BAU D. *III Numerical linear algebra*. – Philadelphia: SIAM, 1997.

Дополнительная

- [56] АЛЕКСЕЕВ Е.Р., ЧЕСНОКОВА О.В., РУДЧЕНКО Е.А. *Scilab. Решение инженерных и математических задач*. – Москва: Alt Linux – Бином, 2008.
- [57] АЛЕФЕЛЬД Г., ХЕРЦБЕРГЕР Ю. *Введение в интервальные вычисления*. – Москва: Мир, 1987.
- [58] ДЖОРДЖ А., ЛЮ ДЖ. *Численное решение больших разреженных систем уравнений*. – Москва: Мир, 1984.
- [59] ДРОБИШЕВИЧ В.И., ДЫМНИКОВ В.П., РИВИН Г.С. *Задачи по вычислительной математике*. – Москва: Наука, 1980.
- [60] КАЛИТКИН Н.Н. *Численные методы*. – Москва: Наука, 1978.
- [61] КРЫЛОВ А.Н. *Лекции о приближённых вычислениях*. – Москва: ГИТТЛ, 1954, а также более ранние издания.
- [62] КУБЛАНОВСКАЯ В.Н. О некоторых алгоритмах для решения полной проблемы собственных значений // *Журнал вычисл. матем. и мат. физики*. – 1961. – Т. 1, №4. – С. 555–570.
- [63] МАРЧУК Г.И. *Методы вычислительной математики*. – Москва: Наука, 1989.
- [64] ШАРЫЙ С.П. *Конечномерный интервальный анализ*. – Электронная книга, 2010 (см. <http://www.nsc.ru/interval/Library/InteBooks>)
- [65] GREGORY R.T., KARNEY D.L. *A collection of matrices for testing computational algorithms*. – Hantington, New York: Robert E. Krieger Publishing Company, 1978.
- [66] KREINOVICH V., LAKEYEV A.V., NOSKOV S.I. Approximate linear algebra is intractable // *Linear Algebra and its Applications*. – 1996. – Vol. 232. – P. 45–54.
- [67] KREINOVICH V., LAKEYEV A.V., ROHN J., KAHL P. *Computational complexity and feasibility of data processing and interval computations*. – Dordrecht: Kluwer, 1997.
- [68] MOLER C. Professor SVD // *The MathWorks News & Notes*. – October 2006. – P. 26–29.

- [69] WILF H.S. *Finite sections of some classical inequalities*. – Heidelberg: Springer, 1970.
- [70] TODD J. The condition number of the finite segment of the Hilbert matrix // *National Bureau of Standards, Applied Mathematics Series*. – 1954. – Vol. 39. – P. 109–116.

Глава 4

Решение нелинейных уравнений и их систем

Предметом рассмотрения этой главы книги является задача решения системы уравнений

$$\left\{ \begin{array}{lcl} F_1(x_1, x_2, \dots, x_n) & = & 0, \\ F_2(x_1, x_2, \dots, x_n) & = & 0, \\ \vdots & \ddots & \vdots \\ F_n(x_1, x_2, \dots, x_n) & = & 0, \end{array} \right. \quad (4.1)$$

над полем вещественных чисел $\mathbb{R}$, или, кратко,

$$F(x) = 0, \quad (4.2)$$

где $x = (x_1, x_2, \dots, x_n) \in \mathbb{R}^n$ — вектор неизвестных переменных,

$F_i(x)$, $i = 1, 2, \dots, n$ — некоторые вещественнозначные функции,

$F(x) = (F_1(x), F_2(x), \dots, F_n(x))^T$ — вектор-столбец функций F_i .

Нужно найти набор значений $\tilde{x}_1, \tilde{x}_2, \dots, \tilde{x}_n$ переменных $x_1, x_2, \dots, x_n$, который и будет называться *решением*, обращающий в равенства все уравнения системы (4.1)–(4.2). В некоторых случаях желательно найти все решения системы, иногда достаточно одного. В случае отсутствия решений у системы (4.1)–(4.2) нередко требуется предоставить обоснованный вывод этого факта в виде протокола работы программы и т. п.

Наряду с задачами, рассмотренными в Главе 2, интерполяцией и приближениями функций, вычислением интегралов, задача решения уравнений и систем уравнений является одной из классических задач численного анализа.

Всюду далее мы предполагаем, что функции $F_i(x)$ по меньшей мере непрерывны, а количество уравнений в системе (4.1)–(4.2) совпадает с количеством неизвестных переменных. Помимо записи систем уравнений в каноническом виде (4.1)–(4.2) часто встречаются и другие формы их представления, например,

$$G(x) = H(x) \quad (4.3)$$

с какими-то функциями G, H . Чрезвычайно важным частным случаем этой формы является известный нам *рекуррентный вид* системы уравнений (уравнения),

$$x = G(x). \quad (4.4)$$

в котором неизвестная переменная выражена через саму себя. В этом случае решение системы уравнений (или уравнения) есть *неподвижная точка* отображения G , т. е. такой элемент области определения G , который переводится этим отображением сам в себя.

Как правило, системы уравнений различного вида могут быть приведены друг к другу равносильными преобразованиями. В частности, несложно установить связь решений уравнений и систем уравнений вида (4.1)–(4.2) с неподвижными точками отображений, т. е. с решениями уравнений в рекуррентном виде (4.4). Ясно, что

$$F(x) = 0 \quad \Longleftrightarrow \quad x = x - \Lambda F(x),$$

где Λ — ненулевой скаляр в одномерном случае или же неособенная матрица в случае вектор-функции F . Поэтому решение уравнения

$$F(x) = 0$$

является неподвижной точкой отображения

$$G(x) = x - \Lambda F(x).$$

Обращаясь к решению нелинейных уравнений и их систем, мы обнаруживаем себя в гораздо более сложных условиях, нежели при решении систем линейных алгебраических уравнений. Стройная и весьма полная теория разрешимости систем линейных уравнений, базирующаяся

на классических результатах линейной алгебры, обеспечивала в случае СЛАУ уверенность в существовании решения и его единственности. Для нелинейных уравнений столь общей и простой теории не существует. Напротив, будучи объединёнными лишь общим признаком «отрицания линейности», нелинейные уравнения отличаются огромным разнообразием

4.1 Вычислительно-корректные задачи

4.1a Формальные определения

Напомним общеизвестный факт: на вычислительных машинах (как электронных, так и механических, как цифровых, так и аналоговых) в условиях приближённого представления входных числовых данных и приближённого характера вычислений над полем вещественных чисел $\mathbb{R}$ мы в принципе можем решать лишь те постановки задач, ответы которых непрерывно зависят от входных данных, т. е. устойчивы по отношению к возмущениям в этих начальных данных. Дело в том, что решение задачи на любой вычислительной машине сопровождается неизбежными ошибками и погрешностями, вызванными конечным характером представления чисел, конечностью исполнительных устройств и т.п. Потенциально эти погрешности могут быть сделаны сколь угодно малыми, но в принципе избавиться от них не представляется возможным. Получается, что реально

- мы решаем на вычислительной машине не исходную математическую задачу, а более или менее близкую к ней,
- сам процесс решения на ЭВМ отличается от своего идеального математического прообраза.

Возникновение и бурное развитие компьютерной алгебры с её «безошибочными» вычислениями едва ли опровергает высказанный выше тезис, так как исходные постановки задач для систем символьных преобразований требуют *точную* представимость входных данных, которые поэтому подразумеваются целыми или, на худой конец, рациональными с произвольной длиной числителя и знаменателя (см. [2]), а все преобразования над ними не выводят за пределы поля рациональных чисел.

Под *массовой задачей* [13] будем понимать некоторый общий вопрос, формулировка которого содержит несколько свободных переменных — *параметров* — могущих принимать значения в пределах предписанных им множеств. В целом массовая задача Π определяется

- 1) общим списком всех её параметров с областями их определения,
- 2) формулировкой тех свойств, которым должен удовлетворять *ответ*, т. е. решение задачи.

Индивидуальная задача I получается из массовой задачи Π путём присваивания всем параметрам задачи Π каких-то конкретных значений. Наконец, *разрешающим отображением* задачи Π назовём отображение, сопоставляющее каждому набору входных данных-параметров ответ соответствующей индивидуальной задачи.

Определение 4.1.1 . *Станем говорить, что массовая математическая задача является вычислительно корректной, если её разрешающее отображение $\mathcal{P} \rightarrow \mathcal{A}$ из множества входных данных $\mathcal{P}$ во множество $\mathcal{A}$ ответов задачи непрерывно относительно некоторых топологий на $\mathcal{P}$ и $\mathcal{A}$, определяемых содержательным смыслом задачи.*

Те задачи, ответы на которые неустойчивы по отношению к возмущениям входных данных, могут решаться на ЭВМ с конечной разрядной сеткой лишь опосредованно, после проведения мероприятий, необходимых для защиты от этой неустойчивости или её нейтрализации.

Например, задача решения систем линейных уравнений $Ax = b$ с невырожденной квадратной матрицей A является вычислительно-корректной. Если топология на пространстве $\mathbb{R}^n$ её решений задается обычным евклидовым расстоянием и подобным же традиционным образом задаётся расстояние между векторами правой части и матрицами, то существуют хорошо известные неравенства (см. §1.2), оценивающие сверху границы изменения решений x через изменения элементов матрицы A , правой части b и число обусловленности матрицы A .

Для систем нелинейных уравнений, могущих иметь неединственное решение, топологию на множестве ответов $\mathcal{A}$ нужно задавать уже каким-либо расстоянием между множествами, например, с помощью так называемой *хаусдорфовой метрики* [8]. Напомним её определение.

Если задано метрическое пространство с метрикой ϱ , то *расстоянием* точки a до множества X называется величина $\varrho(a, X)$, определяемая как $\inf_{x \in X} \varrho(a, x)$. *Хаусдорфовым расстоянием* между компактными множествами X и Y называют величину

$$\varrho(X, Y) = \max \left\{ \max_{x \in X} \varrho(x, Y), \max_{y \in Y} \varrho(y, X) \right\}.$$

При этом $\varrho(X, Y) = +\infty$, если $X = \emptyset$ или $Y = \emptyset$. Введённая таким образом величина действительно обладает всеми свойствами расстояния и может быть использована для задания топологии на пространствах решений тех задач, ответы к которым неединственны.

4.16 Задача решения уравнений не является вычислительно-корректной

Уже простейшие примеры показывают, что задача решения уравнений и систем уравнений не является вычислительно-корректной. Например, квадратное уравнение

$$x^2 + px + q = 0 \quad (4.5)$$

для

$$p^2 = 4q \quad (4.6)$$

имеет лишь одно решение $x = -p/2$. Но при любых сколь угодно малых возмущениях коэффициента p и свободного члена q , нарушающих равенство (4.6), уравнение (4.5) теряет это единственное решение или же приобретает ещё одно (см. Рис. 4.1).

Аналогичным образом ведёт себя решение двумерной системы уравнений, эквивалентной (4.5),

$$\begin{cases} x + y = r, \\ xy = s \end{cases}$$

при $s = r^2/4$. При этом раздвоение решения не является большим грехом, коль скоро мы можем рассматривать хаусдорфово расстояние между целостными множествами решений. Но вот исчезновение единственного решения — это чрезвычайное событие, однозначно указывающее на разрывность разрешающего отображения.

Как видим, математическую постановку задачи нахождения решений уравнений нужно «исправить», заменив какой-нибудь вычислительно-корректной постановкой задачи. Приступая к поиску ответа на




Рис. 4.1. Неустойчивая зависимость решений уравнения (4.5)–(4.6) от сколь угодно малых изменений его коэффициентов.

этот математический вопрос, отметим, прежде всего, что с точки зрения практических приложений задачи, которые мы обычно формулируем в виде решения уравнений или систем уравнений, традиционно выписывая

$$F(x) = 0, \quad (4.2)$$

имеют весьма различную природу. Это и будет отправной точкой нашей ревизии постановки задачи решения уравнений и систем уравнений.

4.1в ε -решения уравнений

В ряде практических задач пользователю требуется не точное равенство некоторого выражения нулю, а лишь его «исчезающая малость» в сравнении с каким-то а priori установленным порогом. Аналогичным образом часто имеет смысл рассматривать соотношения, выражающие равенство двух каких-то выражений.

Таковы, например, уравнения материального баланса в большинстве физических, химических и других естественнонаучных расчётов. Точное равенство нулю здесь неявным образом и не требуется, так как масса молекулы, размеры атома, заряд элементарной частицы, длина световой волны и т.п. — все это величины вполне конечные (хотя и весьма малые), обуславливающие точность тех или иных уравнений баланса и пр.

Например, не имеет смысла требовать, чтобы закон сохранения заряда выполнялся с погрешностью, меньшей чем величина элементарного электрического заряда (т. е. заряда электрона, равного $1.6 \cdot 10^{-19}$ Кл). Также бессмысленно требовать, чтобы погрешность изготовления или подгонки деталей оптических систем была существенно меньше длины световой волны (от $4 \cdot 10^{-7}$ м до $7.6 \cdot 10^{-7}$ м в зависимости от цвета). А что касается температуры, то при обычных земных условиях определение её с точностью превосходящей 0.001 градуса вообще проблематично в силу принципиальных соображений.

Наконец, ограниченная точность, с которой известны абсолютно все физические константы¹, также воздвигает границы для требований равенства в физических соотношениях.

Во всех вышеприведенных примерах под решением уравнения понимается значение переменной, обращающее значение функции в пренебрежимо малую величину:

Для заданных отображения $F : \mathbb{R}^n \rightarrow \mathbb{R}^n$ и $\varepsilon > 0$ найти значения неизвестной переменной x , такие что $F(x) \approx 0$ с абсолютной погрешностью ε , т. е. $\|F(x)\| < \varepsilon$.

Решением этой задачи является целое множество точек, которые мы будем называть ε -решениями или почти решениями, если порог этой пренебрежимой несуществен или не оговорен явно.

Нетрудно понять, что ε -решения устойчивы к малым возмущениям исходных данных, а задача «о нахождении почти решений» является вычислительно-корректной, если отображение F непрерывно.

¹В лучшем случае относительная погрешность известных на сегодняшний день значений физических констант равна 10^{-10} , см. [51].

Как уже отмечалось выше, в некоторых задачах система уравнений более естественно записывается не как (4.2), а в виде (4.3)

$$G(x) = H(x),$$

и требуется обеспечить с относительной погрешностью ϵ равенство её левой и правой частей:

Для заданных отображений $G, H : \mathbb{R}^n \rightarrow \mathbb{R}^n$ и $\epsilon > 0$ найти значения неизвестной переменной x , такие что $G(x) \approx H(x)$ с относительной погрешностью ϵ , т.е.

$$\frac{\|G(x) - H(x)\|}{\max\{\|G(x)\|, \|H(x)\|\}} < \epsilon.$$

Решения этой задачи мы также будем называть ϵ -решениями системы уравнений вида (4.3).

Математические понятия, определения которых привлекают малый допуск ϵ , не являются новинкой. Таковы, к примеру, ϵ -энтропия множеств в метрических пространствах, ϵ -субдифференциал функции, ϵ -оптимальные решения задач оптимизации и т.п. Наиболее близким, по-видимости, к нашим ϵ -решениям является концепция ϵ -спектра матрицы, которой интенсивно оперирует ряд авторов [11, 52, 47]. Говорят, что точка z на комплексной плоскости принадлежит ϵ -спектру матрицы A , если существует комплексный вектор v единичной длины, такой что $\|(A - zI)v\| \leq \epsilon$, где $\|\cdot\|$ — какая-то индуцированная матричная норма.

4.1г Недостаточность ϵ -решений

Но есть и принципиально другой тип задач, которые образно могут быть названы задачами «об определении перехода через нуль» и не сводятся к нахождению ϵ -решений. Таковы задачи, в которых требуется гарантированно отследить переход функции к значениям противоположного знака (или, более общо, переход через некоторое критическое значение). При этом, в частности, в любой окрестности решения

должны присутствовать как положительные значения функции, так и её отрицательные значения, тогда как в задачах нахождения «почти решений» это условие может и не выполняться.

Фазовый переход в физической (или химической системе) — типичная задача такого сорта, так как в процессе фазового перехода температура системы не меняется. Если мы хотим узнать, прошёл ли фазовый переход полностью, то нужно зафиксировать момент достижения множества состояний, лежащего по другую сторону от границы раздела!

Другой пример. Рассмотрим систему линейных дифференциальных уравнений с постоянными коэффициентами

$$\frac{dx}{dt} = Ax, \quad (4.7)$$

матрица которой $A = A(\theta)$ зависит от параметра θ (возможно, векторного). Пусть при некотором начальном значении $\theta = \theta_0$ собственные значения матрицы A имеют отрицательные вещественные части, так что все решения системы (4.7) устойчивы по Ляпунову (и даже асимптотически устойчивы). При каких значениях параметра θ рассматриваемая система делается неустойчивой?

Традиционный ответ на этот вопрос: «Срыв устойчивости в системе (4.7) произойдет при $\operatorname{Re} \lambda(A(\theta)) = 0$ ». Но он неправилен, так как для потери устойчивости необходимо не точное равенство нулю действительных частей некоторых собственных чисел матрицы, а переход их через нуль в область положительного знака. Без этого перехода через мнимую ось и «ещё чуть-чуть дальше» система останется устойчивой, сколь бы близко мы не придвинули собственные значения к мнимой оси или даже достигли бы её. Здесь важен именно переход «через и за» критическое значение, в отсутствие которого качественное изменение в поведении системы не совершится, и этот феномен совершенно не ухватывается понятиями ϵ -решения из §4.1в или ϵ -спектра из [11, 52, 47].

Рассмотренная ситуация, в действительности, весьма типична для динамических систем, где условием совершения многих типов бифуркаций является переход некоторого параметра через так называемое *бифуркационное значение*. К примеру, при переходе через мнимую ось пары комплексных собственных чисел матрицы линеаризованной системы происходит бифуркация Андронова-Хопфа (называемая также бифуркацией рождения цикла, см. [35]). И здесь принципиален именно переход через некоторый порог, а не близость к нему, на которую делается упор в понятиях ϵ -решения и ϵ -спектра.

Нетрудно понять, что такое «переход через нуль» для непрерывной функции одного переменного $f : \mathbb{R} \rightarrow \mathbb{R}$. Но в многомерной ситуации мы сталкиваемся с методическими трудностями, возникающими из необходимости иметь для нестрогого понятия «прохождение функции через нуль» чисто математическое определение. Из требования вычислительной корректности следует, что в любой окрестности такого решения каждая из компонент $F_i(x)$ вектор-функции $F(x)$ должна принимать как положительные, так и отрицательные значения. Но как именно? Какими должны (или могут) быть значения компонент $F_j(x)$, $j \neq i$, если $F_i(x) > 0$ или $F_i(x) < 0$?

В разрешении этого затруднения нам на помощь приходят нелинейный анализ и алгебраическая топология.

4.2 Теоретические основы численных методов

Этот параграф мы посвятим напоминанию некоторых важных фактов из математического анализа, которые существенно используются при численном решении уравнений и систем уравнений.

В математическом анализе хорошо известна

Теорема Больцано-Коши. *Если функция $f : \mathbb{R} \rightarrow \mathbb{R}$ непрерывна на интервале $X \subset \mathbb{R}$ и на его концах принимает значения разных знаков, то внутри интервала X существует нуль функции f , т. е. точка $\tilde{x} \in X$, в которой $f(\tilde{x}) = 0$.*

Часто её называют также «теоремой Больцано» (см., к примеру, [37]), так как именно Б. Больцано первым обнаружил это замечательное свойство непрерывных функций. Многомерное обобщение этого результата было опубликовано более чем столетием позже в заметке [44]:

Теорема Миранды. *Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}^n$, $f(x) = (f_1(x), f_2(x), \dots, f_n(x))^T$ — функция, непрерывная на бруссе $X \subset \mathbb{R}^n$ со сторонами, параллельными координатным осям, и для любого $i = 1, 2, \dots, n$ имеет место либо*

$$f_i(X_1, \dots, X_{i-1}, \underline{X}_i, X_{i+1}, \dots, X_n) \leq 0$$

$$\text{и } f_i(X_1, \dots, X_{i-1}, \overline{X}_i, X_{i+1}, \dots, X_n) \geq 0,$$




Рис. 4.2. Иллюстрация теоремы Больцано-Коши

либо

$$f_i(\mathbf{X}_1, \dots, \mathbf{X}_{i-1}, \underline{\mathbf{X}}_i, \mathbf{X}_{i+1}, \dots, \mathbf{X}_n) \geq 0$$

$$\text{и } f_i(\mathbf{X}_1, \dots, \mathbf{X}_{i-1}, \overline{\mathbf{X}}_i, \mathbf{X}_{i+1}, \dots, \mathbf{X}_n) \leq 0,$$

т. е. области значений каждой компоненты функции $f(x)$ на соответствующих противоположных гранях бруса $\mathbf{X}$ имеют разные знаки. Тогда на брус $\mathbf{X}$ существует нуль функции f , т. е. точка $\tilde{x} \in \mathbf{X}$, в которой $f(\tilde{x}) = 0$.

Характерной особенностью теоремы Миранды является специальная форма множества, на котором утверждается существование нуля функции: оно должно быть бруском со сторонами, параллельными координатным осям, т. е. интервальным вектором. Кроме того, для полноценного применения теоремы Миранды нужно уметь находить или как-то оценивать области значений функций на подобных множествах.

Удобное средство для решения этой задачи предоставляют методы интервального анализа. Задача об определении области значений функции на брусах из области её определения эквивалентна задаче оптимизации, но в интервальном анализе она принимает специфическую форму задачи о вычислении так называемого *интервального расширения функции* (см. §1.4).

Аналогичным образом интервальные методы позволяют придать

конструктивный характер следующему известному результату математического анализа:

Теорема Брауэра о неподвижной точке. Пусть D — выпуклое компактное множество в $\mathbb{R}^n$. Если непрерывное отображение $g : \mathbb{R}^n \rightarrow \mathbb{R}^n$ переводит D в себя, $g(D) \subseteq D$, то оно имеет на D неподвижную точку x^* , т. е. такую что $x^* = g(x^*)$.

Если вместо произвольных выпуклых компактов ограничиться интервальными векторами-брусами в $\mathbb{R}^n$, а для оценивания области значений применять его внешнюю оценку в виде интервального расширения, то условия теоремы Брауэра могут быть конструктивно проверены на компьютере.

С учётом сказанного выше во введении к главе (стр. 271) о равносильности рекуррентного вида систем уравнений (4.4) канонической форме (4.1)–(4.2) чрезвычайно полезными для вычислительной математики оказываются результаты анализа, утверждающие существование неподвижных точек у отображений, и именно такой является теорема Брауэра. Наиболее часто существование неподвижных точек можно гарантировать у отображений, которые удовлетворяют тем или иным дополнительным условиям, и самыми популярными из них являются так называемые условия сжимаемости (сжатия) образа.

Напомним, что отображение $g : X \rightarrow X$ метрического пространства X с расстоянием $\text{dist} : X \rightarrow \mathbb{R}_+$ называется *сжимающим* (или просто *сжатием*), если существует такая положительная постоянная $\alpha < 1$, что для любой пары элементов $x, y \in X$ имеет место неравенство

$$\text{dist}(g(x), g(y)) \leq \alpha \cdot \text{dist}(x, y).$$

Теорема 4.2.1 (теорема Банаха о неподвижной точке). Сжимающее отображение $g : X \rightarrow X$ полного метрического пространства X в себя имеет единственную неподвижную точку. Она может быть найдена методом последовательных приближений

$$x^{(k+1)} \leftarrow g(x^{(k)}), \quad k = 0, 1, 2, \dots,$$

при любом начальном приближении $x^{(0)} \in X$.

Доказательство этого результата можно найти, к примеру, в [17].

Но иногда бывает полезно работать с векторнозначным расстоянием — *мультиметрикой*, — которая вводится на $\mathbb{R}^n$ как

$$\text{Dist}(x, y) := \begin{pmatrix} \text{dist}(x_1, y_1) \\ \vdots \\ \text{dist}(x_n, y_n) \end{pmatrix} \in \mathbb{R}_+^n. \quad (4.8)$$

Для мультиметрических пространств аналогом теоремы Банаха о неподвижной точке для сжимающих отображений является приводимая ниже теорема Шрёдера о неподвижной точке. Перед тем, как дать её точную формулировку, введём

Определение 4.2.1 *Отображение $g : X \rightarrow X$ мультиметрического пространства X с мультиметрикой $\text{Dist} : X \rightarrow \mathbb{R}_+^n$ называется P -сжимающим (или просто P -сжатием), если существует неотрицательная $n \times n$ -матрица P со спектральным радиусом $\rho(P) < 1$, такая что для всех $x, y \in X$ имеет место*

$$\text{Dist}(g(x), g(y)) \leq P \cdot \text{Dist}(x, y). \quad (4.9)$$

Следует отметить, что математики, к сожалению, не придерживаются здесь единой терминологии. Ряд авторов (см. [46]) за матрицей P из (4.9) закрепляют отдельное понятие «оператора Липшица (матрицы Липшица) отображения g », и в условиях Определения 4.2.1 говорят, что «оператор Липшица для g сжимающий».

Теорема 4.2.2 (теорема Шрёдера о неподвижной точке) *Пусть отображение $g : \mathbb{R}^n \supseteq X \rightarrow \mathbb{R}^n$ является P -сжимающим на замкнутом подмножестве X пространства $\mathbb{R}^n$ с мультиметрикой Dist . Тогда для любого $x^{(0)}$ последовательность итераций*

$$x^{(k+1)} = g(x^{(k)}), \quad k = 0, 1, 2, \dots,$$

сходится к единственной неподвижной точке x^ отображения g в X и имеет место оценка*

$$\text{Dist}(x^{(k)}, x^*) \leq (I - P)^{-1} P \cdot \text{Dist}(x^{(k)}, x^{(k-1)}).$$

Доказательство можно найти, например, в книгах [1, 18, 27, 46]

4.3 Классические методы решения уравнений

Пример 4.3.1 Рабочие имеют кусок кровельного материала шириной $l = 3.3$ метра и хотят покрыть им пролёт шириной $h = 3$ метра, сделав крышу круглой, в форме дуги окружности. Для того, чтобы придать правильную форму балке, поддерживающей кровлю, нужно знать, какой именно радиус закругления крыши при этом получится (см. Рис. 4.3).




Рис. 4.3. Проектирование круглой крыши.

Обозначим искомый радиус закругления крыши через R . Если 2α — величина дуги (в радианах), соответствующей крыше, то

$$\frac{l}{2\alpha} = R.$$

С другой стороны, из рассмотрения прямоугольного треугольника с катетом $h/2$ и гипотенузой R получаем

$$R \sin \alpha = h/2.$$

Исключая из этих двух соотношений R , получим уравнение относительно одной неизвестной α :

$$l \sin \alpha = \alpha h. \quad (4.10)$$

Его решение не может быть выражено в явном виде, и потому далее мы обсудим возможности его численного решения. ■

Уравнение (4.10) является простейшим нелинейным *трансцендентным* уравнением.

4.3а Предварительная локализация решений

Обычно первым этапом численного решения уравнений и систем уравнений является предварительная локализация, т. е. уточнение местонахождения, искомых решений. Это вызвано тем, что большинство численных методов для поиска решений имеют локальный характер, т. е. сходятся к этим решениям лишь из достаточно близких начальных приближений.

Для локализации решений могут применяться как численные, так и аналитические методы, а также их смесь — гибридные методы, которые (следуя Д. Кнуту) можно назвать *получисленными* или *полуаналитическими*.

Особенно много аналитических результатов существует о локализации решений алгебраических уравнений (корней полиномов), что, конечно, имеет причину в очень специальном виде этих уравнений, допускающем исследование с помощью выкладок и т. п.

Теорема 4.3.1 Пусть для алгебраического уравнения вида

$$a_n x^n + a_{n-1} x^{n-1} + \dots + a_1 x + a_0 = 0$$

обозначено

$$\alpha = \max\{a_0, \dots, a_{n-1}\}, \quad \beta = \max\{a_1, \dots, a_n\}.$$

Тогда все решения этого уравнения принадлежат кольцу в комплексной плоскости, определяемому условием

$$\frac{1}{1 + \beta/|a_0|} \leq |x| \leq 1 + \frac{\alpha}{|a_n|}.$$

Полезно *правило знаков Декарта*, утверждающее, что число положительных корней полинома с вещественными коэффициентами равно числу перемен знаков в ряду его коэффициентов или на чётное число меньше этого числа. При этом корни считаются с учётом кратности, а нулевые коэффициенты при подсчёте числа перемен знаков не учитываются. Если, к примеру, заранее известно, что все корни данного полинома вещественны, то правило знаков Декарта даёт точное число

корней. Рассматривая полином с переменной $(-x)$ можно с помощью этого же результата найти число отрицательных корней исходного полинома.

4.36 Метод дихотомии

Этот метод часто называют также *методом бисекции* или *методом половинного деления* и т.п. Он заключается в последовательном делении пополам интервала локализации корня уравнения, на концах которого функция принимает значения разных знаков.




Рис. 4.4. Иллюстрация метода дихотомии (деления пополам)

Недостаток этого простейшего варианта метода дихотомии — возможность потери решений, как это изображено на рисунке. Этого можно избежать, если отслеживать постоянный знак производной функции.

4.3в Метод простой итерации

Методом простой итерации обычно называют стационарный одношаговый итерационный процесс, который организуется после того, как исходное уравнение каким-либо способом приведено к равносильному рекуррентному виду $x = \Phi(x)$. Далее, после выбора некоторого начального приближения $x^{(0)}$, запускается итерационный процесс

$$x^{(k+1)} \leftarrow \Phi(x^{(k)}), \quad k = 0, 1, 2, \dots$$

При благоприятных обстоятельствах последовательность $\{x^{(k)}\}$ сходится, и её пределом является решение исходного уравнения. Но в общем случае и характер сходимости, и вообще её наличие существенно зависят как от отображения Φ , так и от начального приближения к решению.

Пример 4.3.2 Уравнение (4.10) из Примера 4.3 нетрудно привести к рекуррентному виду

$$\alpha = \frac{l}{h} \sin \alpha,$$

и, взяв в качестве начального приближения, например, $\alpha^{(0)} = 1$, через 50 итераций

$$\alpha^{(k+1)} \leftarrow \frac{l}{h} \sin \alpha^{(k)}, \quad k = 0, 1, 2, \dots, \quad (4.11)$$

получить пять верных знаков точного решения $\alpha^* = 0.748986642697\dots$ (читатель легко может самостоятельно проверить все числовые данные этого примера с помощью любой системы компьютерной математики).

Итерационный процесс (4.11) сходится к решению α^* не из любого начального приближения. Если $\alpha^{(0)} = \pi l$, $l \in \mathbb{Z}$, то в результате итераций (4.11) получаем $\alpha^{(k)} = 0$, $k = 1, 2, \dots$. Если же $\alpha^{(0)}$ таково, что синус от него отрицателен, то итерации (4.11) сходятся к решению $(-\alpha^*)$ уравнения (4.10). И нулевое, и отрицательное решения очевидно не имеют содержательного смысла.

С другой стороны, переписывание исходного уравнения (4.11) в другом рекуррентном виде —

$$\alpha = \frac{1}{l} \arcsin(\alpha h)$$

— приводит к тому, что характер сходимости метода простой итерации совершенно меняется. Из любого начального приближения, меньшего по модулю чем примерно 0.226965, итерации

$$\alpha^{(k+1)} \leftarrow \frac{1}{l} \arcsin(\alpha^{(k)} h), \quad k = 0, 1, 2, \dots,$$

сходятся лишь к нулевому решению. Большие по модулю начальные приближения быстро выводят за границы области определения вещественного арксинуса, переводя итерации в комплексную плоскость, где они снова сходятся к нулевому решению. Таким образом, искомого решения α^* мы при этом никак не получаем. ■

4.3г Метод Ньютона и его модификации

Для определения погрешности приближённого решения $\tilde{x}$ и контроля вычислений можно применять формулу

$$|\tilde{x} - x^*| \leq \frac{f(\tilde{x})}{\min_{\xi \in [a, b]} |f'(\xi)|}, \quad (4.12)$$

которая следует из теоремы Лагранжа о среднем (формулы конечных приращений):

$$f(\tilde{x}) - f(x^*) = f'(\xi)(\tilde{x} - x^*),$$

для некоторой точки $\xi \in \square\{\tilde{x}, x^*\}$, т.е. интервалу с концами $\tilde{x}$ и x^* . Ясно, что тогда

$$|f(\tilde{x}) - f(x^*)| \geq \min_{\xi} |f'(\xi)| \cdot |\tilde{x} - x^*|,$$

и при $\min_{\xi \in [a, b]} |f'(\xi)| \neq 0$ получаем оценку (4.12).

4.3д Методы Чебышёва

4.4 Классические методы решения систем уравнений

4.4а Метод простой итерации

4.4б Метод Ньютона и его модификации

4.5 Интервальные линейные системы уравнений

Предметом рассмотрения настоящего пункта являются интервальные системы линейных алгебраических уравнений (ИСЛАУ) вида

$$Ax = b, \quad (4.13)$$

где $A = (a_{ij})$ — это интервальная $m \times n$ -матрица и $b = (b_i)$ — интервальный m -вектор. Строго говоря, для интервальных уравнений решения и множества решений могут быть определены разнообразными

способами (см. [36]), но ниже мы ограничимся так называемым *объединённым множеством решений* для (4.13), которое образовано всевозможными решениями x точечных систем $Ax = b$, когда матрица A и вектор b независимо пробегает $\mathbf{A}$ и $\mathbf{b}$ соответственно. Объединённое множество решений определяется строго как

$$\Xi(\mathbf{A}, \mathbf{b}) = \{x \in \mathbb{R}^n \mid (\exists A \in \mathbf{A})(\exists b \in \mathbf{b})(Ax = b)\}, \quad (4.14)$$

и ниже мы будем называть его просто *множеством решений* интервальной линейной системы (4.13), так как другие множества решений нами не исследуются. Точное описание множества решений может расти экспоненциально с размерностью вектора неизвестных n , а потому является практически невозможным уже при n , превосходящем несколько десятков. С другой стороны, в большинстве реальных постановок задач точное описание на самом деле и не нужно. На практике бывает вполне достаточно нахождения *оценки* для множества решений, т.е. приближенного описания, удовлетворяющего содержательно-смыслу рассматриваемой задачи.

Приведём полезный технический результат, который часто используется в связи с исследованием и оцениванием множества решений интервальных систем линейных алгебраических уравнений.

Теорема 4.5.1 (характеризация Бека) *Если $\mathbf{A} \in \mathbb{IR}^{m \times n}$, $\mathbf{b} \in \mathbb{IR}^m$, то*

$$\begin{aligned} \Xi(\mathbf{A}, \mathbf{b}) &= \{x \in \mathbb{R}^n \mid \mathbf{A}x \cap \mathbf{b} \neq \emptyset\} \\ &= \{x \in \mathbb{R}^n \mid 0 \in \mathbf{A}x - \mathbf{b}\}. \end{aligned}$$

Доказательство. Если $\tilde{x} \in \Xi(\mathbf{A}, \mathbf{b})$, то $\tilde{A}\tilde{x} = \tilde{b}$ для некоторых $\tilde{A} \in \mathbf{A}$, $\tilde{b} \in \mathbf{b}$. Следовательно, по крайней мере $\tilde{b} \in \mathbf{A}\tilde{x} \cap \mathbf{b}$, так что действительно $\mathbf{A}\tilde{x} \cap \mathbf{b} \neq \emptyset$.

Наоборот, если $\mathbf{A}\tilde{x} \cap \mathbf{b} \neq \emptyset$, то это пересечение $\mathbf{A}\tilde{x} \cap \mathbf{b}$ содержит вектор $\tilde{b} \in \mathbb{R}^m$, для которого должно иметь место равенство $\tilde{b} = \tilde{A}\tilde{x}$ с некоторой $\tilde{A} \in \mathbf{A}$. Итак, $\tilde{x} \in \Xi(\mathbf{A}, \mathbf{b})$.

Второе равенство следует из того, что $\mathbf{A}\tilde{x} \cap \mathbf{b} \neq \emptyset$ тогда и только тогда, когда $0 \in \mathbf{A}\tilde{x} - \mathbf{b}$. ■

Теорема 4.5.2 (характеризация Оеттли-Прагера) *Для объединённого множества решений ИСЛАУ имеет место*

$$x \in \Xi(\mathbf{A}, \mathbf{b}) \Leftrightarrow |(\text{mid } \mathbf{A})x - \text{mid } \mathbf{b}| \leq \text{rad } \mathbf{A} \cdot |x| + \text{rad } \mathbf{b}, \quad (4.15)$$

где неравенство между векторами понимается покомпонентным образом.

Доказательство. Включение $p \subseteq q$ для интервальных векторов-брусков p и q равносильно покомпонентному неравенству

$$|\text{mid } q - \text{mid } p| \leq \text{rad } q - \text{rad } p.$$

Следовательно, характеристика Бека может быть переписана в следующем виде:



4.6 Интервальные методы решения уравнений и систем уравнений

Задача решения уравнений и систем уравнений является одной из классических задач вычислительной математики, для решения которой развито немало эффективных подходов — метод простой итерации, метод Ньютона, их модификации и т.п. Преимущества и недостатки этих классических методов мы обсудили выше в §§4.3–4.4 (см. также [5, 27, 31, 42]). Для дальнейшего нам важны два факта:

- Для уравнений, в которых фигурируют функции, не обладающие «хорошими» глобальными свойствами, все традиционные методы имеют *локальный характер*, т.е. обеспечивают отыскание решения, находящегося в некоторой (иногда достаточно малой) окрестности начального приближения. Задача нахождения *всех* решений уравнения или системы уравнений, как правило, рассматривается лишь в специальных руководствах и методы её решения оказываются очень сложными.
- Гарантированные оценки погрешности найденного приближения к решению в традиционных методах дать весьма непросто.

Указание приближённого значения величины и его максимальной погрешности равносильно тому, что мы знаем левую и правую границы возможных значений этой величины, и поэтому можно переформулировать нашу задачу в следующем усиленном виде —

Для каждого решения системы уравнений

$$F(x) = 0$$

на данном множестве $D \subseteq \mathbb{R}^n$ найти
гарантированные двусторонние границы

, (4.16)

— который будем называть *задачей доказательного глобального решения* системы уравнений. Эпитет «доказательный» означает здесь, что получаемый нами ответ к задаче — границы решений и т.п. — имеет статус математически строго доказанного утверждения о расположении решений (при условии, что ЭВМ работает корректно)²

Задача (4.16) оказывается чрезвычайно сложной, а в классическом численном анализе почти полностью отсутствуют развитые методы для её решения. Из часто используемых подходов, имеющих ограниченный успех, следует упомянуть *аналитическое исследование, мультистарт, методы продолжения* [27].

Итак, пусть к решению предъявлена система уравнений (4.2)

$$F(x) = 0$$

на брус $\mathbf{X} \subset \mathbb{R}^n$. Отметим, что эту задачу можно переписать в виде

$$\text{ran}(F, \mathbf{X}) \ni 0,$$

и потому техника интервального оценивания множеств значений функций оказывается весьма полезной при решении вопроса о существовании или несуществовании решений системы (4.2). В частности, если нуль содержится во внутренней интервальной оценке множества значений $\text{ran}(F, \mathbf{X})$ отображения F , то на брус $\mathbf{X}$ гарантированно находится решение системы (4.2). С другой стороны, если в нашем распоряжении имеется интервальное расширение $\mathbf{F}$ функции F на $\mathbf{X}$, то $\mathbf{F}(\mathbf{X}) \supseteq \text{ran}(F, \mathbf{X})$. Поэтому $0 \notin \mathbf{F}(\mathbf{X})$ влечёт вывод о том, что на $\mathbf{X}$ нет решений рассматриваемой системы уравнений.

²Термин «доказательные вычисления на ЭВМ» впервые систематически использовал К.И. Бабенко [49]. Этот термин является хорошим русским эквивалентом таких распространённых английских оборотов как *verified computation*, *verification numerics* и др.

Далее, перепишем исходную систему (4.2) в равносильной рекуррентной форме

$$x = T(x) \quad (4.17)$$

с некоторым отображением $T : \mathbb{R}^n \rightarrow \mathbb{R}^n$. Оно может быть взято, к примеру, в виде

$$T(x) = x - F(x)$$

либо

$$T(x) = x - \Lambda F(x),$$

с неособенной $n \times n$ -матрицей Λ , либо как-нибудь ещё. Пусть также $\mathbf{T} : \mathbb{IR}^n \rightarrow \mathbb{IR}^n$ — интервальное расширение отображения T . Ясно, что решения системы (4.17) могут лежать лишь в пересечении $\mathbf{X} \cap \mathbf{T}(\mathbf{X})$. Поэтому если

$$\mathbf{X} \cap \mathbf{T}(\mathbf{X}) = \emptyset,$$

то в $\mathbf{X}$ нет решений системы уравнений (4.17). Коль скоро искомое решение содержится и в $\mathbf{T}(\mathbf{X})$, то для дальнейшего уточнения бруса, в котором может присутствовать решение, мы можем организовать итерации с пересечением

$$\mathbf{X}^{(0)} \leftarrow \mathbf{X}, \quad (4.18)$$

$$\mathbf{X}^{(k+1)} \leftarrow \mathbf{T}(\mathbf{X}^{(k)}) \cap \mathbf{X}^{(k)}, \quad k = 0, 1, 2, \dots \quad (4.19)$$

Следует особо отметить, что в получающихся при этом брусах наличие решения, вообще говоря, не гарантируется. Они являются лишь «подозрительными» на существование решения.

Но вот если для бруса $\mathbf{X}$ выполнено

$$\mathbf{T}(\mathbf{X}) \subseteq \mathbf{X},$$

то по теореме Брауэра о неподвижной точке (стр. 281) в $\mathbf{X}$ гарантированно находится решение системы (4.17). Для уточнения этого бруса мы снова можем воспользоваться итерациями (4.18)–(4.19). Таким образом, наихудшим, с точки зрения уточнения информации о решении системы, является случай

$$\mathbf{T}(\mathbf{X}) \supsetneq \mathbf{X}. \quad (4.20)$$

Приведённую выше последовательность действий по обнаружению решения системы уравнений и уточнению его границ мы будем называть далее кратко *тестом существования*. Условимся также считать,

что его результатом является брус пересечения ($\mathbf{X} \cap \mathbf{T}(\mathbf{X})$) либо предел последовательности (4.18)–(4.19). Если этот брус непуст, то он либо наверняка содержит решение системы уравнений, либо является подозрительным на наличие в нём решения. Если же результат теста существования пуст, то в исходном брусе решений системы уравнений нет.

В действительности, каждый из изложенных выше приёмов уточнения решения допускает далеко идущие модификации и улучшения. Например, это относится к итерациям вида (4.18)–(4.19), которые могут быть последовательно применены не к целым брусам $\mathbf{X}^{(k)}$, а к отдельным их компонентам в комбинации с различными способами приведения исходной системы к рекуррентному виду (4.17). На этом пути мы приходим к чрезвычайно эффективным алгоритмам, которые получили наименование *методов распространения ограничений* (см., к примеру, [30]).

Как простейший тест существования, так и его более продвинутые варианты без особых проблем реализуются на ЭВМ и работают тем лучше, чем более качественно вычисляются интервальные расширения функций F в (4.2) и T в (4.17) и чем меньше ширина бруса $\mathbf{X}$. Последнее связано с тем, что погрешность оценивания области значений функции посредством любого интервального расширения убывает с уменьшением размеров бруса, на котором производится это оценивание. (см. §1.4).

4.6а Одномерный интервальный метод Ньютона

В этом параграфе мы рассмотрим простейший случай одного уравнения с одним неизвестным.

Предположим, что $f : \mathbb{R} \supseteq \mathbf{x} \rightarrow \mathbb{R}$ — непрерывно дифференцируемая функция, имеющая нуль x^* на интервале $\mathbf{x}$, т. е. $f(x^*) = 0$. Тогда для любой точки $\tilde{x} \in \mathbf{x}$ из этого же интервала в силу теоремы Лагранжа о среднем значении

$$f(\tilde{x}) - f(x^*) = (\tilde{x} - x^*) \cdot f'(\xi),$$

где ξ — некоторая точка между $\tilde{x}$ и x^* . Но так как $f(x^*) = 0$, то отсюда следует

$$x^* = \tilde{x} - \frac{f(\tilde{x})}{f'(\xi)}.$$

Если $\mathbf{f}'(\mathbf{x})$ является каким-либо интервальным расширением производной функции $f(x)$ на $\mathbf{x}$, то $f'(\xi) \in \mathbf{f}'(\mathbf{x})$ и

$$x^* \in \tilde{x} - \frac{f(\tilde{x})}{\mathbf{f}'(\mathbf{x})}.$$

Интервальное выражение, фигурирующее в правой части этого включения, будет играть в дальнейшем важную роль и потому достойно выделения самостоятельным понятием.

Определение 4.6.1 Для заданной функции $f : \mathbb{R} \rightarrow \mathbb{R}$ отображение

$$\mathcal{N} : \mathbb{IR} \times \mathbb{R} \rightarrow \mathbb{IR},$$

действующее по правилу

$$\mathcal{N}(\mathbf{x}, \tilde{x}) := \tilde{x} - \frac{f(\tilde{x})}{\mathbf{f}'(\mathbf{x})}$$

называется (одномерным) интервальным оператором Ньютона.




Рис. 4.5. Иллюстрация работы одномерного интервального метода Ньютона. Ситуация 1.

Допустим на время, что $0 \notin \mathbf{f}'(\mathbf{x})$, так что $\mathcal{N}(\mathbf{x}, \tilde{x})$ является вполне определённым конечным интервалом. Так как любой нуль функции

$f(x)$ на $\mathbf{x}$ лежит также и в $\mathcal{N}(\mathbf{x}, \tilde{x})$, то разумно взять в качестве следующего более точного приближения к решению пересечение

$$\mathbf{x} \cap \mathcal{N}(\mathbf{x}, \tilde{x}),$$

которое окажется, по крайней мере, не хуже $\mathbf{x}$.




Рис. 4.6. Иллюстрация работы одномерного интервального метода Ньютона. Ситуация 2.

Далее, если $0 \in \mathbf{f}'(\mathbf{x})$, мы можем придать смысл оператору Ньютона, воспользовавшись интервальной арифметикой Кахана. В действительности, эта модификация даже усилит интервальный метод Ньютона, так как мы получим возможность отделять решения друг от друга: в результате выполнения шага интервального метода Ньютона при $0 \in \text{int } \mathbf{f}'(\mathbf{x})$ получаются, как правило, два непересекающихся интервала.

Свойства одномерного интервального метода Ньютона:

1. Всякий нуль функции f на исходном интервале $\mathbf{x}$ корректно выделяется методом.
2. Если на исходном интервале $\mathbf{x}$ нет нулей функции f , то этот факт будет установлен методом за конечное число итераций.
3. Если $0 \notin \mathbf{f}'(\mathbf{x})$ для некоторого $\mathbf{x}$, то на следующем шаге метода будет исключена по крайней мере половина $\mathbf{x}$
4. Если $0 \notin \mathbf{f}'(\mathbf{x})$, то асимптотический порядок сходимости метода к нулю функции f на интервале $\mathbf{x}$ является квадратичным.

4.6б Многомерный интервальный метод Ньютона

Переходя к решению систем нелинейных уравнений, следует отметить, что многомерные версии интервального метода Ньютона гораздо более многочисленны, чем одномерные, и отличаются очень большим разнообразием. В многомерном случае мы можем варьировать не только выбор точки $\tilde{x}$, вокруг которой осуществляется разложение, форму интервального расширения производных или наклонов функции, как это было в одномерном случае, но также и способ внешнего оценивания множества решений интервальной линейной системы, к которой приводится оценивание бруса решения. В оставшейся части этого параграфа мы рассмотрим простейшую форму многомерного интервального метода Ньютона, а его более специальным версиям, которые связываются с именами Кравчика и Хансена-Сенгупты, будут посвящены отдельные параграфы.

Определение 4.6.2 [46] Для отображения $F : \mathbb{R}^n \supseteq D_0 \rightarrow \mathbb{R}^m$ матрица $\mathbf{A} \in \mathbb{IR}^{m \times n}$ называется интервальной матрицей Липшица на $D \subseteq D_0$, если для любых $x, y \in D$ равенство

$$F(y) - F(x) = A(y - x)$$

имеет место с некоторой вещественной $m \times n$ -матрицей $A \in \mathbf{A}$.

Предположим, что на брусе $\mathbf{x}$ к решению предъявлена система нелинейных уравнений

$$F(x) = 0. \quad (4.21)$$

Если $\mathbf{L}$ — интервальная матрица Липшица отображения F на $\mathbf{x}$, то для любых точек $x, \tilde{x} \in \mathbf{x}$ справедливо представление

$$F(x) \in F(\tilde{x}) + \mathbf{L}(x - \tilde{x}).$$

В частности, если x — решение системы уравнений (4.21), т. е. $F(x) = 0$, то

$$0 \in F(\tilde{x}) + \mathbf{L}(x - \tilde{x}). \quad (4.22)$$

Вспомним характеристику Бека для объединённого множества решений ИСЛАУ (Теорема 4.5.1): получается, что точка x удовлетворяет

включению (4.22) тогда и только тогда, когда она принадлежит объединённому множеству решений интервальной линейной системы

$$\mathbf{L}(x - \tilde{x}) = -F(\tilde{x}). \quad (4.23)$$

Далее, если $Encl$ — процедура внешнего оценивания множества решений ИСЛАУ, то справедливо включение

$$x - \tilde{x} \in Encl(\mathbf{L}, -F(\tilde{x})),$$

так что

$$x \in \tilde{x} + Encl(\mathbf{L}, -F(\tilde{x})).$$

Определение 4.6.3 Пусть для внешнего оценивания множеств решений ИСЛАУ зафиксирована процедура $Encl$, а для отображения $F : \mathbb{R}^n \supseteq D \rightarrow \mathbb{R}^n$ известна интервальная матрица Липшица $\mathbf{L} \in \mathbb{IR}^{n \times n}$. Отображение

$$\mathcal{N} : \mathbb{ID} \times \mathbb{R}^n \rightarrow \mathbb{IR}^n,$$

задаваемое правилом

$$\mathcal{N}(\mathbf{x}, \tilde{x}) = \tilde{x} + Encl(\mathbf{L}, -F(\tilde{x})),$$

называется интервальным оператором Ньютона на $\mathbb{ID}$ относительно точки $\tilde{x}$.

Как лучше выбирать центр разложения $\tilde{x}$? Имеет смысл делать это так, чтобы величина $\|F(\tilde{x})\|$ была, по-возможности, меньшей. Чем меньше будет норма вектор-функции $F(\tilde{x})$, тем меньшим будет норма векторов, образующих множество решений интервальной линейной системы

$$\mathbf{L}(x - \tilde{x}) = -F(\tilde{x}),$$

которое мы должны пересекать с исходным брусом. Может быть, мы получим при этом более узкую внешнюю оценку множества решений исходной нелинейной системы и более точно определим статус исследуемого бруса. Численные эксперименты как будто подтверждают этот вывод.

Процедуру для уточнения центра разложения можно организовать как метод типа Ньютона, коль скоро нам известна интервальная матрица Липшица.

Наиболее неблагоприятной ситуацией при работе интервального метода Ньютона является, конечно, появление включения

$$\mathcal{N}(\mathbf{x}, \tilde{x}) \supseteq \mathbf{x}.$$

Тогда все последующие шаги заклиниваются на брус $\mathbf{x}$ и не дают никакой дополнительной информации об искомым решениях системы. Как поступать в этом случае? Ответ на этот вопрос рассматривается в следующем параграфе.

4.6в Метод Кравчика

Пусть на брус $\mathbf{x} \in \mathbb{IR}^n$ задана система n нелинейных уравнений с n неизвестными

$$F(x) = 0,$$

для которой требуется уточнить двусторонние границы решений. Возьмём какую-нибудь точку $\tilde{x} \in \mathbf{x}$ и организуем относительно неё разложение функции F :

$$F(x) \in F(\tilde{x}) + \mathbf{L}(x - \tilde{x}),$$

где $\mathbf{L} \in \mathbb{R}^{n \times n}$ — интервальная матрица Липшица отображения F на брус $\mathbf{x}$. Если x — это точка решения системы, то

$$0 \in F(\tilde{x}) + \mathbf{L}(x - \tilde{x}), \quad (4.22)$$

но далее, в отличие от интервального метода Ньютона, мы не будем переходить к рассмотрению интервальной линейной системы (4.23), а домножим обе части этого включения слева на точечную $n \times n$ -матрицу, которую нам будет удобно обозначить как $(-\Lambda)$:

$$0 \in -\Lambda F(\tilde{x}) - \Lambda \mathbf{L}(x - \tilde{x}).$$

Добавление к обоим частям получившегося соотношения по $(x - \tilde{x})$ приводит к

$$x - \tilde{x} \in -\Lambda F(\tilde{x}) - \Lambda \mathbf{L}(x - \tilde{x}) + (x - \tilde{x}),$$

что равносильно

$$x \in \tilde{x} - \Lambda F(\tilde{x}) + (I - \Lambda \mathbf{L})(x - \tilde{x}),$$

так как для неинтервального общего множителя $(x - \tilde{x})$ можно воспользоваться дистрибутивным соотношением (1.9). Наконец, если решение x системы уравнений предполагается принадлежащим брусу $\mathbf{x}$,

мы можем взять интервальное расширение по $x \in \mathbf{x}$ правой части полученного включения, придя к соотношению

$$x \in \tilde{x} - \Lambda F(\tilde{x}) + (I - \Lambda \mathbf{L})(\mathbf{x} - \tilde{x}),$$

Определение 4.6.4 Пусть определены некоторые правила, сопоставляющие всякому брусу $\mathbf{x} \in \mathbb{IR}^n$ точку $\tilde{x} \in \mathbf{x}$ и вещественную $n \times n$ -матрицу $\mathbf{L}$ и пусть также $\mathbf{L} \in \mathbb{IR}^{n \times n}$ — интервальная матрица Липшица отображения $F : \mathbb{R}^n \supseteq D \rightarrow \mathbb{R}^n$ на D . Отображение

$$\mathcal{K} : \mathbb{ID} \times \mathbb{R} \rightarrow \mathbb{IR}^n,$$

задаваемое выражением

$$\mathcal{K}(\mathbf{x}, \tilde{x}) := \tilde{x} - \Lambda F(\tilde{x}) + (I - \Lambda \mathbf{L})(\mathbf{x} - \tilde{x}),$$

называется оператором Кравчика на $\mathbb{ID}$ относительно точки $\tilde{x}$.

Теорема 4.6.1 Пусть $F : \mathbb{R}^n \supseteq D \rightarrow \mathbb{R}^n$ — непрерывное по Липшицу отображение, $\mathbf{L}$ — его интервальная матрица Липшица и $\tilde{x} \in \mathbf{x} \subseteq \mathbb{ID}$. Тогда

- (i) каждое решение системы $F(x) = 0$ на брусе $\mathbf{x}$ лежит также в $\mathcal{K}(\mathbf{x}, \tilde{x})$;
- (ii) если $\mathbf{x} \cap \mathcal{K}(\mathbf{x}, \tilde{x}) = \emptyset$, то в $\mathbf{x}$ нет решений системы $F(x) = 0$;
- (iii) если $\mathcal{K}(\mathbf{x}, \tilde{x}) \subseteq \mathbf{x}$, то в $\mathbf{x}$ находится хотя бы одно решение системы $F(x) = 0$;
- (iv) если $\tilde{x} \in \text{int } \mathbf{x}$ и $\emptyset \neq \mathcal{K}(\mathbf{x}, \tilde{x}) \subseteq \text{int } \mathbf{x}$, то матрица $\mathbf{L}$ сильно неособенна и в $\mathcal{K}(\mathbf{x}, \tilde{x})$ содержится в точности одно решение системы $F(x) = 0$.

Оператор Кравчика — это не что иное, как центрированная форма интервального расширения отображения $\Phi(x) = x - \Lambda F(x)$, возникающего в правой части системы уравнений после её приведения к рекуррентному виду

$$x = \Phi(x).$$

4.7 Глобальное решение уравнений и систем уравнений

Если ширина бруса $\mathbf{X}$ велика, то на нём описанные в предшествующем параграфе методики уточнения решения могут оказаться малоуспешными в том смысле, что мы получим включение (4.20), из которого нельзя вывести никакого определённого заключения ни о существовании решения на брус $\mathbf{X}$, ни о его отсутствии. Кроме того, сам этот брус, как область потенциально содержащая решение, несколько не будет уточнён (уменьшен).

Тогда практикуют принудительное дробление $\mathbf{X}$ на более мелкие подбрусы. Наиболее популярна при этом *бисекция* — разбиение бруса $\mathbf{X}$ на две (равные или неравные) части вдоль какой-нибудь грани, например, на половинки

$$\mathbf{X}' = (\mathbf{X}_1, \dots, [\underline{\mathbf{X}}_\iota, \text{mid } \mathbf{X}_\iota], \dots, \mathbf{X}_n),$$

$$\mathbf{X}'' = (\mathbf{X}_1, \dots, [\text{mid } \mathbf{X}_\iota, \overline{\mathbf{X}}_\iota], \dots, \mathbf{X}_n)$$

для некоторого номера $\iota \in \{1, 2, \dots, n\}$. При этом подбрусы $\mathbf{X}'$ и $\mathbf{X}''$ называются *потомками* бруса $\mathbf{X}$. Далее эти потомки можно разбить ещё раз, и ещё ... столько, сколько необходимо для достижения желаемой малости их размеров, при которой мы сможем успешно выполнять на этих брусах рассмотренные выше тесты существования решений.

Если мы не хотим упустить при этом ни одного решения системы, то должны хранить все возникающие в процессе такого дробления подбрусы, относительно которых тестом существования не доказано строго, что они не содержат решений. Организуем поэтому *рабочий список* $\mathcal{L}$ из всех потомков начального бруса $\mathbf{X}$, подозрительных на содержание решений.³ В целом же алгоритм глобального доказательного решения системы уравнений организуем в виде повторяющейся последовательности следующих действий:

- извлечение некоторого бруса из списка $\mathcal{L}$,
- дробление этого бруса на потомки,
- проверка существования решений в каждом из подбрусов-потомков, по результатам которой мы

³Хотя мы называем эту структуру данных «списком», в смысле программной реализации это может быть не обязательно список, но и *стек* (магазин), и *куча* [4].

- либо выдаём этот подбрус в качестве ответа к решаемой задаче,
- либо заносим его в рабочий список $\mathcal{L}$ для последующей обработки,
- либо исключаем из дальнейшего рассмотрения, как не содержащий решений рассматриваемой системы.

Кроме того, чтобы обеспечить ограниченность времени работы алгоритма, на практике имеет смысл задаться некоторым порогом мелкости (малости размеров) брусков δ , при достижении которого дальше дробить брусок уже не имеет смысла. Псевдокод получающегося алгоритма приведён в Табл. 4.1.

Отметим, что неизбежные ограничения на вычислительные ресурсы ЭВМ могут воспрепятствовать решению этим алгоритмом задачи (4.16) «до конца», поскольку могут возникнуть ситуации, когда

- 1) размеры обрабатываемого бруса уже меньше δ , но нам ещё не удаётся ни доказать существование в нём решений, ни показать их отсутствие;
- 2) размеры обрабатываемого бруса ещё больше δ , но вычислительные ресурсы уже не позволяют производить его обработку дальше: исчерпались выделенное время, память и т.п.

В реальных вычислениях остановка алгоритма Табл. 4.1 может происходить поэтому не только при достижении пустого рабочего списка $\mathcal{L}$ (когда исчерпана вся область поиска решений), но и, к примеру, при достижении определённого числа шагов или времени счёта и т.п. Тогда все бруски, оставшиеся в рабочем списке $\mathcal{L}$, оказываются не до конца обработанными, и мы условимся так и называть их — «недообработанные». Итак, в общем случае результатом работы нашего алгоритма должны быть три списка брусков:

список **НавернякаРешения**, состоящий из брусков шириной меньше δ , которые гарантированно содержат решения,

список **ВозможноРешения**, состоящий из брусков шириной меньше δ , подозрительных на содержание решения, и

Таблица 4.1. Простейший интервальный алгоритм
глобального доказательного решения уравнений

Вход Система уравнений $F(x) = 0$. Брус $\mathbf{X} \in \mathbb{IR}^n$. Интервальное расширение $\mathbf{F} : \mathbb{IX} \rightarrow \mathbb{IR}$ функции F. Заданная точность $\delta > 0$ локализации решений системы.
Выход Список НавернякаРешения из брусов размера менее δ, которые гарантированно содержат решения системы уравнений в $\mathbf{X}$. Список ВозможноРешения из брусов размера менее δ, которые могут содержать решения системы уравнений в $\mathbf{X}$. Список Недообработанные из брусов размера более δ, которые могут содержать решения системы уравнений в $\mathbf{X}$.
Алгоритм инициализируем рабочий список $\mathcal{L}$ исходным брусом $\mathbf{X}$; DO WHILE (($\mathcal{L} \neq \emptyset$) и (не исчерпаны ресурсы ЭВМ)) извлекаем из рабочего списка $\mathcal{L}$ брус $\mathbf{Y}$; применяем к $\mathbf{Y}$ тест существования решения, его результат обозначаем также через $\mathbf{Y}$; IF (в $\mathbf{Y}$ доказано отсутствие решений) THEN удаляем брус $\mathbf{Y}$ из рассмотрения ELSE IF ((размер бруса $\mathbf{Y}$) $< \delta$) THEN заносим $\mathbf{Y}$ в соответствующий из списков НавернякаРешения или ВозможноРешения ELSE рассекаем $\mathbf{Y}$ на потомки $\mathbf{Y}'$ и $\mathbf{Y}''$ и заносим их в рабочий список $\mathcal{L}$ END IF END IF END DO все брусы из $\mathcal{L}$ перемещаем в список Недообработанные;

список Недообработанные, состоящий брусков, которые алгоритму не удалось обработать «до конца» и которые имеют ширину не меньше δ ,

такие что все решения рассматриваемой системы уравнений, не принадлежащие брусьям из списка НавернякаРешения, содержатся в брусьях из списков ВозможноРешения и Недообработанные.

Алгоритмы описанного выше типа, дополненные различными усовершенствованиями, получили большое развитие в интервальном анализе в последние десятилетия (см., например, книги [40, 41, 45, 46]), а реализованные на их основе программные комплексы существенно продвинули практику численного решения уравнений и систем уравнений.

Литература к Главе 4

Основная

- [1] АЛЕФЕЛЬД Г., ХЕРЦБЕРГЕР Ю. *Введение в интервальные вычисления*. – Москва: Мир, 1987.
- [2] АКРИТАС А. *Основы компьютерной алгебры с приложениями*. – Москва: Мир, 1994.
- [3] БАРАХНИН В.Б., ШАПЕЕВ В.П. *Введение в численный анализ*. – Санкт-Петербург–Москва–Краснодар: Лань, 2005.
- [4] БАУЭР Ф.Л., ГООЗ Г. *Информатика. В 2-х ч.* – Москва: Мир, 1990.
- [5] БАХВАЛОВ Н.С., ЖИДКОВ Н.П., КОВЕЛЬКОВ Г.М. *Численные методы*. – Москва: Бином, 2003, а также другие издания этой книги.
- [6] БАХВАЛОВ Н.С., КОРНЕВ А.А., ЧИЖОНКОВ Е.В. *Численные методы. Решение задач и упражнения*. – Москва: Дрофа, 2008.
- [7] БЕРЕЗИН И.С., ЖИДКОВ Н.П. *Методы вычислений. Т. 1–2*. – Москва: Наука, 1966.
- [8] БЕРЖЕ М. *Геометрия. Т. 1, 2*. – Москва: Наука, 1984.
- [9] ВЕРЖВИЦКИЙ В.М. *Численные методы. Части 1–2*. – Москва: «Оникс 21 век», 2005.
- [10] ВОЛКОВ Е.А. *Численные методы*. – Москва: Наука, 1987.
- [11] ГОДУНОВ С.К. *Современные аспекты линейной алгебры*. – Новосибирск: Научная книга, 1997.
- [12] ГОДУНОВ С.К., АНТОНОВ А.Г., КИРИЛЛЮК О.П., КОСТИН В.И. *Гарантированная точность решения систем линейных уравнений в евклидовых пространствах*. – Новосибирск: Наука, 1992.
- [13] ГЭРИ М., ДЖОНСОН Д. *Вычислительные машины и труднорешаемые задачи*. – Москва: Мир, 1982.

- [14] Демидович Б.П., Марон А.А. *Основы вычислительной математики*. – Москва: Наука, 1970.
- [15] Дэннис Дж., мл., Шнабель Р. *Численные методы безусловной оптимизации и решения нелинейных уравнений*. – Москва: Мир, 1988.
- [16] Калиткин Н.Н. *Численные методы*. – Москва: Наука, 1978.
- [17] Канторович Л.В., Акилов Г.П. *Функциональный анализ*. – Москва: Наука, 1984.
- [18] Коллатц Л. *Функциональный анализ и вычислительная математика*. – Москва: Мир, 1969.
- [19] Крылов А.Н. *Лекции о приближённых вычислениях*. – Москва: ГИТТЛ, 1954, а также более ранние издания.
- [20] Крылов В.И., Бовков В.В., Монастырный П.И. *Вычислительные методы*. Т. 1–2. – Москва: Наука, 1976.
- [21] Кунц К.С. *Численный анализ*. – Киев: Техника, 1964.
- [22] Мацокин А.М. *Численный анализ. Вычислительные методы линейной алгебры. Конспекты лекций для преподавания в III семестре ММФ НГУ*. – Новосибирск: НГУ, 2009–2010.
- [23] Мацокин А.М., Сорокин С.Б. *Численные методы. Часть 1. Численный анализ*. – Новосибирск: НГУ, 2006.
- [24] Меньшиков Г.Г. *Локализуемые вычисления. Конспект лекций*. – Санкт-Петербург: СПбГУ, Факультет прикладной математики–процессов управления, 2003.
- [25] Миньков С.Л., Миньков Л.Л. *Основы численных методов*. – Томск: Издательство научно-технической литературы, 2005.
- [26] Мысовских И.П. *Лекции по методам вычислений*. – Санкт-Петербург: Издательство Санкт-Петербургского университета, 1998.
- [27] Ортега Дж., Рейнболдт В. *Итерационные методы решения нелинейных систем уравнений со многими неизвестными*. – Москва: Мир, 1975.
- [28] Островский А.М. *Решение уравнений и систем уравнений*. – Москва: Издательство иностранной литературы, 1963.
- [29] Самарский А.А., Гулин А.В. *Численные методы*. – Москва: Наука, 1989.
- [30] Семёнов А.Л., Важев И.В., Кашеварова Т.П. и др. *Интервальные методы распространения ограничений и их приложения // Системная информатика*. – Новосибирск: Издательство СО РАН, 2004. – Вып. 9. – С. 245–358.
- [31] Трауб Дж. *Итерационные методы решения уравнений*. – Москва: Мир, 1985.
- [32] Тыртышников Е.Е. *Методы численного анализа*. – Москва: Академия, 2007.
- [33] Успенский В.А., Семёнов А.Л. *Теория алгоритмов: основные открытия и приложения*. – Москва: Наука, 1987.
- [34] Фихтенгольц Г.М. *Курс дифференциального и интегрального исчисления*. Т. 1. – Москва: Наука, 1966.

- [35] Холодниок М., Клич А., Кубичек М., Мареk М. *Методы анализа нелинейных динамических моделей*. – Москва: Мир, 1991.
- [36] Шарый С.П. *Конечномерный интервальный анализ*. – Электронная книга, 2010 (см. <http://www.nsc.ru/interval/Library/InteBooks>)
- [37] Шилов Г.Е. *Математический анализ. Функции одного переменного. Ч. 1–2*. – Москва: Наука, 1969.
- [38] Авертх О. *Precise numerical methods using C++*. – San Diego: Academic Press, 1998.
- [39] AKYILDIZ Y., AL-SUWAIYEL M.I. No pathologies for interval Newton's method // *Interval Computations*. – 1993. – No. 1. – P. 60–72.
- [40] HANSEN E., WALSTER G.B. *Global optimization using interval analysis*. – New York: Marcel Dekker, 2003.
- [41] KEARFOTT R.B. *Rigorous global search: Continuous problems*. – Dordrecht: Kluwer, 1996.
- [42] KELLEY C.T. *Iterative methods for linear and nonlinear equations*. – Philadelphia: SIAM, 1995.
- [43] KREINOVICH V., LAKEYEV A.V., ROHN J., KAHL P. *Computational complexity and feasibility of data processing and interval computations*. – Dordrecht: Kluwer, 1997.
- [44] MIRANDA C. Un' osservazione su un teorema di Brouwer // *Bollet. Unione Mat. Ital. Serie II*. – 1940. – Т. 3. – С. 5–7.
- [45] MOORE R.E., KEARFOTT R.B., CLOUD M. *Introduction to interval analysis*. – Philadelphia: SIAM, 2009.
- [46] NEUMAIER A. *Interval methods for systems of equations*. – Cambridge: Cambridge University Press, 1990.
- [47] TREFETHEN L.N. Pseudospectra of linear operators // *SIAM Review*. 1997. – Vol. 39, No. 3. – P. 383–406.
- [48] TREFETHEN L.N., BAU D. III *Numerical linear algebra*. – Philadelphia: SIAM, 1997.

Дополнительная

- [49] БАБЕНКО К.И. *Основы численного анализа*. – Москва: Наука, 1986.
- [50] ЗАГУСКИН В.Л. *Справочник по численным методам решения алгебраических и трансцендентных уравнений*. – Москва: Физматгиз, 1960.
- [51] <http://physics.nist.gov/cuu/Constants/index.html>
- [52] <http://web.comlab.ox.ac.uk/projects/pseudospectra/>
- [53] Scilab — The Free Platform for Numerical Computation. <http://www.scilab.org>

Обозначения

$\Rightarrow$	логическая импликация
$\Longleftrightarrow$	логическая равносильность
$\&$	логическая конъюнкция, связка «и»
$\rightarrow$	отображение множеств
$\mapsto$	правило сопоставления элементов при отображении
$\leftarrow$	оператор присваивания в алгоритмах
$\circ$	знак композиции отображений
$\emptyset$	пустое множество
$x \in X$	элемент x принадлежит множеству X
$x \notin X$	элемент x не принадлежит множеству X
$X \cup Y$	объединение множеств X и Y
$X \cap Y$	пересечение множеств X и Y
$X \setminus Y$	разность множеств X и Y
$X \subseteq Y$	множество X есть подмножество множества Y
$X \times Y$	прямое декартово произведение множеств X и Y
$\mathbb{N}$	множество натуральных чисел
$\mathbb{R}$	множество вещественных (действительных) чисел
$\mathbb{R}_+$	множество неотрицательных вещественных чисел
$\mathbb{C}$	множество комплексных чисел
$\mathbb{IR}$	классическая интервальная арифметика
$\mathbb{R}^n$	множество вещественных n -мерных векторов
$\mathbb{C}^n$	множество комплексных n -векторов

$\mathbb{R}^n$	множество n -мерных интервальных векторов
$\mathbb{R}^{m \times n}$	множество вещественных $m \times n$ -матриц
$\mathbb{IR}^{m \times n}$	множество интервальных $m \times n$ -матриц
$\bar{z}$	комплексно сопряжённое к числу $z \in \mathbb{C}$
$\operatorname{sgn} a$	знак числа $a \in \mathbb{R}$
$\underline{a}, \inf a$	левый конец интервала a
$\overline{a}, \sup a$	правый конец интервала a
$\operatorname{mid} a$	середина интервала a
$\operatorname{wid} a$	ширина интервала a
dist	метрика (расстояние)
Dist	мультиметрика (векторнозначное расствие)
$\operatorname{dom} f$	область определения функции f
$\operatorname{ran}(f, X)$	область значений функции f на X
$\operatorname{int} X$	топологическая внутренность множества X
$\operatorname{cl} X$	топологическое замыкание множества X
$f^{\angle}(\cdot)$	разделённая разность от функции f
δ_{ij}	символ Кронекера, 1 при $i = j$ и 0 иначе
i	мнимая единица
I	единичная матрица соответствующих размеров
$\ \cdot\ $	векторная или матричная норма
$A^{\top}$	матрица, транспонированная к матрице A
A^{-1}	матрица, обратная к матрице A
$\rho(A)$	спектральный радиус матрицы A
$\lambda(A), \lambda_i(A)$	собственные числа матрицы A
$\sigma(A), \sigma_i(A)$	сингулярные числа матрицы A
$\operatorname{cond}(A)$	число обусловленности матрицы A
$\operatorname{diag}\{z_1, \dots, z_n\}$	диагональная $n \times n$ -матрица с элементами $z_1, \dots, z_n$ по главной диагонали

Если x — вектор, то его подвектор, состоящий из компонент x_k с индексами k из некоторого индексного подмножества K обозначается через x_K , а дополнительный к нему вектор — через $x_{\notin K}$ или $x_{\neq k}$, если

$K = \{k\}$. Аналогичных соглашений будем придерживаться и в отношении матриц, так что, к примеру, если A является $m \times n$ -матрицей, то $A_{:, \neq k}$ — это матрица размера $m \times (n - 1)$, полученная из A удалением k -го столбца.

Интервалы и другие интервальные величины (векторы, матрицы и др.) всюду в тексте обозначаются жирным математическим шрифтом, например, $\mathbf{A}$, $\mathbf{B}$, $\mathbf{C}$, ..., $\mathbf{x}$, $\mathbf{y}$, $\mathbf{z}$, тогда как неинтервальные (точечные) величины никак специально не выделяются. Арифметические операции с интервальными величинами — это операции классической интервальной арифметики $\mathbb{IR}$ (см. §1.3). Наконец, если не оговорено противное, под векторами (точечными или интервальными) всюду понимаются вектор-столбцы.

Конец доказательства теоремы или предложения и конец примера выделяются в тексте стандартным знаком «■».

Значительная часть описываемых в книге алгоритмов снабжается псевдокодами на неформальном алгоритмическом языке, в котором операторные скобки

DO FOR ... END DO означают оператор цикла со счётчиком, который задаётся после FOR,

DO WHILE ... END DO означают оператор цикла с предусловием, стоящим после WHILE,

IF ... THEN ... ELSE ... END или IF ... THEN ... END означают условные операторы с условием, стоящим после IF.

Краткий биографический словарь

Абель, Нильс Хенрик (Niels Henrik Abel, 1802–1829)

— норвежский математик.

Адамар, Жак Саломон (Jacques Salomon Hadamard, 1865–1963)

— французский математик.

Андронов, Александр Александрович (1901–1952)

— советский физик и механик.

Бабенко, Константин Иванович (1919–1987)

— советский математик и механик.

Банах, Стефан (Stefan Bahach, 1892–1945)

— польский математик.

Бернштейн, Сергей Натанович (1880–1968)

— российский и советский математик.

Больцано, Бернард (Bernard Bolzano, 1781–1848)

— чешский теолог, философ и математик.

Брадис, Владимир Модестович (1890–1975)

— русский и советский математик и педагог.

Брауэр, Лёйтзен Эгберт Ян (Luitzen Egbertus Jan Brouwer, 1881–1966)

— голландский математик.

Валлис, Джон (John Wallis, 1616–1703)

— английский математик.

Вандермонд, Александр Теофиль (Alexandre Theophill Vandermonde, 1735–1796) — французский музыкант и математик.

Вейерштрасс, Карл Теодор (Karl Theodor Weierstrass, 1815–1897)

— немецкий математик.

Виет, Франсуа (François Viète, 1540–1603)

— французский математик.

Гаусс, Карл Фридрих (Carl Friedrich Gauss, 1777–1855)

— немецкий математик, внёсший также фундаментальный вклад в численные методы, астрономию и геодезию.

Гельфанд, Израиль Моисеевич (1913–2009)

— советский математик. С 1989 года жил и работал в США.

Гершгорин, Семён Аронович (1901–1933)

— советский математик, живший и работавший в Ленинграде.

Гивенс, Джеймс Уоллес (James Wallace Givens, 1910–1993)

— американский математик.

Гильберт, Давид (David Hilbert, 1862–1943)

— немецкий математик.

Грам, Йорген Педерсен (Jorgen Pedersen Gram, 1850–1916)

— датский математик.

Евклид, или Эвклид (др.-греч. *Ευκλείδης*, ок. 300 г. до н. э.)

— древнегреческий математик.

Зейдель, Филипп Людвиг (Philipp Ludwig Seidel, 1821–1896)

— немецкий астроном и математик.

Канторович, Леонид Витальевич (1912–1986)

— советский математик и экономист, один из создателей теории линейного программирования.

Котес, Роджер (Roger Cotes, 1682–1716)

— английский математик.

Коши, Огюстен Луи (Augustin Louis Cauchy, 1789–1857)

— французский математик.

Кравчик, Рудольф (Krawczyk, Rudolf)

— немецкий математик.

Крамер, Габриэль (Gabriel Cramer, 1704–1752)

— швейцарский математик.

Красносельский, Марк Александрович (1920–1997)

— советский и российский математик.

- Крейн, Селим Григорьевич (1917–1999)
— советский и российский математик.
- Кронекер, Леопольд (Leopold Kronecker, 1823–1891)
— немецкий математик.
- Крылов, Алексей Николаевич (1863–1945)
— русский и советский математик, механик и кораблестроитель.
- Кублановская, Вера Николаевна (род. 1920)
— советский и российский математик.
- Кузьмин, Родион Осиевич (1891–1949)
— русский и советский математик.
- Лагранж, Жозеф Луи (Joseph Louis Lagrange, 1736–1813)
— французский математик и механик.
- Лежандр, Адриен Мари (Adrien Marie Legendre, 1752–1833)
— французский математик и механик.
- Лейбниц, Готфрид Вильгельм (Gottfried Wilhelm Leibnitz, 1646–1716)
— немецкий философ, математик и физик, один из создателей дифференциального и интегрального исчисления.
- Липшиц, Рудольф (Rudolf Lipschitz, 1832–1903)
— немецкий математик.
- Лобачевский, Николай Иванович (1792–1856)
— русский математик, создатель неевклидовой геометрии.
- Локуцкий, Олег Вячеславович (1922–1990)
— советский математик.
- Ляпунов, Александр Михайлович (1857–1918)
— русский математик и механик, основоположник математической теории устойчивости.
- Марков, Андрей Андреевич (1856–1922)
— русский математик.
- Марцинкевич, Юзеф (Józef Marcinkiewicz, 1910–1941)
— польский математик.
- Миранда, Карло (Carlo Miranda, 1912–1982)
— итальянский математик.
- Нейман, Карл Готфрид (Karl Gottfried Neumann, 1832–1925)

— немецкий математик.⁴

Ньютон, Исаак (Isaac Newton, 1643–1727)

— английский физик и математик, заложивший основы дифференциального и интегрального исчисления и механики.

Пойа (Полиа), Дьёрдь (иногда Джордж) (György Polya, 1887–1985)

— венгерский и американский математик.

Ричардсон, Льюис Фрай (Lewis Fry Richardson, 1881–1953)

— английский математик, физик и метеоролог.

Родриг, Бенжамен Оленд (Benjamin Olinde Rodrigues, 1795–1851)

— французский математик и банкир.

Рунге, Карл Давид (Karl David Runge, 1856–1927)

— немецкий физик и математик.

Руффини, Паоло (Paolo Ruffini, 1765–1822)

— итальянский математик.

Симпсон, Томас (Thomas Simpson, 1710–1761)

— английский математик.

Стеклов, Владимир Андреевич (1863–1926)

— русский математик и механик.

Стирлинг, Джеймс (James Stirling, 1692–1770)

— шотландский математик.

Таусски, Ольга (Olga Tausski, 1906–1995)

— американский математик.

Тейлор, Брук (Brook Taylor, 1685–1731)

— английский математик.

Фабер, Георг (Georg Faber, 1877–1966)

— немецкий математик.

Фаддеев, Дмитрий Константинович (1907–1989)

— советский математик.

Фаддеева, Вера Николаевна (1906–1983)

— советский математик.

⁴Не следует путать его с Джоном фон Нейманом (John von Neumann, 1903–1957), американским математиком венгерского происхождения, разработчиком первых ЭЦВМ, именем которого назван также спектральный признак устойчивости разностных схем.

Фробениус, Фердинанд Георг (Ferdinand Georg Frobenius, 1849–1917)
— немецкий математик.

Фрэнсис, Джон (John G.F. Francis, род. 1934)
— английский математик и программист.

Хаусдорф, Феликс (Felix Hausdorff, 1868–1942)
— немецкий математик.

Хаусхолдер, Элстон (Alston Scott Householder, 1904–1993)
— американский математик.

Хессенберг, Карл Адольф (Karl Adolf Hessenberg, 1904–1959)
— немецкий математик и инженер.

Холесский, Андре-Луи (André-Louis Cholesky, 1875–1918)
— французский геодезист и математик.⁵

Хопф, Хайнц (Heinz Hopf, 1896–1971)
— немецкий и швейцарский математик.

Чебышёв, Пафнутий Львович (1821–1894)
— русский математик и механик, внёсший основополагающий вклад
в теорию приближений и теорию вероятностей.

Шрёдер, Иоганн (Johann Schröder, 1925–2007)
— немецкий математик.

Эйлер, Леонард (Leonhard Euler, 1707–1783)
— швейцарский и российский математик, механик и физик. Работе
в России посвятил 31 год жизни, умер и похоронен в Петербурге.

Эрмит, Шарль (Charles Hermite, 1822–1901)
— французский математик.

Якоби, Карл Густав (Carl Gustav Jacobi, 1804–1851)
— немецкий математик.

⁵В русской научной литературе его фамилия нередко транслитерируется как «Холецкий» или даже «Халецкий».

Предметный указатель

- ε -решения, 275
- алгебраическая степень точности, 104
- биортогональность, 235
- целевая функция, 219
- число обусловленности, 146
- дефект сплайна, 52
- диагональное преобладание, 125
- дифференцирование
 - автоматическое, 61
- дифференцирование численное, 61
- дифференцирование символьное, 61
- доминирующее собственное значение, 242
- доминирующий собственный вектор, 242
- экстраполяция, 40
- эквивалентные нормы, 137
- энергетическая норма, 129
- эрмитова интерполяция, 47
- формула Маркова, 112
- формула Родрига, 82
- формула Симпсона, 92
- формула кубатурная, 88
- формула квадратурная, 88
- формула парабол, 92
- формула прямоугольников, 89
- формула трапеций, 91
- формулы Гаусса, 104
- формулы Ньютона-Котеса, 89
- формулы численного дифференцирования, 62, 65
- характеризация Бека, 287
- характеризация Оеттли-Прагера, 288
- хессенбергова форма, 262
- интерполирование, 24
- интерполяция эрмитова, 47
- интервальная арифметика, 13
- интервальная арифметика классическая, 14
- интервальное расширение, 15
- итерационные методы, 154
- коэффициент чувствительности, 11
- коэффициенты Фурье, 80
- коэффициенты перекоса, 238
- комплексификация, 141
- конечные методы, 154
- круги Гершгорина, 241
- линейная задача о наименьших квадратах, 228
- матрица Гильберта, 81, 150
- матрица Грама, 79
- матрица Липшица интервальная, 294
- матрица Уилкинсона, 239
- матрица Вандермонда, 27, 150
- матрица неразложимая, 126
- матрица отражения, 172
- матрица перестановки, 167

- матрица почти треугольная, 262
- матрица предобуславливающая, 196
- матрица разложимая, 126
- матрица скалярная, 198
- матрица строго нижняя треугольная, 203
- матрица строго верхняя треугольная, 203
- матрица транспозиции, 166
- матрица трёхдиагональная, 184
- матрица вращения, 178
- матричная норма, 131
- матричный ряд Неймана, 144
- мера диагонального преобладания, 208
- метод Гаусса, 157
- метод Гаусса-Зейделя, 205
- метод Хаусхолдера, 175
- метод Холесского, 184
- метод Шульца, 227
- метод Якоби, 202
- метод градиентного спуска, 219
- метод квадратного корня, 184
- метод минимальных невязок, 226
- метод наискорейшего спуска, 223
- метод отражений, 175
- метод прогонки, 186
- метод простой итерации, 198
- метод релаксации, 211
- множитель Холесского, 180
- мультиметрика, 281
- непрерывность по Липшицу, 12
- нестационарный итерационный процесс, 190
- невязка, 209
- норма, 127
- норма энергетическая, 129
- нормальная система уравнений, 228
- обобщённая степень, 37
- обратные степенные итерации, 251
- оператор Кравчика, 297
- оператор Ньютона интервальный, 292
- ортогонализация Грама-Шмидта, 81, 180
- основная теорема интервальной арифметики, 16
- почти решения, 275
- полином интерполяционный, 27
- полином интерполяционный Лагранжа, 30
- полином интерполяционный Ньютона, 37
- полиномы Чебышёва, 41
- полиномы Лежандра, 82
- порядок точности формулы, 67, 102
- правило Рунге, 113
- предобуславливание, 196
- предобуславливатель, 196
- пример Рунге, 50
- принцип релаксации, 209
- принцип вариационный, 217
- признак Адамара, 125
- прямые методы, 154
- расщепление матрицы, 197
- разделённая разность, 30
- разложение Холесского, 180
- разложение сингулярное, 123
- разностные уравнения трёхточечные, 185
- рекуррентный вид системы, 195, 270
- рекуррентный вид уравнения, 270
- ряд Фурье, 80
- сдвиг спектра, 250
- схема единственного деления, 158
- сингулярные числа, 121
- сингулярные векторы, 121
- след матрицы, 255
- собственный вектор, 229

- собственное значение, 229
- спектральная норма, 136
- спектральный радиус, 140
- сплайн, 52
- стационарный итерационный
 - процесс, 190
- степенной метод, 245
- степень сплайна, 52
- субдистрибутивность, 14
- сжатие, 280
- сжимающее отображение, 280
- шаблон, 65
- теорема Абеля-Руффини, 231
- теорема Банаха о неподвижной
 - точке, 280
- теорема Бауэра-Файка, 233
- теорема Больцано-Коши, 278
- теорема Брауэра о неподвижной
 - точке, 280
- теорема Фабера, 51
- теорема Марцинкевича, 52
- теорема Миранды, 278
- теорема Стеклова-Пойа, 99
- теорема Шрёдера о неподвижной
 - точке, 281
- теорема Таусски, 127
- теорема Вейерштрасса, 49
- теорема о сингулярном
 - разложении, 123
- тригонометрические полиномы,
 - 26
- трёхдиагональная матрица, 58
- узлы сплайна, 52
- ведущий элемент, 164
- векторная норма, 127
- вырожденный интервал, 13
- задача некорректная, 10, 73
- задача о наименьших квадратах
 - линейная, 228
- задача приближения функции, 75
- задача сглаживания, 81
- задача вычислительно
 - корректная, 272
- P*-сжатие, 281
- LU-разложение, 161
- QR-алгоритм, 259, 262
- QR-разложение, 170